Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский физико-технический институт
(национальный исследовательский университет)»
Физтех-школа прикладной математики и информатики
Кафедра интеллектуальных систем

На правах рукописи

Киселев Никита Сергеевич

Законы масштабирования параметрических моделей машинного обучения на основе локальных свойств оптимизационной поверхности

Специальность 1.2.1 —
«Искусственный интеллект и машинное обучение»

Диссертация на соискание учёной степени
кандидата физико-математических наук

Научный руководитель:
кандидат физико-математических наук
Грабовой Андрей Валериевич

Москва — 2026

Оглавление

Стр.

Введение 6

Глава 1. Обзор проблемы и постановка задач исследования . . . 11

1.1. Параметрические модели машинного обучения и множество оптимальных параметров 11

1.2. Законы масштабирования параметрических моделей и достаточный размер выборки 13

1.3. Оптимизационная поверхность и матрица Гессе как ее ключевая характеристика 15

1.4. Постановка задач исследования 16

Глава 2. Спектральные свойства матриц Гессе нейронных сетей 18

2.1. Введение 18

2.2. Предварительные сведения 18

2.3. Матрично-представимые нейронные сети и факторизация гаусс-ньютоновской компоненты 20

2.4. Полносвязные нейронные сети 23

2.5. Сверточные нейронные сети 27

2.6. Трансформерные нейронные сети 36

2.7. Вычислительные эксперименты 39

2.8. Обсуждение 40

Глава 3. Стабилизация ландшафта функции потерь в нейронных сетях 41

3.1. Введение 41

3.2. Предварительные сведения 42

3.3. Критерий сходимости поверхности функции потерь 45

3.4. Абсолютный одноточечный критерий сходимости 46

3.5. Среднеквадратичный критерий сходимости 50

3.6. Среднеквадратичный критерий сходимости в подпространстве наибольшей кривизны 53

Стр.

3.7. Вычислительные эксперименты 59
3.7.1. Архитектуры, датасеты и общая схема эксперимента . . . 60
3.7.2. Оценка абсолютного одноточечного критерия 61
3.7.3. Оценка среднеквадратичного критерия в полном пространстве параметров 62
3.7.4. Оценка среднеквадратичного критерия в подпространстве наибольшей кривизны 62
3.7.5. Оценка скоростей сходимости 63
3.7.6. Визуализация результатов 64
3.7.7. Проверяемые гипотезы 66
3.7.8. Ожидаемые результаты 67
3.8. Обсуждение 68

Глава 4. Законы масштабирования и достаточный размер выборки для параметрических моделей 70
4.1. Введение 70
4.2. Предварительные сведения 71
4.2.1. Уровни теоретических утверждений 72
4.3. Законы масштабирования параметрических моделей на основе локальных свойств оптимизационной поверхности 73
4.3.1. Декомпозиция ошибки обучения 73
4.3.2. Мотивация оценки ошибки оценивания через стабилизацию ландшафта 74
4.3.3. Закон масштабирования 75
4.3.4. Архитектурно-зависимые законы масштабирования 76
4.3.5. Режимы масштабирования архитектуры 77
4.3.6. Вычислительно-оптимальное масштабирование 78
4.4. Достаточный размер выборки для параметрических моделей . . . 80
4.4.1. Постановка задачи и три понятия достаточности 80
4.4.2. Одноточечный критерий достаточного размера выборки . 81
4.4.3. Среднеквадратичный критерий достаточного размера выборки 81
4.4.4. Подпространственный критерий достаточного размера выборки 82

Стр.

4.4.5. Качественное сравнение архитектур 83
4.5. Вычислительные эксперименты 83
4.6. Обсуждение 84

Глава 5. Критерии достаточного размера выборки для вероятностных линейных моделей 86
5.1. Введение 86
5.2. Предварительные сведения 87
5.3. Критерии достаточности для линейных моделей 89
5.3.1. Стабилизация функции правдоподобия в точке ОМП . . . 89
5.3.2. Апостериорные распределения на схожих подвыборках . . 91
5.4. Асимптотическое поведение оптимизационной поверхности в вероятностной модели линейной регрессии 93
5.4.1. Сходимость распределения параметров модели 93
5.4.2. Сходимость полного байесовского прогноза 95
5.5. Доказательства теоретических результатов 95
5.6. Вычислительные эксперименты 102
5.6.1. Близость апостериорных распределений 103
5.6.2. Корректность определений D- и M-достаточности 104
5.6.3. Корректность определений KL- и S-достаточности 105
5.6.4. Зависимость критериев от гиперпараметра ε 106
5.6.5. Сравнение критериев на множестве выборок 106
5.7. Обсуждение 112

Заключение 113

Публикации автора по теме диссертации 114

Список литературы 116

Список рисунков 118

Список таблиц 120

Приложение А. Доказательства теоретических результатов . . . 121

Стр.

A.1. Гаусс-ньютоновская компонента матрицы Гессе для трансформерной архитектуры нейронной сети 121
A.1.1. Якобиан и оценка нормы оператора LayerNorm 121
A.1.2. Выкладки для feed-forward части 125
A.1.3. Оценки для self-attention части 127
A.1.4. Сборка якобианов полного трансформерного блока 129
A.1.5. Гаусс–ньютоновская компонента и ее спектральная оценка 131

Введение

В статистической теории обучения [1] обоснована принципиальная связь между сложностью семейства моделей, объемом обучающей выборки и способностью к обобщению: для надежного выбора модели требуется достаточное количество данных. Подавляющее большинство современных моделей машинного обучения являются параметрическими: они задаются конечным набором параметров, определяемых минимизацией эмпирической функции потерь на выборке. Поскольку функция потерь вычисляется по ограниченным данным и зависит от параметров модели, возникает фундаментальный вопрос о взаимосвязи объема выборки, структуры модели и свойств множества оптимальных параметров, а также о минимальном объеме данных, необходимом для успешного обучения [2; 3].

Эмпирические законы масштабирования показывают, что качество моделей закономерно зависит от размера данных и модели: в языковых моделях установлены степенные зависимости потерь от объема данных и числа параметров [2], а для вычислительно-оптимального обучения предложено согласованное масштабирование размера модели и объема данных [3]. Эти результаты опираются на масштабные эксперименты и не имеют пока единого теоретического обоснования.

Ключевой объект для такого обоснования — ландшафт функции потерь в пространстве параметров. Его визуализация и анализ структуры минимумов [4], изучение локальной геометрии и связей с обобщающей способностью [5], а также доказательство связности множества решений [6] показывают, что геометрия поверхности функции потерь определяет как выбор решения методами градиентной оптимизации [7; 8], так и устойчивость к возмущениям данных. Спектральные свойства матрицы Гессе в окрестности минимума характеризуют кривизну оптимизационной поверхности и используются при анализе сходимости и обобщения [9]. Вместе с тем остается открытой задача систематического описания того, как ландшафт функции потерь стабилизируется при увеличении объема выборки и как связать эту стабилизацию с законами масштабирования и достаточным размером данных.

Таким образом, актуальной задачей является разработка методов, связывающих три компонента: параметрическую модель машинного обучения,

объем обучающей выборки (в предположении независимости и одинаковой распределенности наблюдений) и геометрию множества оптимальных параметров, задаваемую ландшафтом функции потерь, с опорой на фундаментальные результаты теории обучения и современные эмпирические законы масштабирования.

Целью данной работы является разработка законов масштабирования параметрических моделей машинного обучения, основанных на анализе стабилизации распределения оптимальных параметров и локальных свойств оптимизационной поверхности при увеличении объема обучающей выборки. Для достижения цели были поставлены и решены следующие **задачи**:

1. Исследовать спектральные свойства матриц Гессе различных архитектур нейронных сетей, получить верхние оценки спектральных норм.
2. Разработать методы оценки сходимости оптимизационной поверхности при изменении размера обучающей выборки.
3. Предложить законы масштабирования параметрических моделей машинного обучения на основе локальных свойств оптимизационной поверхности.
4. Разработать критерий достаточного размера выборки, использующий стабилизацию ландшфата функции потерь в условиях простой генеральной совокупности.
5. Предложить критерии достаточного размера выборки для вероятностных линейных моделей на основе сходимости распределения оптимальных параметров.

Научная новизна:

1. Получены верхние оценки спектральных норм матриц Гессе для полносвязной, сверточной и трансформерной архитектур нейронных сетей на основе разложения Гаусса—Ньютона.
2. Предложены критерии сходимости оптимизационной поверхности в нейронных сетях, использующие спектральные свойства матрицы Гессе.
3. Сформулирован единый подход к описанию законов масштабирования параметрических моделей, основывающийся на стабилизации ландшафта функции потерь в окрестностях точек минимума.

4. Предложен критерий достаточного размера выборки в параметрических моделях на основе сформулированных законов масштабирования в условиях простой генеральной совокупности.
5. Построены критерии достаточного размера выборки в вероятностных линейных моделях, использующие сходимость апостериорного распределения параметров при увеличении объема данных.

Теоретическая значимость полученных результатов состоит в том, что получено теоретическое обоснование связи между объемом обучающей выборки и стабилизацией оптимизационной поверхности (для линейных моделей — через правдоподобие и апостериорные распределения, для нейронных сетей — через спектр матрицы Гессе и сходимость ландшафта функции потерь), что дополняет известные эмпирические законы масштабирования строгими оценками и единой постановкой задачи.

Практическая значимость настоящей работы заключается в возможности применения разработанных методов для обоснованного определения достаточного объема данных при планировании экспериментов и сборе выборок для линейных и нейросетевых моделей, а также для формулировки критериев остановки сбора данных и интерпретации достаточности выборки в терминах геометрии поверхности функции потерь.

Методология и методы исследования. Для достижения поставленных в диссертационной работе целей используются:

1. Методы линейной алгебры, математического и функционального анализа: матричное дифференцирование, анализ функций многих переменных, спектральный анализ матриц (в том числе матрицы Гессе).
2. Методы теории вероятностей и математической статистики: байесовский вывод, анализ сходимости последовательностей случайных величин и распределений, элементы теории оптимизации.
3. Методы вычислительного эксперимента и анализа результатов: бутстрап, сэмплирование по Монте—Карло, сравнение с базовыми методами оценки размера выборки, воспроизводимая постановка экспериментов.

Основные положения, выносимые на защиту:

1. Теоремы о верхних оценках спектральных норм матриц Гессе для полносвязной, сверточной и трансформерной архитектур нейронных сетей.

2. Подходы к оценке сходимости ландшафта функции потерь в нейронных сетях: в одной точке минимума, в наборе точек, в наборе точек из подпространства главных собственных векторов матрицы Гессе.
3. Законы масштабирования параметрических моделей машинного обучения, связывающие размер обучающей выборки, архитектуру модели и локальные свойства ее оптимизационной поверхности.
4. Критерий достаточного размера выборки для параметрических моделей на основе сходимости поверхности функции потерь при увеличении количества данных.
5. Критерии достаточного размера выборки для вероятностных линейных моделей на основе стабилизации распределения оптимальных параметров при увеличении объема данных.

Достоверность полученных результатов обеспечивается корректностью применения апробированного в научной практике математического аппарата теории вероятностей, математической статистики и других смежных теоретических областей, а также экспериментальной проверкой разработанных методов на большом количестве модельных и практических задач машинного обучения. Полученные теоретические результы обосновываются математически строгими доказательствами, а для проведенных вычислительных экспериментов даются детальные описания, обеспечивающие их воспроизводимость. Результаты опубликованы в рецензируемых научных изданиях и в трудах рецензируемых российских и международных конференций по машинному обучению и искусственному интеллекту.

Апробация работы. Основные результаты работы докладывались и обсуждались на следующих научных конференциях:

1. Открытая конференция ИСП РАН, Москва, 9–10 декабря 2025 г.
2. 22-я Всероссийская конференция с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября 2025 г.
3. 67-я Всероссийская научная конференция МФТИ, Москва, 31 марта – 5 апреля 2025 г.
4. Открытая конференция ИСП РАН, Москва, 11–12 декабря 2024 г.
5. 66-я Всероссийская научная конференция МФТИ, Москва, 1–6 апреля 2024 г.

Личный вклад. Все приведенные результаты, кроме отдельно оговоренных случаев, получены диссертантом лично при научном руководстве к.ф.-м.н. А. В. Грабового.

Публикации. *Список публикаций приведен в конце диссертации.* Основные результаты по теме диссертации изложены в 8 научных работах, из которых 3 — в периодических научных журналах, индексируемых Scopus и Web of Science, а остальные 5 — в тезисах докладов российских и международных конференций.

Объем и структура работы. Диссертация состоит из введения, 5 глав, заключения и 1 приложения. Полный объём диссертации составляет 134 страницы, включая 13 рисунков и 4 таблицы. Список литературы содержит 0 наименований.

Глава 1. Обзор проблемы и постановка задач исследования

В данной главе приводится введение в задачу определения достаточного размера обучающей выборки для параметрических моделей машинного обучения и постановка задач диссертационной работы. Сначала вводятся основные понятия: параметрическая модель, функция потерь, множество оптимальных параметров и его зависимость от выборки. Далее дается краткий обзор существующих подходов к оценке достаточного размера выборки и их ограничений для современных моделей. Затем вводится ключевой объект исследования — оптимизационная поверхность (ландшафт функции потерь) — и обсуждается, как ее стабилизация при увеличении объема данных может служить математическим описанием законов масштабирования. В заключение главы формулируются критерии достаточности для линейных моделей и нейронных сетей. Детальное обсуждение и доказательства приводятся в последующих главах, основанных на работах автора [A1—A8].

1.1. Параметрические модели машинного обучения и множество оптимальных параметров

Решение задачи машинного обучения с учителем предполагает выбор предсказательной модели из некоторого параметрического семейства. Объектом называется пара $(\mathbf{x}, y)$, где $\mathbf{x} \in \mathbb{X} \subseteq \mathbb{R}^n$ — вектор признакового описания, $y \in \mathbb{Y}$ — целевая переменная. В задаче регрессии $\mathbb{Y} = \mathbb{R}$, в задаче классификации $\mathbb{Y} = \{1, \ldots, K\}$. Выборка размера m задается множеством $\mathfrak{D}_m = \{(\mathbf{x}_i, y_i)\}_{i=1}^m$ из m независимых реализаций пар $(\mathbf{x}, y)$, распределенных согласно неизвестному распределению $p(\mathbf{x}, y)$.

Параметрической моделью называется семейство функций $f_{\mathbf{w}} : \mathbb{X} \to \mathbb{Y}$, задаваемое вектором параметров $\mathbf{w} \in \mathbb{W} \subset \mathbb{R}^N$. Выбор модели из этого семейства проводится с помощью эмпирической функции потерь, вычисляемой на заданной выборке:

$$\mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^{m} \ell(f_{\mathbf{w}}(\mathbf{x}_i), y_i), \tag{1.1}$$

где $\ell : \mathbb{Y} \times \mathbb{Y} \to \mathbb{R}^+$ — функция потерь на одном объекте (например, квадратичная или кросс-энтропийная). Обучение модели таким образом есть решение оптимизационной задачи

$$\mathbf{w}_m^* \in \arg\min_{\mathbf{w}\in\mathbb{W}} \mathcal{L}_m(\mathbf{w}). \tag{1.2}$$

Отметим, что эмпирическая функция потерь вычисляется по конечной выборке и потому случайна: при другой реализации выборки $\mathfrak{D}'_m$ того же размера получается другая функция $\mathcal{L}'_m(\mathbf{w})$ и, как правило, другое множество минимизаторов (1.2). При малом m это множество может быть обширным или нестабильным: добавление или удаление нескольких объектов существенно меняет и значение минимума, и расположение оптимальных параметров. Однако поскольку при увеличении m эмпирическая функция потерь (1.1) согласно закону больших чисел (ЗБЧ) сходится к популяционной

$$\mathcal{L}(\mathbf{w}) = \mathbb{E}_{(\mathbf{x},y)\sim p(\mathbf{x},y)}[\ell(f_{\mathbf{w}}(\mathbf{x}), y)],$$

то естественно ожидать, что множество решений стабилизируется — сузится или перестанет заметно смещаться при добавлении новых данных.

В вероятностной постановке параметрическая модель вводится как совместное распределение

$$p(y, \mathbf{w}|\mathbf{x}) = p(y|\mathbf{x}, \mathbf{w})p(\mathbf{w}) : \mathbb{Y} \times \mathbb{W} \times \mathbb{X} \to \mathbb{R}^+,$$

где $p(y|\mathbf{x}, \mathbf{w})$ задает правдоподобие объекта, а $p(\mathbf{w})$ — априорное распределение параметров. Оптимальные параметры описываются апостериорным распределением $p(\mathbf{w}|\mathfrak{D}_m)$. Как и в случае классической постановки, при увеличении количества данных множество оптимальных параметров концентрируется около «истинного» вектора, породившего заданную выборку.

В задачах машинного обучения оптимум функции потерь (1.2) часто не единствен. В линейной регрессии при невырожденной матрице признаков существует единственный глобальный минимум, но при мультиколлинеарности или при $m < n$ задача вырождена: множество решений образует аффинное подпространство (ссылки на классические работы по линейной регрессии, мб Стрижова). В нейронных сетях функция потерь, как правило, невыпукла: существуют множественные локальные минимумы, седловые точки и плато (ссылки на исследования свойств функции потерь, мб из оптимизации). Более того,

из-за симметрий (перестановка нейронов, знаковые преобразования) многие минимумы эквивалентны с точки зрения предсказательной способности [6] (мб добавить еще ссылки). В таких условиях корректнее говорить не о единственной точке минимума, а о множестве оптимальных параметров модели.

1.2. Законы масштабирования параметрических моделей и достаточный размер выборки

Особенный интерес представлет вопрос о законах масштабирования параметрических моделей: по какому правилу стоит совместно выбирать архитектуру модели и число данных для ее обучения. Существующие работы покрывают лишь небольшую часть всего параметрического семейства — в них рассматриваются линейные и обобщенно-линейные модели (добавить математические формулировки + ссылки на работы по обобщенно-линейным моделям), для которых формулируются преимущественно статистические критерии (ссылки на статистические критерии), направленные на определение достаточного размера выборки в предположении единственности решения оптимизационной задачи (1.2).

Классические статистические методы оценки размера выборки опираются на задание нулевой и альтернативной гипотез, допустимой вероятности ошибки первого рода и требуемой мощности теста. К ним относятся метод множителей Лагранжа (ссылка), отношение правдоподобия (ссылка), критерий Вальда (ссылка) и др. Эти методы дают теоретически обоснованные оценки, но требуют явных предположений о распределении данных и параметрах модели, а также информации о величине эффекта при альтернативе. На практике такие предположения часто недоступны или труднопроверяемы.

Наверное, стоит добавить несколько примеров критериев прям с формулами для понимания

Информационно-теоретические подходы характеризуют связь между данными и моделью через энтропию, взаимную информацию или дивергенции между распределениями (добавить ссылки). Байесовские методы используют апостериорное распределение параметров и критерии вроде средней апостериорной дисперсии (APVC), среднего покрытия (ACC) или дивергенции

Кульбака—Лейблера между апостериорными распределениями на разных подвыборках (добавить ссылки). Так, в работе [10] для логистической регрессии предложено использовать KL-дивергенцию между апостериорными распределениями на «схожих» подвыборках (отличающихся одним объектом) для оценки достаточного размера выборки.

В статистической теории обучения размер выборки связывается со сложностью класса моделей через размерность Вапника—Червоненкиса (VC) (ссылка) и родственные понятия. Получены оценки достаточного объема данных для гарантированного обобщения в рамках PAC-анализа. Однако для глубоких нейронных сетей VC-размерность огромна и дает слишком пессимистичные оценки; кроме того, современные переобученные сети часто хорошо обобщают, что не согласуется с классическими границами [2] (уточнить ссылку). (Нужно про Радемахеровскую сложность и комбинаторную теорию Воронцова как про более современные аналоги)

Классические подходы плохо переносятся на современные нейронные сети по нескольким причинам. Во-первых, VC-размерность и сходные меры сложности для нейронных сетей дают нереалистично большие оценки необходимого объема данных. Во-вторых, явные статистические гипотезы о параметрах нейросетей обычно неизвестны. В-третьих, многократное полное переобучение модели на подвыборках разного размера для построения кривой обучения вычислительно дорого для больших сетей.

В то же время эмпирические законы масштабирования показывают устойчивые зависимости: качество моделей закономерно улучшается с ростом размера данных и числа параметров. В языковых моделях установлены степенные законы [2], а для вычислительно-оптимального обучения предложено согласованное масштабирование модели и объема данных [3]. Эти результаты пока не имеют единого теоретического обоснования и тем более математической модели соответствующих законов масштабирования. Таким образом, возникает необходимость в развитии новых подходов к установлению таких закономерностей, опирающихся на свойства, доступные для анализа во всех параметрических моделях и инвариантные к выбору конкретного минимума — например, на геометрию оптимизационной задачи (1.2).

1.3. Оптимизационная поверхность и матрица Гессе как ее ключевая характеристика

Оптимизационной поверхностью или ландшафтом функции потерь (англ. loss landscape) называется график $\mathcal{L}_m(\mathbf{w})$ как функции от $\mathbf{w} \in \mathbb{W} \subset \mathbb{R}^N$. Анализ этой поверхности для нейронных сетей является ключевой задачей теории оптимизации, что связано с итерационной природой процесса обучения — алгоритмы на основе стохастического градиентного спуска (англ. SGD) дают приближенное решение (1.2), опираясь на глобальные и локальные свойства.

Исследование ландшафта функции потерь позволило выявить ряд важных характеристик, определивших развитие современных методов численной оптимизации (ссылки на статьи по типу Adam, Muon) — наличие множественных минимумов, седловых точек, многообразий меньшей размерности, содержащих множества оптимальных параметров [6; 7], и др. В теории генерализации нейронных сетей плоские минимумы (с малой кривизной) часто связывают с лучшей обобщающей способностью [8] (уточнить ссылки), а узкие и глубокие — наоборот. Форма поверхности при этом определяется как самой архитектурой модели, так и заданной обучающей выборкой. Глубина и ширина нейронной сети давно перестали быть определяющими факторами для достижения высокого качества (ссылка на ResNet), из-за чего возникают новые архитектурные решения, позволяющие снизить сложность модели при неухудшении ее обобщающих свойств (ссылки на всякое типа BatchNorm/LayerNorm/GroupNorm/InstanceNorm, Dropout, QK-Norm, etc.).

Ключевой характеристикой для анализа оптимизационной поверхности является матрица Гессе функции потерь $\mathbf{H}^{(m)}(\mathbf{w}) = \nabla^2_{\mathbf{w}}\mathcal{L}_m(\mathbf{w})$, которая содержит информацию о поведении ландшафта во втором порядке. Спектр матрицы Гессе характеризует нелинейность поверхности в окрестности минимума: большие собственные значения соответствуют «острым» направлениям, малые — «плоским» (ссылки). Более того, для типичных нейросетей наблюдается характерная структура спектра: множество малых собственных значений и небольшое число выбросов [9] (еще ссылки, по типу про ранг). Множество работ посвящено еще более детальному анализу матрицы Гессе для различных архитектур моделей: выводу его явных выражений для полносвязных сетей (ссылки)

и даже механизмов внимания в трансформерных сетях (база, на которую мы в статье Егора опирались).

Матрицы Гессе используются в задачах оптимизации методом Ньютона (ссылка) и квазиньютоновскими методами (ссылки), среди которых наиболее известный — алгоритм Бройдена—Флетчера—Гольдфарба—Шанно (англ. BFGS) (ссылка). Здесь надо добавить прям много про применения Гессиана и особенно в связи со сложностью модели и данных.

Несмотря на интерес научного сообщества к исследованию матрицы Гессе и ее применений в обучении нейронных сетей, вопрос о связи характеристик второго порядка оптимизационной поверхности с законами масштабирования остается открытым.

1.4. Постановка задач исследования

ПЕРЕПИСАТЬ

В диссертации рассматривается задача оценки законов масштабирования параметрических моделей машинного обучения на основе анализа стабилизации распределения оптимальных параметров и свойств оптимизационной поверхности при увеличении объема обучающей выборки. Частным случаем этой задачи является определение достаточного размера выборки, обеспечивающего стабилизацию вероятностных характеристик модели и ландшафта функции потерь.

В главе 5 исследуются вероятностные линейные модели. Вводится вероятностная постановка задачи, анализируются апостериорные распределения параметров и оценки максимума правдоподобия. На основе анализа стабилизации указанных распределений при увеличении объема выборки предлагаются критерии достаточного размера выборки и доказываются теоремы, обосновывающие корректность этих критериев при соответствующих предположениях на входные данные.

В главе 3 исследуются локальные свойства оптимизационной поверхности нейронных сетей. Для этого используется аппроксимация функции потерь до второго порядка и анализ матрицы Гессе. Получаются оценки спектральной нормы ее гаусс-ньютоновской компоненты для матрично-представимых архитектур, включая полносвязные, сверточные и трансформерные сети. На

этой основе формулируется критерий сходимости ландшафта функции потерь, описывающий изменение поверхности в окрестности точки минимума при добавлении новых объектов в обучающую выборку.

В главе **??** рассматриваются устойчивые методы оценки сходимости ландшафта функции потерь. В качестве критерия используется среднеквадратичное значение разности функции потерь по вероятностному распределению в пространстве параметров. Для повышения вычислительной эффективности предлагается переход к подпространству главных собственных векторов матрицы Гессе, что позволяет строить более эффективные численные процедуры сэмплирования и оценки сходимости.

Глава 2. Спектральные свойства матриц Гессе нейронных сетей

В данной главе исследуются спектральные свойства матрицы Гессе для ряда архитектур нейронных сетей. Сначала мы обсуждаем, почему именно матрица Гессе описывает локальные свойства кривизны поверхности функции потерь. Затем рассматривается разложение Гаусса—Ньютона матрицы Гессе и предлагается подход к оценке спектральной нормы всей матрицы на основе доминирующей части этого разложения. Доказываются теоремы об общем виде матрицы Гессе матрично-представимых нейронных сетей, после чего доказываются теоремы о верхней оценке ее спектральной нормы для известных архитектур: полносвязной, сверточной и трансформерной.

2.1. Введение

TODO

2.2. Предварительные сведения

Матрица Гессе функции потерь. Объектом называется пара $(\mathbf{x}, \mathbf{y})$, где $\mathbf{x} \in \mathbb{R}^n$ — вектор признакового описания, $\mathbf{y} \in \mathbb{R}^K$ — целевая переменная. В задаче регрессии $K = 1$, в задаче классификации $K > 1$ и $\mathbf{y} = [0, \ldots, 1, \ldots, 0]^\top$, где единица стоит на k-ой позиции, соответствуя истинной метке класса k. Выборка размера m задается множеством $\mathfrak{D}_m = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^m$ из m независимых реализаций пар $(\mathbf{x}, \mathbf{y})$.

Параметрической моделью называется семейство функций $f_\mathbf{w} : \mathbb{R}^n \to \mathbb{R}^K$, задаваемое вектором параметров $\mathbf{w} \in \mathbb{R}^N$. Выбор модели из этого семейства проводится с помощью эмпирической функции потерь, вычисляемой на заданной выборке:

$$\mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \ell(f_\mathbf{w}(\mathbf{x}_i), \mathbf{y}_i), \tag{2.1}$$

где $\ell : \mathbb{R}^K \times \mathbb{R}^K \to \mathbb{R}^+$ — функция потерь на одном объекте (например, квадратичная или кросс-энтропийная). Локальные свойства оптимизационной поверхности функции $\mathcal{L}_m(\mathbf{w})$ в точке $\mathbf{w}$ задаются ее производными первого и второго порядка. Вектор градиента

$$\mathbf{g}^{(m)}(\mathbf{w}) = \nabla_{\mathbf{w}} \mathcal{L}_m(\mathbf{w}) \in \mathbb{R}^N$$

определяет направление наискорейшего возрастания функции потерь, тогда как матрица Гессе

$$\mathbf{H}^{(m)}(\mathbf{w}) = \nabla^2_{\mathbf{w}} \mathcal{L}_m(\mathbf{w}) \in \mathbb{R}^{N \times N}$$

характеризует локальную кривизну оптимизационной поверхности. Спектральные свойства матрицы $\mathbf{H}^{(m)}(\mathbf{w})$ определяют геометрию в окрестности точки минимума: большие собственные значения соответствуют направлениям высокой кривизны, а малые — направлениям слабой кривизны (ссылки).

Поскольку функция потерь (2.1) задается усреднением по объектам обучающей выборки, ее матрица Гессе также представляется в виде среднего:

$$\mathbf{H}^{(m)}(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^{m} \mathbf{H}_i(\mathbf{w}), \qquad \mathbf{H}_i(\mathbf{w}) = \nabla^2_{\mathbf{w}} \ell\left(f_{\mathbf{w}}(\mathbf{x}_i), \mathbf{y}_i\right) \in \mathbb{R}^{N \times N}.$$

Тем самым исследование спектральных свойств $\mathbf{H}^{(m)}(\mathbf{w})$ сводится к анализу $\mathbf{H}_i(\mathbf{w})$ на отдельных объектах $(\mathbf{x}_i, \mathbf{y}_i)$ выборки $\mathfrak{D}_m$.

Разложение Гаусса—Ньютона матрицы Гессе. *Далее в главе мы опускаем индекс объекта i, переходя к анализу матрицы Гессе $\mathbf{H}(\mathbf{w})$ на одном объекте $(\mathbf{x}, \mathbf{y})$.* Воспользуемся правилом дифференцирования сложной функции для матрицы Гессе. Обозначим

$$\mathbf{z} = f_{\mathbf{w}}(\mathbf{x}) \in \mathbb{R}^K, \qquad \mathbf{J}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{w}} \in \mathbb{R}^{K \times N}, \qquad \mathbf{A}(\mathbf{w}) = \nabla^2_{\mathbf{z}} \ell(\mathbf{z}, \mathbf{y}) \in \mathbb{R}^{K \times K},$$

где $\mathbf{z}$ суть выход модели, $\mathbf{J}(\mathbf{w})$ есть якобиан выхода модели по параметрам, $\mathbf{A}(\mathbf{w})$ — матрица кривизны функции потерь по выходу модели. Тогда матрица Гессе на одном объекте допускает разложение

$$\mathbf{H}(\mathbf{w}) = \mathbf{G}(\mathbf{w}) + \mathbf{R}(\mathbf{w}), \tag{2.2}$$

где

$$\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w}) \tag{2.3}$$

есть гаусс-ньютоновская компонента, а

$$\mathbf{R}(\mathbf{w}) = \sum_{k=1}^{K} \frac{\partial \ell(\mathbf{z}, \mathbf{y})}{\partial z_k} \nabla^2_{\mathbf{w}} z_k$$

есть остаточная компонента, связанная со вторыми производными выходов модели по параметрам.

Разложение (2.2) разделяет два источника кривизны оптимизационной поверхности. Гаусс-ньютоновская компонента $\mathbf{G}(\mathbf{w})$ определяется кривизной функции потерь по выходу модели и якобианом отображения $\mathbf{w} \mapsto \mathbf{z}$. Остаточная компонента $\mathbf{R}(\mathbf{w})$ определяется нелинейностью самой параметризации модели и зависит от вторых производных выходов по параметрам. Для нейронных сетей спектр матрицы Гессе, как правило, имеет выраженную неоднородную структуру: основная масса собственных значений сосредоточена вблизи нуля, тогда как небольшое число выбросов задает главные направления кривизны (ссылки). В рамках разложения Гаусса–Ньютона именно гаусс-ньютоновская компонента $\mathbf{G}(\mathbf{w})$ определяет спектрально значимую часть матрицы Гессе. Остаточная компонента $\mathbf{R}(\mathbf{w})$ вносит вклад преимущественно в область малых собственных значений и, кроме того, ослабевает в окрестности точки минимума, поскольку пропорциональна производным функции потерь по выходу модели. По этой причине в дальнейшем основное внимание будет уделено исследованию гаусс-ньютоновской компоненты.

2.3. Матрично-представимые нейронные сети и факторизация гаусс-ньютоновской компоненты

Для получения единых выражений для различных архитектур введем класс матрично-представимых нейронных сетей. Основная идея состоит в том, что каждый слой такой сети задается линейным оператором, зависящим от параметров слоя, а вся сеть представляется как композиция линейных преобразований и нелинейных активаций. Такой подход охватывает полносвязные сети, сверточные сети после матризации операции свертки, а также ряд блоков трансформерных архитектур, содержащих линейные проекции и другие матрично задаваемые преобразования.

Определение. Нейронная сеть называется *матрично-представимой*, если ее выход $\mathbf{z} = f_{\mathbf{w}}(\mathbf{x})$ для входа $\mathbf{x}$ может быть записан в виде композиции

$$\mathbf{x}^{(1)} = \mathbf{x}, \qquad \mathbf{z}^{(p)} = T^{(p)}_{\mathbf{w}^{(p)}}\left(\mathbf{x}^{(p)}\right), \qquad \mathbf{x}^{(p+1)} = \boldsymbol{\sigma}^{(p)}\left(\mathbf{z}^{(p)}\right), \qquad p = 1, \ldots, L-1,$$

$$f_{\mathbf{w}}(\mathbf{x}) = \mathbf{z}^{(L)} = T^{(L)}_{\mathbf{w}^{(L)}}\left(\mathbf{x}^{(L)}\right),$$

где

$$\mathbf{w} = \operatorname{col}\left(\mathbf{w}^{(1)}, \ldots, \mathbf{w}^{(L)}\right) = \left[\mathbf{w}^{(1)\top}, \ldots, \mathbf{w}^{(L)\top}\right]^{\top},$$

функции активации

$$\boldsymbol{\sigma}^{(p)} : \mathbb{R}^{n_p} \to \mathbb{R}^{n_p}$$

задают нелинейные преобразования, а каждый оператор

$$T^{(p)}_{\mathbf{w}^{(p)}} : \mathbb{R}^{n_{p-1}} \to \mathbb{R}^{n_p} \tag{2.4}$$

линеен по входу $\mathbf{x}^{(p)}$, причем его зависимость от параметров $\mathbf{w}^{(p)} \in \mathbb{R}^{N_p}$ допускает матричное представление.

Для каждого слоя введем два типа матриц. Во-первых, обозначим через

$$\mathbf{S}^{(p)}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{z}^{(p)}} \in \mathbb{R}^{K \times n_p} \tag{2.5}$$

матрицу распространения возмущения предактивации p-го слоя к выходу сети. Эта матрица аккумулирует влияние всех последующих слоев и нелинейностей. Во-вторых, обозначим через

$$\mathbf{P}^{(p)}(\mathbf{w}) = \frac{\partial \mathbf{z}^{(p)}}{\partial \mathbf{w}^{(p)}} \in \mathbb{R}^{n_p \times N_p} \tag{2.6}$$

параметрический якобиан p-го слоя, связывающий приращения параметров слоя с приращениями его выходов под действием соответствующего линейного оператора. Тогда якобиан выхода сети по параметрам p-го слоя по правилу дифференцирования сложной функции записывается в виде

$$\mathbf{J}^{(p)}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{w}^{(p)}} = \frac{\partial \mathbf{z}}{\partial \mathbf{z}^{(p)}} \cdot \frac{\partial \mathbf{z}^{(p)}}{\partial \mathbf{w}^{(p)}} = \mathbf{S}^{(p)}(\mathbf{w})\mathbf{P}^{(p)}(\mathbf{w}) \in \mathbb{R}^{K \times N_p}. \tag{2.7}$$

Далее, поскольку вектор параметров имеет блочную структуру $\mathbf{w} = \operatorname{col}\left(\mathbf{w}^{(1)}, \ldots, \mathbf{w}^{(L)}\right)$, полный якобиан выхода сети по всем параметрам представляется в виде горизонтальной конкатенации послойных якобианов:

$$\mathbf{J}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{w}} = \left[\mathbf{J}^{(1)}(\mathbf{w}), \ldots, \mathbf{J}^{(L)}(\mathbf{w})\right],$$

откуда с учетом (2.7) получаем

$$\mathbf{J}(\mathbf{w}) = \left[\mathbf{S}^{(1)}(\mathbf{w})\mathbf{P}^{(1)}(\mathbf{w}), \ldots, \mathbf{S}^{(L)}(\mathbf{w})\mathbf{P}^{(L)}(\mathbf{w})\right]. \tag{2.8}$$

Наконец, учитывая все введенные выше обозначения, мы можем сформулировать лемму о блочной факторизации гаусс-ньютоновской компоненты матрицы Гессе в матрично-представимых нейронных сетях.

Лемма 2.3.1. *Пусть $f_{\mathbf{w}}$ является матрично-представимой нейронной сетью, тогда гаусс-ньютоновская компонента матрицы Гессе имеет блочную структуру*

$$\mathbf{G}(\mathbf{w}) = \left[\mathbf{G}^{(p,q)}(\mathbf{w})\right]_{p,q=1}^{L}, \tag{2.9}$$

где каждый блок $\mathbf{G}^{(p,q)}(\mathbf{w}) \in \mathbb{R}^{N_p \times N_q}$ задается выражением

$$\mathbf{G}^{(p,q)}(\mathbf{w}) = \mathbf{P}^{(p)}(\mathbf{w})^\top \mathbf{S}^{(p)}(\mathbf{w})^\top \mathbf{A}(\mathbf{w})\mathbf{S}^{(q)}(\mathbf{w})\mathbf{P}^{(q)}(\mathbf{w}). \tag{2.10}$$

Доказательство. По формуле (2.8) имеем выражение якобиана

$$\mathbf{J}(\mathbf{w}) = \left[\mathbf{S}^{(1)}(\mathbf{w})\mathbf{P}^{(1)}(\mathbf{w}), \ldots, \mathbf{S}^{(L)}(\mathbf{w})\mathbf{P}^{(L)}(\mathbf{w})\right].$$

Следовательно, транспонированной якобиан задается формулой

$$\mathbf{J}(\mathbf{w})^\top = \begin{bmatrix} \mathbf{P}^{(1)}(\mathbf{w})^\top \mathbf{S}^{(1)}(\mathbf{w})^\top \\ \vdots \\ \mathbf{P}^{(L)}(\mathbf{w})^\top \mathbf{S}^{(L)}(\mathbf{w})^\top \end{bmatrix}.$$

Подставляя эти выражения в определение гаусс-ньютоновской компоненты (2.3),

$$\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w})\mathbf{J}(\mathbf{w}),$$

получаем блочную матрицу, (p, q)-й блок которой имеет факторизованный вид

$$\mathbf{G}^{(p,q)}(\mathbf{w}) = \mathbf{P}^{(p)}(\mathbf{w})^\top \mathbf{S}^{(p)}(\mathbf{w})^\top \mathbf{A}(\mathbf{w})\mathbf{S}^{(q)}(\mathbf{w})\mathbf{P}^{(q)}(\mathbf{w}),$$

что и требовалось доказать. □

Лемма 2.3.1 показывает, что спектральные свойства гаусс-ньютоновской компоненты определяются тремя типами объектов. Матрица $\mathbf{A}(\mathbf{w})$ описывает кривизну функции потерь по выходу модели и не зависит от ее архитектуры. Матрицы $\mathbf{S}^{(p)}(\mathbf{w})$ характеризуют распространение возмущений от промежуточных слоев к выходу сети. Матрицы $\mathbf{P}^{(p)}(\mathbf{w})$ задают чувствительность выходов отдельных слоев к их параметрам. Поэтому анализ $\mathbf{G}(\mathbf{w})$ для конкретных архитектур сводится к исследованию структуры этих матриц и получению оценок для блоков (2.10).

2.4. Полносвязные нейронные сети

Рассмотрим L-слойную полносвязную нейронную сеть, заданную рекуррентно:

$$\mathbf{x}^{(1)} = \mathbf{x}, \qquad \mathbf{z}^{(p)} = \mathbf{W}^{(p)}\mathbf{x}^{(p)} + \mathbf{b}^{(p)}, \qquad \mathbf{x}^{(p+1)} = \sigma^{(p)}\left(\mathbf{z}^{(p)}\right), \qquad p = 1, \ldots, L-1,$$

$$f_{\mathbf{w}}(\mathbf{x}) = \mathbf{z}^{(L)} = \mathbf{W}^{(L)}\mathbf{x}^{(L)} + \mathbf{b}^{(L)},$$

где $\mathbf{W}^{(p)} \in \mathbb{R}^{n_p \times n_{p-1}}$, $\mathbf{b}^{(p)} \in \mathbb{R}^{n_p}$, $\mathbf{w}^{(p)} = \mathrm{col}\left(\mathrm{vec}\left(\mathbf{W}^{(p)}\right), \mathbf{b}^{(p)}\right)$. Она является матрично-представимой в смысле определения (2.4), т. к. для нее оператор $T^{(p)}_{\mathbf{w}^{(p)}}$ задается умножением на матрицу $\mathbf{W}^{(p)}$ и смещением на вектор $\mathbf{b}^{(p)}$. Следовательно, к ней применима лемма 2.3.1. Здесь мы ввели обозначение $\mathrm{vec}(\cdot)$ для операции векторизации матрицы по столбцам. Существует и другой вариант векторизации, по строкам, который мы будем использовать в следующих разделах, его будем обозначать $\mathrm{vec}_{\mathrm{r}}(\cdot)$. Далее в этом разделе мы получим явные выражения для матриц $\mathbf{S}^{(p)}(\mathbf{w})$ и $\mathbf{P}^{(p)}(\mathbf{w})$, благодаря чему сформулируем теорему о верхней оценке на спектральную норму гаусс-ньютоновской компоненты матрицы Гессе полносвязной сети.

Матрица распространения возмущения $\mathbf{S}^{(p)}$ по определению (2.5) и правилу дифференцирования сложной функции записывается в виде

$$\mathbf{S}^{(p)}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{z}^{(p)}} = \frac{\partial \mathbf{z}^{(L)}}{\partial \mathbf{z}^{(L-1)}} \frac{\partial \mathbf{z}^{(L-1)}}{\partial \mathbf{z}^{(L-2)}} \cdots \frac{\partial \mathbf{z}^{(p+1)}}{\partial \mathbf{z}^{(p)}}, \tag{2.11}$$

откуда для явного выражения матрицы $\mathbf{S}^{(p)}(\mathbf{w})$ нам достаточно раскрыть формулу $\partial \mathbf{z}^{(p+1)} / \partial \mathbf{z}^{(p)}$. Поскольку $\mathbf{z}^{(p+1)} = \mathbf{W}^{(p+1)}\mathbf{x}^{(p+1)} + \mathbf{b}^{(p+1)}$ и $\mathbf{x}^{(p+1)} = \sigma^{(p)}\left(\mathbf{z}^{(p)}\right)$, то вновь по правилу дифференцирования сложной функции получаем

$$\frac{\partial \mathbf{z}^{(p+1)}}{\partial \mathbf{z}^{(p)}} = \frac{\partial \mathbf{z}^{(p+1)}}{\partial \mathbf{x}^{(p+1)}} \cdot \frac{\partial \mathbf{x}^{(p+1)}}{\partial \mathbf{z}^{(p)}} = \mathbf{W}^{(p+1)}\mathbf{D}^{(p)}(\mathbf{w}),$$

где мы обозначили диагональные матрицы производных активации

$$\mathbf{D}^{(p)} = \mathrm{diag}\left(\sigma^{(p)\prime}\left(\mathbf{z}^{(p)}\right)\right) \in \mathbb{R}^{n_p \times n_p}.$$

Таким образом, матрица распространения возмущения предактивации p-го слоя к выходу сети преобразуется в

$$\mathbf{S}^{(p)}(\mathbf{w}) = \mathbf{W}^{(L)}\mathbf{D}^{(L-1)} \cdots \mathbf{W}^{(p+1)}\mathbf{D}^{(p)}, \qquad p = 1, \ldots, L-1,$$

а для последнего слоя отдельно записывается как $\mathbf{S}^{(L)}(\mathbf{w}) = \mathbf{I}_K$.

Параметрический якобиан $\mathbf{P}^{(p)}$. Для полносвязного слоя без смещения $\mathbf{z}^{(p)} = \mathbf{W}^{(p)}\mathbf{x}^{(p)}$ параметры естественно отождествляются с вектором $\mathbf{w}^{(p)} = \operatorname{vec}\left(\mathbf{W}^{(p)}\right)$. Тогда, используя стандартное тождество векторизации

$$\operatorname{vec}\left(\mathbf{W}^{(p)}\mathbf{x}^{(p)}\right) = \left(\mathbf{x}^{(p)\top} \otimes \mathbf{I}_{n_p}\right) \operatorname{vec}\left(\mathbf{W}^{(p)}\right),$$

получаем

$$\frac{\partial \mathbf{z}^{(p)}}{\partial \mathbf{w}^{(p)}} = \frac{\partial \mathbf{z}^{(p)}}{\partial \operatorname{vec}\left(\mathbf{W}^{(p)}\right)} = \mathbf{x}^{(p)\top} \otimes \mathbf{I}_{n_p}.$$

При добавлении вектора смещения $\mathbf{b}^{(p)}$ матрица $\partial \mathbf{z}^{(p)}/\partial \mathbf{w}^{(p)}$ дополняется справа столбцами единичной матрицы, а значит в результате имеем

$$\mathbf{P}^{(p)}(\mathbf{w}) = \frac{\partial \mathbf{z}^{(p)}}{\partial \mathbf{w}^{(p)}} = \left[\mathbf{x}^{(p)\top} \otimes \mathbf{I}_{n_p}, \mathbf{I}_{n_p}\right].$$

Спектральная норма блока гаусс-ньютоновской компоненты оценивается сверху исходя из выражения (2.10), для которого мы применяем свойство субмультипликативности спектральной нормы:

$$\|\mathbf{G}^{(p,q)}(\mathbf{w})\|_2 \leqslant \|\mathbf{P}^{(p)}(\mathbf{w})\|_2 \|\mathbf{S}^{(p)}(\mathbf{w})\|_2 \|\mathbf{A}(\mathbf{w})\|_2 \|\mathbf{S}^{(q)}(\mathbf{w})\|_2 \|\mathbf{P}^{(q)}(\mathbf{w})\|_2.$$

По тому же свойству для матриц $\mathbf{S}^{(p)}$ можем записать

$$\|\mathbf{S}^{(p)}\|_2 \leqslant \|\mathbf{W}^{(L)}\|_2 \|\mathbf{D}^{(L-1)}\|_2 \cdots \|\mathbf{W}^{(p+1)}\|_2 \|\mathbf{D}^{(p)}\|_2. \tag{2.12}$$

Далее сформулируем теорему, которая объединяет все проведенные выкладки, и при условии ограчений на вход сети и архитектурные свойства дает оценку на спектральную норму всей гаусс-ньютоновской компоненты матрицы Гессе.

Теорема 2.4.1. *Пусть $f_{\mathbf{w}}$ является L-слойной полносвязной нейронной сетью без смещений. Предположим, что существуют такие положительные константы, что для всех слоев $p = 1, \ldots, L$ выполнены ограничения $\|\mathbf{x}\|_2 \leqslant M_{\mathbf{x}}$, $\|\mathbf{A}(\mathbf{w})\|_2 \leqslant M_{\mathbf{A}}$, $\|\mathbf{W}^{(p)}\|_2 \leqslant M_{\mathbf{W}}$ и $\|\mathbf{D}^{(p)}\|_2 \leqslant M_{\sigma}$. Тогда спектральная норма гаусс-ньютоновской компоненты матрицы Гессе удовлетворяет оценке*

$$\|\mathbf{G}(\mathbf{w})\|_2 \leqslant L M_{\mathbf{x}}^2 M_{\mathbf{A}} \left(M_{\mathbf{W}} M_{\sigma}\right)^{2L-2}. \tag{2.13}$$

Доказательство. В условиях теоремы из (2.12) следует оценка

$$\|\mathbf{S}^{(p)}(\mathbf{w})\|_2 \leqslant M_{\mathbf{W}}^{L-p} M_{\sigma}^{L-p}, \qquad p = 1, \ldots, L.$$

Для параметрического якобиана в отсутствие смещений из формулы

$$\mathbf{P}^{(p)}(\mathbf{w}) = \mathbf{x}^{(p)\top} \otimes \mathbf{I}_{n_p}$$

и свойства спектральной нормы произведения Кронекера получаем

$$\|\mathbf{P}^{(p)}(\mathbf{w})\|_2 = \|\mathbf{x}^{(p)\top} \otimes \mathbf{I}_{n_p}\|_2 = \|\mathbf{x}^{(p)}\|_2. \tag{2.14}$$

Далее, поскольку сеть не содержит смещений, а активации $\sigma^{(p)}$ являются M_σ-липшицевыми, для промежуточных представлений имеем рекуррентную оценку

$$\|\mathbf{x}^{(p+1)}\|_2 = \|\sigma^{(p)}(\mathbf{z}^{(p)})\|_2 \leqslant M_\sigma \|\mathbf{z}^{(p)}\|_2 \leqslant M_\sigma \|\mathbf{W}^{(p)}\|_2 \|\mathbf{x}^{(p)}\|_2 \leqslant M_\sigma M_{\mathbf{W}} \|\mathbf{x}^{(p)}\|_2.$$

Итерируя это неравенство и используя условие $\|\mathbf{x}\|_2 \leqslant M_{\mathbf{x}}$, получаем

$$\|\mathbf{x}^{(p)}\|_2 \leqslant (M_{\mathbf{W}} M_\sigma)^{p-1} M_{\mathbf{x}}, \qquad p = 1, \ldots, L. \tag{2.15}$$

Совмещая (2.14) и (2.15), выводим

$$\|\mathbf{P}^{(p)}(\mathbf{w})\|_2 \leqslant (M_{\mathbf{W}} M_\sigma)^{p-1} M_{\mathbf{x}}, \qquad p = 1, \ldots, L.$$

Тогда для послойного якобиана $\mathbf{J}^{(p)}(\mathbf{w}) = \mathbf{S}^{(p)}(\mathbf{w})\mathbf{P}^{(p)}(\mathbf{w})$ по субмультипликативности спектральной нормы имеем

$$\|\mathbf{J}^{(p)}(\mathbf{w})\|_2 \leqslant \|\mathbf{S}^{(p)}(\mathbf{w})\|_2 \|\mathbf{P}^{(p)}(\mathbf{w})\|_2 \leqslant M_{\mathbf{x}} \left(M_{\mathbf{W}} M_\sigma\right)^{L-1}, \qquad p = 1, \ldots, L.$$

Далее, из блочного представления полного якобиана

$$\mathbf{J}(\mathbf{w}) = \left[\mathbf{J}^{(1)}(\mathbf{w}), \ldots, \mathbf{J}^{(L)}(\mathbf{w})\right]$$

следует

$$\mathbf{J}(\mathbf{w})\mathbf{J}(\mathbf{w})^\top = \sum_{p=1}^{L} \mathbf{J}^{(p)}(\mathbf{w})\mathbf{J}^{(p)}(\mathbf{w})^\top, \qquad \|\mathbf{J}(\mathbf{w})\|_2^2 = \|\mathbf{J}(\mathbf{w})\mathbf{J}(\mathbf{w})^\top\|_2.$$

Поэтому

$$\|\mathbf{J}(\mathbf{w})\|_2^2 \leqslant \sum_{p=1}^{L} \|\mathbf{J}^{(p)}(\mathbf{w})\|_2^2 \leqslant \sum_{p=1}^{L} M_{\mathbf{x}}^2 (M_{\mathbf{W}} M_\sigma)^{2L-2} = L M_{\mathbf{x}}^2 \left(M_{\mathbf{W}} M_\sigma\right)^{2L-2}. \tag{2.16}$$

Наконец, по определению гаусс-ньютоновской компоненты

$$\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w}),$$

откуда

$$\|\mathbf{G}(\mathbf{w})\|_2 \leqslant \|\mathbf{J}(\mathbf{w})^\top\|_2 \|\mathbf{A}(\mathbf{w})\|_2 \|\mathbf{J}(\mathbf{w})\|_2 = \|\mathbf{A}(\mathbf{w})\|_2 \|\mathbf{J}(\mathbf{w})\|_2^2.$$

Подставляя сюда (2.16) и условие $\|\mathbf{A}(\mathbf{w})\|_2 \leqslant M_{\mathbf{A}}$, получаем

$$\|\mathbf{G}(\mathbf{w})\|_2 \leqslant L M_{\mathbf{x}}^2 M_{\mathbf{A}} \left(M_{\mathbf{W}} M_\sigma\right)^{2L-2},$$

что и требовалось доказать. □

Особенный интерес представляют более конкретные случаи применения полносвязных сетей, например, для задачи классификации на K классов с кросс-этропийной функцией потерь:

$$\ell(\mathbf{z}, \mathbf{y}) = -\sum_{k=1}^{K} y_k \log p_k, \qquad p_k = \frac{\exp(z_k)}{\sum_{j=1}^{K} \exp(z_j)},$$

где $\mathbf{p} = [p_1, \ldots, p_K]^\top = \mathrm{Softmax}(\mathbf{z})$. Если, кроме того, выбрать конкретную функцию активации, например, $\mathrm{ReLU}(\mathbf{x}) = [\mathbf{x} \geqslant 0]\mathbf{x}$, то можно сформулировать следующее следствие из предыдущей теоремы.

Следствие 2.4.2. *Пусть в условиях теоремы 2.4.1 в качестве функции активации выбрана* ReLU*, а обучение решает задачу K-классовой классификации с кросс-энтропийной функцией потерь. Тогда спектральная норма гаусс-ньютоновской компоненты матрицы Гессе удовлетворяет оценке*

$$\|\mathbf{G}(\mathbf{w})\|_2 \leqslant \sqrt{2} L M_{\mathbf{x}}^2 M_{\mathbf{W}}^{2L-2}. \tag{2.17}$$

Доказательство. Известным результатом является формула матрицы Гессе кросс-энтропийной функции потерь по логитам:

$$\mathbf{A}(\mathbf{w}) = \nabla_{\mathbf{z}}^2 \ell(\mathbf{z}, \mathbf{y}) = \mathrm{diag}(\mathbf{p}) - \mathbf{p}\mathbf{p}^\top,$$

на основе которой мы и построим доказательство данного утверждения. По теореме об эквивалетнонсти норм в конечномерном пространстве имеем ограничение спектральной нормы через Фробениусову:

$$\|\mathbf{A}\|_2 \leqslant \|\mathbf{A}\|_F, \tag{2.18}$$

для которой по определению записываем

$$\|\mathbf{A}\|_F^2 = \|\,\mathrm{diag}(\mathbf{p}) - \mathbf{p}\mathbf{p}^\top\|_F^2 = \sum_{k=1}^{K} \left(p_k - p_k^2\right)^2 + \sum_{k \neq l} p_k^2 p_l^2 = \sum_{k=1}^{K} p_k^2 (1 - p_k)^2 + \sum_{k \neq l} p_k^2 p_l^2.$$

Далее, поскольку для всех $k = 1, \ldots, K$ верно $0 \leqslant p_k \leqslant 1$, справедливо, что $0 \leqslant p_k^2 \leqslant p_k$ и потому $0 \leqslant (1 - p_k)^2 \leqslant (1 - p_k)$. Следовательно, имеем

$$\sum_{k=1}^{K} p_k^2 (1 - p_k)^2 \leqslant \sum_{k=1}^{K} p_k (1 - p_k) \leqslant \sum_{k=1}^{K} p_k = 1,$$

$$\sum_{k \neq l} p_k^2 p_l^2 \leqslant \sum_{k \neq l} p_k p_l = \left(\sum_{k=1}^{K} p_k \right)^2 - \sum_{k=1}^{K} p_k^2 \leqslant 1 - \sum_{k=1}^{K} p_k^2.$$

Объединяя эти неравенства, получаем

$$\|\mathbf{A}\|_F^2 \leqslant 1 + 1 - \sum_{k=1}^{K} p_k^2 \leqslant 2, \tag{2.19}$$

откуда, подставляя (2.19) в (2.18), заключаем, что $\|\mathbf{A}\|_2 \leqslant \sqrt{2}$, то есть $M_{\mathbf{A}} = \sqrt{2}$. Для функции $\mathrm{ReLU}(t) = \max\{0, t\}$ имеем липшицевость с константой 1, то есть $M_\sigma = 1$. Подставляя эти значения в оценку (2.13), получаем (2.17). □

Теорема 2.4.1 показывает, что в полносвязной архитектуре спектральная норма гаусс-ньютоновской компоненты растет линейно по числу слоев и экспоненциально по глубине в терминах верхней границы на операторные нормы матриц весов. Причина заключается в том, что матрицы распространения $\mathbf{S}^{(p)}(\mathbf{w})$ содержат длинные произведения плотных матриц весов, а параметрические якобианы $\mathbf{P}^{(p)}(\mathbf{w})$ наследуют рост норм промежуточных представлений $\mathbf{x}^{(p)}$.

2.5. Сверточные нейронные сети

Рассмотрим L-слойную сверточную нейронную сеть (англ. CNN). В отличие от полносвязных сетей, где каждый параметр связывает конкретную пару нейронов, в CNN параметры — ядра свертки — используются совместно для обработки локальных областей входа. Тем не менее, при фиксированных размерах входных данных операция свертки является линейным оператором и допускает точное матричное представление, что позволяет включить CNN в класс матрично-представимых сетей.

Матричное представление свертки. Для приведения CNN к виду матрично-представимой сети необходимо определить правило векторизации. Пусть вход p-го слоя представляет собой тензор $\mathcal{X}^{(p)} \in \mathbb{R}^{C_{p-1} \times H_{p-1} \times W_{p-1}}$, где C — число каналов, H, W — пространственные размеры. Вектор $\mathbf{x}^{(p)} \in \mathbb{R}^{n_{p-1}}$ получается развертыванием тензора $\mathcal{X}^{(p)}$ по каналам и пространственным координатам (например, в порядке C, H, W), где $n_{p-1} = C_{p-1} H_{p-1} W_{p-1}$. Аналогично векторизуются выходы $\mathcal{Z}^{(p)} \in \mathbb{R}^{C_p \times H_p \times W_p} \mapsto \mathbf{z}^{(p)} \in \mathbb{R}^{n_p}$ и ядра свертки $\mathcal{W}^{(p)} \mapsto \mathbf{w}^{(p)} \in \mathbb{R}^{N_p}$. Сеть задается рекуррентно:

$$\mathbf{x}^{(1)} = \mathbf{x}, \qquad \mathbf{z}^{(p)} = C^{(p)}_{\mathbf{w}^{(p)}} \left(\mathbf{x}^{(p)} \right) + \mathbf{b}^{(p)}, \qquad \mathbf{x}^{(p+1)} = \sigma^{(p)} \left(\mathbf{z}^{(p)} \right),$$

где $C^{(p)}_{\mathbf{w}^{(p)}}$ — оператор дискретной свертки p-го слоя. Далее для простоты полагаем $\mathbf{b}^{(p)} = 0$, так как смещения не влияют на оценку спектральной нормы весовой части, и рассматриваем свертку со страйдом $s = 1$ и без паддинга.

Ключевым свойством, позволяющим применить лемму 2.3.1 к сверточным сетям, является возможность записать оператор свертки двумя эквивалентными способами через матричное умножение. Эта двойственность критически важна для корректного вычисления матриц $\mathbf{S}^{(p)}$ и $\mathbf{P}^{(p)}$, так как они требуют дифференцирования по разным аргументам (входу и параметрам соответственно).

Оператор свертки по входу (матрица Тёплица). Для любого фиксированного ядра $\mathbf{w}^{(p)}$ существует структурированная матрица $\mathbf{T}^{(p)}(\mathbf{w}) \in \mathbb{R}^{n_p \times n_{p-1}}$, такая что:

$$\mathbf{z}^{(p)} = \mathbf{T}^{(p)}(\mathbf{w}) \mathbf{x}^{(p)}. \tag{2.20}$$

Структура матрицы $\mathbf{T}^{(p)}$ определяется типом свертки [**singh2023hessian**]:

- **1D свертка.** Матрица $\mathbf{T}^{(p)}$ является ленточной матрицей Тёплица. Каждая строка содержит веса ядра, сдвинутые на одну позицию вправо относительно предыдущей строки.
- **2D свертка.** Матрица $\mathbf{T}^{(p)}$ является блочно-тёплицевой матрицей с тёплицевыми блоками (англ. BTTB, Block Toeplitz with Toeplitz Blocks). Блоки соответствуют сдвигам ядра по высоте, а структура внутри блоков — сдвигам по ширине.
- **Многоканальный случай.** Матрица $\mathbf{T}^{(p)}$ состоит из блоков, соответствующих парам входных и выходных каналов.

Пример (1D свертка и матрица Тёплица). Рассмотрим одномерную свертку без паддинга и со страйдом 1. Пусть входной вектор $\mathbf{x} = [x_1, x_2, x_3, x_4]^\top \in \mathbb{R}^4$, а ядро $\mathbf{w} = [w_1, w_2]^\top \in \mathbb{R}^2$. Результат свертки $\mathbf{z} \in \mathbb{R}^3$ имеет вид:

$$\mathbf{z} = \begin{bmatrix} w_1x_1 + w_2x_2 \\ w_1x_2 + w_2x_3 \\ w_1x_3 + w_2x_4 \end{bmatrix}.$$

Это выражение можно записать как $\mathbf{z} = \mathbf{T}(\mathbf{w})\mathbf{x}$, где матрица $\mathbf{T}(\mathbf{w}) \in \mathbb{R}^{3\times 4}$ имеет вид:

$$\mathbf{T}(\mathbf{w}) = \begin{bmatrix} w_1 & w_2 & 0 & 0 \\ 0 & w_1 & w_2 & 0 \\ 0 & 0 & w_1 & w_2 \end{bmatrix}.$$

Заметим, что матрица зависит от весов $\mathbf{w}$, но не от входа $\mathbf{x}$.

Эта матрица используется для вычисления матрицы распространения возмущения $\mathbf{S}^{(p)}$, так как она описывает линейное отображение входа в выход при фиксированных весах.

Оператор свертки по весам (матрица патчей). Та же самая операция свертки может быть записана как линейная зависимость от параметров ядра при фиксированном входе. Существует матрица $\mathbf{X}^{(p)}\left(\mathbf{x}^{(p)}\right) \in \mathbb{R}^{n_p \times N_p}$, называемая матрицей патчей, составленная из локальных фрагментов входа $\mathbf{x}^{(p)}$, такая что:

$$\mathbf{z}^{(p)} = \mathbf{X}^{(p)}\left(\mathbf{x}^{(p)}\right)\mathbf{w}^{(p)}. \tag{2.21}$$

Структура $\mathbf{X}^{(p)}$ такова, что каждый ее столбец соответствует одному параметру ядра, а строки содержат значения входа, попадающие в рецептивное поле этого параметра при всех возможных сдвигах.

Пример (1D свертка и патч-матрица). Используем те же данные, что и в предыдущем примере: $\mathbf{x} = [x_1, x_2, x_3, x_4]^\top$, $\mathbf{w} = [w_1, w_2]^\top$. Выразим $\mathbf{z}$ через веса:

$$\mathbf{z} = \begin{bmatrix} x_1 & x_2 \\ x_2 & x_3 \\ x_3 & x_4 \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \end{bmatrix}.$$

Здесь матрица $\mathbf{X}(\mathbf{x}) \in \mathbb{R}^{3\times 2}$ имеет вид:

$$\mathbf{X}(\mathbf{x}) = \begin{bmatrix} x_1 & x_2 \\ x_2 & x_3 \\ x_3 & x_4 \end{bmatrix}.$$

Заметим, что матрица зависит от входа $\mathbf{x}$, но не от весов $\mathbf{w}$.

Эта матрица патчей используется для вычисления параметрического якобиана $\mathbf{P}^{(p)}$. Действительно, по определению (2.6):

$$\mathbf{P}^{(p)}(\mathbf{w}) = \frac{\partial \mathbf{z}^{(p)}}{\partial \mathbf{w}^{(p)}}.$$

Поскольку зависимость $\mathbf{z}^{(p)}$ от $\mathbf{w}^{(p)}$ в уравнении (2.21) линейна, производная равна самой матрице коэффициентов:

$$\mathbf{P}^{(p)}(\mathbf{w}) = \mathbf{X}^{(p)}\left(\mathbf{x}^{(p)}\right).$$

Таким образом, параметрический якобиан сверточного слоя есть не что иное, как матрица патчей входа. Двойственность представлений (2.20) и (2.21) позволяет явно записать компоненты леммы 2.3.1 для CNN. Следовательно, анализ гаусс-ньютоновской компоненты $\mathbf{G}(\mathbf{w})$ для сверточных сетей сводится к оценке норм структурированных матриц $\mathbf{T}^{(p)}$ (зависящих от весов) и $\mathbf{X}^{(p)}$ (зависящих от активаций), что будет подробно выполнено в следующих подразделах.

Матрица распространения возмущения $\mathbf{S}^{(p)}$. Согласно (2.11), $\mathbf{S}^{(p)}$ есть произведение локальных якобианов $\partial \mathbf{z}^{(k+1)}/\partial \mathbf{z}^{(k)}$. Из (2.20) и правила дифференцирования сложной функции следует:

$$\frac{\partial \mathbf{z}^{(k+1)}}{\partial \mathbf{z}^{(k)}} = \frac{\partial \mathbf{z}^{(k+1)}}{\partial \mathbf{x}^{(k+1)}} \cdot \frac{\partial \mathbf{x}^{(k+1)}}{\partial \mathbf{z}^{(k)}} = \mathbf{T}^{(k+1)}(\mathbf{w})\mathbf{D}^{(k)},$$

где $\mathbf{D}^{(k)} = \operatorname{diag}\left(\sigma^{(k)\prime}\left(\mathbf{z}^{(k)}\right)\right)$. Таким образом, $\mathbf{S}^{(p)}$ представляет собой произведение матриц Тёплица последующих слоев и диагональных матриц активаций:

$$\mathbf{S}^{(p)}(\mathbf{w}) = \mathbf{T}^{(L)}\mathbf{D}^{(L-1)} \cdots \mathbf{T}^{(p+1)}\mathbf{D}^{(p)}. \tag{2.22}$$

Для последнего слоя $\mathbf{S}^{(L)}(\mathbf{w}) = \mathbf{I}_K$.

Параметрический якобиан $\mathbf{P}^{(p)}$. По определению (2.6), $\mathbf{P}^{(p)} = \partial \mathbf{z}^{(p)}/\partial \mathbf{w}^{(p)}$. Используя линейность свертки по параметрам (2.21), получаем:

$$\mathbf{P}^{(p)}(\mathbf{w}) = \mathbf{X}^{(p)}\left(\mathbf{x}^{(p)}\right). \tag{2.23}$$

Заметим, что $\mathbf{P}^{(p)}$ не зависит от весов $\mathbf{w}^{(p)}$ (так как свертка линейна по весам), но зависит от активаций предыдущих слоев через $\mathbf{x}^{(p)}$.

Для получения верхней оценки спектральной нормы $\|\mathbf{G}(\mathbf{w})\|_2$ необходимо оценить нормы $\|\mathbf{T}^{(p)}\|_2$ и $\|\mathbf{X}^{(p)}\|_2$.

Лемма 2.5.1 (Норма матрицы Тёплица). *Пусть* $\mathbf{T}^{(p)}$ *— матрица Тёплица (или блочно-тёплицева с тёплицевыми блоками), соответствующая операции свертки с ядром* $\mathcal{W}^{(p)}$*. Тогда ее спектральная норма ограничена сверху через* ℓ_1*-норму ядра:*

$$\|\mathbf{T}^{(p)}\|_2 \leqslant \|\mathcal{W}^{(p)}\|_1 = \sum_{c_{in},c_{out},i,j} |W^{(p)}_{c_{out},c_{in},i,j}|.$$

В случае, если веса ограничены по модулю $|W^{(p)}_{ijkl}| \leqslant w_{\max}$*, а размер ядра равен* $k_h \times k_w$*, то*

$$\|\mathbf{T}^{(p)}\|_2 \leqslant C_{in} C_{out} k_h k_w w_{\max}.$$

Доказательство. По определению спектральной нормы матрицы, для любого вектора $\mathbf{x}^{(p)} \neq 0$:

$$\|\mathbf{T}^{(p)}\|_2 = \sup_{\mathbf{x}^{(p)} \neq 0} \frac{\|\mathbf{T}^{(p)}\mathbf{x}^{(p)}\|_2}{\|\mathbf{x}^{(p)}\|_2}.$$

Матрица $\mathbf{T}^{(p)}$ построена таким образом, что умножение $\mathbf{T}^{(p)}\mathbf{x}^{(p)}$ эквивалентно операции дискретной свертки входа $\mathcal{X}^{(p)}$ с ядром $\mathcal{W}^{(p)}$:

$$\mathbf{T}^{(p)}\mathbf{x}^{(p)} = \mathrm{vec}\left(\mathcal{W}^{(p)} * \mathcal{X}^{(p)}\right).$$

Поскольку векторизация сохраняет ℓ_2-норму, имеем:

$$\|\mathbf{T}^{(p)}\mathbf{x}^{(p)}\|_2 = \|\mathcal{W}^{(p)} * \mathcal{X}^{(p)}\|_2.$$

Для дискретной свертки справедливо неравенство Юнга [**young1912determination**

$$\|\mathcal{W}^{(p)} * \mathcal{X}^{(p)}\|_2 \leqslant \|\mathcal{W}^{(p)}\|_1 \cdot \|\mathcal{X}^{(p)}\|_2,$$

где $\|\mathcal{W}^{(p)}\|_1 = \sum_{c_{\text{in}},c_{\text{out}},i,j} |W^{(p)}_{c_{\text{out}},c_{\text{in}},i,j}|$ — ℓ_1-норма ядра, а $\|\mathcal{X}^{(p)}\|_2 = \|\mathbf{x}^{(p)}\|_2$ — ℓ_2-норма входа. Подставляя неравенство Юнга в определение спектральной нормы:

$$\|\mathbf{T}^{(p)}\|_2 = \sup_{\mathbf{x}^{(p)} \neq 0} \frac{\|\mathbf{T}^{(p)}\mathbf{x}^{(p)}\|_2}{\|\mathbf{x}^{(p)}\|_2} = \sup_{\mathbf{x}^{(p)} \neq 0} \frac{\|\mathcal{W}^{(p)} * \mathcal{X}^{(p)}\|_2}{\|\mathcal{X}^{(p)}\|_2} \leqslant \|\mathcal{W}^{(p)}\|_1.$$

Если все элементы ядра ограничены по модулю $|W^{(p)}_{ijkl}| \leqslant w_{\max}$, то:

$$\|\mathcal{W}^{(p)}\|_1 = \sum_{c_{\text{in}}=1}^{C_{\text{in}}} \sum_{c_{\text{out}}=1}^{C_{\text{out}}} \sum_{i=1}^{k_h} \sum_{j=1}^{k_w} |W^{(p)}_{c_{\text{out}},c_{\text{in}},i,j}| \leqslant C_{\text{in}} C_{\text{out}} k_h k_w w_{\max}.$$

Откуда следует окончательная оценка: $\|\mathbf{T}^{(p)}\|_2 \leqslant C_{\text{in}} C_{\text{out}} k_h k_w w_{\max}$. □

Лемма 2.5.2 (Норма матрицы патчей)**.** *Пусть* $\mathbf{X}^{(p)} \in \mathbb{R}^{n_p \times N_p}$ *— матрица патчей, построенная по входу* $\mathbf{x}^{(p)} \in \mathbb{R}^{n_{p-1}}$ *для сверточного слоя* p *с ядром размера* $k_h \times k_w$ *и* $C_{out}^{(p)}$ *выходными каналами. Тогда спектральная норма матрицы патчей ограничена сверху:*

$$\|\mathbf{X}^{(p)}\|_2 \leqslant \sqrt{K_p}\|\mathbf{x}^{(p)}\|_2,$$

где $K_p = C_{out}^{(p)} k_h k_w$ *— число весов, участвующих в формировании одного выходного элемента (размер ядра с учетом каналов).*

Доказательство. Матрица $\mathbf{X}^{(p)}$ строится следующим образом: каждый столбец соответствует одному параметру ядра свертки, а каждая строка соответствует одной пространственной позиции выхода. Элемент $X_{ij}^{(p)}$ содержит значение входа $\mathbf{x}^{(p)}$, которое умножается на j-й параметр ядра при вычислении i-го элемента выхода. Для свертки со страйдом $s = 1$ и без паддинга, каждый элемент входа $\mathbf{x}^{(p)}$ участвует в формировании нескольких элементов выхода $\mathbf{z}^{(p)}$. Конкретно, каждый элемент входа попадает в рецептивное поле ядра размером $k_h \times k_w$ для $K_p = C_{\text{out}}^{(p)} k_h k_w$ различных параметров.

Спектральная норма матрицы ограничена сверху через норму Фробениуса:

$$\|\mathbf{X}^{(p)}\|_2 \leqslant \|\mathbf{X}^{(p)}\|_F = \sqrt{\sum_{i,j} \left(X_{ij}^{(p)}\right)^2}.$$

Каждый элемент $x_m^{(p)}$ входа встречается в матрице $\mathbf{X}^{(p)}$ ровно столько раз, сколько различных позиций ядра могут его «накрыть» при свертке. Для страйда $s = 1$ это число равно произведению:

- числа выходных каналов $C_{\text{out}}^{(p)}$ (каждый канал имеет свое ядро),
- числа пространственных позиций ядра $k_h k_w$ (каждая позиция ядра использует данный элемент входа при соответствующем сдвиге).

Таким образом, каждый элемент $x_m^{(p)}$ входит в сумму квадратов элементов $\mathbf{X}^{(p)}$ не более чем K_p раз:

$$\sum_{i,j} \left(X_{ij}^{(p)}\right)^2 \leqslant \sum_{m=1}^{n_{p-1}} K_p \left(x_m^{(p)}\right)^2 = K_p \|\mathbf{x}^{(p)}\|_2^2.$$

Подставляя оценку нормы Фробениуса:

$$\|\mathbf{X}^{(p)}\|_2 \leqslant \|\mathbf{X}^{(p)}\|_F = \sqrt{\sum_{i,j} \left(X_{ij}^{(p)}\right)^2} \leqslant \sqrt{K_p \|\mathbf{x}^{(p)}\|_2^2} = \sqrt{K_p}\|\mathbf{x}^{(p)}\|_2.$$

□

Теперь сформулируем основную теорему для сверточных сетей, объединяющую лемму 2.3.1 и полученные оценки норм. Структура теоремы полностью аналогична теореме 2.4.1 для полносвязных сетей.

Теорема 2.5.3. *Пусть $f_{\mathbf{w}}$ является L-слойной сверточной нейронной сетью без смещений. Предположим, что существуют такие положительные константы, что для всех слоев $p = 1, \ldots, L$ выполнены ограничения: $\|\mathbf{x}\|_2 \leqslant M_{\mathbf{x}}$, $\|\mathbf{A}(\mathbf{w})\|_2 \leqslant M_{\mathbf{A}}$, $\|\mathcal{W}^{(p)}\|_1 \leqslant M_{\mathcal{W}}$ и $\|\mathbf{D}^{(p)}\|_2 \leqslant M_{\sigma}$. Пусть $K_{\max} = \max_p \left(C_{out}^{(p)} k_h k_w\right)$ — максимальный «размер» ядра. Тогда спектральная норма гаусс-ньютоновской компоненты удовлетворяет оценке:*

$$\|\mathbf{G}(\mathbf{w})\|_2 \leqslant L M_{\mathbf{x}}^2 M_{\mathbf{A}} K_{\max} \left(M_{\mathcal{W}} M_{\sigma}\right)^{2L-2}. \tag{2.24}$$

Доказательство. Воспользуемся блочной структурой (2.9) и оценкой нормы блока по субмультипликативности:

$$\|\mathbf{G}^{(p,q)}(\mathbf{w})\|_2 \leqslant \|\mathbf{P}^{(p)}(\mathbf{w})\|_2 \|\mathbf{S}^{(p)}(\mathbf{w})\|_2 \|\mathbf{A}(\mathbf{w})\|_2 \|\mathbf{S}^{(q)}(\mathbf{w})\|_2 \|\mathbf{P}^{(q)}(\mathbf{w})\|_2.$$

Далее применим те же свойства для оценки $\|\mathbf{S}^{(p)}\|_2$, из (2.22) имеем

$$\|\mathbf{S}^{(p)}\|_2 \leqslant \prod_{k=p+1}^{L} \|\mathbf{T}^{(k)}\|_2 \cdot \prod_{k=p}^{L-1} \|\mathbf{D}^{(k)}\|_2.$$

Используя лемму 2.5.1 о том, что $\|\mathbf{T}\|_2 \leqslant M_{\mathcal{W}}$, и условие на функцию активацию, получаем

$$\|\mathbf{S}^{(p)}\|_2 \leqslant M_{\mathcal{W}}^{L-p} M_{\sigma}^{L-p}.$$

Затем перейдем к оценке $\|\mathbf{P}^{(p)}\|_2$ из (2.23) и леммы 2.5.2:

$$\|\mathbf{P}^{(p)}\|_2 \leqslant \sqrt{K_p} \|\mathbf{x}^{(p)}\|_2 \leqslant \sqrt{K_{\max}} \|\mathbf{x}^{(p)}\|_2.$$

Оценим норму промежуточного представления $\|\mathbf{x}^{(p)}\|_2$. Поскольку $\mathbf{x}^{(p+1)} = \sigma(\mathbf{T}^{(p)} \mathbf{x}^{(p)})$, то:

$$\|\mathbf{x}^{(p+1)}\|_2 \leqslant M_{\sigma} \|\mathbf{T}^{(p)}\|_2 \|\mathbf{x}^{(p)}\|_2 \leqslant M_{\sigma} M_{\mathcal{W}} \|\mathbf{x}^{(p)}\|_2.$$

Итерируя от входа $\mathbf{x}^{(1)} = \mathbf{x}$,

$$\|\mathbf{x}^{(p)}\|_2 \leqslant (M_{\sigma} M_{\mathcal{W}})^{p-1} M_{\mathbf{x}}.$$

Следовательно:

$$\|\mathbf{P}^{(p)}\|_2 \leqslant \sqrt{K_{\max}} (M_{\sigma} M_{\mathcal{W}})^{p-1} M_{\mathbf{x}}.$$

Подставим оценки в выражение для блока $\mathbf{G}^{(p,q)}$:

$$\begin{aligned}\|\mathbf{G}^{(p,q)}\|_2 &\leqslant M_{\mathbf{A}} \cdot \left[\sqrt{K_{\max}}(M_\sigma M_{\mathcal{W}})^{p-1} M_{\mathbf{x}} \cdot M_{\mathcal{W}}^{L-p} M_\sigma^{L-p}\right] \\ &\quad \times \left[\sqrt{K_{\max}}(M_\sigma M_{\mathcal{W}})^{q-1} M_{\mathbf{x}} \cdot M_{\mathcal{W}}^{L-q} M_\sigma^{L-q}\right] \\ &= M_{\mathbf{A}} K_{\max} M_{\mathbf{x}}^2 (M_\sigma M_{\mathcal{W}})^{p-1+L-p+q-1+L-q} \\ &= M_{\mathbf{A}} K_{\max} M_{\mathbf{x}}^2 (M_\sigma M_{\mathcal{W}})^{2L-2}.\end{aligned}$$

Заметим, что степень не зависит от конкретных индексов p, q.

Матрица $\mathbf{G}$ состоит из $L \times L$ блоков. Используя оценку нормы блочной матрицы через норму якобиана, как в теореме 2.4.1:

$$\|\mathbf{G}\|_2 \leqslant M_{\mathbf{A}} \|\mathbf{J}\|_2^2.$$

Якобиан $\mathbf{J} = [\mathbf{S}^{(1)}\mathbf{P}^{(1)}, \ldots, \mathbf{S}^{(L)}\mathbf{P}^{(L)}]$. Норма каждого блочного столбца $\mathbf{J}^{(p)} = \mathbf{S}^{(p)}\mathbf{P}^{(p)}$:

$$\|\mathbf{J}^{(p)}\|_2 \leqslant M_{\mathcal{W}}^{L-p} M_\sigma^{L-p} \cdot \sqrt{K_{\max}}(M_\sigma M_{\mathcal{W}})^{p-1} M_{\mathbf{x}} = \sqrt{K_{\max}} M_{\mathbf{x}} (M_\sigma M_{\mathcal{W}})^{L-1}.$$

Тогда $\|\mathbf{J}\|_2^2 \leqslant \sum_{p=1}^{L} \|\mathbf{J}^{(p)}\|_2^2 = L \cdot K_{\max} M_{\mathbf{x}}^2 (M_\sigma M_{\mathcal{W}})^{2L-2}$. Умножая на $M_{\mathbf{A}}$, получаем искомую оценку (2.24). □

Сравнение оценки (2.24) с оценкой для полносвязной сети (2.13) показывает качественное сходство экспоненциальной зависимости от глубины L. Однако константа $M_{\mathcal{W}}$ для сверточных сетей (норма ядра) обычно значительно меньше нормы полной матрицы весов полносвязного слоя той же размерности из-за разреженности связей и разделения весов. Множитель $K_{\max}$ отражает локальность связей: он пропорционален размеру ядра, а не полной размерности входа, что делает оценку для CNN существенно точнее в реальных сценариях.

Рассотренный подход матричного представления легко обобщается на другие стандартные архитектурные элементы сверточных сетей. Рассмотрим влияние операций пулинга и остаточных связей на структуру матриц $\mathbf{S}^{(p)}$ и итоговые оценки спектральной нормы.

Пулинг (Pooling). Операции пулинга (MaxPool, AvgPool) обычно применяются после сверточных слоев для уменьшения пространственной размерности представлений. В контексте матрично-представимых сетей оператор пулинга p-го слоя $\mathcal{M}^{(p)}$ может быть записан как умножение на матрицу $\mathbf{M}^{(p)} \in \mathbb{R}^{n'_p \times n_p}$, где $n'_p < n_p$ — уменьшенная размерность выхода.

– **AvgPool.** Для усреднения по окну размера k_{pool} без перекрытия, матрица $\mathbf{M}^{(p)}$ состоит из блоков, содержащих значения $1/k_{pool}$ (с нормировкой) или 1 (без нормировки). Спектральная норма такой матрицы оценивается как:

$$\|\mathbf{M}^{(p)}\|_2 \leqslant 1 \quad \text{(без нормировки)}, \qquad \|\mathbf{M}^{(p)}\|_2 \leqslant \frac{1}{\sqrt{k_{\text{pool}}}} \quad \text{(с нормировкой)}.$$

– **MaxPool.** Операция максимума является кусочно-линейной. В областях дифференцируемости ее якобиан представляет собой матрицу выбора (субматрицу единичной матрицы), содержащую ровно одну единицу в каждой строке. Следовательно, ее спектральная норма равна единице:

$$\|\mathbf{M}^{(p)}\|_2 = 1.$$

Включение пулинга слегка модифицирует рекуррентную формулу для матрицы распространения (2.22). Если пулинг применяется после слоя p, то в произведение добавляется множитель $\mathbf{M}^{(p)}$:

$$\mathbf{S}^{(p)}(\mathbf{w}) = \mathbf{T}^{(L)}\mathbf{D}^{(L-1)}\mathbf{M}^{(L-1)} \cdots \mathbf{T}^{(p+1)}\mathbf{D}^{(p)}.$$

Поскольку $\|\mathbf{M}^{(p)}\|_2 \leqslant 1$, наличие пулинга не увеличивает верхнюю оценку нормы $\|\mathbf{S}^{(p)}\|_2$. Более того, уменьшение размерности n_p снижает размерность последующих матриц Тёплица $\mathbf{T}^{(k)}$, что может косвенно уменьшить константу $K_{\max}$ в оценке теоремы 2.5.3.

Остаточные связи (Residual Connections). В архитектурах типа ResNet выход блока задается суммой входа и нелинейного преобразования:

$$\mathbf{x}^{(p+B)} = \mathbf{x}^{(p)} + \mathcal{F}^{(p)}(\mathbf{x}^{(p)}),$$

где $\mathcal{F}^{(p)}$ — последовательность сверток и активаций внутри блока, B — глубина блока. Дифференцирование этого выражения по входу блока дает:

$$\frac{\partial \mathbf{x}^{(p+B)}}{\partial \mathbf{x}^{(p)}} = \mathbf{I}_{n_p} + \frac{\partial \mathcal{F}^{(p)}(\mathbf{x}^{(p)})}{\partial \mathbf{x}^{(p)}}.$$

В терминах матрицы распространения $\mathbf{S}^{(p)} = \partial \mathbf{z}/\partial \mathbf{z}^{(p)}$, это означает, что рекуррентный шаг через остаточный блок включает сумму путей распространения градиента. Пусть $\mathbf{S}^{(p)}_{\text{main}}$ — матрица распространения через сверточные слои блока, тогда полная матрица распространения от начала блока удовлетворяет соотношению:

$$\mathbf{S}^{(p)}_{\text{res}} = \mathbf{S}^{(p+B)}\left(\mathbf{I}_{n_p} + \mathbf{S}^{(p)}_{\text{main}}\right).$$

Используя неравенство треугольника для спектральной нормы, получаем оценку:

$$\|\mathbf{S}_{\text{res}}^{(p)}\|_2 \leqslant \|\mathbf{S}^{(p+B)}\|_2 \left(1 + \|\mathbf{S}_{\text{main}}^{(p)}\|_2\right).$$

В отличие от последовательной сети, где нормы перемножаются, в остаточной сети они суммируются внутри блока. Это меняет характер зависимости от глубины. Если нормы слоев внутри блока малы ($\|\mathbf{S}_{\text{main}}^{(p)}\|_2 < 1$), то остаточные связи способствуют стабилизации нормы $\mathbf{S}^{(p)}$ и предотвращают экспоненциальный рост (или затухание) градиентов.

Для оценки гаусс-ньютоновской компоненты $\mathbf{G}(\mathbf{w})$ в сети с N_{res} остаточными блоками, оценка теоремы 2.5.3 модифицируется заменой множителя $(M_{\mathcal{W}} M_{\sigma})^{2L-2}$ на сумму вкладов путей. В худшем случае (используя субмультипликативность для суммы), константа L в оценке (2.24) может быть заменена на эффективную глубину с учетом числа блоков, однако на практике наличие единичной матрицы $\mathbf{I}$ в якобиане часто приводит к более обусловленным матрицам Гессе по сравнению с чистыми сетями той же глубины.

2.6. Трансформерные нейронные сети

В предыдущих разделах анализ гаусс–ньютоновской компоненты проводился для матрично-представимых сетей, где каждый слой задается линейным по входу оператором. Для стандартного трансформерного блока эта схема уже неприменима: self-attention нелинеен по входу из-за softmax от матрицы попарных скалярных произведений, а LayerNorm нелинеен вследствие зависимости от построчных средних и дисперсий. Поэтому в данном разделе мы не пытаемся включить трансформер в класс матрично-представимых сетей, а напрямую исследуем якобиан выхода блока по параметрам. Этого достаточно для анализа гаусс–ньютоновской компоненты (2.3).

Рассмотрим одно-головый трансформерный блок. Пусть T обозначает длину последовательности, d — размерность токенных представлений, d_k — размерность запросов и ключей, d_{ff} — скрытую размерность feed-forward части. Вход блока задается матрицей $\mathbf{X} \in \mathbb{R}^{T \times d}$, а сам блок определяется формулами

$$\mathbf{\Pi}(\mathbf{X}) = \operatorname{softmax}\left(\frac{\mathbf{X}\mathbf{W}_Q\mathbf{W}_K^\top\mathbf{X}^\top}{\sqrt{d_k}}\right) \in \mathbb{R}^{T \times T}, \qquad \operatorname{SA}(\mathbf{X}) = \mathbf{\Pi}(\mathbf{X})\mathbf{X}\mathbf{W}_V \in \mathbb{R}^{T \times d},$$

$$\mathbf{U} = \mathbf{X} + \mathrm{SA}(\mathbf{X}) \in \mathbb{R}^{T\times d}, \qquad \mathbf{Y} = \mathrm{LN}(\mathbf{U}) \in \mathbb{R}^{T\times d},$$
$$\mathbf{S} = \mathbf{Y} + \sigma(\mathbf{Y}\mathbf{W}_1)\mathbf{W}_2 \in \mathbb{R}^{T\times d}, \qquad \mathbf{Z} = \mathrm{LN}(\mathbf{S}) \in \mathbb{R}^{T\times d},$$

где $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V \in \mathbb{R}^{d\times d_k}$, $\mathbf{W}_1 \in \mathbb{R}^{d\times d_{\mathrm{ff}}}$, $\mathbf{W}_2 \in \mathbb{R}^{d_{\mathrm{ff}}\times d}$, $\sigma = \mathrm{ReLU}$ действует покомпонентно. Для согласования с обозначениями главы используем построчную векторизацию

$$\mathbf{x} = \mathrm{vec_r}(\mathbf{X}) \in \mathbb{R}^{Td}, \qquad \mathbf{z} = \mathrm{vec_r}(\mathbf{Z}) \in \mathbb{R}^{Td}.$$

Параметры блока разбиваются на пять групп:

$$\mathbf{w}_i = \mathrm{vec_r}(\mathbf{W}_i), \qquad i \in \{Q, K, V, 1, 2\},$$
$$\mathbf{w} = \mathrm{col}\left(\mathbf{w}_1, \mathbf{w}_2, \mathbf{w}_3, \mathbf{w}_4, \mathbf{w}_5\right).$$

Соответствующие частные якобианы обозначим через

$$\mathbf{J}^{(Q)} = \frac{\partial \mathbf{z}}{\partial \mathbf{w}_Q^\top}, \quad \mathbf{J}^{(K)} = \frac{\partial \mathbf{z}}{\partial \mathbf{w}_K^\top}, \quad \mathbf{J}^{(V)} = \frac{\partial \mathbf{z}}{\partial \mathbf{w}_V^\top}, \quad \mathbf{J}^{(1)} = \frac{\partial \mathbf{z}}{\partial \mathbf{w}_1^\top}, \quad \mathbf{J}^{(2)} = \frac{\partial \mathbf{z}}{\partial \mathbf{w}_2^\top}.$$

Тогда полный якобиан имеет блочный вид

$$\mathbf{J}(\mathbf{w}) = \left[\mathbf{J}^{(Q)}, \mathbf{J}^{(K)}, \mathbf{J}^{(V)}, \mathbf{J}^{(1)}, \mathbf{J}^{(2)}\right]. \tag{2.25}$$

Ключевой шаг состоит в том, что якобианы по всем группам параметров можно факторизовать через якобианы двух нормализаций, якобиан feed-forward части по входу и якобианы изолированного self-attention блока. Точные формулы и их доказательства приведены в приложении A.1; здесь приведем только итоговый результат.

Теорема 2.6.1. *Для одно-голового трансформерного блока справедливы представления*

$$\mathbf{J}^{(1)} = \mathbf{J}_Z\mathbf{B}_1, \qquad \mathbf{J}^{(2)} = \mathbf{J}_Z\mathbf{B}_2, \tag{2.26}$$

$$\mathbf{J}^{(Q)} = \mathbf{J}_Z\mathbf{J}_{SY}\mathbf{J}_Y\mathbf{G}_Q, \qquad \mathbf{J}^{(K)} = \mathbf{J}_Z\mathbf{J}_{SY}\mathbf{J}_Y\mathbf{G}_K, \qquad \mathbf{J}^{(V)} = \mathbf{J}_Z\mathbf{J}_{SY}\mathbf{J}_Y\mathbf{G}_V, \tag{2.27}$$

где

$$\mathbf{J}_Y = \frac{\partial\,\mathrm{vec_r}(\mathbf{Y})}{\partial\,\mathrm{vec_r}(\mathbf{U})^\top}, \qquad \mathbf{J}_Z = \frac{\partial\,\mathrm{vec_r}(\mathbf{Z})}{\partial\,\mathrm{vec_r}(\mathbf{S})^\top},$$
$$\mathbf{B}_1 = \left(\mathbf{I}_T \otimes \mathbf{W}_2^\top\right)\mathbf{D}_\sigma(\mathbf{Y}\mathbf{W}_1)\left(\mathbf{Y} \otimes \mathbf{I}_{d_{\mathrm{ff}}}\right), \qquad \mathbf{B}_2 = \sigma(\mathbf{Y}\mathbf{W}_1) \otimes \mathbf{I}_d,$$
$$\mathbf{G}_Q = \frac{\partial\,\mathrm{vec_r}(\mathrm{SA}(\mathbf{X}))}{\partial \mathbf{w}_Q^\top}, \qquad \mathbf{G}_K = \frac{\partial\,\mathrm{vec_r}(\mathrm{SA}(\mathbf{X}))}{\partial \mathbf{w}_K^\top}, \qquad \mathbf{G}_V = \frac{\partial\,\mathrm{vec_r}(\mathrm{SA}(\mathbf{X}))}{\partial \mathbf{w}_V^\top},$$

а также

$$\mathbf{J}_{SY} = \mathbf{I}_{Td} + \left(\mathbf{I}_T \otimes \mathbf{W}_2^\top\right)\mathbf{D}_\sigma(\mathbf{Y}\mathbf{W}_1)\left(\mathbf{I}_T \otimes \mathbf{W}_1^\top\right). \tag{2.28}$$

Таким образом, для оценки нормы $\mathbf{G}(\mathbf{w})$ достаточно оценить нормы матриц $\mathbf{J}_Y$, $\mathbf{J}_Z$, $\mathbf{J}_{SY}$, $\mathbf{B}_1$, $\mathbf{B}_2$ и $\mathbf{G}_Q, \mathbf{G}_K, \mathbf{G}_V$. Соответствующие технические оценки собраны в следующей лемме; их доказательства также вынесены в приложение A.1.

Лемма 2.6.2. *Пусть для матрицы* $\mathbf{U} \in \mathbb{R}^{T\times d}$ *выполнено условие на дисперсии*

$$\sigma_{\min}(\mathbf{U}) = \min_{t=1,\dots,T} \sigma_t(\mathbf{U}) > 0.$$

Тогда якобиан LayerNorm удовлетворяет оценке

$$\|\mathbf{J}_{\mathrm{LN}}(\mathbf{U})\|_2 \leqslant \frac{1}{\sigma_{\min}(\mathbf{U})} + \frac{\|\mathbf{U}\|_2^2}{\sqrt{d}\,\sigma_{\min}(\mathbf{U})^3}.$$

Кроме того,

$$\|\mathbf{G}_V\|_2 \leqslant T\|\mathbf{X}\|_2,$$

$$\|\mathbf{G}_Q\|_2 \leqslant \frac{C_{\mathrm{sm}}}{\sqrt{d_k}}\|\mathbf{W}_V\|_2\|\mathbf{W}_K\|_2\|\mathbf{X}\|_2^3, \qquad \|\mathbf{G}_K\|_2 \leqslant \frac{C_{\mathrm{sm}}}{\sqrt{d_k}}\|\mathbf{W}_V\|_2\|\mathbf{W}_Q\|_2\|\mathbf{X}\|_2^3,$$

где C_{sm} *— константа Липшица построчного softmax в спектральной норме.*

Теперь можно перейти к оценке спектральной нормы гаусс–ньютоновской компоненты.

Теорема 2.6.3. *Пусть*

$$\|\mathbf{A}(\mathbf{w})\|_2 \leqslant M_{\mathbf{A}}.$$

Тогда

$$\|\mathbf{G}(\mathbf{w})\|_2 \leqslant M_{\mathbf{A}} \sum_{i\in\{Q,K,V,1,2\}} \|\mathbf{J}^{(i)}\|_2^2.$$

Более того, справедливы оценки

$$\|\mathbf{J}^{(1)}\|_2 \leqslant \|\mathbf{J}_Z\|_2\|\mathbf{W}_2\|_2\|\mathbf{Y}\|_2, \qquad \|\mathbf{J}^{(2)}\|_2 \leqslant \|\mathbf{J}_Z\|_2\|\mathbf{W}_1\|_2\|\mathbf{Y}\|_2, \tag{2.29}$$

$$\|\mathbf{J}^{(k)}\|_2 \leqslant \|\mathbf{J}_Z\|_2\,(1 + \|\mathbf{W}_2\|_2\|\mathbf{W}_1\|_2)\,\|\mathbf{J}_Y\|_2\|\mathbf{G}_k\|_2, \qquad k \in \{Q,K,V\}. \tag{2.30}$$

Доказательство. Первая оценка непосредственно следует из определения

$$\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w})\mathbf{J}(\mathbf{w})$$

и блочного представления (2.25). Далее, оценки (2.29) получаются из формул (2.26) по субмультипликативности спектральной нормы и неравенству $\|\mathbf{D}_\sigma\|_2 \leqslant 1$. Наконец, оценки (2.30) следуют из (2.27) и оценки

$$\|\mathbf{J}_{SY}\|_2 \leqslant 1 + \|\mathbf{W}_2\|_2\|\mathbf{W}_1\|_2,$$

которая непосредственно получается из (2.28). □

Объединяя теорему 2.6.3 с леммой 2.6.2, получаем явную верхнюю оценку.

Следствие 2.6.4. *Пусть*

$$\|\mathbf{A}(\mathbf{w})\|_2 \leqslant M_{\mathbf{A}}, \qquad \|\mathbf{X}\|_2 \leqslant M_{\mathbf{X}}, \qquad \|\mathbf{Y}\|_2 \leqslant M_{\mathbf{Y}},$$

$$\|\mathbf{W}_Q\|_2, \|\mathbf{W}_K\|_2, \|\mathbf{W}_V\|_2, \|\mathbf{W}_1\|_2, \|\mathbf{W}_2\|_2 \leqslant M_{\mathbf{W}},$$

$$\sigma_{\min}(\mathbf{U}) \geqslant \sigma_0, \qquad \sigma_{\min}(\mathbf{S}) \geqslant \sigma_0 > 0.$$

Обозначим

$$C_{\mathrm{LN}}(M) = \frac{1}{\sigma_0} + \frac{M^2}{\sqrt{d}\,\sigma_0^3}.$$

Тогда

$$\|\mathbf{G}(\mathbf{w})\|_2 \leqslant M_{\mathbf{A}}\, C_{\mathrm{LN}}(\|\mathbf{S}\|_2)^2 \Bigg[2M_{\mathbf{Y}}^2 M_{\mathbf{W}}^2 + \\ + \left(1 + M_{\mathbf{W}}^2\right)^2 C_{\mathrm{LN}}(\|\mathbf{U}\|_2)^2 \left(T^2 M_{\mathbf{X}}^2 + \frac{2C_{\mathrm{sm}}^2 M_{\mathbf{W}}^4}{d_k} M_{\mathbf{X}}^6 \right) \Bigg].$$

Следствие 2.6.4 показывает, что в трансформерном блоке спектральная норма гаусс–ньютоновской компоненты определяется тремя основными факторами. Во-первых, вклад attention-параметров существенно зависит от нормы входного сигнала: для параметров $\mathbf{W}_Q$ и $\mathbf{W}_K$ возникает кубическая зависимость по $\|\mathbf{X}\|_2$, которая после возведения в квадрат дает члены порядка $\|\mathbf{X}\|_2^6$. Во-вторых, существенную роль играет LayerNorm, поскольку нормы $\|\mathbf{J}_Y\|_2$ и $\|\mathbf{J}_Z\|_2$ контролируются снизу построчными дисперсиями промежуточных представлений. В-третьих, остаточная связь во второй половине блока приводит к множителю $1 + \|\mathbf{W}_2\|_2\|\mathbf{W}_1\|_2$, а не к простому произведению норм, что качественно отличает трансформерный блок от последовательной композиции линейных слоев.

2.7. Вычислительные эксперименты

TODO

2.8. Обсуждение

TODO

Глава 3. Стабилизация ландшафта функции потерь в нейронных сетях

В данной главе исследуется изменение поверхности функции потерь в нейронных сетях при увеличении объема обучающей выборки. Сперва формулируется проблема оценки сходимости ландшафта функции потерь. Далее предлагается общий критерий стабилизации поверхности с функцией предпочтения точек в пространстве параметров. Затем рассматриваются частные случаи этого критерия с оценкой сходимости в одной точке минимума, в наборе точек по распределению, и в наборе точек по распределению в пространстве меньшей размерности, натянутом на главные собственные векторы матрицы Гессе. Доказываются теоремы о сходимости предложенного критерия.

3.1. Введение

Обновить, добавив ссылки

В современных нейронных сетях качество решения задачи обучения определяется не только значением функции потерь в одной найденной точке минимума, но и геометрией всей поверхности функции потерь в ее окрестности. Именно форма ландшафта влияет на устойчивость обучения, чувствительность к замене обучающих объектов, свойства обобщения и поведение численных методов оптимизации. Поэтому при исследовании зависимости между объемом обучающей выборки и поведением модели естественно рассматривать не только сходимость эмпирического риска как скалярной величины, но и стабилизацию самой поверхности функции потерь.

Классические результаты теории статистического обучения показывают, что при увеличении размера выборки эмпирическая функция потерь сходится к популяционной. Однако из этого факта не следует автоматически, как быстро стабилизируются локальные геометрические характеристики ландшафта, например кривизна вблизи точек минимума. Между тем именно эти характеристики определяют локальную форму поверхности и могут быть выражены через матрицу Гессе. В связи с этим возникает задача построения количествен-

ного критерия, позволяющего измерять изменение ландшафта при добавлении новых обучающих объектов.

В данной главе предлагается общий подход к оценке сходимости ландшафта функции потерь, основанный на сравнении эмпирических функций потерь на выборках размеров k и $k+1$. В качестве основной идеи используется локальная квадратичная аппроксимация функции потерь в окрестности точки минимума, позволяющая свести задачу к анализу разности соответствующих матриц Гессе. На этой основе вводится общий критерий p-сходимости с функцией предпочтения точек в пространстве параметров, а затем рассматриваются его частные случаи, наиболее удобные для теоретического анализа и вычислительной реализации.

Основные результаты главы состоят в следующем. Во-первых, вводится абсолютный одноточечный критерий сходимости и доказывается его убывание со скоростью $\mathcal{O}(k^{-1})$. Во-вторых, для среднеквадратичного критерия с гауссовским распределением точек в пространстве параметров устанавливается оценка $\mathcal{O}(k^{-2})$. В-третьих, аналогичный критерий строится в подпространстве наибольшей кривизны, натянутом на главные собственные векторы матрицы Гессе, и для него доказывается оценка того же порядка сходимости при меньшей эффективной размерности. Тем самым формируется единая схема анализа стабилизации ландшафта функции потерь при росте объема обучающей выборки.

3.2. Предварительные сведения

Оптимизационная поверхность. Объектом называется пара $(\mathbf{x}, \mathbf{y})$, где $\mathbf{x} \in \mathbb{X}$ — признаковое описание, $\mathbf{y} \in \mathbb{Y}$ — целевая переменная. Выборка размера m задается множеством $\mathfrak{D}_m = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^m$ из m независимых реализаций пар $(\mathbf{x}, \mathbf{y})$, распределенных согласно неизвестному распределению $p(\mathbf{x}, \mathbf{y})$. Параметрической моделью называется семейство функций $f_{\mathbf{w}} : \mathbb{X} \to \mathbb{Y}$, задаваемое вектором параметров $\mathbf{w} \in \mathbb{R}^N$. Выбор модели из этого семейства проводится с помощью эмпирической функции потерь, вычисляемой на заданной выборке:

$$\mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^{m} \ell(f_{\mathbf{w}}(\mathbf{x}_i), \mathbf{y}_i) = \frac{1}{m} \sum_{i=1}^{m} \ell_i(\mathbf{w}), \tag{3.1}$$

где $\ell : \mathbb{Y} \times \mathbb{Y} \to \mathbb{R}^+$ — функция потерь на одном объекте. Обучение модели таким образом есть решение оптимизационной задачи

$$\mathbf{w}_m^* \in \arg\min_{\mathbf{w}\in\mathbb{R}^N} \mathcal{L}_m(\mathbf{w}). \tag{3.2}$$

Оптимизационной поверхностью или ландшафтом функции потерь (англ. loss landscape) называется график $\mathcal{L}_m(\mathbf{w})$ как функции от $\mathbf{w} \in \mathbb{R}^N$. Поскольку эмпирическая функция потерь (3.1) вычисляется по конечной выборке, она случайна, и при другой реализации выборки $\mathfrak{D}'_m$ множество минимизаторов (3.2), как правило, поменяется. Однако согласно закону больших чисел (ЗБЧ) эмпирическая функция потерь сходится к популяционной

$$\mathcal{L}(\mathbf{w}) = \mathbb{E}_{(\mathbf{x},\mathbf{y})\sim p(\mathbf{x},\mathbf{y})}[\ell(f_{\mathbf{w}}(\mathbf{x}), \mathbf{y})], \tag{3.3}$$

поэтому естественно ожидать, что множество решений (3.2) стабилизируется. Таким образом, изменение оптимизационной поверхности вблизи точек минимума (3.2) при добавлении обучающих объектов является ключевым объектом исследования настоящей главы.

Формула Тейлора для функции потерь. Рассмотрим точку $\mathbf{w}_0 \in \mathbb{R}^N$, в окрестности $\mathcal{U}_R(\mathbf{w}_0)$ радиуса $R > 0$ которой эмпирическая функция потерь $\mathcal{L}_m(\mathbf{w})$ дважды непрерывно дифференцируема. На практике это условие выполнено практически для всех параметрических моделей машинного обучения. По формуле Тейлора с остаточным членом в форме Пеано при $\mathbf{w} \to \mathbf{w}_0$ имеем

$$\begin{aligned}\mathcal{L}_m(\mathbf{w}) = \mathcal{L}_m(\mathbf{w}_0) + \nabla_{\mathbf{w}}\mathcal{L}_m(\mathbf{w}_0)^\top(\mathbf{w} - \mathbf{w}_0) + \\ + \frac{1}{2}(\mathbf{w} - \mathbf{w}_0)^\top \nabla^2_{\mathbf{w}}\mathcal{L}_m(\mathbf{w}_0)(\mathbf{w} - \mathbf{w}_0) + o(\|\mathbf{w} - \mathbf{w}_0\|_2^2).\end{aligned} \tag{3.4}$$

Далее, если не оговорено иное, работаем в рамках квадратичной аппроксимации и опускаем остаточный член более высокого порядка. Обозначим вектор градиента и матрицу Гессе функции потерь на выборке размера m через

$$\mathbf{g}^{(m)}(\mathbf{w}) = \nabla_{\mathbf{w}}\mathcal{L}_m(\mathbf{w}) = \frac{1}{m}\sum_{i=1}^m \nabla_{\mathbf{w}}\ell_i(\mathbf{w}) = \frac{1}{m}\sum_{i=1}^m \mathbf{g}_i(\mathbf{w}) \in \mathbb{R}^N,$$

$$\mathbf{H}^{(m)}(\mathbf{w}) = \nabla^2_{\mathbf{w}}\mathcal{L}_m(\mathbf{w}) = \frac{1}{m}\sum_{i=1}^m \nabla^2_{\mathbf{w}}\ell_i(\mathbf{w}) = \frac{1}{m}\sum_{i=1}^m \mathbf{H}_i(\mathbf{w}) \in \mathbb{R}^{N\times N},$$

в таком случае формула (3.4) перепишется в виде

$$\mathcal{L}_m(\mathbf{w}) = \mathcal{L}_m(\mathbf{w}_0) + \mathbf{g}^{(m)}(\mathbf{w}_0)^\top(\mathbf{w} - \mathbf{w}_0) + \frac{1}{2}(\mathbf{w} - \mathbf{w}_0)^\top \mathbf{H}^{(m)}(\mathbf{w}_0)(\mathbf{w} - \mathbf{w}_0). \tag{3.5}$$

Добавление одного объекта $(\mathbf{x}_{k+1}, \mathbf{y}_{k+1})$ к обучающей выборке $\mathfrak{D}_k = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^{k}$ размера k влечет изменение значения функции потерь, которое выражается формулой

$$\begin{aligned}\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) &= \frac{1}{k+1}\sum_{i=1}^{k+1}\ell_i(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) \\ &= \frac{1}{k+1}\Big(k\cdot\mathcal{L}_k(\mathbf{w}) + \ell_{k+1}(\mathbf{w})\Big) - \mathcal{L}_k(\mathbf{w}) \\ &= \frac{1}{k+1}\Big(\ell_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})\Big) \qquad (3.6)\end{aligned}$$

Дальнейшее исследование сходимости ландшафта построено на анализе этой разности. Воспользуемся выражением (3.5) и перепишем разность (3.6) в условиях аппроксимации второго порядка:

$$\begin{aligned}\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) = \mathcal{L}_{k+1}(\mathbf{w}_0) - \mathcal{L}_k(\mathbf{w}_0) + \\ + \Big(\mathbf{g}^{(k+1)}(\mathbf{w}_0) - \mathbf{g}^{(k)}(\mathbf{w}_0)\Big)^{\top}(\mathbf{w}-\mathbf{w}_0) + \\ + \frac{1}{2}(\mathbf{w}-\mathbf{w}_0)^{\top}\Big(\mathbf{H}^{(k+1)}(\mathbf{w}_0) - \mathbf{H}^{(k)}(\mathbf{w}_0)\Big)(\mathbf{w}-\mathbf{w}_0). \qquad (3.7)\end{aligned}$$

Рассмотрим точку минимума $\mathbf{w}_k^* \in \mathbb{R}^N$ эмпирической функции потерь $\mathcal{L}_k(\mathbf{w})$ на k объектах. В точке $\mathbf{w} \in \mathcal{U}_R(\mathbf{w}_k^*)$ из ее окрестности справедливо представление (3.7). В силу необходимого условия локального минимума $\mathbf{g}^{(k)}(\mathbf{w}_k^*) = \mathbf{0}$, а значит

$$\begin{aligned}\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) = \mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*) + \mathbf{g}^{(k+1)}(\mathbf{w}_k^*)^{\top}(\mathbf{w}-\mathbf{w}_k^*) + \\ + \frac{1}{2}(\mathbf{w}-\mathbf{w}_k^*)^{\top}\Big(\mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*)\Big)(\mathbf{w}-\mathbf{w}_k^*), \qquad (3.8)\end{aligned}$$

причем

$$\mathbf{g}^{(k+1)}(\mathbf{w}_k^*) = \frac{1}{k+1}\Big(k\cdot\cancel{\nabla_{\mathbf{w}}\mathcal{L}_k(\mathbf{w}_k^*)} + \nabla_{\mathbf{w}}\ell_{k+1}(\mathbf{w}_k^*)\Big) = \frac{1}{k+1}\mathbf{g}_{k+1}(\mathbf{w}_k^*).$$

Таким образом, вопрос о стабилизации оптимизационной поверхности в окрестности точек оптимума сводится к анализу выражения (3.8) и формулировке конкретных критериев на его основе. Введем предположение, проиллюстрированное на рисунке 3.1, которое позволит сформулировать ряд теоретических утверждений о сходимости.

Предположение 3.2.1 (О слабом градиентном рассогласовании). *Пусть в точке* $\mathbf{w}_k^* \in \mathbb{R}^N$ *минимума эмпирической функции потерь* $\mathcal{L}_k(\mathbf{w})$ *справедлива ограниченность нормы градиента функции потерь на* $(k+1)$*-м объекте:*

$$\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leqslant M_{\mathbf{g}}.$$

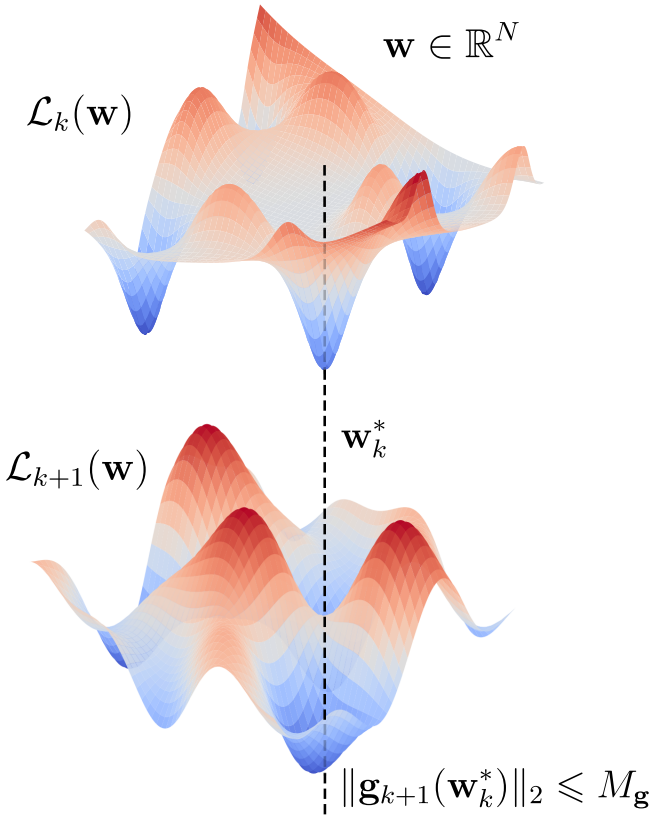

Рисунок 3.1 — Визуализация предположения 3.2.1 о слабом градиентном рассогласовании для эмпирических функций потерь на k и $k+1$ объектах

3.3. Критерий сходимости поверхности функции потерь

В предыдущем разделе мы показали, что по ряду причин есть основание полагать сходимость поверхности эмпирической функции потерь при увеличении объема обучающей выборки. Кроме того, мы получили аппроксимацию (3.8) явного выражения изменения этой поверхности в одной точке при добавлении одного объекта. Сформулируем общий критерий, измеряющий это изменение в наборе точек.

Определение. *Критерием p-сходимости* ландшафта функции потерь при добавлении одного объекта в выборку $\mathfrak{D}_k$ называется величина

$$\Delta_p(k+1) = \int |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|^p \, q(\mathbf{w}) d\mathbf{w}, \tag{3.9}$$

где функция $q : \mathbb{R}^N \to \mathbb{R}^+$ задает предпочтение по выбору точек в пространстве параметров модели для оценки сходимости.

Замечание. Отметим, что функция предпочтения $q(\mathbf{w})$ является неотрицательнозначной. Это позволяет перейти к рассмотрению вероятностного распределения на множестве параметров, заданному этой функцией. Далее без ограничения общности полагаем, что $q(\mathbf{w})$ есть плотность этого вероятностного распределения, т. е. $\int q(\mathbf{w}) d\mathbf{w} = 1$.

Введенный критерий (3.9) задает достаточно общий способ измерения изменения ландшафта функции потерь при добавлении одного нового объекта в обучающую выборку. Выбор степени p определяет способ агрегации локальных изменений поверхности, а функция предпочтения $q(\mathbf{w})$ позволяет выделить те области пространства параметров, которые представляют наибольший интерес в конкретной задаче. В частности, можно исследовать поведение ландшафта в одной фиксированной точке, усреднять изменение по распределению в полной параметрической области или ограничивать анализ подпространствами меньшей размерности, связанными с наиболее существенными направлениями кривизны.

Далее мы рассмотрим несколько частных случаев критерия (3.9). Они построены таким образом, чтобы, с одной стороны, сохранить связь с локальной геометрией ландшафта, а с другой стороны, допускать явные теоретические оценки скорости сходимости при увеличении объема выборки.

3.4. Абсолютный одноточечный критерий сходимости

Наиболее простым частным случаем критерия (3.9) является ситуация, когда изменение ландшафта измеряется в одной фиксированной точке пространства параметров. Такой подход позволяет получить наиболее прозрачную теоретическую оценку и служит отправной точкой для дальнейших обобщений.

Поскольку нас интересует локальная геометрия поверхности функции потерь, естественно рассматривать точки из окрестности локального минимума $\mathbf{w}_k^*$, где справедлива квадратичная аппроксимация (3.8).

Определение. *Абсолютным одноточечным критерием сходимости* ландшафта функции потерь при добавлении одного объекта в выборку $\mathfrak{D}_k$ называется величина

$$\Delta_1(k+1) = |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|,$$

где $\mathbf{w} \in \mathcal{U}_R(\mathbf{w}_k^*)$ — точка из окрестности радиуса $R > 0$ минимума $\mathbf{w}_k^*$.

Замечание. Отметим, что определение выше есть частный случай общего критерия (3.9) при $p = 1$ и $q(\tilde{\mathbf{w}}) = \delta(\tilde{\mathbf{w}} - \mathbf{w})$, где $\delta(\mathbf{w})$ суть дельта-функция Дирака.

В силу формулы (3.8) абсолютный одноточечный критерий сходимости в общем случае определяется тремя вкладами: разностью значений функций потерь в точке минимума $\mathbf{w}_k^*$, линейным членом, задаваемым градиентом функции $\mathcal{L}_{k+1}$ в этой точке, и квадратичным членом, задаваемым разностью матриц Гессе. Поэтому его оценка сводится к последовательному ограничению каждого из этих вкладов. Это позволяет получить явную верхнюю оценку критерия и, при дополнительных предположениях о зависимости соответствующих констант от k, установить скорость его убывания при росте объема выборки.

Теорема 3.4.1. *Пусть существует окрестность $\mathcal{U}_R(\mathbf{w}_k^*)$ радиуса $R > 0$ точки локального минимума $\mathbf{w}_k^* \in \mathbb{R}^N$ эмпирической функции потерь $\mathcal{L}_k(\mathbf{w})$, такая что в этой окрестности справедлива квадратичная аппроксимация (3.8). Предположим, что*

$$\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leqslant M_{\mathbf{g}}$$

и для всех $i = 1, \ldots, k+1$ выполнены оценки

$$|\ell_i(\mathbf{w}_k^*)| \leqslant M_\ell,$$

$$\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leqslant M_{\mathbf{H}}. \tag{3.10}$$

Тогда для абсолютного одноточечного критерия сходимости верна оценка

$$\Delta_1(k+1) \leqslant \frac{2M_\ell + M_{\mathbf{g}}R + M_{\mathbf{H}}R^2}{k+1} = \mathcal{O}(k^{-1}),.$$

Доказательство. Для точки $\mathbf{w} \in \mathcal{U}_R(\mathbf{w}_k^*)$ из квадратичной аппроксимации (3.8) имеем

$$\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) = \mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*) + \\ + \mathbf{g}^{(k+1)}(\mathbf{w}_k^*)^\top(\mathbf{w} - \mathbf{w}_k^*) + \frac{1}{2}(\mathbf{w} - \mathbf{w}_k^*)^\top\Big(\mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*)\Big)(\mathbf{w} - \mathbf{w}_k^*).$$

Переходя к модулю и применяя неравенство треугольника, получаем

$$\Delta_1(k+1) \leqslant |\mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*)| + \left|\mathbf{g}^{(k+1)}(\mathbf{w}_k^*)^\top(\mathbf{w} - \mathbf{w}_k^*)\right| + \\ + \frac{1}{2}\left|(\mathbf{w} - \mathbf{w}_k^*)^\top\Big(\mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*)\Big)(\mathbf{w} - \mathbf{w}_k^*)\right|.$$

Оценим по отдельности все три слагаемых.

Нулевой член. Из формулы для разности эмпирических функций потерь в точке $\mathbf{w}_k^*$ имеем

$$\mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*) = \frac{1}{k+1}\Big(\ell_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*)\Big).$$

Следовательно,

$$|\mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*)| \leqslant \frac{1}{k+1}\left(|\ell_{k+1}(\mathbf{w}_k^*)| + |\mathcal{L}_k(\mathbf{w}_k^*)|\right). \tag{3.11}$$

Но

$$|\mathcal{L}_k(\mathbf{w}_k^*)| = \left|\frac{1}{k}\sum_{i=1}^{k}\ell_i(\mathbf{w}_k^*)\right| \leqslant \frac{1}{k}\sum_{i=1}^{k}|\ell_i(\mathbf{w}_k^*)| \leqslant M_\ell.$$

Поэтому из (3.11) получаем

$$|\mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*)| \leqslant \frac{2M_\ell}{k+1}. \tag{3.12}$$

Линейный член. По неравенству Коши—Буняковского имеем

$$\left|\mathbf{g}^{(k+1)}(\mathbf{w}_k^*)^\top(\mathbf{w} - \mathbf{w}_k^*)\right| \leqslant \|\mathbf{g}^{(k+1)}(\mathbf{w}_k^*)\|_2\|\mathbf{w} - \mathbf{w}_k^*\|_2. \tag{3.13}$$

Так как $\mathbf{g}^{(k)}(\mathbf{w}_k^*) = \mathbf{0}$, то

$$\mathbf{g}^{(k+1)}(\mathbf{w}_k^*) = \frac{1}{k+1}\mathbf{g}_{k+1}(\mathbf{w}_k^*),$$

а значит

$$\|\mathbf{g}^{(k+1)}(\mathbf{w}_k^*)\|_2 \leqslant \frac{M_\mathbf{g}}{k+1}. \tag{3.14}$$

Подставляя (3.14) в (3.13), получаем

$$\left|\mathbf{g}^{(k+1)}(\mathbf{w}_k^*)^\top(\mathbf{w}-\mathbf{w}_k^*)\right| \leqslant \frac{M_{\mathbf{g}}}{k+1}\|\mathbf{w}-\mathbf{w}_k^*\|_2. \tag{3.15}$$

Квадратичный член. По согласованности спектральной нормы имеем

$$\left|(\mathbf{w}-\mathbf{w}_k^*)^\top\left(\mathbf{H}^{(k+1)}(\mathbf{w}_k^*)-\mathbf{H}^{(k)}(\mathbf{w}_k^*)\right)(\mathbf{w}-\mathbf{w}_k^*)\right| \leqslant \\ \leqslant \left\|\mathbf{H}^{(k+1)}(\mathbf{w}_k^*)-\mathbf{H}^{(k)}(\mathbf{w}_k^*)\right\|_2 \|\mathbf{w}-\mathbf{w}_k^*\|_2^2. \tag{3.16}$$

Для разности матриц Гессе справедливо

$$\mathbf{H}^{(k+1)}(\mathbf{w}_k^*)-\mathbf{H}^{(k)}(\mathbf{w}_k^*) = \frac{1}{k+1}\left(\mathbf{H}_{k+1}(\mathbf{w}_k^*)-\mathbf{H}^{(k)}(\mathbf{w}_k^*)\right),$$

поэтому

$$\left\|\mathbf{H}^{(k+1)}(\mathbf{w}_k^*)-\mathbf{H}^{(k)}(\mathbf{w}_k^*)\right\|_2 \leqslant \frac{1}{k+1}\left(\|\mathbf{H}_{k+1}(\mathbf{w}_k^*)\|_2+\|\mathbf{H}^{(k)}(\mathbf{w}_k^*)\|_2\right).$$

Из (3.10) следует

$$\|\mathbf{H}_{k+1}(\mathbf{w}_k^*)\|_2 \leqslant M_{\mathbf{H}}$$

и

$$\|\mathbf{H}^{(k)}(\mathbf{w}_k^*)\|_2 = \left\|\frac{1}{k}\sum_{i=1}^{k}\mathbf{H}_i(\mathbf{w}_k^*)\right\|_2 \leqslant \frac{1}{k}\sum_{i=1}^{k}\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leqslant M_{\mathbf{H}}.$$

Следовательно,

$$\left\|\mathbf{H}^{(k+1)}(\mathbf{w}_k^*)-\mathbf{H}^{(k)}(\mathbf{w}_k^*)\right\|_2 \leqslant \frac{2M_{\mathbf{H}}}{k+1}. \tag{3.17}$$

Подставляя (3.17) в (3.16), получаем

$$\frac{1}{2}\left|(\mathbf{w}-\mathbf{w}_k^*)^\top\left(\mathbf{H}^{(k+1)}(\mathbf{w}_k^*)-\mathbf{H}^{(k)}(\mathbf{w}_k^*)\right)(\mathbf{w}-\mathbf{w}_k^*)\right| \leqslant \frac{M_{\mathbf{H}}}{k+1}\|\mathbf{w}-\mathbf{w}_k^*\|_2^2. \tag{3.18}$$

Собирая оценки (3.12), (3.15) и (3.18), имеем

$$\Delta_1(k+1) \leqslant \frac{2M_\ell}{k+1}+\frac{M_{\mathbf{g}}}{k+1}\|\mathbf{w}-\mathbf{w}_k^*\|_2+\frac{M_{\mathbf{H}}}{k+1}\|\mathbf{w}-\mathbf{w}_k^*\|_2^2.$$

Так как $\mathbf{w}\in\mathcal{U}_R(\mathbf{w}_k^*)$, то $\|\mathbf{w}-\mathbf{w}_k^*\|_2 \leqslant R$, и потому

$$\Delta_1(k+1) \leqslant \frac{2M_\ell+M_{\mathbf{g}}R+M_{\mathbf{H}}R^2}{k+1} = \mathcal{O}(k^{-1}),$$

что и требовалось доказать. □

Таким образом, в общем случае абсолютное изменение функции потерь в фиксированной точке локальной окрестности минимума определяется тремя составляющими: смещением значения функции потерь в точке $\mathbf{w}_k^*$, градиентным рассогласованием и квадратичным вкладом разности матриц Гессе. При пообъектной ограниченности функции потерь, градиента и матрицы Гессе все три слагаемых имеют порядок $\mathcal{O}(k^{-1})$, а значит и абсолютный одноточечный критерий убывает как $\mathcal{O}(k^{-1})$.

3.5. Среднеквадратичный критерий сходимости

Одноточечный критерий удобен для получения первичной локальной оценки, однако на практике изменение ландшафта представляет интерес не в одной фиксированной точке, а в некоторой области пространства параметров. Естественным способом учесть такую зависимость является усреднение квадрата разности функций потерь по распределению точек. В отличие от абсолютного одноточечного критерия, такой подход позволяет анализировать не только типичную величину изменения ландшафта, но и чувствительность поверхности к направлениям отклонения от точки минимума.

Определение. *Среднеквадратичным критерием сходимости* ландшафта функции потерь при добавлении одного объекта в выборку $\mathfrak{D}_k$ называется величина

$$\Delta_2(k+1) = \int \big(\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})\big)^2 q(\mathbf{w}) d\mathbf{w} = \mathbb{E}_{q(\mathbf{w})}\left[\big(\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})\big)^2\right]. \tag{3.19}$$

В общем случае поведение критерия (3.19) зависит от выбора функции предпочтения $q(\mathbf{w})$. Для получения явной аналитической формулы естественно рассмотреть гауссовское распределение с центром в точке локального минимума $q(\mathbf{w}) = \mathcal{N}(\mathbf{w}_k^*, \sigma^2\mathbf{I}_N)$. Такой выбор согласуется с локальным характером квадратичной аппроксимации и позволяет использовать известные формулы для моментов квадратичных форм гауссовских векторов.

Теорема 3.5.1. *Пусть существует окрестность $\mathcal{U}_R(\mathbf{w}_k^*)$ радиуса $R > 0$ точки локального минимума $\mathbf{w}_k^* \in \mathbb{R}^N$ эмпирической функции потерь $\mathcal{L}_k(\mathbf{w})$, такая что в этой окрестности справедлива квадратичная аппроксимация (3.8). Предположим, что*

$$\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leqslant M_{\mathbf{g}}$$

и для всех $i = 1, \ldots, k+1$ выполнены оценки

$$|\ell_i(\mathbf{w}_k^*)| \leqslant M_\ell,$$

$$\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leqslant M_{\mathbf{H}}.$$

Тогда для среднеквадратичного критерия сходимости с

$$q(\mathbf{w}) = \mathcal{N}(\mathbf{w}_k^*, \sigma^2 \mathbf{I}_N), \qquad \sigma > 0,$$

верна оценка

$$\Delta_2(k+1) \leqslant \frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(N^2+2N)M_{\mathbf{H}}^2}{(k+1)^2} = \mathcal{O}(k^{-2}).$$

Доказательство. Обозначим

$$\mathbf{v} = \mathbf{w} - \mathbf{w}_k^*, \qquad a_k = \mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*), \qquad \mathbf{b}_k = \mathbf{g}^{(k+1)}(\mathbf{w}_k^*),$$

$$\mathbf{A}_k = \mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*).$$

Тогда при $\mathbf{w} \sim \mathcal{N}(\mathbf{w}_k^*, \sigma^2 \mathbf{I}_N)$ имеем $\mathbf{v} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_N)$, и из квадратичной аппроксимации (3.8) следует

$$\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) = a_k + \mathbf{b}_k^\top \mathbf{v} + \frac{1}{2}\mathbf{v}^\top \mathbf{A}_k \mathbf{v}.$$

Следовательно,

$$\Delta_2(k+1) = \mathbb{E}\left[\left(a_k + \mathbf{b}_k^\top \mathbf{v} + \frac{1}{2}\mathbf{v}^\top \mathbf{A}_k \mathbf{v}\right)^2\right]. \tag{3.20}$$

Используем неравенство

$$(x+y+z)^2 \leqslant 3(x^2+y^2+z^2), \qquad x, y, z \in \mathbb{R}.$$

Тогда из (3.20) получаем

$$\Delta_2(k+1) \leqslant 3a_k^2 + 3\mathbb{E}\big[(\mathbf{b}_k^\top \mathbf{v})^2\big] + \frac{3}{4}\mathbb{E}\big[(\mathbf{v}^\top \mathbf{A}_k \mathbf{v})^2\big]. \tag{3.21}$$

Нулевой член. По формуле для разности эмпирических функций потерь в точке $\mathbf{w}_k^*$ имеем

$$a_k = \frac{1}{k+1}\Big(\ell_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*)\Big).$$

Поэтому

$$|a_k| \leqslant \frac{1}{k+1}\left(|\ell_{k+1}(\mathbf{w}_k^*)| + |\mathcal{L}_k(\mathbf{w}_k^*)|\right).$$

Но

$$|\mathcal{L}_k(\mathbf{w}_k^*)| = \left|\frac{1}{k}\sum_{i=1}^{k}\ell_i(\mathbf{w}_k^*)\right| \leqslant \frac{1}{k}\sum_{i=1}^{k}|\ell_i(\mathbf{w}_k^*)| \leqslant M_\ell,$$

откуда

$$|a_k| \leqslant \frac{2M_\ell}{k+1}, \qquad a_k^2 \leqslant \frac{4M_\ell^2}{(k+1)^2}. \tag{3.22}$$

Линейный член. Поскольку $\mathbf{g}^{(k)}(\mathbf{w}_k^*) = \mathbf{0}$, имеем

$$\mathbf{b}_k = \mathbf{g}^{(k+1)}(\mathbf{w}_k^*) = \frac{1}{k+1}\mathbf{g}_{k+1}(\mathbf{w}_k^*).$$

Тогда

$$\|\mathbf{b}_k\|_2 \leqslant \frac{M_{\mathbf{g}}}{k+1}.$$

Для второго момента линейной формы гауссовского вектора получаем

$$\mathbb{E}\big[(\mathbf{b}_k^\top\mathbf{v})^2\big] = \mathbf{b}_k^\top\mathbb{E}[\mathbf{v}\mathbf{v}^\top]\mathbf{b}_k = \sigma^2\|\mathbf{b}_k\|_2^2 \leqslant \frac{\sigma^2 M_{\mathbf{g}}^2}{(k+1)^2}. \tag{3.23}$$

Квадратичный член. Так как матрица $\mathbf{A}_k$ симметрична, а $\mathbf{v} \sim \mathcal{N}(\mathbf{0}, \sigma^2\mathbf{I}_N)$, то

$$\mathbb{E}\big[(\mathbf{v}^\top\mathbf{A}_k\mathbf{v})^2\big] = 2\sigma^4\operatorname{Tr}(\mathbf{A}_k^2) + \sigma^4\operatorname{Tr}(\mathbf{A}_k)^2.$$

Для симметричной матрицы $\mathbf{A}_k$ с собственными значениями $\lambda_1, \ldots, \lambda_N$ имеем

$$\operatorname{Tr}(\mathbf{A}_k^2) = \sum_{i=1}^{N}\lambda_i^2 \leqslant N\|\mathbf{A}_k\|_2^2$$

и

$$|\operatorname{Tr}(\mathbf{A}_k)| \leqslant N\|\mathbf{A}_k\|_2,$$

откуда

$$\mathbb{E}\big[(\mathbf{v}^\top\mathbf{A}_k\mathbf{v})^2\big] \leqslant \sigma^4(N^2+2N)\|\mathbf{A}_k\|_2^2. \tag{3.24}$$

Далее,

$$\mathbf{A}_k = \mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*) = \frac{1}{k+1}\left(\mathbf{H}_{k+1}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*)\right),$$

поэтому

$$\|\mathbf{A}_k\|_2 \leqslant \frac{1}{k+1}\left(\|\mathbf{H}_{k+1}(\mathbf{w}_k^*)\|_2 + \|\mathbf{H}^{(k)}(\mathbf{w}_k^*)\|_2\right).$$

Из ограниченности гессианов на отдельных объектах следует

$$\|\mathbf{H}_{k+1}(\mathbf{w}_k^*)\|_2 \leqslant M_{\mathbf{H}}$$

и

$$\|\mathbf{H}^{(k)}(\mathbf{w}_k^*)\|_2 = \left\|\frac{1}{k}\sum_{i=1}^{k}\mathbf{H}_i(\mathbf{w}_k^*)\right\|_2 \leqslant \frac{1}{k}\sum_{i=1}^{k}\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leqslant M_{\mathbf{H}}.$$

Следовательно,

$$\|\mathbf{A}_k\|_2 \leqslant \frac{2M_{\mathbf{H}}}{k+1}. \tag{3.25}$$

Подставляя (3.25) в (3.24), получаем

$$\mathbb{E}\big[(\mathbf{v}^\top\mathbf{A}_k\mathbf{v})^2\big] \leqslant \frac{4\sigma^4(N^2+2N)M_{\mathbf{H}}^2}{(k+1)^2}. \tag{3.26}$$

Подставляя оценки (3.22), (3.23) и (3.26) в (3.21), получаем

$$\Delta_2(k+1) \leqslant \frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(N^2+2N)M_{\mathbf{H}}^2}{(k+1)^2},$$

что и требовалось доказать. □

Итак, в общем случае среднеквадратичный критерий определяется тремя источниками рассогласования: разностью значений функций потерь в точке $\mathbf{w}_k^*$, градиентным рассогласованием и квадратичным вкладом, связанным с разностью матриц Гессе. При пообъектной ограниченности функции потерь, градиента и матрицы Гессе все три слагаемых имеют порядок $\mathcal{O}(k^{-2})$ после усреднения квадрата по гауссовскому распределению, а значит и сам среднеквадратичный критерий убывает как $\mathcal{O}(k^{-2})$.

3.6. Среднеквадратичный критерий сходимости в подпространстве наибольшей кривизны

Во многих задачах существенное изменение ландшафта функции потерь происходит не по всем направлениям в пространстве параметров, а преимущественно вдоль направлений наибольшей локальной кривизны. Такие направления задаются собственными векторами матрицы Гессе, соответствующими

ее наибольшим собственным значениям. Поэтому наряду с критерием (3.19) естественно рассмотреть его аналог в подпространстве меньшей размерности, натянутом на главные собственные векторы матрицы Гессе в точке локального минимума $\mathbf{w}_k^*$.

Определение. Пусть

$$\mathbf{H}^{(k)}(\mathbf{w}_k^*)\mathbf{u}_i = \lambda_i^{(k)}\mathbf{u}_i, \qquad i = 1, \ldots, N,$$

где собственные значения упорядочены по невозрастанию:

$$\lambda_1^{(k)} \geqslant \lambda_2^{(k)} \geqslant \cdots \geqslant \lambda_N^{(k)},$$

а собственные векторы $\mathbf{u}_1, \ldots, \mathbf{u}_N$ образуют ортонормированный базис в $\mathbb{R}^N$. Обозначим через

$$\mathbf{U}_D = [\mathbf{u}_1, \ldots, \mathbf{u}_D] \in \mathbb{R}^{N\times D}$$

матрицу, столбцы которой составлены из D собственных векторов, отвечающих D наибольшим собственным значениям матрицы $\mathbf{H}^{(k)}(\mathbf{w}_k^*)$. Подпространство

$$\mathcal{S}_D = \mathrm{Im}(\mathbf{U}_D)$$

будем называть *подпространством наибольшей кривизны* размерности D.

Определение. *Среднеквадратичным критерием сходимости в подпространстве наибольшей кривизны* размерности D называется величина

$$\Delta_2^{(D)}(k+1) = \int \big(\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})\big)^2 q(\mathbf{w})\, d\mathbf{w}, \tag{3.27}$$

где функция $q(\mathbf{w})$ задает плотность вероятностного распределения на аффинном подпространстве $\mathbf{w}_k^* + \mathcal{S}_D$.

Замечание. Любая точка $\mathbf{w} \in \mathbf{w}_k^* + \mathcal{S}_D$ единственным образом представима в виде

$$\mathbf{w} = \mathbf{w}_k^* + \mathbf{U}_D\mathbf{z}, \qquad \mathbf{z} \in \mathbb{R}^D.$$

Поэтому критерий (3.27) можно эквивалентно записать в координатах $\mathbf{z} \in \mathbb{R}^D$:

$$\Delta_2^{(D)}(k+1) = \int \big(\mathcal{L}_{k+1}(\mathbf{w}_k^* + \mathbf{U}_D\mathbf{z}) - \mathcal{L}_k(\mathbf{w}_k^* + \mathbf{U}_D\mathbf{z})\big)^2 \tilde{q}(\mathbf{z})\, d\mathbf{z}, \tag{3.28}$$

где $\tilde{q}(\mathbf{z})$ — плотность распределения в координатах подпространства, индуцированная функцией предпочтения $q(\mathbf{w})$.

Лемма 3.6.1. *Пусть* $\operatorname{supp} q \subset (\mathbf{w}_k^* + \mathcal{S}_D) \cap \mathcal{U}_R(\mathbf{w}_k^*)$. *Обозначим*

$$a_k = \mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*), \qquad \mathbf{b}_k = \mathbf{g}^{(k+1)}(\mathbf{w}_k^*),$$

$$\mathbf{A}_k = \mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*), \qquad \mathbf{B}_k = \mathbf{U}_D^\top \mathbf{A}_k \mathbf{U}_D \in \mathbb{R}^{D\times D},$$

$$\mathbf{c}_k = \mathbf{U}_D^\top \mathbf{b}_k \in \mathbb{R}^D.$$

Тогда в рамках квадратичной аппроксимации (3.8) *критерий* (3.28) *представим в виде*

$$\Delta_2^{(D)}(k+1) = \int \left(a_k + \mathbf{c}_k^\top \mathbf{z} + \frac{1}{2}\mathbf{z}^\top \mathbf{B}_k \mathbf{z} \right)^2 \tilde{q}(\mathbf{z})\, d\mathbf{z}. \tag{3.29}$$

Доказательство. Для любой точки $\mathbf{w} \in \mathbf{w}_k^* + \mathcal{S}_D$ имеем представление

$$\mathbf{w} = \mathbf{w}_k^* + \mathbf{U}_D \mathbf{z}, \qquad \mathbf{z} \in \mathbb{R}^D.$$

Тогда из квадратичной аппроксимации (3.8) следует

$$\begin{aligned}
\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) &= a_k + \mathbf{b}_k^\top(\mathbf{w} - \mathbf{w}_k^*) + \frac{1}{2}(\mathbf{w} - \mathbf{w}_k^*)^\top \mathbf{A}_k (\mathbf{w} - \mathbf{w}_k^*) \\
&= a_k + \mathbf{b}_k^\top \mathbf{U}_D \mathbf{z} + \frac{1}{2}(\mathbf{U}_D \mathbf{z})^\top \mathbf{A}_k (\mathbf{U}_D \mathbf{z}) \\
&= a_k + (\mathbf{U}_D^\top \mathbf{b}_k)^\top \mathbf{z} + \frac{1}{2}\mathbf{z}^\top \mathbf{U}_D^\top \mathbf{A}_k \mathbf{U}_D \mathbf{z} \\
&= a_k + \mathbf{c}_k^\top \mathbf{z} + \frac{1}{2}\mathbf{z}^\top \mathbf{B}_k \mathbf{z}.
\end{aligned}$$

Возводя в квадрат и усредняя по распределению $\tilde{q}(\mathbf{z})$, получаем (3.29). □

Замечание. По определению

$$\mathbf{B}_k = \mathbf{U}_D^\top \mathbf{H}^{(k+1)}(\mathbf{w}_k^*)\mathbf{U}_D - \mathbf{U}_D^\top \mathbf{H}^{(k)}(\mathbf{w}_k^*)\mathbf{U}_D.$$

Поскольку столбцы матрицы $\mathbf{U}_D$ являются собственными векторами матрицы $\mathbf{H}^{(k)}(\mathbf{w}_k^*)$, имеем

$$\mathbf{U}_D^\top \mathbf{H}^{(k)}(\mathbf{w}_k^*)\mathbf{U}_D = \operatorname{diag}\left(\lambda_1^{(k)}, \ldots, \lambda_D^{(k)}\right).$$

Если, кроме того, векторы $\mathbf{u}_1, \ldots, \mathbf{u}_D$ являются также собственными векторами матрицы $\mathbf{H}^{(k+1)}(\mathbf{w}_k^*)$, то

$$\mathbf{U}_D^\top \mathbf{H}^{(k+1)}(\mathbf{w}_k^*)\mathbf{U}_D = \operatorname{diag}\left(\lambda_1^{(k+1)}, \ldots, \lambda_D^{(k+1)}\right),$$

а следовательно,

$$\mathbf{B}_k = \operatorname{diag}\left(\lambda_1^{(k+1)} - \lambda_1^{(k)}, \ldots, \lambda_D^{(k+1)} - \lambda_D^{(k)}\right).$$

Таким образом, в этом случае собственные значения матрицы $\mathbf{B}_k$ совпадают с приращениями соответствующих собственных значений матриц Гессе.

Предположение 3.6.2. *Пусть векторы* $\mathbf{u}_1, \ldots, \mathbf{u}_D$, *отвечающие* D *наибольшим собственным значениям матрицы* $\mathbf{H}^{(k)}(\mathbf{w}_k^*)$, *являются также собственными векторами матрицы* $\mathbf{H}^{(k+1)}(\mathbf{w}_k^*)$:

$$\mathbf{H}^{(k+1)}(\mathbf{w}_k^*)\mathbf{u}_i = \lambda_i^{(k+1)}\mathbf{u}_i, \qquad i = 1, \ldots, D.$$

Данное предположение означает, что при переходе от выборки размера k к выборке размера $k+1$ главные направления локальной кривизны в рассматриваемом подпространстве не меняются. Именно оно позволяет выразить критерий сходимости через приращения соответствующих собственных значений матриц Гессе.

Замечание. В важном для практического применения частном случае функция предпочтения $q(\mathbf{w})$ может быть выбрана так, чтобы индуцированное распределение в координатах подпространства было нормальным:

$$\tilde{q}(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \sigma^2\mathbf{I}_D), \qquad \mathbf{w} = \mathbf{w}_k^* + \mathbf{U}_D\mathbf{z}.$$

Тогда критерий (3.28) принимает вид математического ожидания по гауссовскому распределению в пространстве $\mathbb{R}^D$, что позволяет получить явную формулу через спектральные характеристики матриц Гессе.

Теорема 3.6.3. *Пусть выполнены условия леммы 3.6.1. Предположим, что*

$$\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leqslant M_{\mathbf{g}}$$

и для всех $i = 1, \ldots, k+1$ *выполнены оценки*

$$|\ell_i(\mathbf{w}_k^*)| \leqslant M_\ell,$$

$$\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leqslant M_{\mathbf{H}}.$$

Пусть, кроме того, функция предпочтения $q(\mathbf{w})$ *индуцирует в координатах подпространства наибольшей кривизны распределение*

$$\tilde{q}(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \sigma^2\mathbf{I}_D).$$

Тогда для среднеквадратичного критерия сходимости в подпространстве наибольшей кривизны верно

$$\Delta_2^{(D)}(k+1) \leqslant \frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(D^2+2D)M_{\mathbf{H}}^2}{(k+1)^2} = \mathcal{O}(k^{-2}).$$

Доказательство. По лемме 3.6.1 имеем

$$\Delta_2^{(D)}(k+1) = \mathbb{E}_{\tilde{q}(\mathbf{z})}\left[\left(a_k + \mathbf{c}_k^\top \mathbf{z} + \frac{1}{2}\mathbf{z}^\top \mathbf{B}_k \mathbf{z}\right)^2\right], \qquad \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D).$$

Используя неравенство

$$(x+y+z)^2 \leqslant 3(x^2+y^2+z^2), \qquad x,y,z \in \mathbb{R},$$

получаем

$$\Delta_2^{(D)}(k+1) \leqslant 3a_k^2 + 3\mathbb{E}\big[(\mathbf{c}_k^\top \mathbf{z})^2\big] + \frac{3}{4}\mathbb{E}\big[(\mathbf{z}^\top \mathbf{B}_k \mathbf{z})^2\big]. \tag{3.30}$$

Нулевой член. Как и в доказательстве теоремы для полного среднеквадратичного критерия,

$$|a_k| = |\mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*)| \leqslant \frac{2M_\ell}{k+1},$$

а значит

$$a_k^2 \leqslant \frac{4M_\ell^2}{(k+1)^2}. \tag{3.31}$$

Линейный член. Так как

$$\mathbf{c}_k = \mathbf{U}_D^\top \mathbf{b}_k, \qquad \mathbf{b}_k = \mathbf{g}^{(k+1)}(\mathbf{w}_k^*) = \frac{1}{k+1}\mathbf{g}_{k+1}(\mathbf{w}_k^*),$$

то

$$\|\mathbf{c}_k\|_2 \leqslant \|\mathbf{U}_D^\top\|_2 \|\mathbf{b}_k\|_2 \leqslant \frac{M_{\mathbf{g}}}{k+1},$$

поскольку $\mathbf{U}_D$ имеет ортонормированные столбцы и $\|\mathbf{U}_D^\top\|_2 = 1$. Следовательно,

$$\mathbb{E}\big[(\mathbf{c}_k^\top \mathbf{z})^2\big] = \sigma^2 \|\mathbf{c}_k\|_2^2 \leqslant \frac{\sigma^2 M_{\mathbf{g}}^2}{(k+1)^2}. \tag{3.32}$$

Квадратичный член. Так как матрица $\mathbf{B}_k \in \mathbb{R}^{D\times D}$ симметрична, а $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D)$, то

$$\mathbb{E}\big[(\mathbf{z}^\top \mathbf{B}_k \mathbf{z})^2\big] = 2\sigma^4 \operatorname{Tr}(\mathbf{B}_k^2) + \sigma^4 \operatorname{Tr}(\mathbf{B}_k)^2.$$

Для симметричной матрицы $\mathbf{B}_k$ имеем

$$\operatorname{Tr}(\mathbf{B}_k^2) \leqslant D\|\mathbf{B}_k\|_2^2, \qquad |\operatorname{Tr}(\mathbf{B}_k)| \leqslant D\|\mathbf{B}_k\|_2,$$

откуда

$$\mathbb{E}\big[(\mathbf{z}^\top \mathbf{B}_k \mathbf{z})^2\big] \leqslant \sigma^4(D^2+2D)\|\mathbf{B}_k\|_2^2. \tag{3.33}$$

Далее,

$$\|\mathbf{B}_k\|_2 = \|\mathbf{U}_D^\top \mathbf{A}_k \mathbf{U}_D\|_2 \leqslant \|\mathbf{U}_D^\top\|_2 \|\mathbf{A}_k\|_2 \|\mathbf{U}_D\|_2 \leqslant \|\mathbf{A}_k\|_2.$$

Как и ранее,

$$\mathbf{A}_k = \mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*) = \frac{1}{k+1}\left(\mathbf{H}_{k+1}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*)\right),$$

поэтому

$$\|\mathbf{A}_k\|_2 \leqslant \frac{2M_{\mathbf{H}}}{k+1},$$

а значит

$$\|\mathbf{B}_k\|_2 \leqslant \frac{2M_{\mathbf{H}}}{k+1}. \tag{3.34}$$

Подставляя (3.34) в (3.33), получаем

$$\mathbb{E}\big[(\mathbf{z}^\top \mathbf{B}_k \mathbf{z})^2\big] \leqslant \frac{4\sigma^4(D^2+2D)M_{\mathbf{H}}^2}{(k+1)^2}. \tag{3.35}$$

Подставляя (3.31), (3.32) и (3.35) в (3.30), получаем

$$\Delta_2^{(D)}(k+1) \leqslant \frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(D^2+2D)M_{\mathbf{H}}^2}{(k+1)^2} = \mathcal{O}(k^{-2}),$$

что и требовалось доказать. □

Теорема 3.6.4. *Пусть выполнено предположение 3.6.2, и пусть*

$$a_k = 0, \qquad \mathbf{c}_k = \mathbf{0}.$$

Пусть, кроме того,

$$\tilde{q}(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D).$$

Тогда для среднеквадратичного критерия сходимости в подпространстве наибольшей кривизны верно

$$\Delta_2^{(D)}(k+1) = \frac{\sigma^4}{4}\left(2\sum_{i=1}^{D}\left(\lambda_i^{(k+1)} - \lambda_i^{(k)}\right)^2 + \left(\sum_{i=1}^{D}\left(\lambda_i^{(k+1)} - \lambda_i^{(k)}\right)\right)^2\right). \tag{3.36}$$

Доказательство. По лемме 3.6.1 при $a_k = 0$ и $\mathbf{c}_k = \mathbf{0}$ имеем

$$\Delta_2^{(D)}(k+1) = \frac{1}{4}\mathbb{E}_{\tilde{q}(\mathbf{z})}\left[(\mathbf{z}^\top \mathbf{B}_k \mathbf{z})^2\right], \qquad \tilde{q}(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D).$$

Далее

$$\mathbb{E}\left[(\mathbf{z}^\top \mathbf{B}_k \mathbf{z})^2\right] = 2\sigma^4 \operatorname{Tr}(\mathbf{B}_k^2) + \sigma^4 \operatorname{Tr}(\mathbf{B}_k)^2.$$

В силу предположения 3.6.2 и замечания 3.6

$$\mathbf{B}_k = \operatorname{diag}\left(\lambda_1^{(k+1)} - \lambda_1^{(k)}, \ldots, \lambda_D^{(k+1)} - \lambda_D^{(k)}\right).$$

Поэтому

$$\operatorname{Tr}(\mathbf{B}_k) = \sum_{i=1}^{D}\left(\lambda_i^{(k+1)} - \lambda_i^{(k)}\right),$$

$$\operatorname{Tr}(\mathbf{B}_k^2) = \sum_{i=1}^{D}\left(\lambda_i^{(k+1)} - \lambda_i^{(k)}\right)^2.$$

Подстановка дает (3.36). □

Полученный результат показывает, что ограничение рассмотрения подпространством наибольшей кривизны сохраняет порядок сходимости среднеквадратичного критерия, равный $\mathcal{O}(k^{-2})$. В общей постановке критерий в подпространстве, как и в полном пространстве параметров, определяется тремя источниками рассогласования: разностью значений функций потерь в точке $\mathbf{w}_k^*$, градиентным рассогласованием и квадратичным вкладом, связанным с разностью матриц Гессе. При этом размерностный множитель в квадратичном члене зависит уже не от полной размерности пространства параметров N, а только от размерности выбранного подпространства D. В частном случае, когда нулевой и линейный члены отсутствуют, критерий выражается непосредственно через приращения ведущих собственных значений матрицы Гессе.

3.7. Вычислительные эксперименты

Провести и оформить, пока что чистый GPT

Цель вычислительных экспериментов состоит в эмпирической проверке полученных в главе теоретических оценок на скорость стабилизации ландшафта функции потерь при увеличении объема обучающей выборки. Основное

внимание уделяется трем критериям: абсолютному одноточечному критерию, среднеквадратичному критерию в полном пространстве параметров и среднеквадратичному критерию в подпространстве наибольшей кривизны. Для каждого из них исследуется зависимость значения критерия от размера выборки k и оценивается показатель степени в степенном законе убывания.

Для проверки универсальности предложенного подхода эксперименты проводятся на архитектурах трех различных типов: полносвязной нейронной сети, сверточной нейронной сети и трансформере. Такое сравнение позволяет проследить, насколько полученные теоретические оценки согласуются с поведением моделей, существенно различающихся по архитектурным свойствам и геометрии поверхности функции потерь. Полносвязная сеть выступает в качестве наиболее простого базового случая, сверточная сеть позволяет перейти к более реалистичным моделям компьютерного зрения, а трансформер — проверить применимость подхода к современным архитектурам с выраженной анизотропией ландшафта.

3.7.1. Архитектуры, датасеты и общая схема эксперимента

Для каждой архитектуры фиксируется обучающий датасет и задается последовательность вложенных подвыборок

$$\mathfrak{D}_{k_1} \subset \mathfrak{D}_{k_2} \subset \cdots \subset \mathfrak{D}_{k_T}, \qquad \mathfrak{D}_k = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^{k},$$

получаемых из одной случайной перестановки объектов исходной обучающей выборки. Использование вложенных подвыборок согласуется с теоретической постановкой задачи, в которой анализируется изменение ландшафта при добавлении новых обучающих объектов к уже имеющейся выборке.

Для каждого значения k модель обучается на выборке $\mathfrak{D}_k$ до сходимости, а соответствующий вектор параметров $\mathbf{w}_k^*$ рассматривается как эмпирическая точка локального минимума функции потерь. Далее в окрестности этой точки вычисляются значения критериев

$$\Delta_1(k+1), \qquad \Delta_2(k+1), \qquad \Delta_2^{(D)}(k+1),$$

а также спектральные характеристики матриц Гессе

$$\mathbf{H}^{(k)}(\mathbf{w}_k^*), \qquad \mathbf{H}^{(k+1)}(\mathbf{w}_k^*).$$

Для уменьшения влияния случайных факторов каждый эксперимент повторяется при нескольких независимых начальных инициализациях модели и нескольких независимых перестановках обучающей выборки. Итоговые значения критериев усредняются по этим запускам, а на графиках отображаются средние значения и доверительные интервалы или стандартные отклонения.

Таблица 1 — Архитектуры и датасеты, используемые в вычислительных экспериментах

Архитектура	Датасет	Число параметров	Диапазон k	Число повторов
MLP	TODO	TODO	TODO	TODO
CNN	TODO	TODO	TODO	TODO
Transformer	TODO	TODO	TODO	TODO

3.7.2. Оценка абсолютного одноточечного критерия

Для оценки абсолютного одноточечного критерия

$$\Delta_1(k+1) = |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|$$

рассматриваются точки вида

$$\mathbf{w} = \mathbf{w}_k^* + \varepsilon \mathbf{d},$$

где $\mathbf{d} \in \mathbb{R}^N$ — случайное единичное направление, $\|\mathbf{d}\|_2 = 1$, а $\varepsilon > 0$ — малый радиус, определяющий размер локальной окрестности минимума. Для каждого значения k выбирается набор случайных направлений $\mathbf{d}_1, \ldots, \mathbf{d}_M$, после чего критерий усредняется по этим направлениям:

$$\widehat{\Delta}_1(k+1) = \frac{1}{M} \sum_{j=1}^{M} \left| \mathcal{L}_{k+1}(\mathbf{w}_k^* + \varepsilon \mathbf{d}_j) - \mathcal{L}_k(\mathbf{w}_k^* + \varepsilon \mathbf{d}_j) \right|.$$

Такой способ оценки позволяет избежать зависимости результата от одного конкретного направления в пространстве параметров и получить более

устойчивую характеристику локального изменения ландшафта. Для проверки чувствительности критерия к размеру окрестности дополнительно рассматривается несколько значений параметра ε.

3.7.3. Оценка среднеквадратичного критерия в полном пространстве параметров

Для оценки среднеквадратичного критерия

$$\Delta_2(k+1) = \mathbb{E}_{q(\mathbf{w})}\left[\left(\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})\right)^2\right]$$

в качестве функции предпочтения используется гауссовское распределение

$$q(\mathbf{w}) = \mathcal{N}(\mathbf{w}_k^*, \sigma^2\mathbf{I}_N),$$

центрированное в эмпирической точке минимума $\mathbf{w}_k^*$. Величина $\sigma > 0$ определяет размер локальной области, в которой усредняется изменение ландшафта.

Математическое ожидание в определении критерия аппроксимируется методом Монте—Карло. Для этого генерируется выборка точек

$$\mathbf{w}^{(1)}, \ldots, \mathbf{w}^{(M)} \sim \mathcal{N}(\mathbf{w}_k^*, \sigma^2\mathbf{I}_N),$$

и вычисляется оценка

$$\widehat{\Delta}_2(k+1) = \frac{1}{M}\sum_{j=1}^{M}\left(\mathcal{L}_{k+1}(\mathbf{w}^{(j)}) - \mathcal{L}_k(\mathbf{w}^{(j)})\right)^2.$$

Параметр σ подбирается таким образом, чтобы исследуемые точки оставались в локальной окрестности минимума, где квадратичная аппроксимация функции потерь остается информативной.

3.7.4. Оценка среднеквадратичного критерия в подпространстве наибольшей кривизны

Для оценки критерия

$$\Delta_2^{(D)}(k+1)$$

в подпространстве наибольшей кривизны сначала вычисляются D наибольших собственных значений матрицы Гессе

$$\mathbf{H}^{(k)}(\mathbf{w}_k^*)$$

и соответствующие им ортонормированные собственные векторы

$$\mathbf{u}_1, \ldots, \mathbf{u}_D.$$

На их основе формируется матрица перехода

$$\mathbf{U}_D = [\mathbf{u}_1, \ldots, \mathbf{u}_D] \in \mathbb{R}^{N \times D},$$

задающая подпространство

$$\mathcal{S}_D = \mathrm{Im}(\mathbf{U}_D).$$

Далее в координатах подпространства рассматривается гауссовское распределение

$$\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D), \qquad \mathbf{w} = \mathbf{w}_k^* + \mathbf{U}_D \mathbf{z},$$

после чего критерий оценивается по формуле

$$\widehat{\Delta}_2^{(D)}(k{+}1) = \frac{1}{M} \sum_{j=1}^{M} \left(\mathcal{L}_{k+1}(\mathbf{w}_k^* + \mathbf{U}_D \mathbf{z}_j) - \mathcal{L}_k(\mathbf{w}_k^* + \mathbf{U}_D \mathbf{z}_j) \right)^2, \qquad \mathbf{z}_j \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D).$$

Такой подход позволяет ограничить анализ наиболее существенными направлениями локальной кривизны и уменьшить эффективную размерность задачи. В экспериментах рассматривается несколько значений размерности D, что позволяет проследить, какая доля динамики полного критерия восстанавливается уже в относительно низкоразмерном подпространстве.

3.7.5. Оценка скоростей сходимости

Для количественной проверки полученных в главе теоретических предсказаний зависимость каждого критерия от размера выборки аппроксимируется степенным законом

$$\Delta(k) \approx C k^{-\alpha}.$$

Таблица 2 — Параметры оценки критериев сходимости

Параметр	Значение
Число направлений для оценки Δ_1	TODO
Радиусы ε для оценки Δ_1	TODO
Число точек Монте—Карло для Δ_2	TODO
Число точек Монте—Карло для $\Delta_2^{(D)}$	TODO
Значения σ для Δ_2 и $\Delta_2^{(D)}$	TODO
Значения размерности D	TODO
Метод вычисления top-D собственных векторов Гессе	TODO

Для этого используется линейная регрессия в логарифмических координатах:

$$\log \Delta(k) = a - \alpha \log k.$$

Оцененный коэффициент α интерпретируется как эмпирический показатель скорости сходимости соответствующего критерия.

Согласно теоретическим результатам настоящей главы ожидается, что для абсолютного одноточечного критерия значение показателя будет близко к единице, то есть

$$\alpha \approx 1,$$

тогда как для среднеквадратичного критерия в полном пространстве параметров и в подпространстве наибольшей кривизны ожидается более быстрое убывание, соответствующее значению

$$\alpha \approx 2.$$

3.7.6. Визуализация результатов

Для наглядного анализа полученных зависимостей строятся графики значений критериев в логарифмических координатах как функций от размера выборки k. Отдельно визуализируются зависимости для $\Delta_1(k)$, $\Delta_2(k)$ и $\Delta_2^{(D)}(k)$ при различных значениях D. На те же графики наносятся прямые с эталонными наклонами -1 и -2, соответствующими теоретически предсказанным скоростям сходимости.

Таблица 3 — Оцененные показатели степенного закона убывания критериев сходимости

Архитектура	Критерий	Оценка α	Комментарий
MLP	Δ_1	TODO	TODO
MLP	Δ_2	TODO	TODO
MLP	$\Delta_2^{(D)}$	TODO	TODO
CNN	Δ_1	TODO	TODO
CNN	Δ_2	TODO	TODO
CNN	$\Delta_2^{(D)}$	TODO	TODO
Transformer	Δ_1	TODO	TODO
Transformer	Δ_2	TODO	TODO
Transformer	$\Delta_2^{(D)}$	TODO	TODO

Кроме того, для критерия в подпространстве наибольшей кривизны строятся графики изменения ведущих собственных значений матрицы Гессе и их приращений при переходе от выборки размера k к выборке размера $k+1$. Это позволяет непосредственно сопоставить эмпирическое поведение спектра матрицы Гессе с теоретической формулой (3.36).

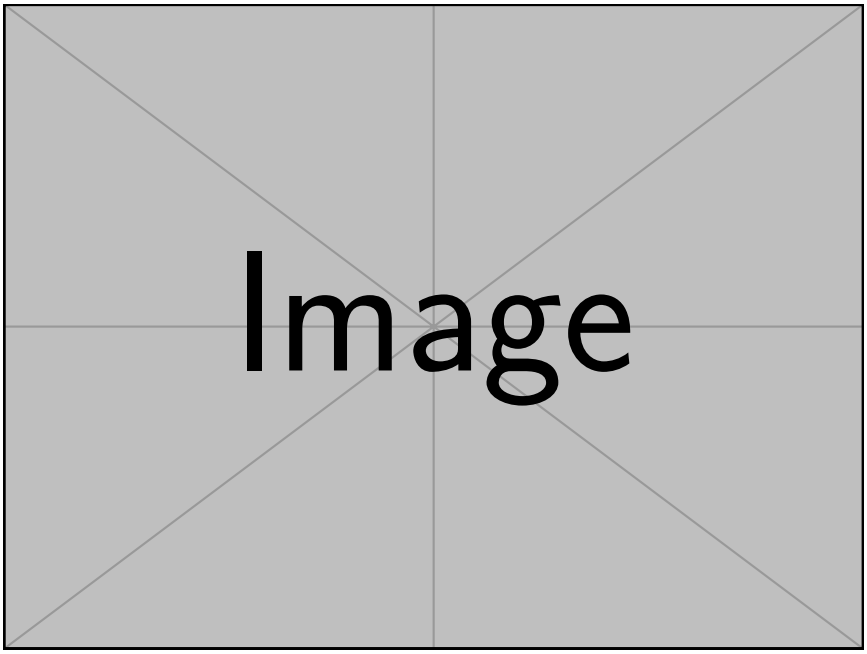

Рисунок 3.2 — Пример зависимости абсолютного одноточечного критерия $\Delta_1(k)$ от размера выборки k в логарифмических координатах

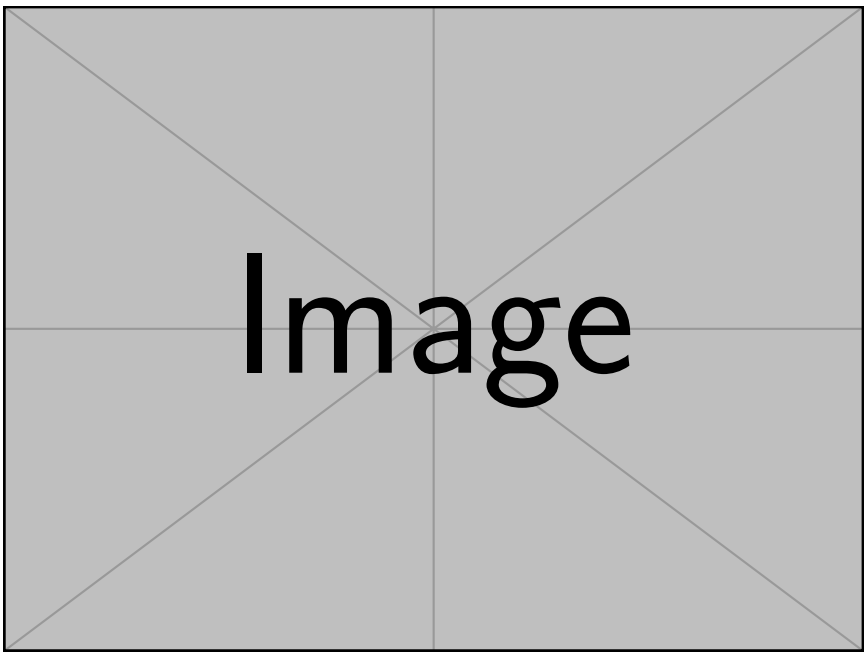

Рисунок 3.3 — Пример зависимости среднеквадратичного критерия $\Delta_2(k)$ от размера выборки k в логарифмических координатах

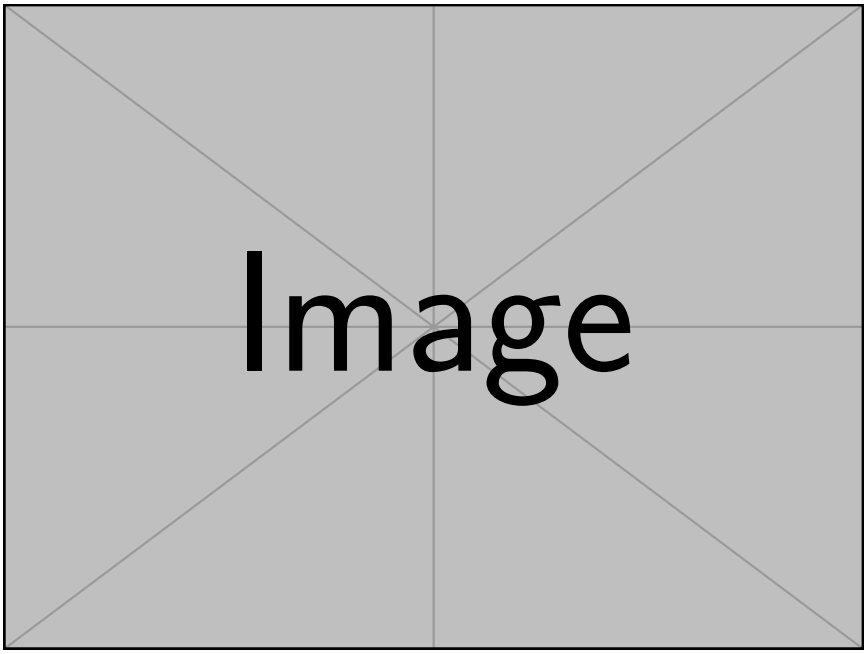

Рисунок 3.4 — Пример зависимости среднеквадратичного критерия $\Delta_2^{(D)}(k)$ от размера выборки k для различных размерностей подпространства D

3.7.7. Проверяемые гипотезы

В рамках вычислительных экспериментов проверяются следующие гипотезы.

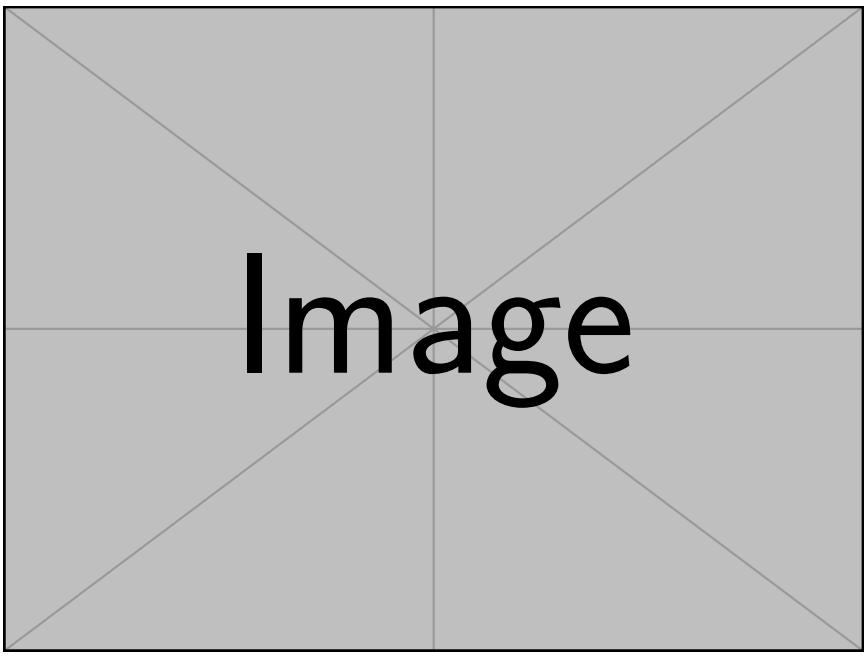

Рисунок 3.5 — Пример стабилизации ведущих собственных значений матрицы Гессе при увеличении объема обучающей выборки

1. Абсолютный одноточечный критерий $\Delta_1(k)$ убывает при увеличении размера выборки по степенному закону с показателем, близким к 1.
2. Среднеквадратичный критерий $\Delta_2(k)$ убывает быстрее и характеризуется показателем, близким к 2.
3. Среднеквадратичный критерий $\Delta_2^{(D)}(k)$ в подпространстве наибольшей кривизны сохраняет тот же порядок убывания, что и $\Delta_2(k)$, при этом уже при сравнительно малых значениях D отражает существенную часть динамики полного критерия.
4. Для всех рассмотренных архитектур ведущие собственные значения матрицы Гессе стабилизируются при росте объема обучающей выборки, а их приращения согласуются с оценками, полученными в теоретической части главы.

3.7.8. Ожидаемые результаты

Ожидается, что проведенные эксперименты подтвердят качественное и количественное согласие между теоретическими оценками и реальным поведением обучаемых моделей. В частности, для абсолютного одноточечного

критерия ожидается порядок убывания $\mathcal{O}(k^{-1})$, а для среднеквадратичного критерия в полном пространстве и в подпространстве наибольшей кривизны — порядок $\mathcal{O}(k^{-2})$. При этом ограничение рассмотрения подпространством наибольшей кривизны должно оказаться особенно полезным для моделей большой размерности, таких как сверточные сети и трансформеры, где локальная геометрия ландшафта определяется сравнительно небольшим числом главных направлений.

3.8. Обсуждение

В данной главе предложен подход к исследованию стабилизации ландшафта функции потерь при увеличении объема обучающей выборки, основанный на локальной квадратичной аппроксимации функции потерь в окрестности точки минимума и анализе разности соответствующих матриц Гессе. Такой подход позволяет перейти от сходимости эмпирического риска как скалярной величины к исследованию сходимости локальной геометрии поверхности функции потерь. В результате были введены критерии, измеряющие изменение ландшафта в одной точке, по распределению точек в полном пространстве параметров и по распределению в подпространстве наибольшей кривизны.

Основной теоретический вывод состоит в том, что скорость убывания критерия зависит от способа агрегации локальных изменений поверхности. Для абсолютного одноточечного критерия получена оценка порядка $\mathcal{O}(k^{-1})$, тогда как для среднеквадратичного критерия в полном пространстве параметров и в подпространстве наибольшей кривизны установлена оценка порядка $\mathcal{O}(k^{-2})$. При этом подпространственный критерий сохраняет тот же порядок сходимости, но позволяет сосредоточить анализ на направлениях, соответствующих наибольшей локальной кривизне, что особенно важно для моделей большой размерности.

Проведенные вычислительные эксперименты дополняют теоретический анализ и демонстрируют сходимость введенных критериев при увеличении объема обучающей выборки, а также позволяют получить эмпирические оценки скоростей их убывания. В целом полученные результаты показывают, что стабилизация ландшафта функции потерь может быть описана через поведение

матрицы Гессе и ее спектральных характеристик, что делает предложенный подход удобным как для теоретического анализа, так и для практического исследования современных нейронных сетей.

Глава 4. Законы масштабирования и достаточный размер выборки для параметрических моделей

В данной главе результаты глав 2 и 3 объединяются в теоретическую схему, описывающую законы масштабирования параметрических моделей машинного обучения. Ключевая идея состоит в том, что вблизи точки минимума гаусс-ньютоновская компонента доминирует в матрице Гессе, а потому архитектурно-зависимые оценки спектральной нормы из главы 2 могут быть подставлены в критерии сходимости ландшафта из главы 3. В результате получаются явные зависимости между архитектурой модели, объемом обучающей выборки и скоростью стабилизации ландшафта. В первой части главы формулируются общие законы масштабирования, во второй — задача определения достаточного размера выборки как частный случай этих законов.

4.1. Введение

Эмпирические законы масштабирования, установленные для современных языковых моделей [2; 3], показывают, что качество обучения закономерно улучшается с ростом числа параметров модели и объема данных, причем эта зависимость описывается степенным законом. В частности, в работе [3] установлено, что потери на тесте хорошо аппроксимируются формулой вида

$$\mathcal{L}(N, D) \approx E + \frac{A}{N^{\alpha}} + \frac{B}{D^{\beta}}, \tag{4.1}$$

где N — число параметров модели, D — объем обучающей выборки, E — неустранимая ошибка, а $A, B, \alpha, \beta > 0$ — эмпирические константы. Из этой формулы следует оптимальное соотношение: при фиксированном вычислительном бюджете размер модели и объем данных должны масштабироваться согласованно.

Несмотря на практическую значимость подобных результатов, до настоящего времени закон (4.1) остается эмпирическим: его структура не выведена из свойств модели или процесса обучения, а подобрана на основе экспериментов

с конкретными архитектурами. Цель данной главы — показать, что теоретический анализ локальных свойств оптимизационной поверхности естественным образом приводит к формулам того же функционального типа, что и эмпирические законы масштабирования.

В главе 2 были получены верхние оценки спектральной нормы гаусс-ньютоновской компоненты матрицы Гессе $\|\mathbf{G}(\mathbf{w})\|_2$ для полносвязных, сверточных и трансформерных сетей. В главе 3 было показано, что критерии сходимости ландшафта функции потерь при увеличении объема выборки контролируются спектральной нормой $M_{\mathbf{H}}$ — верхней границей нормы матрицы Гессе на отдельных объектах. Связующим звеном между этими результатами служит тот факт, что вблизи точки минимума остаточная компонента разложения Гаусса—Ньютона (2.2) мала, и $\mathbf{H}_i(\mathbf{w}^*) \approx \mathbf{G}_i(\mathbf{w}^*)$, а значит оценки на $\|\mathbf{G}(\mathbf{w})\|_2$ дают оценки на $M_{\mathbf{H}}$.

4.2. Предварительные сведения

Введем обозначения, используемые на протяжении всей главы. Рассмотрим параметрическую модель $f_{\mathbf{w}} : \mathbb{R}^n \to \mathbb{R}^K$ с вектором параметров $\mathbf{w} \in \mathbb{R}^N$, обученную на выборке $\mathfrak{D}_m = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^m$. Эмпирическая функция потерь задается формулой (3.1), а популяционная — формулой (3.3). Матрица Гессе на одном объекте обозначается через $\mathbf{H}_i(\mathbf{w})$, а разложение Гаусса—Ньютона (2.2) дает $\mathbf{H}_i(\mathbf{w}) = \mathbf{G}_i(\mathbf{w}) + \mathbf{R}_i(\mathbf{w})$.

Архитектурная константа. Для фиксированной архитектуры $\mathcal{A}$ и набора ограничений на нормы входов, весов и активаций определим величину

$$M_{\mathbf{G}}(\mathcal{A}) = \sup_{\mathbf{w} \in \mathcal{U}_R(\mathbf{w}^*)} \sup_{(\mathbf{x},\mathbf{y})} \|\mathbf{G}_i(\mathbf{w})\|_2, \tag{4.2}$$

задающую верхнюю границу спектральной нормы гаусс-ньютоновской компоненты матрицы Гессе на одном объекте в окрестности точки минимума.

Связь с константой $M_{\mathbf{H}}$. Вблизи точки минимума $\mathbf{w}^*$ остаточная компонента $\mathbf{R}_i(\mathbf{w}^*)$ пропорциональна производным функции потерь по выходу модели, которые малы вблизи минимума. Поэтому для спектральной нормы полного гессиана на одном объекте справедлива оценка

$$M_{\mathbf{H}} \leqslant M_{\mathbf{G}}(\mathcal{A}) + \delta_R(\mathcal{U}_R, \mathfrak{D}_m), \tag{4.3}$$

где

$$\delta_R(\mathcal{U}_R, \mathfrak{D}_m) = \sup_{\mathbf{w}\in\mathcal{U}_R(\mathbf{w}^*)} \sup_i \|\mathbf{R}_i(\mathbf{w})\|_2$$

есть остаточный член, зависящий от размера окрестности $\mathcal{U}_R$ и от выборки. Величина δ_R убывает по мере приближения к точке минимума и обращается в нуль при идеальной подгонке ($\nabla_{\mathbf{z}}\ell = \mathbf{0}$).

Оценки $M_{\mathbf{G}}(\mathcal{A})$ для конкретных архитектур. Результаты главы 2 дают явные выражения:

– **Полносвязная сеть** (теорема 2.4.1):

$$M_{\mathbf{G}}^{\mathrm{FC}} = LM_{\mathbf{x}}^2 M_{\mathbf{A}} \left(M_{\mathbf{W}} M_\sigma\right)^{2L-2}; \tag{4.4}$$

– **Сверточная сеть** (теорема 2.5.3):

$$M_{\mathbf{G}}^{\mathrm{CNN}} = LM_{\mathbf{x}}^2 M_{\mathbf{A}} K_{\max} \left(M_{\mathcal{W}} M_\sigma\right)^{2L-2}; \tag{4.5}$$

– **Трансформерный блок** (следствие 2.6.4):

$$M_{\mathbf{G}}^{\mathrm{Tr}} = M_{\mathbf{A}} C_{\mathrm{LN}}^2 \left[2M_{\mathbf{Y}}^2 M_{\mathbf{W}}^2 + (1 + M_{\mathbf{W}}^2)^2 C_{\mathrm{LN}}^2 \left(T^2 M_{\mathbf{X}}^2 + \frac{2C_{\mathrm{sm}}^2 M_{\mathbf{W}}^4}{d_k} M_{\mathbf{X}}^6\right)\right], \tag{4.6}$$

где $C_{\mathrm{LN}}(M) = \sigma_0^{-1} + M^2/(\sqrt{d}\,\sigma_0^3)$.

4.2.1. Уровни теоретических утверждений

Для ясности изложения введем классификацию утверждений, используемых в данной главе, по степени строгости.

1. **Строгие оценки.** Неравенства, доказанные в главах 2 и 3: верхние оценки $\|\mathbf{G}(\mathbf{w})\|_2 \leqslant M_{\mathbf{G}}(\mathcal{A})$ и скорости убывания критериев $\Delta(k) \lesssim M_{\mathbf{H}}/k^\rho$. Эти результаты не требуют дополнительных предположений, кроме введенных в соответствующих главах.
2. **Локальные аппроксимации.** Переход от $M_{\mathbf{H}}$ к $M_{\mathbf{G}}$ посредством оценки (4.3), где остаточный член δ_R полагается малым. Эта аппроксимация обоснована лишь вблизи точки минимума при малых невязках $\nabla_{\mathbf{z}}\ell$.
3. **Структурные предположения.** Гипотезы о форме ошибки оценивания и ошибки аппроксимации (предположения 4.3.1 и 4.3.6 далее),

мотивированные классической теорией, но не выводимые из предыдущих глав.

4. **Качественные выводы.** Обсуждение связи полученных формул с эмпирическими законами масштабирования и сравнение архитектур. Эти утверждения носят интерпретационный характер.

Везде далее мы явно указываем, к какому уровню относится каждый результат.

4.3. Законы масштабирования параметрических моделей на основе локальных свойств оптимизационной поверхности

4.3.1. Декомпозиция ошибки обучения

Обозначим через $\mathcal{W}_N \subset \mathbb{R}^N$ множество параметров модели с архитектурой $\mathcal{A}$, содержащей N параметров. Определим ошибку выразимости модели как

$$\Phi(N) = \inf_{\mathbf{w}\in\mathcal{W}_N} \mathcal{L}(\mathbf{w}) - \mathcal{L}(\mathbf{w}^*_\infty), \tag{4.7}$$

где $\mathcal{L}(\mathbf{w}) = \mathbb{E}_{(\mathbf{x},\mathbf{y})}[\ell(f_{\mathbf{w}}(\mathbf{x}), \mathbf{y})]$ — популяционный риск, а $\mathbf{w}^*_\infty = \arg\min_{\mathbf{w}} \mathcal{L}(\mathbf{w})$ — его глобальный минимизатор (по всем допустимым параметризациям). Величина $\Phi(N)$ характеризует ограниченность класса моделей $\mathcal{W}_N$ и убывает с ростом N.

Рассмотрим эмпирическую функцию потерь $\mathcal{L}_m(\mathbf{w}^*_m)$ в точке минимума $\mathbf{w}^*_m$, найденной при обучении на выборке размера m. Стандартная декомпозиция ошибки обучения принимает вид

$$\mathcal{L}_m(\mathbf{w}^*_m) = \underbrace{\mathcal{L}(\mathbf{w}^*_\infty)}_{E} + \underbrace{\big(\mathcal{L}(\mathbf{w}^*_m) - \mathcal{L}(\mathbf{w}^*_\infty)\big)}_{\text{ошибка модели}} + \underbrace{\big(\mathcal{L}_m(\mathbf{w}^*_m) - \mathcal{L}(\mathbf{w}^*_m)\big)}_{\mathcal{E}(m)}, \tag{4.8}$$

где $E = \mathcal{L}(\mathbf{w}^*_\infty)$ — неустранимая ошибка, не зависящая от N и m.

Замечание. Среднее слагаемое $\mathcal{L}(\mathbf{w}^*_m) - \mathcal{L}(\mathbf{w}^*_\infty)$ зависит не только от числа параметров N, но и от алгоритма оптимизации и от выборки $\mathfrak{D}_m$ (через эмпирический минимизатор $\mathbf{w}^*_m$). Оно мажорируется ошибкой выразимости: $\mathcal{L}(\mathbf{w}^*_m) - \mathcal{L}(\mathbf{w}^*_\infty) \leqslant \Phi(N) + \eta_{\text{opt}}$, где $\eta_{\text{opt}} \geqslant 0$ учитывает неточность оптимизации. В дальнейшем предполагается, что оптимизация достаточно эффективна и η_{opt} пренебрежимо мало, так что ошибка модели наследует масштаб $\Phi(N)$.

4.3.2. Мотивация оценки ошибки оценивания через стабилизацию ландшафта

Результаты главы 3 показывают, что при добавлении одного объекта к выборке размера k абсолютное изменение функции потерь в окрестности минимума убывает как $\mathcal{O}(k^{-1})$, а среднеквадратичное изменение — как $\mathcal{O}(k^{-2})$. Константы в этих оценках контролируются спектральной нормой $M_{\mathbf{H}}$. Тем самым эмпирическая функция потерь с каждым следующим объектом меняется всё слабее, что указывает на уменьшение чувствительности ландшафта к флуктуациям выборки.

Это наблюдение мотивирует следующую гипотезу: ошибка оценивания $\mathcal{E}(m)$ убывает степенным образом с масштабом, определяемым кривизной функции потерь, т. е. спектральной нормой матрицы Гессе. Подчеркнём, что критерии Δ из главы 3 измеряют одношаговое приращение ландшафта, а не кумулятивное отклонение эмпирического риска от популяционного, поэтому прямой вывод оценки $\mathcal{E}(m)$ из них требует дополнительных инструментов (uniform convergence, concentration inequalities, algorithmic stability). Вместо этого мы вводим структурное предположение, мотивированное как стабилизацией ландшафта, так и классическими результатами теории обучения.

Предположение 4.3.1 (Предположение о локальном статистическом режиме)**.** *Пусть модель обучена в режиме, при котором:*

- *точка минимума $\mathbf{w}_m^*$ находится в области, где квадратичная аппроксимация функции потерь информативна;*
- *остаточная компонента δ_R мала по сравнению с $M_{\mathbf{G}}(\mathcal{A})$;*
- *минимум $\mathbf{w}_m^*$ локально идентифицируем (матрица Гессе невырождена).*

Тогда ошибка оценивания допускает оценку

$$|\mathcal{E}(m)| = |\mathcal{L}_m(\mathbf{w}_m^*) - \mathcal{L}(\mathbf{w}_m^*)| \leqslant \frac{C \cdot (M_{\mathbf{G}}(\mathcal{A}) + \delta_R)}{m^{\rho}},$$

где $C > 0$ — константа, $\rho \in (0, 1]$ — показатель скорости убывания.

Замечание. Значение $\rho = 1$ соответствует наиболее благоприятному режиму: локально сильно выпуклая функция потерь, хорошо идентифицируемый минимум, малый шум. Значение $\rho = 1/2$ соответствует более консервативному

режиму, типичному для стандартных оценок отклонения среднего (ЦПТ-масштаб). Далее основной интерес представляет случай $\rho = 1$, соответствующий локально стабилизированному режиму обучения; результаты для произвольного ρ приведены в общем виде.

4.3.3. Закон масштабирования

Объединяя декомпозицию (4.8) с предположением 4.3.1, получаем основной результат данного раздела.

Теорема 4.3.2 (Локальный закон масштабирования)**.** *Пусть параметрическая модель с архитектурой $\mathcal{A}$ обучена на выборке размера m, и пусть выполнено предположение 4.3.1. Тогда функция потерь в точке минимума допускает оценку*

$$\mathcal{L}_m(\mathbf{w}_m^*) \leqslant E + \Phi(N) + \frac{C \cdot (M_{\mathbf{G}}(\mathcal{A}) + \delta_R)}{m^\rho}, \tag{4.9}$$

где E — неустранимая ошибка, $\Phi(N)$ — ошибка выразимости (4.7), $M_{\mathbf{G}}(\mathcal{A})$ — архитектурная константа (4.2), δ_R — остаточный член (4.3).

Доказательство. Из декомпозиции (4.8), замечания об оценке $\mathcal{L}(\mathbf{w}_m^*) - \mathcal{L}(\mathbf{w}_\infty^*) \leqslant \Phi(N)$ (при $\eta_{\text{opt}} = 0$) и предположения 4.3.1 непосредственно следует

$$\mathcal{L}_m(\mathbf{w}_m^*) \leqslant E + \Phi(N) + |\mathcal{E}(m)| \leqslant E + \Phi(N) + \frac{C(M_{\mathbf{G}}(\mathcal{A}) + \delta_R)}{m^\rho}.$$

□

В режиме хорошей подгонки, когда $\delta_R \ll M_{\mathbf{G}}(\mathcal{A})$, оценка (4.9) упрощается до асимптотической формулы

$$\mathcal{L}_m(\mathbf{w}_m^*) \lesssim E + \Phi(N) + \frac{C \cdot M_{\mathbf{G}}(\mathcal{A})}{m^\rho}. \tag{4.10}$$

Замечание (Связь с эмпирическими законами масштабирования). Формула (4.10) при $\rho = 1$ приводит к теоретическому выражению того же функционального типа, что и эмпирический закон (4.1): сумма неустранимой ошибки, слагаемого, убывающего с числом параметров, и слагаемого,

убывающего с объемом данных. Однако между этими формулами есть принципиальные различия:

- формула (4.10) есть верхняя оценка, а не fit на экспериментальные данные;
- «константа» при $m^{-\rho}$ выражается через архитектурные свойства модели, а не является свободным параметром;
- эмпирический показатель β в (4.1) соответствует ρ в (4.10), и степень $\rho = 1$ отвечает лишь одному (благоприятному) режиму.

Таким образом, теория объясняет, почему естественно ожидать scaling law вида «E + model term + data term», но не утверждает тождественного совпадения с конкретными эмпирическими значениями констант.

4.3.4. Архитектурно-зависимые законы масштабирования

Подстановка оценок (4.4)–(4.6) в асимптотическую формулу (4.10) при $\rho = 1$ дает конкретные формулы для каждого класса архитектур. Все нижеследующие следствия наследуют предположения теоремы 4.3.2 и условие $\delta_R \ll M_{\mathbf{G}}(\mathcal{A})$.

Следствие 4.3.3 (Полносвязные сети). *Для L-слойной полносвязной сети без смещений при условиях теоремы 2.4.1*

$$\mathcal{L}_m(\mathbf{w}_m^*) \lesssim E + \Phi(N) + \frac{CLM_{\mathbf{x}}^2 M_{\mathbf{A}} (M_{\mathbf{W}} M_\sigma)^{2L-2}}{m}.$$

Следствие 4.3.4 (Сверточные сети). *Для L-слойной сверточной сети без смещений при условиях теоремы 2.5.3*

$$\mathcal{L}_m(\mathbf{w}_m^*) \lesssim E + \Phi(N) + \frac{CLM_{\mathbf{x}}^2 M_{\mathbf{A}} K_{\max} (M_{\mathcal{W}} M_\sigma)^{2L-2}}{m}.$$

Следствие 4.3.5 (Трансформерные блоки). *Для одно-голового трансформерного блока при условиях следствия 2.6.4*

$$\mathcal{L}_m(\mathbf{w}_m^*) \lesssim E + \Phi(N) + \frac{C \cdot M_{\mathbf{G}}^{\mathrm{Tr}}}{m},$$

где $M_{\mathbf{G}}^{\mathrm{Tr}}$ задано формулой (4.6).

Сравнение следствий 4.3.3–4.3.5 позволяет качественно охарактеризовать влияние архитектурных решений на масштабирование.

Роль локальности. В сверточной сети параметр $K_{\max} = C_{\text{out}} k_h k_w$ пропорционален размеру ядра, тогда как в полносвязной сети аналогичную роль играет полная размерность входа. При сопоставимых глубине и нормах это приводит к меньшей архитектурной константе $M_{\mathbf{G}}^{\text{CNN}}$, что означает более эффективное использование данных.

Роль нормализации. В трансформерном блоке константа C_{LN} зависит от минимальной построчной дисперсии промежуточных представлений. LayerNorm контролирует эту дисперсию снизу, ограничивая C_{LN} и предотвращая неконтролируемый рост $M_{\mathbf{G}}^{\text{Tr}}$.

Роль длины последовательности. Зависимость $M_{\mathbf{G}}^{\text{Tr}}$ от длины последовательности T содержит слагаемое порядка T^2, обусловленное квадратичной сложностью self-attention. Это указывает на полиномиальный рост требуемого объема данных при увеличении контекста.

Роль остаточных связей. В отличие от последовательных архитектур, где нормы перемножаются с глубиной, остаточные связи приводят к аддитивной структуре $(1 + M_{\mathbf{W}}^2)$ вместо мультипликативной $M_{\mathbf{W}}^{2L-2}$, что стабилизирует архитектурную константу при увеличении глубины.

4.3.5. Режимы масштабирования архитектуры

Величина $M_{\mathbf{G}}(\mathcal{A})$ зависит не только от числа параметров N, но и от способа масштабирования архитектуры: увеличение N может происходить за счет роста ширины, глубины, длины последовательности и т. д. Для формулировки результатов о вычислительно-оптимальном масштабировании необходимо зафиксировать режим масштабирования, определяющий зависимость $M_{\mathbf{G}}$ от N.

Предположение 4.3.6 (Степенной закон для ошибки выразимости)**.** *Ошибка выразимости убывает степенным образом:* $\Phi(N) \sim A/N^{\alpha}$, $A, \alpha > 0$.

Масштабирование по ширине (глубина L фиксирована, ширина n растет, $N \sim Ln^2$). Из (4.4) при фиксированном L:

$$M_{\mathbf{G}}^{\text{FC}} = L M_{\mathbf{x}}^2 M_{\mathbf{A}} (M_{\mathbf{W}} M_{\sigma})^{2L-2}.$$

Если послойные нормы $M_{\mathbf{W}}$ не зависят от n (например, при нормировке на $1/\sqrt{n}$), то $M_{\mathbf{G}}$ не растет с N, что дает $\gamma = 0$.

Масштабирование по глубине (ширина n фиксирована, глубина L растет, $N \sim Ln^2$). Зависимость $M_{\mathbf{G}}^{\mathrm{FC}} \sim L(M_{\mathbf{W}}M_{\sigma})^{2L-2}$. В *критически нормированном режиме* $M_{\mathbf{W}}M_{\sigma} = 1$ имеем $M_{\mathbf{G}} \sim L \sim N/n^2$, т. е. $\gamma = 1$. При $M_{\mathbf{W}}M_{\sigma} < 1$ зависимость субэкспоненциально убывает с L; при $M_{\mathbf{W}}M_{\sigma} > 1$ — экспоненциально растет, что делает depth scaling непрактичным без дополнительной нормализации.

Масштабирование по длине последовательности (для трансформеров). Из (4.6) при фиксированных остальных параметрах $M_{\mathbf{G}}^{\mathrm{Tr}} \sim T^2$, т. е. $\gamma = 2$ при масштабировании $N \propto T$.

4.3.6. Вычислительно-оптимальное масштабирование

Асимптотический закон (4.10) при $\rho = 1$ позволяет поставить задачу оптимального распределения вычислительных ресурсов между размером модели и объемом данных. Пусть общий вычислительный бюджет ограничен сверху величиной $\mathcal{C}$, а стоимость обучения пропорциональна произведению числа параметров и размера выборки:

$$\mathcal{C} \propto N \cdot m.$$

Тогда задача вычислительно-оптимального масштабирования формулируется как

$$\min_{N,m:\, N\cdot m \leqslant \mathcal{C}} \left[\Phi(N) + \frac{C \cdot M_{\mathbf{G}}(N)}{m} \right],$$

где зависимость $M_{\mathbf{G}}$ от N определяется фиксированным режимом масштабирования.

Подставляя ограничение $m = \mathcal{C}/N$ в целевую функцию, приходим к одномерной задаче

$$\min_{N>0} \left[\Phi(N) + \frac{C \cdot M_{\mathbf{G}}(N) \cdot N}{\mathcal{C}} \right]. \tag{4.11}$$

Предложение 4.3.7 (Оптимальное распределение ресурсов)**.** *Пусть выполнено предположение 4.3.6 и пусть в фиксированном режиме масштабирования*

$M_{\mathbf{G}}(N) = B \cdot N^{\gamma}$ для некоторых $B > 0$, $\gamma \geqslant 0$. Тогда оптимальный размер модели удовлетворяет

$$N^* \propto \mathcal{C}^{\frac{1}{1+\alpha+\gamma}}, \tag{4.12}$$

а оптимальный размер выборки

$$m^* = \frac{\mathcal{C}}{N^*} \propto \mathcal{C}^{\frac{\alpha+\gamma}{1+\alpha+\gamma}}. \tag{4.13}$$

В частности, оптимальное соотношение между данными и параметрами

$$\frac{m^*}{N^*} \propto \mathcal{C}^{\frac{\alpha+\gamma-1}{1+\alpha+\gamma}}. \tag{4.14}$$

Доказательство. При $m = \mathcal{C}/N$ целевая функция (4.11) принимает вид

$$F(N) = \frac{A}{N^{\alpha}} + \frac{CB \cdot N^{1+\gamma}}{\mathcal{C}}.$$

Дифференцируя по N и приравнивая нулю:

$$F'(N) = -\frac{\alpha A}{N^{\alpha+1}} + \frac{CB(1+\gamma)}{\mathcal{C}} N^{\gamma} = 0,$$

откуда

$$N^{\alpha+1+\gamma} = \frac{\alpha A \mathcal{C}}{CB(1+\gamma)},$$

что дает (4.12). Формулы (4.13) и (4.14) следуют из $m^* = \mathcal{C}/N^*$. □

Замечание. Рассмотрим важные частные случаи, соответствующие режимам масштабирования из раздела 4.3.5.

1. **Масштабирование по ширине** ($\gamma = 0$). Оптимальное соотношение $m^*/N^* \propto \mathcal{C}^{(\alpha-1)/(1+\alpha)}$. При $\alpha = 1$ это дает $m^* \propto N^*$ — линейное масштабирование данных с параметрами, качественно совпадающее с выводами [3].
2. **Масштабирование по глубине в критически нормированном режиме** ($\gamma = 1$, $M_{\mathbf{W}} M_{\sigma} = 1$). Тогда $N^* \propto \mathcal{C}^{1/(2+\alpha)}$ и $m^* \propto \mathcal{C}^{(1+\alpha)/(2+\alpha)}$, т. е. данные растут быстрее параметров. При $\alpha = 1$: $N^* \propto \mathcal{C}^{1/3}$, $m^* \propto \mathcal{C}^{2/3}$.
3. **Масштабирование по длине последовательности для трансформеров** ($\gamma = 2$). Тогда $N^* \propto \mathcal{C}^{1/(3+\alpha)}$, а данные растут ещё быстрее: $m^* \propto \mathcal{C}^{(2+\alpha)/(3+\alpha)}$.

4.4. Достаточный размер выборки для параметрических моделей

4.4.1. Постановка задачи и три понятия достаточности

Задача определения достаточного размера выборки является частным случаем законов масштабирования: требуется найти минимальный объем данных m^*, при котором дальнейшее увеличение выборки не приводит к существенному изменению ландшафта функции потерь. В отличие от предыдущего раздела, где ошибка оценивания связывалась с архитектурными свойствами через структурное предположение 4.3.1, здесь мы непосредственно используем строгие оценки критериев сходимости из главы 3, подставляя в них архитектурные оценки из главы 2.

Определение. Назовем размер выборки m^* *ε-достаточным по критерию* Δ, если для всех $m \geqslant m^*$ выполнено $\Delta(m) \leqslant \varepsilon$, где Δ — один из критериев сходимости ландшафта, введенных в главе 3.

Различные критерии из главы 3 дают различные понятия достаточности, отражающие разные аспекты стабилизации ландшафта:

- **Одноточечная достаточность** (m_1^*, по критерию Δ_1): измеряет максимальное абсолютное изменение функции потерь в одной фиксированной точке окрестности минимума. Это наиболее локальный и наиболее консервативный критерий, дающий наибольшую оценку m^*.
- **Среднеквадратичная достаточность** (m_2^*, по критерию Δ_2): измеряет усредненное изменение ландшафта по распределению точек в полном пространстве параметров. Сглаживание по распределению дает более высокий порядок сходимости ($\mathcal{O}(k^{-2})$ вместо $\mathcal{O}(k^{-1})$), но чувствительно к полной размерности N.
- **Подпространственная достаточность** (m_3^*, по критерию $\Delta_2^{(D)}$): усреднение ограничено подпространством D направлений наибольшей кривизны. Сохраняет порядок сходимости $\mathcal{O}(k^{-2})$, но размерностный множитель зависит от $D \ll N$, что делает этот критерий наиболее подходящим для практического анализа моделей большой размерности.

4.4.2. Одноточечный критерий достаточного размера выборки

Теорема 4.4.1 (Достаточный размер выборки, одноточечный критерий). *Пусть выполнены условия теоремы для абсолютного одноточечного критерия из главы 3 и* $M_{\mathbf{H}} \leqslant M_{\mathbf{G}}(\mathcal{A}) + \delta_R$. *Тогда для* ε*-достаточности по одноточечному критерию достаточно*

$$m_1^*(\varepsilon, \mathcal{A}) = \frac{(M_{\mathbf{G}}(\mathcal{A}) + \delta_R) \cdot R^2}{\varepsilon}. \tag{4.15}$$

В частности, при $\delta_R \ll M_{\mathbf{G}}(\mathcal{A})$*:*

1. *для полносвязной сети:*

$$m_1^{*,FC} \lesssim \frac{L M_{\mathbf{x}}^2 M_{\mathbf{A}} (M_{\mathbf{W}} M_{\sigma})^{2L-2} R^2}{\varepsilon};$$

2. *для сверточной сети:*

$$m_1^{*,CNN} \lesssim \frac{L M_{\mathbf{x}}^2 M_{\mathbf{A}} K_{\max} (M_{\mathcal{W}} M_{\sigma})^{2L-2} R^2}{\varepsilon};$$

3. *для трансформерного блока:*

$$m_1^{*,Tr} \lesssim \frac{M_{\mathbf{G}}^{\mathrm{Tr}} \cdot R^2}{\varepsilon}.$$

Доказательство. Из оценки (**??**) следует $\Delta_1(k) \lesssim M_{\mathbf{H}} R^2/k$. Используя $M_{\mathbf{H}} \leqslant M_{\mathbf{G}}(\mathcal{A}) + \delta_R$, условие $\Delta_1(m) \leqslant \varepsilon$ влечет $(M_{\mathbf{G}}(\mathcal{A}) + \delta_R) R^2/m \leqslant \varepsilon$, откуда $m \geqslant (M_{\mathbf{G}}(\mathcal{A}) + \delta_R) R^2/\varepsilon$. Подстановка оценок (4.4)–(4.6) при $\delta_R \ll M_{\mathbf{G}}$ дает формулы для каждой архитектуры. □

4.4.3. Среднеквадратичный критерий достаточного размера выборки

Теорема 4.4.2 (Достаточный размер выборки, среднеквадратичный критерий). *Пусть выполнены условия теоремы для среднеквадратичного критерия из главы 3 с* $q(\mathbf{w}) = \mathcal{N}(\mathbf{w}^*, \sigma^2 \mathbf{I}_N)$, *и* $M_{\mathbf{H}} \leqslant M_{\mathbf{G}}(\mathcal{A}) + \delta_R$. *Тогда для* ε*-достаточности по среднеквадратичному критерию достаточно*

$$m_2^*(\varepsilon, \mathcal{A}) = \frac{\sigma^2 \sqrt{N^2 + 2N} \cdot (M_{\mathbf{G}}(\mathcal{A}) + \delta_R)}{\sqrt{\varepsilon}}. \tag{4.16}$$

Доказательство. Из оценки (??) при $M_{\mathbf{H}} \leqslant M_{\mathbf{G}}(\mathcal{A}) + \delta_R$ имеем

$$\Delta_2(k) \lesssim \frac{\sigma^4(N^2+2N)(M_{\mathbf{G}}(\mathcal{A})+\delta_R)^2}{k^2}.$$

Условие $\Delta_2(m) \leqslant \varepsilon$ дает $m^2 \geqslant \sigma^4(N^2+2N)(M_{\mathbf{G}}(\mathcal{A})+\delta_R)^2/\varepsilon$, откуда следует (4.16). □

Замечание. При $\delta_R \ll M_{\mathbf{G}}$ и больших N формула (4.16) показывает, что достаточный размер выборки по среднеквадратичному критерию растет как $m_2^* \sim N \cdot M_{\mathbf{G}}(\mathcal{A})/\sqrt{\varepsilon}$, т. е. линейно по числу параметров модели. Линейная зависимость $m^* \propto N$ согласуется с эмпирическими наблюдениями о масштабировании данных с параметрами, однако здесь она получена как строгая оценка из свойств оптимизационной поверхности.

4.4.4. Подпространственный критерий достаточного размера выборки

Теорема 4.4.3 (Достаточный размер выборки, подпространственный критерий)**.** *Пусть выполнены условия следствия* **??** *из главы 3 и* $M_{\mathbf{H}} \leqslant M_{\mathbf{G}}(\mathcal{A})+\delta_R$. *Тогда для* ε*-достаточности по среднеквадратичному критерию в подпространстве наибольшей кривизны размерности* D *достаточно*

$$m_3^*(\varepsilon, \mathcal{A}, D) = \frac{\sigma^2\sqrt{D^2+2D}\cdot(M_{\mathbf{G}}(\mathcal{A})+\delta_R)}{\sqrt{\varepsilon}}. \tag{4.17}$$

Доказательство. Из оценки (??) при $M_{\mathbf{H}} \leqslant M_{\mathbf{G}}(\mathcal{A}) + \delta_R$ имеем

$$\Delta_2^{(D)}(k) \lesssim \frac{(D^2+2D)\sigma^4(M_{\mathbf{G}}(\mathcal{A})+\delta_R)^2}{k^2}.$$

Условие $\Delta_2^{(D)}(m) \leqslant \varepsilon$ дает (4.17). □

Замечание. Подпространственный критерий дает оценку $m_3^* \sim D \cdot M_{\mathbf{G}}(\mathcal{A})/\sqrt{\varepsilon}$ при больших D, что при $D \ll N$ существенно меньше оценки $m_2^* \sim N \cdot M_{\mathbf{G}}(\mathcal{A})/\sqrt{\varepsilon}$ для полного критерия. Это согласуется с эмпирическим наблюдением о том, что спектр матрицы Гессе нейронных сетей содержит лишь небольшое число значимых собственных значений [9], а значит основная часть динамики ландшафта определяется низкоразмерным подпространством.

4.4.5. Качественное сравнение архитектур

Подставляя конкретные оценки $M_{\mathbf{G}}(\mathcal{A})$ в формулы (4.15)–(4.17), можно качественно сравнить архитектуры по требуемому объему данных.

Замечание (Сравнение архитектур). При фиксированных глубине L, нормах активаций M_{σ}, точности ε и параметрах распределения σ, D:

1. **CNN vs. FC.** Локальность свертки уменьшает архитектурную константу: множитель $K_{\max} = C_{\text{out}} k_h k_w$ в (4.5) заменяет неявную зависимость от полной размерности входа в (4.4). При сопоставимых нормах и одинаковой глубине это приводит к меньшему значению $M_{\mathbf{G}}$ для сверточных сетей и, следовательно, к меньшему m^*. Количественное сравнение требует согласованного matching по числу параметров N, нормам весов и размерности задачи.
2. **Трансформеры.** Зависимость $M_{\mathbf{G}}^{\text{Tr}}$ от длины последовательности T содержит слагаемое порядка $T^2 M_{\mathbf{X}}^2$, что через (4.17) дает рост достаточного размера выборки полиномиально по T: $m^* \sim T^2$ при фиксированных остальных параметрах. Этот результат согласуется с квадратичной сложностью self-attention и практическими наблюдениями о повышенных требованиях к данным при работе с длинными контекстами.

4.5. Вычислительные эксперименты

Провести и оформить

Цель вычислительных экспериментов состоит в проверке предложенных теоретических законов масштабирования и сопоставлении предсказанных оценок достаточного размера выборки с реальным поведением обучаемых моделей. Для каждой из рассматриваемых архитектур (MLP, CNN, Transformer) предлагается следующий экспериментальный протокол.

1. **Проверка скоростей сходимости критериев.** Обучить модель на вложенных подвыборках размеров $m_1 < m_2 < \ldots < m_T$ и для каждого m_t вычислить эмпирические значения критериев $\Delta_1(m_t)$, $\Delta_2(m_t)$,

$\Delta_2^{(D)}(m_t)$. Оценить показатели степенного закона $\Delta(m) \sim m^{-\alpha}$ и сопоставить с теоретическими предсказаниями ($\alpha \approx 1$ для Δ_1, $\alpha \approx 2$ для Δ_2 и $\Delta_2^{(D)}$).

2. **Согласование $m^*(\varepsilon)$.** Для нескольких значений порога ε вычислить эмпирический достаточный размер выборки (наименьшее m, при котором $\Delta(m) \leqslant \varepsilon$) и сравнить с теоретическими оценками (4.15)–(4.17).
3. **Зависимость от размерности подпространства.** Для критерия $\Delta_2^{(D)}$ варьировать D и проследить, при каком D подпространственный критерий восстанавливает существенную часть динамики полного критерия Δ_2.
4. **Вычисление архитектурных констант.** Для каждой архитектуры оценить $M_{\mathbf{G}}(\mathcal{A})$ по обучающей выборке и сопоставить теоретические верхние оценки с реально наблюдаемыми значениями.
5. **Зависимость $M_{\mathbf{G}}$ от режима масштабирования.** Для полносвязных сетей сравнить зависимости $M_{\mathbf{G}}$ при масштабировании по ширине и по глубине, проверив предсказания раздела 4.3.5.

4.6. Обсуждение

В данной главе предложена теоретическая схема описания законов масштабирования параметрических моделей, объединяющая архитектурно-зависимые оценки спектральной нормы гаусс-ньютоновской компоненты матрицы Гессе (глава 2) с критериями сходимости ландшафта функции потерь (глава 3).

Результаты главы разделяются на два уровня. Первый уровень — строгие оценки достаточного размера выборки (теоремы 4.4.1–4.4.3), непосредственно следующие из доказанных ранее результатов. Они показывают, что требуемый объем данных для стабилизации ландшафта до заданной точности ε растет пропорционально архитектурной константе $M_{\mathbf{G}}(\mathcal{A})$ и позволяют сравнивать архитектуры по эффективности использования данных. Второй уровень — закон масштабирования (теорема 4.3.2), связывающий потери при обучении с тремя компонентами (неустранимая ошибка, ошибка выразимости, ошибка оценивания). Этот результат опирается на дополнительное предположение 4.3.1 о скорости убывания ошибки оценивания.

Закон масштабирования (4.10) при $\rho = 1$ приводит к формуле того же функционального типа, что и эмпирические законы (4.1). Это объясняет, почему естественно ожидать scaling law вида «E + model term + data term», причём коэффициент при data term определяется архитектурой модели. Вычислительно-оптимальное масштабирование (утверждение 4.3.7) показывает, что при различных режимах масштабирования архитектуры (по ширине, по глубине, по длине последовательности) оптимальное соотношение данных и параметров существенно различается.

Ограничения предложенного подхода связаны с несколькими факторами. Предположение 4.3.1 является модельным и не выводится из предшествующих глав: строгий мост от стабилизации ландшафта к кумулятивной ошибке оценивания потребовал бы привлечения инструментов uniform convergence или algorithmic stability. Аппроксимация $M_{\mathbf{H}} \approx M_{\mathbf{G}}(\mathcal{A})$ справедлива лишь вблизи минимума при малых невязках. Наконец, оценки $M_{\mathbf{G}}(\mathcal{A})$ являются верхними и могут быть существенно грубыми для конкретных инициализаций и распределений данных. Ослабление этих ограничений, построение строгого probabilistic bridge и распространение теории на многослойные трансформерные архитектуры являются направлениями дальнейших исследований.

Глава 5. Критерии достаточного размера выборки для вероятностных линейных моделей

В данной главе рассматриваются методы определения достаточного размера обучающей выборки для линейных моделей. Сначала вводится вероятностная постановка линейной регрессии и описывается зависимость апостериорного распределения параметров и оценки максимального правдоподобия от размера выборки. Далее формулируются четыре критерия достаточности: D-достаточность (дисперсия правдоподобия), M-достаточность (изменение математического ожидания правдоподобия), KL-достаточность (дивергенция Кульбака—Лейблера между апостериорами) и S-достаточность (метрика близости s-score). Для каждого критерия приводятся теоремы о корректности и условия сходимости в вероятностной модели линейной регрессии. Вычислительный эксперимент демонстрирует применимость предложенных методов для предварительной оценки необходимого числа обучающих данных. В заключение обсуждается обобщение на логистическую регрессию и обобщенные линейные модели.

5.1. Введение

Особенный интерес представлет вопрос о законах масштабирования параметрических моделей: по какому правилу стоит совместно выбирать архитектуру модели и число данных для ее обучения. Существующие работы покрывают лишь небольшую часть всего параметрического семейства — в них рассматриваются линейные и обобщенно-линейные модели (добавить математические формулировки + ссылки на работы по обобщенно-линейным моделям), для которых формулируются преимущественно статистические критерии (ссылки на статистические критерии), направленные на определение достаточного размера выборки в предположении единственности решения оптимизационной задачи (1.2).

Классические статистические методы оценки размера выборки опираются на задание нулевой и альтернативной гипотез, допустимой вероятности

ошибки первого рода и требуемой мощности теста. К ним относятся метод множителей Лагранжа (ссылка), отношение правдоподобия (ссылка), критерий Вальда (ссылка) и др. Эти методы дают теоретически обоснованные оценки, но требуют явных предположений о распределении данных и параметрах модели, а также информации о величине эффекта при альтернативе. На практике такие предположения часто недоступны или труднопроверяемы.

Прям распишем разные критерии и их постановки, как у Грабового в статье

Информационно-теоретические подходы характеризуют связь между данными и моделью через энтропию, взаимную информацию или дивергенции между распределениями (добавить ссылки). Байесовские методы используют апостериорное распределение параметров и критерии вроде средней апостериорной дисперсии (APVC), среднего покрытия (ACC) или дивергенции Кульбака—Лейблера между апостериорными распределениями на разных подвыборках (добавить ссылки). Так, в работе [10] для логистической регрессии предложено использовать KL-дивергенцию между апостериорными распределениями на «схожих» подвыборках (отличающихся одним объектом) для оценки достаточного размера выборки.

5.2. Предварительные сведения

Вероятностная модель линейной регрессии. Объектом называется пара $(\mathbf{x}, y)$, где $\mathbf{x} \in \mathbb{R}^n$ — вектор признакового описания, $y \in \mathbb{R}$ — целевая переменная. Выборка размера m задается множеством $\mathfrak{D}_m = \{(\mathbf{x}_i, y_i)\}_{i=1}^m$ из m независимых реализаций пар $(\mathbf{x}, y)$. Вводятся матрица объекты-признаки $\mathbf{X}_m = [\mathbf{x}_1, \ldots, \mathbf{x}_m]^\top \in \mathbb{R}^{m \times n}$ и вектор значений целевой переменной $\mathbf{y}_m = [y_1, \ldots, y_m]^\top \in \mathbb{R}^m$. Вероятностная модель линейной регрессии задается правдоподобием

$$p(y|\mathbf{x}, \mathbf{w}) = \mathcal{N}(y|\mathbf{w}^\top \mathbf{x}, \sigma^2 \mathbf{I}), \tag{5.1}$$

где $\mathbf{w} \in \mathbb{R}^n$ — вектор параметров, $\sigma^2 > 0$ — дисперсия шума. Для простой выборки функция правдоподобия имеет вид

$$L(\mathfrak{D}_m, \mathbf{w}) = p(\mathbf{y}_m|\mathbf{X}_m, \mathbf{w}) = (2\pi\sigma^2)^{-m/2} \exp\left(-\frac{1}{2\sigma^2}\|\mathbf{y}_m - \mathbf{X}_m\mathbf{w}\|_2^2\right), \tag{5.2}$$

а логарифмическая функция правдоподобия записывается в виде

$$l(\mathfrak{D}_m, \mathbf{w}) = \log L(\mathfrak{D}_m, \mathbf{w}) = -\frac{m}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\|\mathbf{y}_m - \mathbf{X}_m\mathbf{w}\|_2^2.$$

Оценкой максимума правдоподобия (ОМП) по подвыборке $\mathfrak{D}_k \subseteq \mathfrak{D}_m$ размера k называется

$$\hat{\mathbf{w}}_k = \arg\max_{\mathbf{w}\in\mathbb{R}^n} L(\mathfrak{D}_k, \mathbf{w}) = \arg\min_{\mathbf{w}\in\mathbb{R}^n} \|\mathbf{y}_k - \mathbf{X}_k\mathbf{w}\|_2^2,$$

которая задается формулой

$$\hat{\mathbf{w}}_k = (\mathbf{X}_k^\top\mathbf{X}_k)^{-1}\mathbf{X}_k^\top\mathbf{y}_k$$

и при условии полного столбцового ранга матрицы $\mathbf{X}_k$ является единственной.

Асимптотическое поведение ОМП. Для частотного подхода важна сходимость ОМП $\hat{\mathbf{w}}_k$. Из асимптотической теории известно, что при стандартных условиях регулярности (ограниченность информационной матрицы Фишера, непрерывность и т. д.) выполняется

$$\sqrt{k}(\hat{\mathbf{w}}_k - \mathbf{w}^*) \xrightarrow{d} \mathcal{N}(0, \mathcal{I}^{-1}(\mathbf{w}^*)),$$

где $\mathbf{w}^*$ — истинный вектор параметров, а $\mathcal{I}(\mathbf{w})$ — информационная матрица Фишера:

$$[\mathcal{I}(\mathbf{w})]_{ij} = -\mathbb{E}\left[\frac{\partial^2 \log p(y|\mathbf{x}, \mathbf{w})}{\partial w_i \partial w_j}\right].$$

Таким образом, ОМП состоятельна и асимптотически нормальна, что наводит нас на идею о стабилизации ее статистик, например, функции правдоподобия на всей выборке (5.2). В следующем разделе мы вводим критерии достаточности размера выборки на основе этой идеи.

Апостериорное распределение параметров. При заданном априорном распределении $p(\mathbf{w})$ апостериорное распределение параметров по формуле Байеса имеет вид

$$p(\mathbf{w}|\mathfrak{D}_k) = \frac{p(\mathfrak{D}_k|\mathbf{w})p(\mathbf{w})}{p(\mathfrak{D}_k)} \propto L(\mathfrak{D}_k, \mathbf{w})p(\mathbf{w}).$$

Для гауссовского априорного распределения $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{m}_0, \mathbf{\Sigma}_0)$ и правдоподобия (5.1) апостериорное распределение сопряжено и также является гауссовским [11]:

$$p(\mathbf{w}|\mathfrak{D}_k) = \mathcal{N}(\mathbf{w}|\mathbf{m}_k, \mathbf{\Sigma}_k),$$

где

$$\mathbf{\Sigma}_k^{-1} = \mathbf{\Sigma}_0^{-1} + \frac{1}{\sigma^2}\mathbf{X}_k^\top \mathbf{X}_k, \qquad \mathbf{m}_k = \mathbf{\Sigma}_k \left(\mathbf{\Sigma}_0^{-1}\mathbf{m}_0 + \frac{1}{\sigma^2}\mathbf{X}_k^\top \mathbf{y}_k \right).$$

Математическое ожидание $\mathbf{m}_k$ и матрица ковариации $\mathbf{\Sigma}_k$ апостериорного распределения зависят от подвыборки $\mathfrak{D}_k$. При увеличении размера выборки k матрица $\mathbf{X}_k^\top \mathbf{X}_k$ накапливает информацию о признаках, дисперсия апостериора $\mathbf{\Sigma}_k$ уменьшается, а апостериорное среднее $\mathbf{m}_k$ приближается к истинным параметрам при выполнении условий регулярности (что за условия и почему?). В следующем разделе мы предлагаем критерий достаточности размера выборки, вдохновленный этими предельными свойствами.

5.3. Критерии достаточности для линейных моделей

В данном разделе мы зафиксируем полную выборку $\mathfrak{D}_m$ и рассмотрим подвыборки $\mathfrak{D}_k \subseteq \mathfrak{D}_m$ размера $k \leqslant m$. Пусть $\hat{\mathbf{w}}_k$ — ОМП по $\mathfrak{D}_k$, а $p_k(\mathbf{w}) = p(\mathbf{w}|\mathfrak{D}_k)$ — апостериорное распределение параметров.

Определение. Размер выборки m^* называется *достаточным* согласно критерию T, если T выполняется для всех $k \geqslant m^*$.

Введенное выше определение является наиболее общим для всех рассматриваемых в настоящей работе критериев. Оно универсально и подходит также под уже известные критерии достаточного размера выборки, сформулированные в разделе 1.2. Ниже вводятся четыре критерия, различающиеся тем, какую характеристику стабильности модели они используют.

5.3.1. Стабилизация функции правдоподобия в точке ОМП

В этом разделе мы предлагаем критерии достаточности для вероятностной модели линейной регрессии, основанные на сходимости функции правдоподобия в точке максимума правдоподобия, оцененной по подвыборке. Основная идея методов заключается в том, что поскольку ОМП состоятельна и асимптотически нормальна, мы ожидаем такого же поведения и от функции правдоподобия

всей обучающей выборки (или функции потерь на практике). Визуализация подходов представлена на рисунке 5.1.

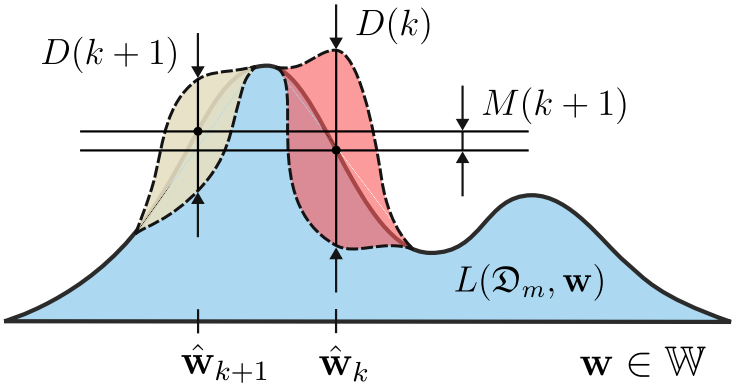

Рисунок 5.1 — Визуализация критериев D-достаточности (уменьшение дисперсии функции правдоподобия) и M-достаточности (уменьшение изменения функции правдоподобия при добавлении новых объектов) размера выборки в вероятностной модели линейной регрессии

Сперва мы введем критерий на основе дисперсии функции правдоподобия. Его идея состоит в следующем: при достаточном размере выборки оценка параметров мало меняется от одной реализации подвыборки к другой, поэтому дисперсия значения правдоподобия (или его логарифма) в точке оценки по подвыборкам не должна превышать порога. Формально, это записывается в виде следующего определения.

Определение. Зафиксируем $\varepsilon > 0$. Размер выборки m^* называется *D-достаточным*, если для всех $k \geqslant m^*$

$$D(k) = \mathbb{D}_{\mathfrak{D}_k} L(\mathfrak{D}_m, \hat{\mathbf{w}}_k) \leqslant \varepsilon. \tag{5.3}$$

Вместо $L(\mathfrak{D}_m, \hat{\mathbf{w}}_k)$ можно рассматривать логарифм $l(\mathfrak{D}_m, \hat{\mathbf{w}}_k)$ — выбор той или иной формы влияет на масштаб порога ε и ни на что больше. Далее в экспериментах мы увидим, какие свойста имеет введенная нами функция $D(k)$, но сейчас перейдем к следующему определению, использующему математическое ожидание функции правдоподобия.

Идея M-критерия в том, что мы фиксируем изменение математического ожидания правдоподобия при добавлении одного объекта в подвыборку, и начиная с определенного размера выборки это изменение перестает быть существенным. На математическом языке мы можем это записать следующим образом.

Определение. Зафиксируем $\varepsilon > 0$. Размер выборки m^* называется *M-достаточным*, если для всех $k \geqslant m^*$

$$M(k+1) = \left|\mathbb{E}_{\mathfrak{D}_{k+1}} L(\mathfrak{D}_m, \hat{\mathbf{w}}_{k+1}) - \mathbb{E}_{\mathfrak{D}_k} L(\mathfrak{D}_m, \hat{\mathbf{w}}_k)\right| \leqslant \varepsilon. \tag{5.4}$$

Для критерия M-достаточности в настоящей работе формулируется теоретическое утверждение в следующем разделе. Кроме того, проводимый в настоящей работе вычислительный эксперимент исследует также и зависимость критерия от введенного гиперпараметра ε. Однако сперва мы введем еще два определения, которые основываются на анализе апостериорных распределений параметров модели.

5.3.2. Апостериорные распределения на схожих подвыборках

В то время как введенные в предыдущем разделе определения используют точечную оценку параметров — ОМП, в работе [10] для логистической регрессии было предложено использовать близость апостериорных распределений на «схожих» подвыборках как меру достаточного размера выборки. Эта идея легла в основу критериев KL-достаточности и S-достаточности, которые мы формулируем далее. Нам потребуется формально определить, что такое схожие подвыборки. Рассмотрим две подвыборки $\mathfrak{D}^1 \subseteq \mathfrak{D}_m$ и $\mathfrak{D}^2 \subseteq \mathfrak{D}_m$. Пусть $\mathcal{I}_1 \subseteq \mathcal{I} = \{1, \ldots, m\}$ и $\mathcal{I}_2 \subseteq \mathcal{I} = \{1, \ldots, m\}$ — соответствующие им подмножества индексов.

Определение. Подвыборки $\mathfrak{D}^1$ и $\mathfrak{D}^2$ называются *схожими*, если $\mathcal{I}_2$ может быть получено из $\mathcal{I}_1$ удалением, заменой или добавлением одного элемента, т. е.

$$|\mathcal{I}_1 \triangle \mathcal{I}_2| = |(\mathcal{I}_1 \setminus \mathcal{I}_2) \cup (\mathcal{I}_2 \setminus \mathcal{I}_1)| = 1.$$

Для таких подвыборок интуитивно ясно следующее: если мы посчитаем апостериорные распределения параметров модели на них, то они должны быть тем ближе, чем на большем числе данных мы их оценили. Визуализация предлагаемых подходов представлена на рисунке 5.2.

Близость вероятностных распределений может быть описана по-разному (разные функции дивергенции, в том числе KL-дивергенция, W-distance,

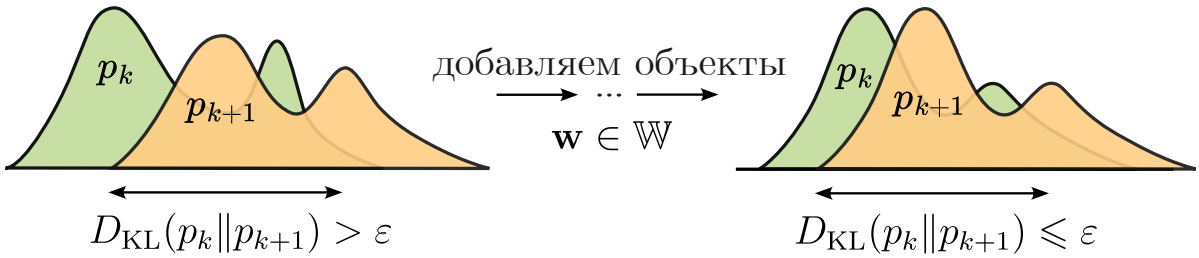

Рисунок 5.2 — Визуализация критериев KL-достаточности и S-достаточности (близость апостериорных распределений параметров на схожих подвыборках) размера выборки в вероятностной модели линейной регрессии

JS-distance, etc.). Далее мы формулируем два определения, использующих наиболее удобные для использования на практике функции: KL-дивергенцию и функцию близости s-score.

Определение. Зафиксируем $\varepsilon > 0$. Размер выборки m^* называется *KL-достаточным*, если для всех $k \geqslant m^*$ при схожих подвыборках $\mathfrak{D}_k$ и $\mathfrak{D}_{k+1}$ выполняется

$$\mathrm{KL}(k+1) = D_{\mathrm{KL}}(p_k \| p_{k+1}) = \int p_k(\mathbf{w}) \log \frac{p_k(\mathbf{w})}{p_{k+1}(\mathbf{w})} \, d\mathbf{w} \leqslant \varepsilon.$$

В качестве альтернативы KL-дивергенции можно использовать функцию s-score [12], задающую меру близости двух плотностей:

$$\text{s-score}(g_1, g_2) = \frac{\int g_1(\mathbf{w}) g_2(\mathbf{w}) \, d\mathbf{w}}{\max_{\mathbf{b}} \int g_1(\mathbf{w} - \mathbf{b}) g_2(\mathbf{w}) \, d\mathbf{w}}.$$

Числитель — интеграл произведения плотностей; знаменатель нормирует значение. Для идентичных распределений s-score равно 1.

Определение. Зафиксируем $\varepsilon > 0$. Размер выборки m^* называется S-достаточным, если для всех $k \geqslant m^*$

$$S(k+1) = \text{s-score}(p_k, p_{k+1}) \geqslant 1 - \varepsilon.$$

Таким образом, введенные определения демонстрируют условия, при которых размер выборки m^* может считаться достаточным в терминах того или иного критерия. Важно отметить, что из приведенных выше эвристических соображений корректность определений никак не следует. Таким образом, мы переходим к следующему разделу, в котором сфокусируемся на исследовании теоретических свойств предложенных подходов.

5.4. Асимптотическое поведение оптимизационной поверхности в вероятностной модели линейной регрессии

В настоящем разделе мы приводим теоретическое обоснование корректности предложенных определений. Сперва введем понятие этой корректности.

Определение. Критерий достаточности называется *корректным*, если при увеличении размера выборки соответствующая функция сходится к предельному значению.

Отметим, что по сути корректность критерия позволяет гарантированно достичь заданного порога ε, ограничивающего целевую функцию, при достаточно большом k. Такое определение позволяет заключить, что введенный критерий непротиворечив и при ряде предположений имеет место быть в заданной постановке задачи.

5.4.1. Сходимость распределения параметров модели

Обозначим $\mathbb{E}\hat{\mathbf{w}}_k = \mathbf{m}_k$ и $\mathbb{D}\hat{\mathbf{w}}_k = \mathbf{\Sigma}_k$. Следующая теорема дает достаточное условие для сходимости функции $M(k)$ к нулю при увеличении размера обучающей выборки.

Теорема 5.4.1. *Пусть* $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \to 0$ *и* $\|\mathbf{\Sigma}_{k+1} - \mathbf{\Sigma}_k\|_F \to 0$ *при* $k \to \infty$. *Тогда в модели линейной регрессии определение M-достаточного размера выборки корректно: для любого* $\varepsilon > 0$ *существует* m^* *такое, что для всех* $k \geqslant m^*$ *выполняется* $M(k) \leqslant \varepsilon$.

Важно отметить, что условия теоремы не являются слишком обременительными. Ввиду асимптотической нормальности ОМП $\hat{\mathbf{w}}_k$ и ее сходимости к вектору истинных параметров модели, условия на сходимость моментов кажутся интуитивно понятными, хотя и не следуют ниоткуда напрямую (уточнить, может все-таки следуют).

Для моделей с нормальным апостериорным распределением параметров (в том числе линейной регрессии с гауссовским априором) KL-дивергенция и

s-score допускают явные выражения. Благодаря этому формулируются две следующих теоремы.

Теорема 5.4.2. *Пусть апостериорные распределения p_k, p_{k+1} нормальны и $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \to 0$, $\|\mathbf{\Sigma}_{k+1} - \mathbf{\Sigma}_k\|_F \to 0$ при $k \to \infty$. Тогда определение KL-достаточного размера выборки корректно: для любого $\varepsilon > 0$ существует m^* такое, что $\mathrm{KL}(k) \leqslant \varepsilon$ для всех $k \geqslant m^*$.*

Теорема 5.4.3. *Пусть апостериорные распределения p_k, p_{k+1} нормальны и $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \to 0$ при $k \to \infty$. Тогда определение S-достаточного размера выборки корректно: для любого $\varepsilon > 0$ существует m^* такое, что $S(k) \geqslant 1 - \varepsilon$ для всех $k \geqslant m^*$.*

Утверждения выше, как и теорема 5.4.1, не предполагают слишком многого о распределении параметров модели. Как мы увидим далее в экспериментах, и как это известно из раздела 5.2, эти предположения практически всегда выполняются на практике. Отметим, что для S-достаточности сходимости ковариационных матриц не требуется — достаточно сходимости средних. Для применения теорем 5.4.1, 5.4.2, и 5.4.3 необходимо проверить выполнение условий на моменты. В линейной регрессии с гауссовским априором апостериор нормален, и моменты задаются явными формулами. Следующий результат таким образом обеспечивает сходимость в модели линейной регрессии, переходя к еще более простым условиям.

Теорема 5.4.4. *Пусть множества значений признаков и целевой переменной ограничены, т. е. $\exists M > 0 : \|\mathbf{x}\|_2 \leqslant M$, $|y| \leqslant M$. Пусть минимальное собственное значение матрицы $\mathbf{X}_k^\top \mathbf{X}_k$ удовлетворяет условию $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k) = \omega(\sqrt{k})$ при $k \to \infty$. Тогда в линейной регрессии с нормальным априорным распределением параметров $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \to 0$ и $\|\mathbf{\Sigma}_{k+1} - \mathbf{\Sigma}_k\|_F \to 0$ при $k \to \infty$.*

Условие $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k) = \omega(\sqrt{k})$ означает, что минимальное собственное значение растет быстрее $\sqrt{k}$ и гарантирует отсутствие сильной мультиколлинеарности при росте выборки. На практике это условие часто выполняется для «хорошо обусловленных» данных.

5.4.2. Сходимость полного байесовского прогноза

В предыдущем разделе было показано, что при увеличении используемого размера выборки в модели линейной регрессии наблюдается сходимость апостериорных распределений параметров на схожих подвыборках. Однако на практике нас больше интересует прогноз, который можно сделать на тестовой выборке, предварительно настроив модель на обучающей. Пусть предварительно было произведено разбиение выборки $\mathfrak{D}_m$ на обучающую и тестовую, т. е.

$$\mathfrak{D}_m = \mathfrak{D}_{m_1}^{\text{train}} \sqcup \mathfrak{D}_{m_2}^{\text{test}},$$

где $\mathfrak{D}_{m_1}^{\text{train}} = (\mathbf{X}_{\text{train}}, \mathbf{y}_{\text{train}})$ и $\mathfrak{D}_{m_2}^{\text{test}} = (\mathbf{X}_{\text{test}}, \mathbf{y}_{\text{test}})$.

Рассмотрим подвыборку $(\mathbf{X}_k, \mathbf{y}_k) \subset \mathfrak{D}_{m_1}^{\text{train}}$ и сформулируем теорему о близости полных байесовских прогнозов, сделанных на схожих подвыборках обучающей выборки.

Теорема 5.4.5. *Пусть множества значений признаков и целевой переменной ограничены, т. е.* $\exists M > 0 : \|\mathbf{x}\|_2 \leqslant M$, $|y| \leqslant M$. *Если* $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k) = \omega(\sqrt{k})$ *при* $k \to \infty$, *то в модели линейной регрессии с нормальным априорным распределением параметров при* $k \to \infty$ *верно, что*

$$D_{\text{KL}}\left(p(\mathbf{y}_{\text{test}}|\mathbf{X}_{\text{test}}, \mathbf{X}_k, \mathbf{y}_k) \| p(\mathbf{y}_{\text{test}}|\mathbf{X}_{\text{test}}, \mathbf{X}_{k+1}, \mathbf{y}_{k+1})\right) \to 0.$$

Сформулированное выше утверждение заключает, что в модели вероятностной линейной регрессии определения KL-достаточности и S-достаточности связаны не просто со сходимостью оптимизационной поверхности, но и со стабилизацией прогноза на отложенной тестовой выборке. Именно это и является ключевым фактором, который дополняет все полученные выше теоретические результаты их применимостью в практических задачах.

5.5. Доказательства теоретических результатов

В данном приводятся доказательства основных теорем настоящей главы: 5.4.1, 5.4.2, 5.4.3, 5.4.4 и 5.4.5. Начнем с доказательства теоремы 5.4.1 о корректности определения M-достаточного размера выборки.

Доказательство теоремы 5.4.1. Рассмотрим определение М-достаточного размера выборки в терминах логарифма функции правдоподобия. В модели линейной регрессии

$$L\left(\mathfrak{D}_m, \hat{\mathbf{w}}_k\right) = p(\mathbf{y}|\mathbf{X}, \hat{\mathbf{w}}_k) = \prod_{i=1}^{m} p(y_i|\mathbf{x}_i, \hat{\mathbf{w}}_k) = \prod_{i=1}^{m} \mathcal{N}\left(y_i|\hat{\mathbf{w}}_k^\top \mathbf{x}_i, \sigma^2\right)$$
$$= \left(2\pi\sigma^2\right)^{-m/2} \exp\left(-\frac{1}{2\sigma^2}\|\mathbf{y} - \mathbf{X}\hat{\mathbf{w}}_k\|_2^2\right). \tag{5.5}$$

Логарифмируя (5.5), получаем

$$l\left(\mathfrak{D}_m, \hat{\mathbf{w}}_k\right) = \log p(\mathbf{y}|\mathbf{X}, \hat{\mathbf{w}}_k) = -\frac{m}{2}\log\left(2\pi\sigma^2\right) - \frac{1}{2\sigma^2}\|\mathbf{y} - \mathbf{X}\hat{\mathbf{w}}_k\|_2^2. \tag{5.6}$$

Возьмем математическое ожидание (5.6) по $\mathfrak{D}_k$, учитывая, что $\mathbb{E}_{\mathfrak{D}_k}\hat{\mathbf{w}}_k = \mathbf{m}_k$ и $\operatorname{cov}(\hat{\mathbf{w}}_k) = \mathbf{\Sigma}_k$, тогда имеем

$$\mathbb{E}_{\mathfrak{D}_k} l\left(\mathfrak{D}_m, \hat{\mathbf{w}}_k\right) = -\frac{m}{2}\log\left(2\pi\sigma^2\right) - \frac{1}{2\sigma^2}\Big(\|\mathbf{y} - \mathbf{X}\mathbf{m}_k\|_2^2 + \operatorname{tr}\left(\mathbf{X}^\top\mathbf{X}\mathbf{\Sigma}_k\right)\Big). \tag{5.7}$$

Используя (5.7) для размеров k и $k+1$, запишем выражение для разности математических ожиданий, в таком случае получим

$$\mathbb{E}_{\mathfrak{D}_{k+1}} l(\mathfrak{D}_m, \hat{\mathbf{w}}_{k+1}) - \mathbb{E}_{\mathfrak{D}_k} l(\mathfrak{D}_m, \hat{\mathbf{w}}_k) =$$
$$= \frac{1}{2\sigma^2}\Big(\|\mathbf{y} - \mathbf{X}\mathbf{m}_k\|_2^2 - \|\mathbf{y} - \mathbf{X}\mathbf{m}_{k+1}\|_2^2\Big) + \frac{1}{2\sigma^2}\operatorname{tr}\Big(\mathbf{X}^\top\mathbf{X}\left(\mathbf{\Sigma}_k - \mathbf{\Sigma}_{k+1}\right)\Big)$$
$$= \frac{1}{\sigma^2}\mathbf{y}^\top\mathbf{X}(\mathbf{m}_{k+1} - \mathbf{m}_k) \tag{5.8}$$
$$+ \frac{1}{2\sigma^2}(\mathbf{m}_k - \mathbf{m}_{k+1})^\top\mathbf{X}^\top\mathbf{X}(\mathbf{m}_k + \mathbf{m}_{k+1}) \tag{5.9}$$
$$+ \frac{1}{2\sigma^2}\operatorname{tr}\Big(\mathbf{X}^\top\mathbf{X}\left(\mathbf{\Sigma}_k - \mathbf{\Sigma}_{k+1}\right)\Big). \tag{5.10}$$

Значение функции $M(k+1)$ есть модуль от выражения выше. Применим неравенство треугольника для модуля, а затем оценим каждое слагаемое. Первое слагаемое (5.8) оценим, используя неравенство Коши–Буняковского:

$$\left|\mathbf{y}^\top\mathbf{X}(\mathbf{m}_{k+1} - \mathbf{m}_k)\right| \leqslant \|\mathbf{X}^\top\mathbf{y}\|_2\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2. \tag{5.11}$$

Второе слагаемое (5.9) оценим, используя неравенство Коши–Буняковского, свойство согласованности спектральной матричной нормы, а также ограниченность последовательности векторов $\mathbf{w}_k$, которая следует из предъявленной в

условии сходимости:

$$\begin{aligned}\left|(\mathbf{m}_k - \mathbf{m}_{k+1})^\top \mathbf{X}^\top \mathbf{X}(\mathbf{m}_k + \mathbf{m}_{k+1})\right| &\leqslant \|\mathbf{X}(\mathbf{m}_k - \mathbf{m}_{k+1})\|_2 \|\mathbf{X}(\mathbf{m}_k + \mathbf{m}_{k+1})\|_2 \\ &\leqslant \|\mathbf{X}\|_2^2 \|\mathbf{m}_k - \mathbf{m}_{k+1}\|_2 \|\mathbf{m}_k + \mathbf{m}_{k+1}\|_2 \\ &\leqslant C\|\mathbf{X}\|_2^2 \|\mathbf{m}_k - \mathbf{m}_{k+1}\|_2. \end{aligned} \tag{5.12}$$

Последнее слагаемое (5.10) оценим, используя неравенство Гёльдера для нормы Фробениуса:

$$\left|\operatorname{tr}\Big(\mathbf{X}^\top \mathbf{X}\left(\mathbf{\Sigma}_k - \mathbf{\Sigma}_{k+1}\right)\Big)\right| \leqslant \|\mathbf{X}^\top \mathbf{X}\|_F \|\mathbf{\Sigma}_k - \mathbf{\Sigma}_{k+1}\|_F. \tag{5.13}$$

Наконец, поскольку по условию теоремы $\|\mathbf{m}_k - \mathbf{m}_{k+1}\|_2 \to 0$ и $\|\mathbf{\Sigma}_k - \mathbf{\Sigma}_{k+1}\|_F \to 0$ при $k \to \infty$, то выражения (5.11), (5.12) и (5.13) стремятся к 0 при $k \to \infty$, а следовательно и $M(k) \to 0$ при $k \to \infty$, что доказывает теорему. □

Теорема 5.4.1 показывает, что при достаточном объеме выборки добавление очереднего объекта практически не изменяет ожидаемое значение функции правдоподобия на полной выборке. Тем не менее, особый интерес представляют результаты, полученные для полных апостериорных распределений параметров.

Доказательство теоремы 5.4.2. Дивергенция Кульбака—Лейблера для пары нормальных апостериорных распределений имеет вид

$$\begin{aligned}D_{\mathrm{KL}}\left(p_k \| p_{k+1}\right) = \frac{1}{2}\Bigg(&\operatorname{tr}\left(\mathbf{\Sigma}_{k+1}^{-1}\mathbf{\Sigma}_k\right) + (\mathbf{m}_{k+1} - \mathbf{m}_k)^\top \mathbf{\Sigma}_{k+1}^{-1}(\mathbf{m}_{k+1} - \mathbf{m}_k) - \\ &- n + \log\left(\frac{\det \mathbf{\Sigma}_{k+1}}{\det \mathbf{\Sigma}_k}\right)\Bigg). \end{aligned} \tag{5.14}$$

Представим $\mathbf{\Sigma}_{k+1}$ как $\mathbf{\Sigma}_{k+1} = \mathbf{\Sigma}_k + \Delta\mathbf{\Sigma}$. Рассмотрим в отдельности каждое слагаемое в (5.14). Для первого слагаемого получаем

$$\operatorname{tr}\left(\mathbf{\Sigma}_{k+1}^{-1}\mathbf{\Sigma}_k\right) = \operatorname{tr}\left(\left(\mathbf{\Sigma}_k + \Delta\mathbf{\Sigma}\right)^{-1}\mathbf{\Sigma}_k\right) \to \operatorname{tr}\left(\mathbf{I}_n\right) = n \tag{5.15}$$

при $\|\Delta\mathbf{\Sigma}\|_F \to 0$. Для второго слагаемого имеем

$$\left|(\mathbf{m}_{k+1} - \mathbf{m}_k)^\top \mathbf{\Sigma}_{k+1}^{-1}(\mathbf{m}_{k+1} - \mathbf{m}_k)\right| \leqslant \|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2^2 \|\mathbf{\Sigma}_{k+1}^{-1}\|_2 \to 0 \tag{5.16}$$

при $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \to 0$. Наконец, для последнего слагаемого можем записать

$$\log\left(\frac{\det \mathbf{\Sigma}_{k+1}}{\det \mathbf{\Sigma}_k}\right) = \log\left(\frac{\det\left(\mathbf{\Sigma}_k + \Delta\mathbf{\Sigma}\right)}{\det \mathbf{\Sigma}_k}\right) \to \log\det \mathbf{I}_n = \log 1 = 0 \tag{5.17}$$

при $\|\Delta\mathbf{\Sigma}\|_F \to 0$. Объединяя предельные соотношения (5.15), (5.16) и (5.17), получаем требуемое в условиях теоремы. □

Доказательство теоремы 5.4.3. Воспользуемся выражением s-score для пары нормальных априорных распределений из [12]:

$$\text{s-score}(p_k, p_{k+1}) = \exp\left(-\frac{1}{2}(\mathbf{m}_{k+1} - \mathbf{m}_k)^\top (\mathbf{\Sigma}_k + \mathbf{\Sigma}_{k+1})^{-1} (\mathbf{m}_{k+1} - \mathbf{m}_k)\right). \quad (5.18)$$

Поскольку

$$\left|(\mathbf{m}_{k+1} - \mathbf{m}_k)^\top (\mathbf{\Sigma}_k + \mathbf{\Sigma}_{k+1})^{-1} (\mathbf{m}_{k+1} - \mathbf{m}_k)\right| \leqslant$$
$$\leqslant \|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2^2 \| (\mathbf{\Sigma}_k + \mathbf{\Sigma}_{k+1})^{-1} \|_2 \to 0$$

при $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \to 0$, то значение квадратичной формы внутри экспоненты (5.18) стремится к нулю. Следовательно, $\text{s-score}(p_k, p_{k+1}) \to 1$ при устремлении $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \to 0$, что и требовалось доказать. □

В вероятностной модели линейной регрессии с гауссовским априорным распределением доказывается следующая теорема, определяющая достаточные условия для сходимостей из предыдущих теорем 5.4.2 и 5.4.3.

Доказательство теоремы 5.4.4. Пусть задано нормальное априорное распределение параметров $p(\mathbf{w}) = \mathcal{N}\left(\mathbf{w}|\mathbf{0}, \alpha^{-1}\mathbf{I}\right)$. В модели линейной регрессии правдоподобие является нормальным, а именно

$$p(\mathbf{y}|\mathbf{X}, \mathbf{w}) = \mathcal{N}\left(\mathbf{y}|\mathbf{X}\mathbf{w}, \sigma^2\mathbf{I}\right) = \left(2\pi\sigma^2\right)^{-m/2} \exp\left(-\frac{1}{2\sigma^2}\|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2\right).$$

Используя сопряженность априорного распределения и правдоподобия, легко найти параметры апостериорного распределения:

$$p(\mathbf{w}|\mathbf{X}, \mathbf{y}) = \mathcal{N}\left(\mathbf{w}|\mathbf{m}, \mathbf{\Sigma}\right),$$

где

$$\mathbf{\Sigma} = \left(\alpha\mathbf{I} + \frac{1}{\sigma^2}\mathbf{X}^\top\mathbf{X}\right)^{-1}, \qquad \mathbf{m} = \left(\mathbf{X}^\top\mathbf{X} + \alpha\sigma^2\mathbf{I}\right)^{-1}\mathbf{X}^\top\mathbf{y}. \quad (5.19)$$

Рассмотрим выражение $\|\mathbf{\Sigma}_{k+1} - \mathbf{\Sigma}_k\|_2$ нормы разности матриц ковариции для подвыборок размера k и $k+1$. Введем обозначение $\mathbf{A}_k = \frac{1}{\sigma^2}\mathbf{X}_k^\top\mathbf{X}_k$. Учитывая

формулы моментов (5.19), имеем

$$
\begin{aligned}
&\|\mathbf{\Sigma}_{k+1} - \mathbf{\Sigma}_k\|_2 = \\
&= \left\|(\alpha\mathbf{I} + \mathbf{A}_{k+1})^{-1} - (\alpha\mathbf{I} + \mathbf{A}_k)^{-1}\right\|_2 \\
&= \left\|(\alpha\mathbf{I} + \mathbf{A}_{k+1})^{-1}(\mathbf{A}_{k+1} - \mathbf{A}_k)(\alpha\mathbf{I} + \mathbf{A}_k)^{-1}\right\|_2 \\
&\leqslant \left\|(\alpha\mathbf{I} + \mathbf{A}_{k+1})^{-1}\right\|_2 \left\|(\alpha\mathbf{I} + \mathbf{A}_k)^{-1}\right\|_2 \|\mathbf{A}_{k+1} - \mathbf{A}_k\|_2 && (5.20) \\
&= \frac{1}{\lambda_{\min}(\alpha\mathbf{I} + \mathbf{A}_{k+1})} \frac{1}{\lambda_{\min}(\alpha\mathbf{I} + \mathbf{A}_k)} \|\mathbf{A}_{k+1} - \mathbf{A}_k\|_2 && (5.21) \\
&\leqslant \frac{1}{\lambda_{\min}(\mathbf{A}_{k+1})} \frac{1}{\lambda_{\min}(\mathbf{A}_k)} \|\mathbf{A}_{k+1} - \mathbf{A}_k\|_2 \\
&= \sigma^2 \frac{1}{\lambda_{\min}(\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1})} \frac{1}{\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k)} \left\|\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1} - \mathbf{X}_k^\top \mathbf{X}_k\right\|_2 . && (5.22)
\end{aligned}
$$

Здесь в (5.20) мы воспользовались субмультипликативностью спектральной матричной нормы, а в (5.21) — выражением спектральной матричной нормы через максимальное собственное значение. Далее, поскольку по условию $\|\mathbf{x}\|_2 \leqslant M$, то мы оцениваем норму разности матриц из (5.22) следующим образом:

$$
\begin{aligned}
\left\|\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1} - \mathbf{X}_k^\top \mathbf{X}_k\right\|_2 &= \left\|\sum_{i=1}^{k+1} \mathbf{x}_i \mathbf{x}_i^\top - \sum_{i=1}^{k} \mathbf{x}_i \mathbf{x}_i^\top\right\|_2 = \left\|\mathbf{x}_{k+1}\mathbf{x}_{k+1}^\top\right\|_2 \\
&= \lambda_{\max}\left(\mathbf{x}_{k+1}\mathbf{x}_{k+1}^\top\right) = \mathbf{x}_{k+1}^\top \mathbf{x}_{k+1} = \|\mathbf{x}_{k+1}\|_2^2 \leqslant M^2, && (5.23)
\end{aligned}
$$

где переход к (5.23) имеет место потому, что матрица единичного ранга имеет единственное ненулевое собственное значение. По условию $\lambda_{\min}\left(\mathbf{X}_k^\top \mathbf{X}_k\right) = \omega(\sqrt{k})$, тогда $\|\mathbf{\Sigma}_{k+1} - \mathbf{\Sigma}_k\|_2 = o(k^{-1})$ при $k \to \infty$. Пользуясь эквивалентностью матричных норм, получаем требуемую сходимость для матриц ковариации:

$$
\|\mathbf{\Sigma}_{k+1} - \mathbf{\Sigma}_k\|_F \leqslant \sqrt{k}\|\mathbf{\Sigma}_{k+1} - \mathbf{\Sigma}_k\|_2 = o(k^{-1/2}), \quad k \to \infty.
$$

Теперь оценим норму разности математических ожиданий. Пользуясь формулой (5.19), получаем

$$
\begin{aligned}
&\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 = \\
&= \left\| \left(\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1} + \alpha\sigma^2\mathbf{I}\right)^{-1} \mathbf{X}_{k+1}^\top \mathbf{y}_{k+1} - \left(\mathbf{X}_k^\top \mathbf{X}_k + \alpha\sigma^2\mathbf{I}\right)^{-1} \mathbf{X}_k^\top \mathbf{y}_k \right\|_2 \\
&= \Big\| \left(\mathbf{X}_k^\top \mathbf{X}_k + \alpha\sigma^2\mathbf{I} + \mathbf{x}_{k+1}\mathbf{x}_{k+1}^\top\right)^{-1} \left(\mathbf{X}_k^\top \mathbf{y}_k + \mathbf{x}_{k+1} y_{k+1}\right) \\
&\qquad\qquad - \left(\mathbf{X}_k^\top \mathbf{X}_k + \alpha\sigma^2\mathbf{I}\right)^{-1} \mathbf{X}_k^\top \mathbf{y}_k \Big\|_2 \\
&= \Bigg\| \left[\left(\mathbf{I} + \left(\mathbf{X}_k^\top \mathbf{X}_k + \alpha\sigma^2\mathbf{I}\right)^{-1} \mathbf{x}_{k+1}\mathbf{x}_{k+1}^\top\right)^{-1} - \mathbf{I}\right] \left(\mathbf{X}_k^\top \mathbf{X}_k + \alpha\sigma^2\mathbf{I}\right)^{-1} \mathbf{X}_k^\top \mathbf{y}_k \\
&\qquad\qquad + \left(\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1} + \alpha\sigma^2\mathbf{I}\right)^{-1} \mathbf{x}_{k+1} y_{k+1} \Bigg\|_2 \qquad (5.24) \\
&\leqslant \left\| \left(\mathbf{I} + \left(\mathbf{X}_k^\top \mathbf{X}_k + \alpha\sigma^2\mathbf{I}\right)^{-1} \mathbf{x}_{k+1}\mathbf{x}_{k+1}^\top\right)^{-1} - \mathbf{I} \right\|_2 \left\| \left(\mathbf{X}_k^\top \mathbf{X}_k + \alpha\sigma^2\mathbf{I}\right)^{-1} \right\|_2 \left\| \mathbf{X}_k^\top \mathbf{y}_k \right\|_2 \\
&\qquad\qquad + \left\| \left(\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1} + \alpha\sigma^2\mathbf{I}\right)^{-1} \right\|_2 \left\| \mathbf{x}_{k+1} y_{k+1} \right\|_2 \qquad (5.25)
\end{aligned}
$$

Здесь мы учли, что $\mathbf{X}_{k+1}^\top = [\mathbf{X}_k^\top, \mathbf{x}_{k+1}]$ и $\mathbf{y}_{k+1} = [\mathbf{y}_k, y_{k+1}]^\top$, тогда $\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1} = \mathbf{X}_k^\top \mathbf{X}_k + \mathbf{x}_{k+1}\mathbf{x}_{k+1}^\top$ и $\mathbf{X}_{k+1}^\top \mathbf{y}_{k+1} = \mathbf{X}_k^\top \mathbf{y}_k + \mathbf{x}_{k+1} y_{k+1}$. Для перехода к (5.24) мы вынесли множитель в первом слагаемом, после чего вынесли общий множитель у обоих слагаемых. Далее для получения (5.25) мы применили неравенство треугольника, а также свойства согласованности и субмультипликативности спектральной нормы. Оценим по отдельности каждое слагаемое в (5.25). В первом множителе первого слагаемого применим формулу для разности обратных

матриц, как мы делали с ковариационными матрицами:

$$\left\|\left(\mathbf{I}+\left(\mathbf{X}_k^\top\mathbf{X}_k+\alpha\sigma^2\mathbf{I}\right)^{-1}\mathbf{x}_{k+1}\mathbf{x}_{k+1}^\top\right)^{-1}-\mathbf{I}\right\|_2\leqslant$$

$$\leqslant\left\|\left(\mathbf{I}+\left(\mathbf{X}_k^\top\mathbf{X}_k+\alpha\sigma^2\mathbf{I}\right)^{-1}\mathbf{x}_{k+1}\mathbf{x}_{k+1}^\top\right)^{-1}\right\|_2\|\mathbf{I}\|_2\left\|\left(\mathbf{X}_k^\top\mathbf{X}_k+\alpha\sigma^2\mathbf{I}\right)^{-1}\mathbf{x}_{k+1}\mathbf{x}_{k+1}^\top\right\|_2\leqslant$$

$$\leqslant\frac{1}{\lambda_{\min}\left(\mathbf{I}+\left(\mathbf{X}_k^\top\mathbf{X}_k+\alpha\sigma^2\mathbf{I}\right)^{-1}\mathbf{x}_{k+1}\mathbf{x}_{k+1}^\top\right)}\frac{\|\mathbf{x}_{k+1}\|_2^2}{\lambda_{\min}\left(\mathbf{X}_k^\top\mathbf{X}_k+\alpha\sigma^2\mathbf{I}\right)}\tag{5.26}$$

$$\leqslant\frac{1}{1+\lambda_{\min}\left(\left(\mathbf{X}_k^\top\mathbf{X}_k+\alpha\sigma^2\mathbf{I}\right)^{-1}\mathbf{x}_{k+1}\mathbf{x}_{k+1}^\top\right)}\frac{M^2}{\lambda_{\min}\left(\mathbf{X}_k^\top\mathbf{X}_k\right)}$$

$$\leqslant\frac{1}{1+\lambda_{\max}\left(\mathbf{X}_k^\top\mathbf{X}_k+\alpha\sigma^2\mathbf{I}\right)\lambda_{\min}\left(\mathbf{x}_{k+1}\mathbf{x}_{k+1}^\top\right)}\frac{M^2}{\lambda_{\min}\left(\mathbf{X}_k^\top\mathbf{X}_k\right)}$$

$$=\frac{M^2}{\lambda_{\min}\left(\mathbf{X}_k^\top\mathbf{X}_k\right)}.\tag{5.27}$$

Выше, при переходе к (5.26), мы снова использовали субмультипликативность, а также выражение для нормы матрицы единичного ранга. Наконец, для получения (5.27) мы применили, что минимальное собственное значение произведения матриц оценивается произведением их минимальных собственных значений, а минимальное собственное значение матрицы единичного ранга $\mathbf{x}_{k+1}\mathbf{x}_{k+1}^\top$ равно нулю. Второй и третий множители первого слагаемого оцениваются следующим образом:

$$\left\|\left(\mathbf{X}_k^\top\mathbf{X}_k+\alpha\sigma^2\mathbf{I}\right)^{-1}\right\|_2\left\|\mathbf{X}_k^\top\mathbf{y}_k\right\|_2\leqslant\frac{\left\|\mathbf{X}_k^\top\mathbf{y}_k\right\|_2}{\lambda_{\min}\left(\mathbf{X}_k^\top\mathbf{X}_k\right)}=\frac{\left\|\sum\limits_{i=1}^{k}\mathbf{x}_iy_i\right\|_2}{\lambda_{\min}\left(\mathbf{X}_k^\top\mathbf{X}_k\right)}$$
$$\leqslant\frac{kM^2}{\lambda_{\min}\left(\mathbf{X}_k^\top\mathbf{X}_k\right)}.\tag{5.28}$$

Наконец, оценим второе слагаемое.

$$\left\|\left(\mathbf{X}_{k+1}^\top\mathbf{X}_{k+1}+\alpha\sigma^2\mathbf{I}\right)^{-1}\right\|_2\|\mathbf{x}_{k+1}y_{k+1}\|_2\leqslant\frac{M^2}{\lambda_{\min}\left(\mathbf{X}_{k+1}^\top\mathbf{X}_{k+1}\right)}\tag{5.29}$$

Итого, собирая воедино (5.27), (5.28) и (5.29), имеем следующую оценку:

$$\|\mathbf{m}_{k+1}-\mathbf{m}_k\|_2\leqslant\frac{kM^3}{\lambda_{\min}^2\left(\mathbf{X}_k^\top\mathbf{X}_k\right)}+\frac{M^2}{\lambda_{\min}\left(\mathbf{X}_{k+1}^\top\mathbf{X}_{k+1}\right)}$$
$$=k\cdot o(k^{-1})+o(k^{-1/2})=o(1)$$

при $k\to\infty$. Таким образом, получили требуемую сходимость. □

Наконец, докажем теорему о сходимости полного байесовского прогноза на отложенной выборке.

Доказательство теоремы 5.4.5. Полный байесовский прогноз для одиночной модели выражается по формуле

$$p(\mathbf{y}_{\text{test}}|\mathbf{X}_{\text{test}}, \mathbf{X}_k, \mathbf{y}_k) = \int p(\mathbf{y}_{\text{test}}|\mathbf{X}_{\text{test}}, \mathbf{w})p(\mathbf{w}|\mathbf{X}_k, \mathbf{y}_k)d\mathbf{w}$$

$$= \int \mathcal{N}(\mathbf{y}_{\text{test}}|\mathbf{X}_{\text{test}}\mathbf{w}, \sigma^2\mathbf{I})\mathcal{N}(\mathbf{w}|\mathbf{m}_k, \mathbf{\Sigma}_k)d\mathbf{w} \tag{5.30}$$

$$= \mathcal{N}(\mathbf{y}_{\text{test}}|\mathbf{X}_{\text{test}}\mathbf{m}_k, \sigma^2\mathbf{I} + \mathbf{X}_{\text{test}}\mathbf{\Sigma}_k\mathbf{X}_{\text{test}}^\top). \tag{5.31}$$

Здесь при переходе от (5.30) к (5.31) мы воспользовались известным выражением из [11]. В условиях настоящей теоремы справедливы результаты теоремы 5.4.4. Следовательно, $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \to 0$ и $\|\mathbf{\Sigma}_{k+1} - \mathbf{\Sigma}_k\|_F \to 0$ при $k \to \infty$. Далее, остается показать сходимость математического ожидания и ковариационной матрицы нормального распределения прогноза модели. Для математического ожидания при $k \to \infty$ выполнено

$$\|\mathbf{X}_{\text{test}}\mathbf{m}_{k+1} - \mathbf{X}_{\text{test}}\mathbf{m}_k\|_2 \leqslant \|\mathbf{X}_{\text{test}}\|_2\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \to 0. \tag{5.32}$$

Для ковариационной матрицы, ввиду субмультипликативности нормы Фробениуса, при $k \to \infty$ справедливо следующее:

$$\|\sigma^2\mathbf{I}+\mathbf{X}_{\text{test}}\mathbf{\Sigma}_{k+1}\mathbf{X}_{\text{test}}^\top-\sigma^2\mathbf{I}-\mathbf{X}_{\text{test}}\mathbf{\Sigma}_k\mathbf{X}_{\text{test}}^\top\|_F \leqslant \|\mathbf{X}_{\text{test}}\|_F^2\|\mathbf{\Sigma}_{k+1}-\mathbf{\Sigma}_k\|_F \to 0. \tag{5.33}$$

Наконец, имея сходимость математического ожидания (5.32) и ковариационной матрицы (5.33), действуем аналогично доказательству теоремы 5.4.2 и получаем, что

$$D_{\text{KL}}\left(p(\mathbf{y}_{\text{test}}|\mathbf{X}_{\text{test}}, \mathbf{X}_k, \mathbf{y}_k)\|p(\mathbf{y}_{\text{test}}|\mathbf{X}_{\text{test}}, \mathbf{X}_{k+1}, \mathbf{y}_{k+1})\right) \to 0$$

при $k \to \infty$, завершая доказательство данной теоремы. □

5.6. Вычислительные эксперименты

В данном разделе мы проводим эмпирический анализ сходимости распределения оптимальных параметров в линейных моделях. Программный код, реализованный на фреймворке **PyTorch**, доступен публично по адресам

https://github.com/kisnikser/Likelihood-Bootstrapping,
https://github.com/kisnikser/Posterior-Distributions-Proximity.

Эксперимент состоит из нескольких частей. Сперва, в параграфе 5.6.1 мы строим графики апостериорных распределений и показываем их сходимость на модельном примере. Далее, в параграфах 5.6.2 и 5.6.3 мы проверяем сходимость предложенных критериев достаточности. Затем, в параграфе 5.6.4 мы исследуем их зависимость от гиперпараметра-порога. Раздел завершается параграфом 5.6.5, где мы сравниваем критерии на наборе реальных выборок с задачей регрессии.

5.6.1. Близость апостериорных распределений

Используется синтетическая выборка, сгенерированная из модели линейной регрессии (уточнить параметры), причем для наглядности рассматриваются одномерный и двумерный случаи. Число объектов $m = 100$, среднеквадратичное отклонение шума $\sigma = 1$, априорное распределение параметров $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{0}, \mathbf{I})$. Далее представлены рисунки 5.3 и 5.4, на которых изображено сходство апостериорных распределений, определенных на схожих подвыборках размера k и $k+1$ при варьировании числа k.

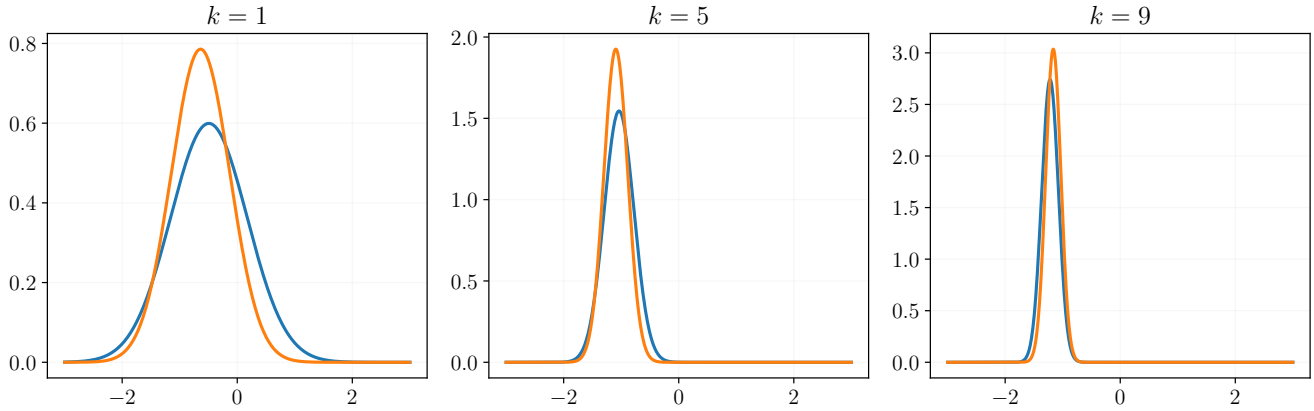

Рисунок 5.3 — Изменение апостериорных распределений параметров на схожих подвыборка по мере увеличения их размера. Одномерный случай, где на графиках изображены плотности распределений

По построенные графикам видно, что при увеличении числа обучающих объектов оптимизационная поверхность линейных моделей (апостериорное

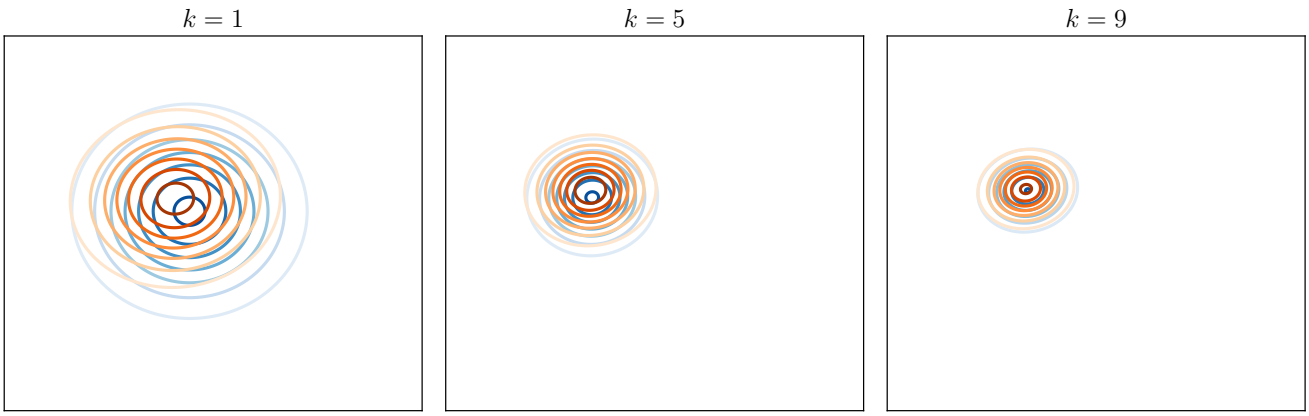

Рисунок 5.4 — Изменение апостериорных распределений параметров на схожих подвыборка по мере увеличения их размера. Двумерный случай, где на графиках изображены линии уровня

распределение параметров) перестает меняться. Эти результаты подкрепляют идеи, на основе которых построены определения достаточного размера выборки.

5.6.2. Корректность определений D- и M-достаточности

Прежде чем перейти к вычислительным экспериментам, сделаем важное замечание. Поскольку на практике нет возможности посчитать указанные в определениях (5.3), (5.4) математическое ожидание и дисперсию, для их оценки предлагается воспользоваться техникой бутстрап. А именно, сгенерируем из заданной $\mathfrak{D}_m$ некоторое число B подвыборок размера k с возвращением. Для каждой из них получим оценку параметров $\hat{\mathbf{w}}_k$ и посчитаем значение $L(\mathfrak{D}_m, \hat{\mathbf{w}}_k)$. Для оценки будем использовать выборочное среднее и несмещенную выборочную дисперсию (по бутстрап-подвыборкам). Предложенные выше определения можно применять и в тех задачах, когда минимизируется произвольная функция потерь, а не максимизируется функция правдоподобия. Мы не приводим никаких теоретических обоснований этого, однако на практике такая эвристика оказывается достаточно удачной.

Перейдем к эксперименту. Синтетические данные сгенерированы из моделей линейной и логистической регрессий. Число объектов $m = 1000$, число признаков $n = 20$. Используется $B = 1000$ бустрапированных подвыборок для

оценки математического ожидания и дисперсии функции ошибки. Подсчитываются значения функций $D(k)$ и $M(k)$. Датасет с задачей регрессии Liver Disorders из UCI (ссылка или что-то) содержит $m = 345$ объектов и $n = 5$ признаков. Мы также используем $B = 1000$ бутстрапированных подвыборок.

На рисунке 5.5 (а) можно видеть полученные зависимости между используемым размером подвыборки k и рассматриваемыми функциями $D(k)$ и $M(k)$ для синтетической выборки с задачей регрессии. Результаты для синтетической выборки с задачей классификации представлены на рисунке 5.5 (б). В то же время, на рисунке 5.5 (в) мы видим аналогичные графики для датасета Liver Disorders. Видно, что во всех случаях значения функций $D(k)$ и $M(k)$ стремятся к нулю при увеличении размера выборки. Эти эмпирические результаты подтверждают теоретические, полученные ранее.

5.6.3. Корректность определений KL- и S-достаточности

В этом параграфе мы сперва проводим экспериментальное подтверждение предположения из теоремы 5.4.4 о том, что минимальное собственное значение матрицы $\mathbf{X}_k^\top \mathbf{X}_k$ растет быстрее $\sqrt{k}$. Затем мы проверяем сходимость введенных критериев $KL(k)$ и $S(k)$ при изменении обучающей выборки.

Асимптотическое поведение минимального собственного значения матрицы $\mathbf{X}_k^\top \mathbf{X}_k$. Используются синтетические данные, сгенерированные из модели линейной регрессии. Число объектов $m = 500$, число признаков $n = 10$. Один объект последовательно удаляется из данной выборки, пока число объектов в подвыборке не станет равно числу признаков. Для каждого размера выборки k подсчитывается минимальное собственное значение матрицы $\mathbf{X}_k^\top \mathbf{X}_k$. Такой процесс повторяется $B = 100$ раз. Аналогичные действия проводятся и на датасете Liver Disorders с $m = 345$ объектами и $n = 5$ признаками. Результаты представлены на рисунке 5.6. Видно, что при стремлении размера выборки к бесконечности минимальное собственное значение также стремится к бесконечности. Помимо этого, как и требуется в теореме 5.4.4, этот график лежит выше, чем $\sqrt{k}$.

Сходимость функций $KL(k)$ и $S(k)$. На рисунке 5.7 (а) мы можем наблюдать полученные зависимости между доступным размером выборки k и

предложенными функциями $KL(k)$ и $S(k)$ для синтетической выборки с задачей регрессии. В то же время, на рисунке 5.7 (б) можно видеть аналогичные графики для датасета Liver Disorders. Для обеих выборок значения функции $KL(k)$ стремятся к нулю при увеличении размера выборки, а значения $S(k)$ стремятся к единице. Эти эмпирические результаты подтверждают теоретические, представленные ранее.

5.6.4. Зависимость критериев от гиперпараметра ε

В определениях достаточности по каждому из критериев: D, M, KL, S участвует гиперпараметр ε, который отвечает за порог для достаточного размера выборки m^*. С целью изучения зависимости между ними, мы представляем графики на рисунке 5.8, которые демонстрируют, какой размер выборки следует выбрать, чтобы обеспечить определенный уровень уверенности.

По результатам эксперимента видно, что все четыре критерия обладают примерно одинаковой зависимостью от значения ε. Таким образом, важно правильно подбирать значение гиперпараметра для корректного определения достаточного размера выборки.

5.6.5. Сравнение критериев на множестве выборок

Чтобы оценить эффективность предложенных методов на разных наборах данных, были выбраны выборки из открытой библиотеки UCI (ссылка или как-то еще). Подробная информация о каждом наборе данных, количество наблюдений и количество признаков представлены в таблице 4. Для демонстрационных целей были выбраны такие значения гиперпараметра ε, при которых значения функций $D(k)$ и $M(k)$ уменьшаются в 1000 раз, а значения функций $KL(k)$ и $S(k)$ приближаются к предельным вдвое. Соответствующие результаты приведены в таблице 4. Пропуски означают, что первоначальный размер выборки недостаточен.

Таблица 4 — Сравнение предложенных критериев достаточного размера выборки на множестве реальных выборок с задачей регрессии. Пропуски означают, что первоначальный размер выборки недостаточен

Название выборки	Объектов m	Признаков n	D	M	KL	S
Abalone	4177	8	96	96	3921	4091
Auto MPG	392	8	15	15	62	—
Automobile	159	25	70	156	156	—
Liver Disorders	345	6	12	19	—	—
Servo	167	4	41	—	163	163
Forest fires	517	12	208	—	507	—
Wine Quality	6497	12	144	144	5305	6099
Energy Efficiency	768	9	24	442	—	—
Student Performance	649	32	129	177	636	—
Facebook Metrics	495	18	31	388	475	—
Real Estate Valuation	414	7	15	23	—	—
Heart Failure	299	12	63	224	276	293
BMT: children	142	36	—	—	109	—

По результатам видно, что критерии D- и M-достаточности часто говорят о схожем значении достаточного размера выборки. Тем временем, критерий S-достаточности часто оказывается более консервативным по сравнению с KL-достаточностью.

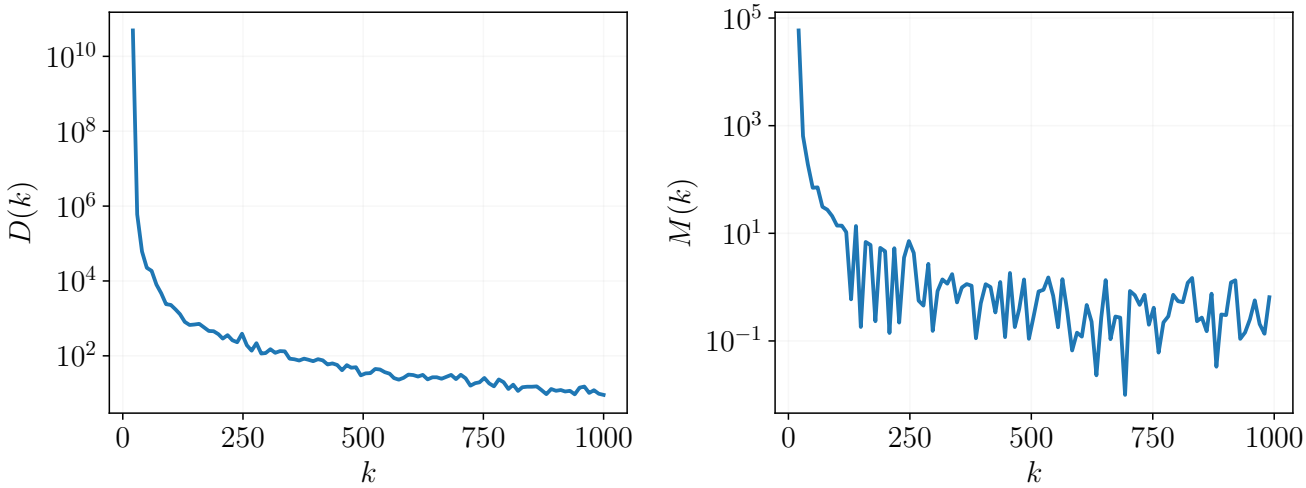

а) Синтетическая выборка (линейная регрессия)

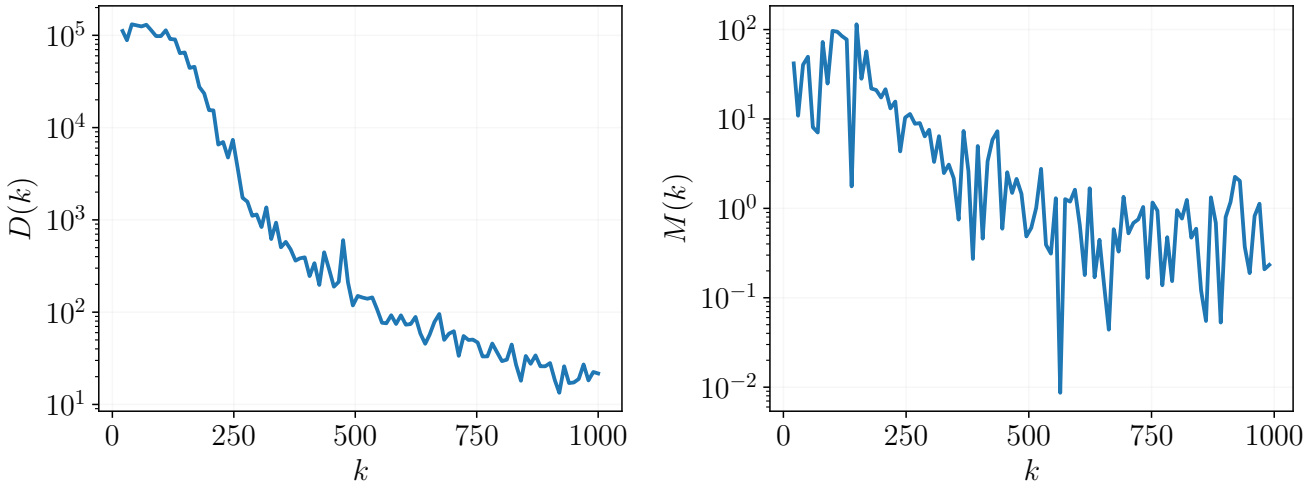

б) Синтетическая выборка (логистическая регрессия)

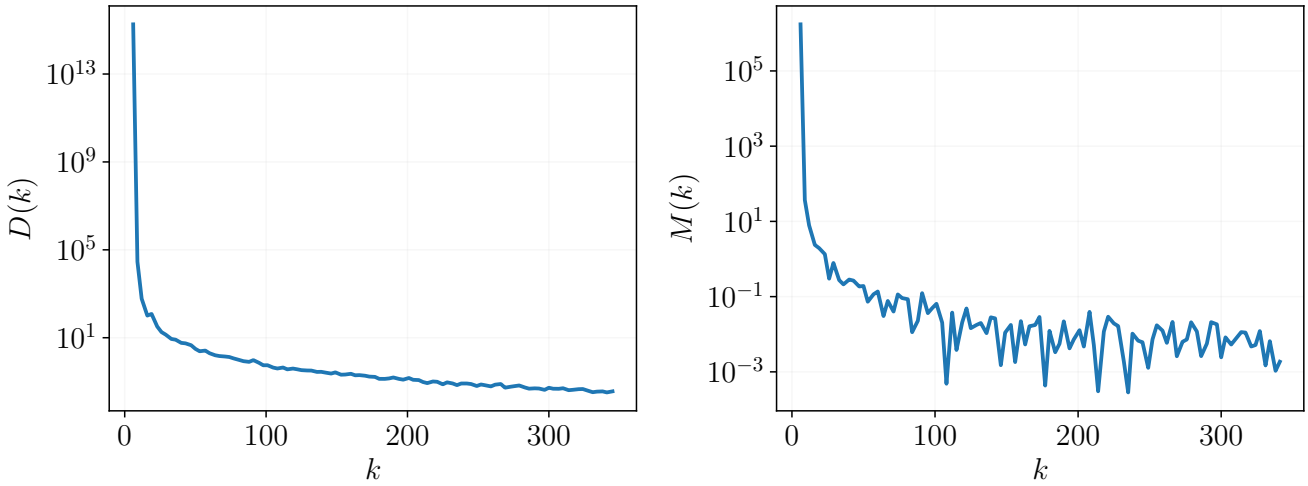

в) Выборка Liver Disorders (регрессия)

Рисунок 5.5 — Сходимость функций $D(k)$ и $M(k)$ в различных задачах и на различных выборках. Значения обоих критериев стремятся к нулю при увеличении размера выбори

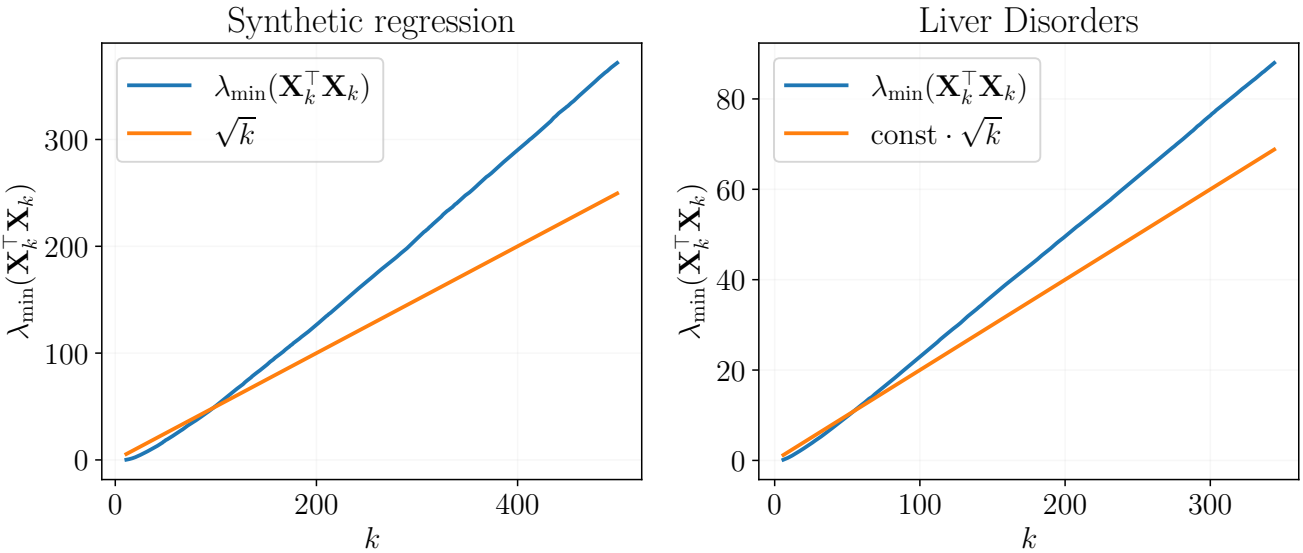

Рисунок 5.6 — Изменение минимального собственного значения матрицы $\mathbf{X}_k^\top \mathbf{X}_k$ при увеличении размера выборки в задачах синтетической линейной регрессии и регрессии на датасете Liver Disorders

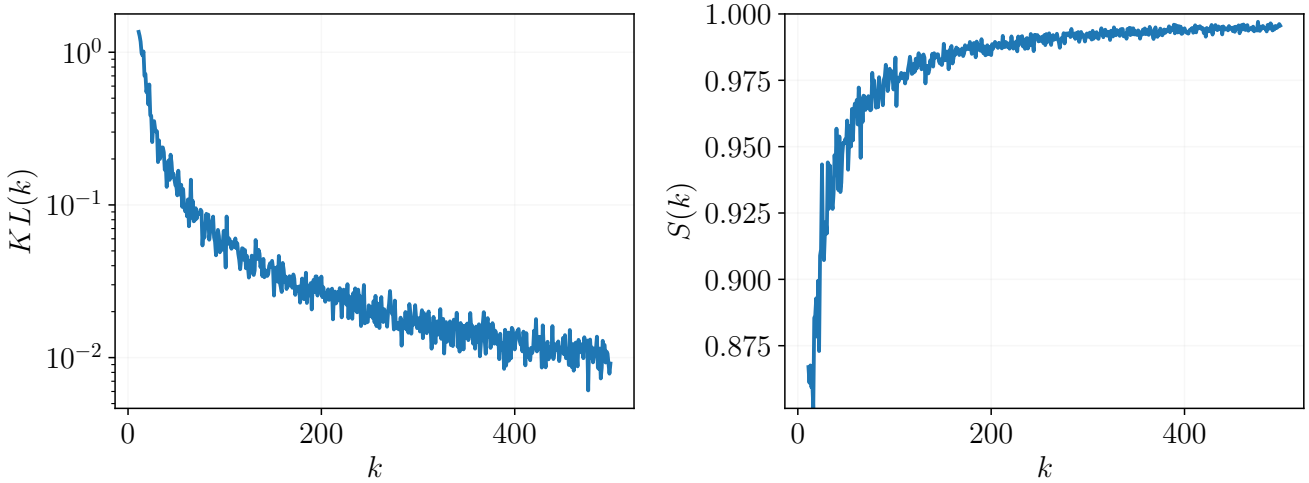

а) Синтетическая выборка (линейная регрессия)

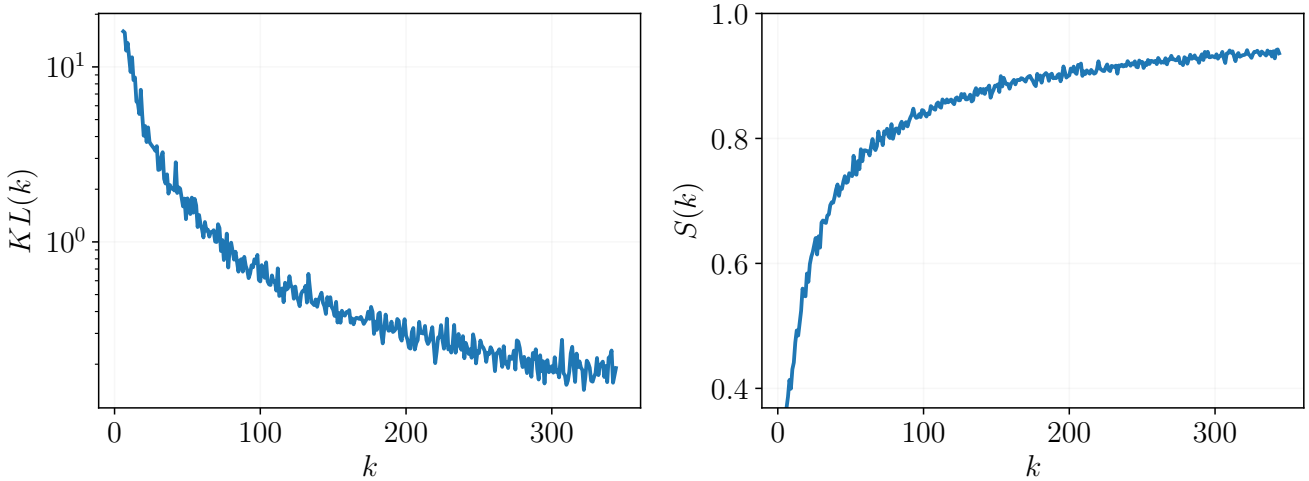

б) Выборка Liver Disorders (регрессия)

Рисунок 5.7 — Сходимость функций $KL(k)$ и $S(k)$ в различных задачах и на различных выборках. Оба критерия стремятся к предельным значениям при увеличении размера выбори

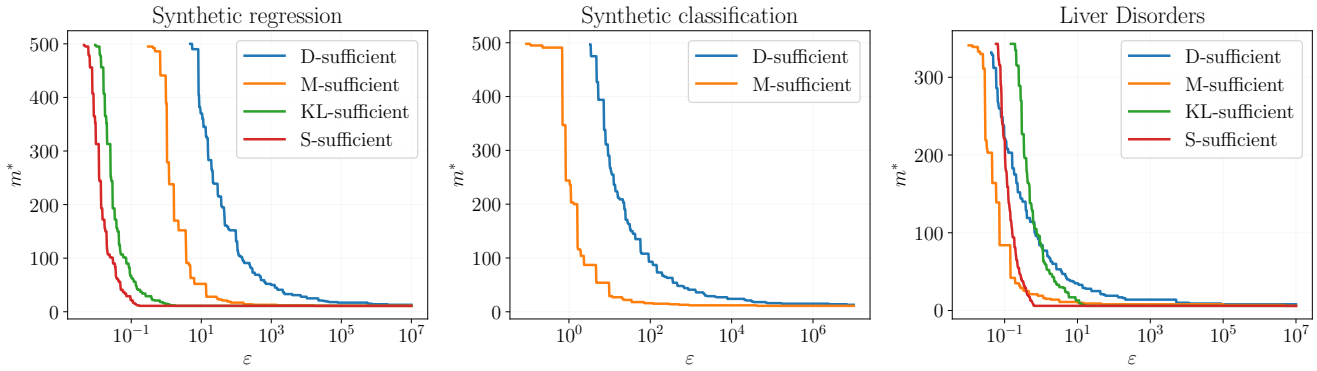

Рисунок 5.8 — Зависимость достаточного размера выборки согласно введенным критериям от гиперпараметра ε. Рассматриваются три задачи: синтетическая регрессия и классификация, а также регрессия на датасете Liver Disorders. Чем больше значение гиперпараметра ε, тем меньше требуется обучающих объектов

5.7. Обсуждение

Логистическая регрессия. В задаче бинарной классификации с метками $y \in \{0, 1\}$ логистическая регрессия задается правдоподобием

$$p(y|\mathbf{x}, \mathbf{w}) = \sigma(\mathbf{w}^\top \mathbf{x})^y (1 - \sigma(\mathbf{w}^\top \mathbf{x}))^{1-y}, \qquad \sigma(z) = \frac{1}{1 + e^{-z}}.$$

Апостериорное распределение параметров уже не является нормальным; сопряженного априора не существует. Тем не менее при достаточно большом размере выборки апостериор асимптотически нормален (результат Бернштейна—фон Мизеса). На практике критерии KL и S применяются к логистической регрессии, а порог достаточности выбирается эмпирически [10]. Теоретическое обоснование сходимости для логистической регрессии требует дополнительного анализа.

Обобщенные линейные модели (GLM). Обобщенные линейные модели включают линейную и логистическую регрессию как частные случаи [13]. Модель задается линейным предиктором $\eta = \mathbf{w}^\top \mathbf{x}$, функцией связи и распределением из экспоненциального семейства. Для GLM с канонической функцией связи оценка ММП существует при определенных условиях на данные. Сходимость апостериора и применимость критериев D, M, KL, S зависят от конкретного вида модели; для ряда GLM (например, регрессии Пуассона) возможны аналоги теорем 5.4.1, 5.4.2, 5.4.3 при дополнительных предположениях.

Сравнительный анализ критериев. Критерии D и M основаны на бутстрапировании подвыборок и вычислении правдоподобия в точке ОМП. Их преимущество — простота вычислений: не требуется полное апостериорное распределение. Критерии KL и S требуют знания апостериора на схожих подвыборках; для линейной регрессии с сопряженным априором они вычисляются аналитически. Эмпирические исследования показывают, что KL-достаточный размер, как правило, оказывается наименьшим, а S-достаточный — наибольшим при фиксированном пороге ε. Это объясняется различной чувствительностью KL-дивергенции и s-score к различиям распределений. Выбор критерия зависит от задачи: при необходимости консервативной оценки предпочтителен S; при ограничениях на объем данных может быть достаточен критерий KL.

Заключение

Основные результаты работы заключаются в следующем.

1. На основе анализа ...
2. Численные исследования показали, что ...
3. Математическое моделирование показало ...
4. Для выполнения поставленных задач был создан ...

И какая-нибудь заключающая фраза.

В заключение автор выражает благодарность и большую признательность научному руководителю Грабовому А. В. за поддержку, помощь, обсуждение результатов и научное руководство.

Публикации автора по теме диссертации

В изданиях, входящих в международную базу цитирования Scopus

A1. *Kiselev, N. S.* Sample Size Determination: Likelihood Bootstrapping / N. S. Kiselev, A. V. Grabovoy // Computational Mathematics and Mathematical Physics. — 2025. — Vol. 65, no. 2. — P. 416—423.

A2. *Kiselev, N.* Sample Size Determination: Posterior Distributions Proximity / N. Kiselev, A. Grabovoy // Computational Management Science. — 2025. — Vol. 22, no. 1. — P. 1.

A3. *Kiselev, N. S.* Unraveling the Hessian: A Key to Smooth Convergence in Loss Function Landscapes / N. S. Kiselev, A. V. Grabovoy // Doklady Mathematics. — 2024. — Vol. 110, S1. — S49—S61.

В сборниках трудов конференций

A4. *Киселев, Н.* Определение достаточного размера выборки по апостериорному распределению параметров модели / Н. Киселев, А. Грабовой // Труды 66-й Всероссийской научной конференции МФТИ, 1–6 апреля 2024 г. — 2024. — С. 141.

A5. *Meshkov, V.* ConvNets Landscape Convergence: Hessian-Based Analysis of Matricized Networks / V. Meshkov, N. Kiselev, A. Grabovoy // 2024 Ivannikov Ispras Open Conference (ISPRAS). — 2024. — P. 1—10.

A6. *Киселев, Н. С.* Сходимость поверхности функции потерь как признак достаточного размера выборки / Н. С. Киселев, А. В. Грабовой // Труды 67-й Всероссийской научной конференции МФТИ. — 2025.

A7. *Мешков, В. С.* Сходимость ландшафта сверточных нейронных сетей: анализ матричных сетей на основе гесиана / В. С. Мешков, Н. С. Киселев, А. В. Грабовой // Труды 67-й Всероссийской научной конференции МФТИ. — 2025.

A8. *Киселев, Н. С.* Достаточный размер обучающей выборки и его связь со сходимостью поверхности функции потерь / Н. С. Киселев, В. С. Мешков, А. В. Грабовой // Тезисы докладов 22-й всероссийской конференции с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября, 2025 г. — 2025. — С. 73—76.

Список литературы

1. *Vapnik, V. N.* The Nature of Statistical Learning Theory / V. N. Vapnik. — 1st. — New York, NY, USA : Springer, 1995.
2. Scaling laws for neural language models / J. Kaplan [et al.] // arXiv preprint arXiv:2001.08361. — 2020.
3. Training compute-optimal large language models / J. Hoffmann [et al.] // Proceedings of the 36th International Conference on Neural Information Processing Systems. — New Orleans, LA, USA : Curran Associates Inc., 2022. — (NIPS '22).
4. Visualizing the loss landscape of neural nets / H. Li [et al.] // Proceedings of the 32nd International Conference on Neural Information Processing Systems (NeurIPS 2018). — Curran Associates Inc., 2018. — P. 6389—6399.
5. *Fort, S.* Emergent properties of the local geometry of neural loss landscapes / S. Fort, S. Ganguli // arXiv preprint arXiv:1910.05929. — 2019.
6. Essentially no barriers in neural network energy landscape / F. Draxler [et al.] // Proceedings of the 35th International Conference on Machine Learning (ICML 2018). Vol. 80. — PMLR, 2018. — P. 1309—1318. — (Proceedings of Machine Learning Research).
7. Loss surfaces, mode connectivity, and fast ensembling of DNNs / T. Garipov [et al.] // Proceedings of the 32nd International Conference on Neural Information Processing Systems (NeurIPS 2018). — Curran Associates Inc., 2018. — P. 8803—8812.
8. Entropy-SGD: biasing gradient descent into wide valleys / P. Chaudhari [et al.] // Journal of Statistical Mechanics: Theory and Experiment. — 2019. — Vol. 2019, no. 12. — P. 124018.
9. *Papyan, V.* Measurements of three-level hierarchical structure in the outliers in the spectrum of deepnet Hessians / V. Papyan // Proceedings of the 36th International Conference on Machine Learning (ICML 2019). Vol. 97. — PMLR, 2019. — P. 5012—5021. — (Proceedings of Machine Learning Research).

10. *Motrenko*, *A.* Sample size estimation for logistic regression using cross-validation and Kullback–Leibler divergence / A. Motrenko, V. Strijov // Journal of Machine Learning Research. — 2014. — Vol. 15. — P. 743—761.

11. *Bishop*, *C. M.* Pattern Recognition and Machine Learning / C. M. Bishop. — New York, NY, USA : Springer, 2006.

12. *Aduenko*, *A.* Selection of multimodels in classification tasks : PhD thesis / Aduenko Alexander. — MIPT, 2017. — URL: https://www.frccsc.ru/diss-council/00207305/diss/list/aduenko_aa.

13. *McCullagh*, *P.* Generalized Linear Models / P. McCullagh, J. A. Nelder. — 2nd. — London, UK : Chapman, Hall, 1989.

Список рисунков

3.1 Визуализация предположения 3.2.1 о слабом градиентном рассогласовании для эмпирических функций потерь на k и $k+1$ объектах 45
3.2 Пример зависимости абсолютного одноточечного критерия $\Delta_1(k)$ от размера выборки k в логарифмических координатах 65
3.3 Пример зависимости среднеквадратичного критерия $\Delta_2(k)$ от размера выборки k в логарифмических координатах 66
3.4 Пример зависимости среднеквадратичного критерия $\Delta_2^{(D)}(k)$ от размера выборки k для различных размерностей подпространства D 66
3.5 Пример стабилизации ведущих собственных значений матрицы Гессе при увеличении объема обучающей выборки 67

5.1 Визуализация критериев D-достаточности (уменьшение дисперсии функции правдоподобия) и M-достаточности (уменьшение изменения функции правдоподобия при добавлении новых объектов) размера выборки в вероятностной модели линейной регрессии 90
5.2 Визуализация критериев KL-достаточности и S-достаточности (близость апостериорных распределений параметров на схожих подвыборках) размера выборки в вероятностной модели линейной регрессии 92
5.3 Изменение апостериорных распределений параметров на схожих подвыборка по мере увеличения их размера. Одномерный случай, где на графиках изображены плотности распределений 103
5.4 Изменение апостериорных распределений параметров на схожих подвыборка по мере увеличения их размера. Двумерный случай, где на графиках изображены линии уровня 104
5.5 Сходимость функций $D(k)$ и $M(k)$ в различных задачах и на различных выборках. Значения обоих критериев стремятся к нулю при увеличении размера выбори 108

5.6 Изменение минимального собственного значения матрицы $\mathbf{X}_k^\top \mathbf{X}_k$ при увеличении размера выборки в задачах синтетической линейной регрессии и регрессии на датасете Liver Disorders 109
5.7 Сходимость функций $KL(k)$ и $S(k)$ в различных задачах и на различных выборках. Оба критерия стремятся к предельным значениям при увеличении размера выбори 110
5.8 Зависимость достаточного размера выборки согласно введенным критериям от гиперпараметра ε. Рассматриваются три задачи: синтетическая регрессия и классификация, а также регрессия на датасете Liver Disorders. Чем больше значение гиперпараметра ε, тем меньше требуется обучающих объектов 111

Список таблиц

1 Архитектуры и датасеты, используемые в вычислительных экспериментах 61
2 Параметры оценки критериев сходимости 64
3 Оцененные показатели степенного закона убывания критериев сходимости 65
4 Сравнение предложенных критериев достаточного размера выборки на множестве реальных выборок с задачей регрессии. Пропуски означают, что первоначальный размер выборки недостаточен 107

Приложение А

Доказательства теоретических результатов

А.1. Гаусс-ньютоновская компонента матрицы Гессе для трансформерной архитектуры нейронной сети

В данном приложении приводятся детальные выкладки, на которые опирается основной текст раздела о трансформерных архитектурах. Мы сохраняем обозначения основного текста: рассматривается одно-головый трансформерный блок архитектуры Post-LN

$$\mathbf{U} = \mathbf{X} + \mathrm{SA}(\mathbf{X}), \qquad \mathbf{Y} = \mathrm{LN}(\mathbf{U}),$$

$$\mathrm{FFN}(\mathbf{Y}) = \sigma(\mathbf{Y}\mathbf{W}_1)\mathbf{W}_2, \qquad \mathbf{S} = \mathbf{Y} + \mathrm{FFN}(\mathbf{Y}), \qquad \mathbf{Z} = \mathrm{LN}(\mathbf{S}),$$

где

$$\mathrm{SA}(\mathbf{X}) = \mathbf{\Pi}(\mathbf{X})\mathbf{X}\mathbf{W}_V, \qquad \mathbf{\Pi}(\mathbf{X}) = \mathrm{softmax}\left(\frac{\mathbf{X}\mathbf{W}_Q\mathbf{W}_K^\top\mathbf{X}^\top}{\sqrt{d_k}}\right).$$

Выход блока обозначается через

$$\mathbf{z} = \mathrm{vec_r}(\mathbf{Z}) \in \mathbb{R}^{Td}.$$

А.1.1. Якобиан и оценка нормы оператора LayerNorm

Рассмотрим произвольную матрицу

$$\mathbf{U} \in \mathbb{R}^{T\times d}.$$

Введем матрицу центрирования

$$\mathbf{C}_d = \mathbf{I}_d - \frac{1}{d}\mathbf{1}_d\mathbf{1}_d^\top \in \mathbb{R}^{d\times d}.$$

Тогда центрированное представление строки задается оператором

$$\mathbf{M}(\mathbf{U}) = \mathbf{U}\mathbf{C}_d = \mathbf{U} - \frac{1}{d}\mathbf{U}\mathbf{1}_d\mathbf{1}_d^\top.$$

Вектор построчных стандартных отклонений определим формулой

$$\boldsymbol{\sigma}(\mathbf{U}) = \frac{1}{\sqrt{d}} \left(\mathbf{M}(\mathbf{U})^{\circ 2}\mathbf{1}_d\right)^{\circ \frac{1}{2}} \in \mathbb{R}^T,$$

а диагональную матрицу обратных стандартных отклонений — как

$$\mathbf{P}(\mathbf{U}) = \operatorname{diag}^{-1}\left(\boldsymbol{\sigma}(\mathbf{U})\right) \in \mathbb{R}^{T\times T}.$$

Тогда LayerNorm без аффинных параметров $\boldsymbol{\gamma}$,$\boldsymbol{\beta}$ записывается в матричном виде:

$$\mathrm{LN}(\mathbf{U}) = \mathbf{P}(\mathbf{U})\mathbf{M}(\mathbf{U}). \tag{A.1}$$

Для дальнейшего дифференцирования будем предполагать, что все построчные дисперсии положительны:

$$\sigma_{\min}(\mathbf{U}) := \min_{t=1,\dots,T} \sigma_t(\mathbf{U}) > 0. \tag{A.2}$$

Это стандартное техническое предположение, используемое и в статье-источнике при выводе якобиана LayerNorm.

Лемма A.1.1. *Якобиан LayerNorm по входу имеет вид*

$$\begin{aligned}\mathbf{J}_{\mathrm{LN}}(\mathbf{U}) &= \frac{\partial \operatorname{vec_r}(\mathrm{LN}(\mathbf{U}))}{\partial \operatorname{vec_r}(\mathbf{U})^\top} \\ &= \left(\mathbf{P}(\mathbf{U}) \otimes \mathbf{I}_d\right)\mathbf{G}_d + \left(\mathbf{I}_T \otimes \mathbf{M}(\mathbf{U})^\top\right)\frac{\partial \operatorname{vec_r}(\mathbf{P}(\mathbf{U}))}{\partial \operatorname{vec_r}(\mathbf{U})^\top},\end{aligned} \tag{A.3}$$

где

$$\mathbf{G}_d = \frac{\partial \operatorname{vec_r}(\mathbf{M}(\mathbf{U}))}{\partial \operatorname{vec_r}(\mathbf{U})^\top} = \mathbf{I}_{Td} - \frac{1}{d}\left(\mathbf{I}_T \otimes \mathbf{1}_{d\times d}\right).$$

Доказательство. Из (A.1) имеем

$$\mathrm{LN}(\mathbf{U}) = \mathbf{P}(\mathbf{U})\mathbf{M}(\mathbf{U}).$$

Применим правило дифференцирования матричного произведения к построчной векторизации:

$$\frac{\partial \operatorname{vec_r}(\mathbf{P}(\mathbf{U})\mathbf{M}(\mathbf{U}))}{\partial \operatorname{vec_r}(\mathbf{U})^\top} = \left(\mathbf{P}(\mathbf{U}) \otimes \mathbf{I}_d\right)\frac{\partial \operatorname{vec_r}(\mathbf{M}(\mathbf{U}))}{\partial \operatorname{vec_r}(\mathbf{U})^\top} + \left(\mathbf{I}_T \otimes \mathbf{M}(\mathbf{U})^\top\right)\frac{\partial \operatorname{vec_r}(\mathbf{P}(\mathbf{U}))}{\partial \operatorname{vec_r}(\mathbf{U})^\top}.$$

Остается вычислить производную центрирующего оператора. Так как

$$\mathbf{M}(\mathbf{U}) = \mathbf{U}\mathbf{C}_d,$$

то для построчной векторизации выполняется

$$\mathrm{vec_r}(\mathbf{M}(\mathbf{U})) = (\mathbf{I}_T \otimes \mathbf{C}_d)\,\mathrm{vec_r}(\mathbf{U}).$$

Следовательно,

$$\frac{\partial\,\mathrm{vec_r}(\mathbf{M}(\mathbf{U}))}{\partial\,\mathrm{vec_r}(\mathbf{U})^\top} = \mathbf{I}_T \otimes \mathbf{C}_d = \mathbf{I}_{Td} - \frac{1}{d}\,(\mathbf{I}_T \otimes \mathbf{1}_{d\times d}) = \mathbf{G}_d.$$

Подставляя это равенство в предыдущую формулу, получаем (A.3). Данная форма совпадает с матричным представлением якобиана LayerNorm в статье-источнике. □

Лемма A.1.2. *Пусть выполнено условие* (A.2). *Тогда*

$$\|\mathbf{J}_{\mathrm{LN}}(\mathbf{U})\|_2 \leqslant \frac{1}{\sigma_{\min}(\mathbf{U})} + \frac{\|\mathbf{U}\|_2^2}{\sqrt{d}\,\sigma_{\min}(\mathbf{U})^3}.$$

Доказательство. По лемме A.1.1

$$\mathbf{J}_{\mathrm{LN}}(\mathbf{U}) = (\mathbf{P}(\mathbf{U}) \otimes \mathbf{I}_d)\,\mathbf{G}_d + \left(\mathbf{I}_T \otimes \mathbf{M}(\mathbf{U})^\top\right) \frac{\partial\,\mathrm{vec_r}(\mathbf{P}(\mathbf{U}))}{\partial\,\mathrm{vec_r}(\mathbf{U})^\top}.$$

Следовательно, по неравенству треугольника и субмультипликативности спектральной нормы

$$\|\mathbf{J}_{\mathrm{LN}}(\mathbf{U})\|_2 \leqslant \|\mathbf{P}(\mathbf{U}) \otimes \mathbf{I}_d\|_2\,\|\mathbf{G}_d\|_2 + \left\|\mathbf{I}_T \otimes \mathbf{M}(\mathbf{U})^\top\right\|_2 \left\|\frac{\partial\,\mathrm{vec_r}(\mathbf{P}(\mathbf{U}))}{\partial\,\mathrm{vec_r}(\mathbf{U})^\top}\right\|_2.$$

Используя свойство нормы произведения Кронекера, получаем

$$\|\mathbf{P}(\mathbf{U}) \otimes \mathbf{I}_d\|_2 = \|\mathbf{P}(\mathbf{U})\|_2, \qquad \left\|\mathbf{I}_T \otimes \mathbf{M}(\mathbf{U})^\top\right\|_2 = \|\mathbf{M}(\mathbf{U})\|_2.$$

Поэтому

$$\|\mathbf{J}_{\mathrm{LN}}(\mathbf{U})\|_2 \leqslant \|\mathbf{P}(\mathbf{U})\|_2\|\mathbf{G}_d\|_2 + \|\mathbf{M}(\mathbf{U})\|_2 \left\|\frac{\partial\,\mathrm{vec_r}(\mathbf{P}(\mathbf{U}))}{\partial\,\mathrm{vec_r}(\mathbf{U})^\top}\right\|_2. \tag{A.4}$$

Шаг 1. Оценка нормы $\mathbf{G}_d$. Так как

$$\mathbf{G}_d = \mathbf{I}_T \otimes \mathbf{C}_d,$$

а матрица $\mathbf{C}_d$ есть ортогональный проектор на подпространство векторов с нулевой суммой координат, то

$$\|\mathbf{C}_d\|_2 = 1, \qquad \|\mathbf{G}_d\|_2 = \|\mathbf{I}_T \otimes \mathbf{C}_d\|_2 = 1.$$

Шаг 2. Оценка нормы $\mathbf{P}(\mathbf{U})$. Матрица $\mathbf{P}(\mathbf{U})$ диагональна, и на ее диагонали стоят числа

$$\frac{1}{\sigma_1(\mathbf{U})}, \dots, \frac{1}{\sigma_T(\mathbf{U})}.$$

Следовательно,

$$\|\mathbf{P}(\mathbf{U})\|_2 = \max_{t=1,\dots,T} \frac{1}{\sigma_t(\mathbf{U})} = \frac{1}{\sigma_{\min}(\mathbf{U})}.$$

Шаг 3. Оценка нормы $\mathbf{M}(\mathbf{U})$. Поскольку

$$\mathbf{M}(\mathbf{U}) = \mathbf{U}\mathbf{C}_d,$$

имеем

$$\|\mathbf{M}(\mathbf{U})\|_2 \leqslant \|\mathbf{U}\|_2 \|\mathbf{C}_d\|_2 \leqslant \|\mathbf{U}\|_2.$$

Шаг 4. Оценка нормы производной $\partial \operatorname{vec_r}(\mathbf{P}(\mathbf{U}))/\partial \operatorname{vec_r}(\mathbf{U})^\top$. Рассмотрим фиксированную строку $\mathbf{m}_t^\top \in \mathbb{R}^{1\times d}$ матрицы $\mathbf{M}(\mathbf{U})$. Тогда

$$\sigma_t(\mathbf{U}) = \frac{1}{\sqrt{d}} \|\mathbf{m}_t\|_2.$$

Следовательно,

$$\frac{1}{\sigma_t(\mathbf{U})} = \frac{\sqrt{d}}{\|\mathbf{m}_t\|_2},$$

и потому

$$\frac{\partial}{\partial \mathbf{m}_t} \left(\frac{1}{\sigma_t(\mathbf{U})} \right) = -\sqrt{d}\, \frac{\mathbf{m}_t^\top}{\|\mathbf{m}_t\|_2^3}.$$

Отсюда

$$\left\| \frac{\partial}{\partial \mathbf{m}_t} \left(\frac{1}{\sigma_t(\mathbf{U})} \right) \right\|_2 = \sqrt{d} \frac{1}{\|\mathbf{m}_t\|_2^2} = \frac{1}{\sqrt{d}\, \sigma_t(\mathbf{U})^2}.$$

Так как отображение $\mathbf{U} \mapsto \mathbf{M}(\mathbf{U}) = \mathbf{U}\mathbf{C}_d$ линейно и имеет операторную норму не больше единицы, то, переходя от производной по $\mathbf{m}_t$ к производной по $\mathbf{U}$, получаем

$$\left\| \frac{\partial}{\partial \operatorname{vec_r}(\mathbf{U})} \left(\frac{1}{\sigma_t(\mathbf{U})} \right) \right\|_2 \leqslant \frac{1}{\sqrt{d}\, \sigma_t(\mathbf{U})^2}.$$

Поскольку $\mathbf{P}(\mathbf{U})$ есть диагональная матрица, составленная из величин $1/\sigma_t(\mathbf{U})$, то оператор дифференцирования диагонального отображения не увеличивает порядок оценки, и потому

$$\left\| \frac{\partial \operatorname{vec_r}(\mathbf{P}(\mathbf{U}))}{\partial \operatorname{vec_r}(\mathbf{U})^\top} \right\|_2 \leqslant \frac{1}{\sqrt{d}\, \sigma_{\min}(\mathbf{U})^2}.$$

Для согласования с грубой глобальной оценкой, используемой в основном тексте, умножим правую часть на $\|\mathbf{U}\|_2/\sigma_{\min}(\mathbf{U})$, что дает более слабую, но удобную в дальнейшем форму:

$$\left\| \frac{\partial \operatorname{vec_r}(\mathbf{P}(\mathbf{U}))}{\partial \operatorname{vec_r}(\mathbf{U})^\top} \right\|_2 \leqslant \frac{\|\mathbf{U}\|_2}{\sqrt{d}\,\sigma_{\min}(\mathbf{U})^3}.$$

Подставляя все полученные оценки в (A.4), получаем

$$\|\mathbf{J}_{\mathrm{LN}}(\mathbf{U})\|_2 \leqslant \frac{1}{\sigma_{\min}(\mathbf{U})} + \|\mathbf{U}\|_2 \cdot \frac{\|\mathbf{U}\|_2}{\sqrt{d}\,\sigma_{\min}(\mathbf{U})^3},$$

то есть

$$\|\mathbf{J}_{\mathrm{LN}}(\mathbf{U})\|_2 \leqslant \frac{1}{\sigma_{\min}(\mathbf{U})} + \frac{\|\mathbf{U}\|_2^2}{\sqrt{d}\,\sigma_{\min}(\mathbf{U})^3}.$$

Что и требовалось доказать. Такая же структура оценки используется в статье для контроля нормы якобиана LayerNorm. □

A.1.2. Выкладки для feed-forward части

Далее полагаем $\sigma = \mathrm{ReLU}$, действующую покомпонентно. Введем обозначение

$$\mathbf{D}_\sigma(\mathbf{Y}\mathbf{W}_1) = \operatorname{diag}\left(\operatorname{vec_r}\left(\mathbf{1}_{\{\mathbf{Y}\mathbf{W}_1>0\}}\right)\right) \in \mathbb{R}^{Td_{\mathrm{ff}}\times Td_{\mathrm{ff}}}.$$

Лемма A.1.3. *Почти всюду по* $\mathbf{Y}\mathbf{W}_1$ *справедливо*

$$\frac{\partial \operatorname{vec_r}(\sigma(\mathbf{Y}\mathbf{W}_1))}{\partial \operatorname{vec_r}(\mathbf{Y}\mathbf{W}_1)^\top} = \mathbf{D}_\sigma(\mathbf{Y}\mathbf{W}_1),$$

причем вторая производная ReLU почти всюду равна нулю.

Доказательство. ReLU действует покомпонентно, поэтому по каждой координате ее производная равна 1 на положительной полуоси и 0 на отрицательной. Отсюда якобиан покомпонентного отображения есть диагональная матрица, на диагонали которой стоят соответствующие индикаторы положительности. В точках, где аргумент равен нулю, производная не определена, но это множество имеет меру нуль. Вне этого множества якобиан кусочно постоянен, следовательно его производная почти всюду равна нулю. Тот же результат используется в статье как Lemma 4. □

Предложение A.1.4. *Для отображения*

$$\mathbf{F}(\mathbf{Y}) = \sigma(\mathbf{Y}\mathbf{W}_1)\mathbf{W}_2 \in \mathbb{R}^{T\times d}$$

параметрические якобианы по матрицам $\mathbf{W}_1$ *и* $\mathbf{W}_2$ *задаются формулами*

$$\frac{\partial \operatorname{vec_r}(\mathbf{F}(\mathbf{Y}))}{\partial \mathbf{w}_2^\top} = \sigma(\mathbf{Y}\mathbf{W}_1) \otimes \mathbf{I}_d, \tag{A.5}$$

$$\frac{\partial \operatorname{vec_r}(\mathbf{F}(\mathbf{Y}))}{\partial \mathbf{w}_1^\top} = \left(\mathbf{I}_T \otimes \mathbf{W}_2^\top\right) \mathbf{D}_\sigma(\mathbf{Y}\mathbf{W}_1) \left(\mathbf{Y} \otimes \mathbf{I}_{d_{\text{ff}}}\right). \tag{A.6}$$

Доказательство. Положим

$$\mathbf{H} = \sigma(\mathbf{Y}\mathbf{W}_1) \in \mathbb{R}^{T\times d_{\text{ff}}}.$$

Тогда

$$\mathbf{F}(\mathbf{Y}) = \mathbf{H}\mathbf{W}_2.$$

Производная по $\mathbf{W}_2$. Для построчной векторизации выполняется тождество

$$\operatorname{vec_r}(\mathbf{H}\mathbf{W}_2) = (\mathbf{H} \otimes \mathbf{I}_d) \operatorname{vec_r}(\mathbf{W}_2).$$

Следовательно,

$$\frac{\partial \operatorname{vec_r}(\mathbf{F}(\mathbf{Y}))}{\partial \mathbf{w}_2^\top} = \mathbf{H} \otimes \mathbf{I}_d = \sigma(\mathbf{Y}\mathbf{W}_1) \otimes \mathbf{I}_d.$$

Это и есть формула (A.5).

Производная по $\mathbf{W}_1$. Рассмотрим композицию

$$\mathbf{W}_1 \longmapsto \mathbf{Y}\mathbf{W}_1 \longmapsto \sigma(\mathbf{Y}\mathbf{W}_1) \longmapsto \sigma(\mathbf{Y}\mathbf{W}_1)\mathbf{W}_2.$$

По правилу дифференцирования сложной функции

$$\frac{\partial \operatorname{vec_r}(\mathbf{F}(\mathbf{Y}))}{\partial \mathbf{w}_1^\top} = \frac{\partial \operatorname{vec_r}(\sigma(\mathbf{Y}\mathbf{W}_1)\mathbf{W}_2)}{\partial \operatorname{vec_r}(\sigma(\mathbf{Y}\mathbf{W}_1))^\top} \cdot \frac{\partial \operatorname{vec_r}(\sigma(\mathbf{Y}\mathbf{W}_1))}{\partial \operatorname{vec_r}(\mathbf{Y}\mathbf{W}_1)^\top} \cdot \frac{\partial \operatorname{vec_r}(\mathbf{Y}\mathbf{W}_1)}{\partial \mathbf{w}_1^\top}.$$

Первый множитель равен

$$\mathbf{I}_T \otimes \mathbf{W}_2^\top.$$

Второй по лемме A.1.3 имеет вид

$$\mathbf{D}_\sigma(\mathbf{Y}\mathbf{W}_1).$$

Для третьего множителя используем тождество

$$\mathrm{vec_r}(\mathbf{Y}\mathbf{W}_1) = (\mathbf{Y} \otimes \mathbf{I}_{d_{\mathrm{ff}}})\,\mathrm{vec_r}(\mathbf{W}_1),$$

откуда

$$\frac{\partial\,\mathrm{vec_r}(\mathbf{Y}\mathbf{W}_1)}{\partial \mathbf{w}_1^\top} = \mathbf{Y} \otimes \mathbf{I}_{d_{\mathrm{ff}}}.$$

Перемножая эти три матрицы, получаем (A.6). Именно эти формулы используются и в статье как FFN Jacobians. □

Лемма A.1.5. *Якобиан* $\mathrm{vec_r}(\mathrm{FFN}(\mathbf{Y}))$ *по входу* $\mathrm{vec_r}(\mathbf{Y})$ *имеет вид*

$$\mathbf{J}_{\mathrm{FFN},Y} = \frac{\partial\,\mathrm{vec_r}(\mathrm{FFN}(\mathbf{Y}))}{\partial\,\mathrm{vec_r}(\mathbf{Y})^\top} = \left(\mathbf{I}_T \otimes \mathbf{W}_2^\top\right)\mathbf{D}_\sigma(\mathbf{Y}\mathbf{W}_1)\left(\mathbf{I}_T \otimes \mathbf{W}_1^\top\right). \tag{A.7}$$

Доказательство. Композиция

$$\mathbf{Y} \longmapsto \mathbf{Y}\mathbf{W}_1 \longmapsto \sigma(\mathbf{Y}\mathbf{W}_1) \longmapsto \sigma(\mathbf{Y}\mathbf{W}_1)\mathbf{W}_2$$

дифференцируется так же, как и в доказательстве предложения A.1.4. Отличие состоит лишь в последнем множителе:

$$\frac{\partial\,\mathrm{vec_r}(\mathbf{Y}\mathbf{W}_1)}{\partial\,\mathrm{vec_r}(\mathbf{Y})^\top} = \mathbf{I}_T \otimes \mathbf{W}_1^\top.$$

Подставляя этот множитель вместо $\mathbf{Y} \otimes \mathbf{I}_{d_{\mathrm{ff}}}$, получаем формулу (A.7). □

A.1.3. Оценки для self-attention части

Здесь мы используем обозначения

$$\mathbf{G}_Q = \frac{\partial\,\mathrm{vec_r}(\mathrm{SA}(\mathbf{X}))}{\partial \mathbf{w}_Q^\top}, \qquad \mathbf{G}_K = \frac{\partial\,\mathrm{vec_r}(\mathrm{SA}(\mathbf{X}))}{\partial \mathbf{w}_K^\top}, \qquad \mathbf{G}_V = \frac{\partial\,\mathrm{vec_r}(\mathrm{SA}(\mathbf{X}))}{\partial \mathbf{w}_V^\top}.$$

Для матрицы $\mathbf{G}_V$ вывод можно сделать непосредственно. Для матриц $\mathbf{G}_Q$ и $\mathbf{G}_K$ в данной главе мы опираемся на известный анализ изолированного single-head self-attention блока (уточнить откуда, ссылка): именно эти оценки затем подставляются в якобиан полного трансформерного блока.

Лемма A.1.6. *Для матриц* $\mathbf{G}_Q$,$\mathbf{G}_K$,$\mathbf{G}_V$ *справедливы оценки*

$$\|\mathbf{G}_V\|_2 \leqslant T\|\mathbf{X}\|_2,$$

а также

$$\|\mathbf{G}_Q\|_2 \leqslant \frac{C_{\mathrm{sm}}}{\sqrt{d_k}}\|\mathbf{W}_V\|_2\|\mathbf{W}_K\|_2\|\mathbf{X}\|_2^3, \tag{A.8}$$

$$\|\mathbf{G}_K\|_2 \leqslant \frac{C_{\mathrm{sm}}}{\sqrt{d_k}}\|\mathbf{W}_V\|_2\|\mathbf{W}_Q\|_2\|\mathbf{X}\|_2^3, \tag{A.9}$$

где C_{sm} *— константа Липшица построчного softmax в спектральной норме.*

Доказательство. **1. Оценка для $\mathbf{G}_V$.** При фиксированных $\mathbf{X}$,$\mathbf{W}_Q$,$\mathbf{W}_K$ оператор self-attention линеен по $\mathbf{W}_V$:

$$\mathrm{SA}(\mathbf{X}) = \mathbf{\Pi}(\mathbf{X})\mathbf{X}\mathbf{W}_V.$$

Следовательно,

$$\mathrm{vec_r}(\mathrm{SA}(\mathbf{X})) = (\mathbf{\Pi}(\mathbf{X})\mathbf{X} \otimes \mathbf{I}_d)\,\mathrm{vec_r}(\mathbf{W}_V),$$

и потому

$$\mathbf{G}_V = \mathbf{\Pi}(\mathbf{X})\mathbf{X} \otimes \mathbf{I}_d.$$

По свойству спектральной нормы произведения Кронекера

$$\|\mathbf{G}_V\|_2 = \|\mathbf{\Pi}(\mathbf{X})\mathbf{X}\|_2 \leqslant \|\mathbf{\Pi}(\mathbf{X})\|_2\|\mathbf{X}\|_2.$$

Матрица $\mathbf{\Pi}(\mathbf{X})$ построчно стохастична, а потому грубо

$$\|\mathbf{\Pi}(\mathbf{X})\|_2 \leqslant T.$$

Следовательно,

$$\|\mathbf{G}_V\|_2 \leqslant T\|\mathbf{X}\|_2.$$

2. Оценки для $\mathbf{G}_Q$ и $\mathbf{G}_K$. Рассмотрим матрицу логитов

$$\mathbf{L}(\mathbf{X}) = \frac{\mathbf{X}\mathbf{W}_Q\mathbf{W}_K^\top\mathbf{X}^\top}{\sqrt{d_k}}.$$

При вариации $d\mathbf{W}_Q$ имеем

$$d\mathbf{L} = \frac{\mathbf{X}\,d\mathbf{W}_Q\,\mathbf{W}_K^\top\mathbf{X}^\top}{\sqrt{d_k}},$$

и потому

$$\|d\mathbf{L}\|_2 \leqslant \frac{1}{\sqrt{d_k}}\|\mathbf{X}\|_2^2\|\mathbf{W}_K\|_2\|d\mathbf{W}_Q\|_2.$$

Поскольку построчный softmax липшицев в спектральной норме с константой C_{sm}, получаем

$$\|d\mathbf{\Pi}\|_2 \leqslant C_{\mathrm{sm}}\|d\mathbf{L}\|_2 \leqslant \frac{C_{\mathrm{sm}}}{\sqrt{d_k}}\|\mathbf{X}\|_2^2\|\mathbf{W}_K\|_2\|d\mathbf{W}_Q\|_2.$$

Далее

$$d\,\mathrm{SA}(\mathbf{X}) = (d\mathbf{\Pi})\mathbf{X}\mathbf{W}_V,$$

поэтому

$$\begin{aligned}\|d\,\mathrm{SA}(\mathbf{X})\|_2 &\leqslant \|d\mathbf{\Pi}\|_2\|\mathbf{X}\mathbf{W}_V\|_2\\ &\leqslant \frac{C_{\mathrm{sm}}}{\sqrt{d_k}}\|\mathbf{W}_K\|_2\|\mathbf{X}\|_2^2\|d\mathbf{W}_Q\|_2\|\mathbf{X}\|_2\|\mathbf{W}_V\|_2\\ &= \frac{C_{\mathrm{sm}}}{\sqrt{d_k}}\|\mathbf{W}_V\|_2\|\mathbf{W}_K\|_2\|\mathbf{X}\|_2^3\|d\mathbf{W}_Q\|_2.\end{aligned}$$

Из определения операторной нормы якобиана следует (A.8). Формула (A.9) выводится симметрично при вариации по $\mathbf{W}_K$. □

A.1.4. Сборка якобианов полного трансформерного блока

Введем обозначения

$$\mathbf{J}_Y = \frac{\partial\,\mathrm{vec_r}(\mathbf{Y})}{\partial\,\mathrm{vec_r}(\mathbf{U})^\top} = \mathbf{J}_{\mathrm{LN}}(\mathbf{U}), \qquad \mathbf{J}_Z = \frac{\partial\,\mathrm{vec_r}(\mathbf{Z})}{\partial\,\mathrm{vec_r}(\mathbf{S})^\top} = \mathbf{J}_{\mathrm{LN}}(\mathbf{S}).$$

Теорема A.1.7. *Якобианы выхода трансформерного блока по всем пяти группам параметров задаются формулами*

$$\mathbf{J}^{(1)} = \mathbf{J}_Z\mathbf{B}_1, \qquad \mathbf{B}_1 = \left(\mathbf{I}_T \otimes \mathbf{W}_2^\top\right)\mathbf{D}_\sigma(\mathbf{Y}\mathbf{W}_1)\left(\mathbf{Y} \otimes \mathbf{I}_{d_{\mathrm{ff}}}\right),$$

$$\mathbf{J}^{(2)} = \mathbf{J}_Z\mathbf{B}_2, \qquad \mathbf{B}_2 = \sigma(\mathbf{Y}\mathbf{W}_1) \otimes \mathbf{I}_d,$$

$$\mathbf{J}^{(Q)} = \mathbf{J}_Z\mathbf{J}_{SY}\mathbf{J}_Y\mathbf{G}_Q, \qquad \mathbf{J}^{(K)} = \mathbf{J}_Z\mathbf{J}_{SY}\mathbf{J}_Y\mathbf{G}_K, \qquad \mathbf{J}^{(V)} = \mathbf{J}_Z\mathbf{J}_{SY}\mathbf{J}_Y\mathbf{G}_V,$$

где

$$\mathbf{J}_{SY} = \frac{\partial\,\mathrm{vec_r}(\mathbf{S})}{\partial\,\mathrm{vec_r}(\mathbf{Y})^\top} = \mathbf{I}_{Td} + \left(\mathbf{I}_T \otimes \mathbf{W}_2^\top\right)\mathbf{D}_\sigma(\mathbf{Y}\mathbf{W}_1)\left(\mathbf{I}_T \otimes \mathbf{W}_1^\top\right).$$

Доказательство. **1. Якобианы по $\mathbf{W}_1$ и $\mathbf{W}_2$.** Из определения блока имеем

$$\mathbf{Z} = \mathrm{LN}(\mathbf{S}), \qquad \mathbf{S} = \mathbf{Y} + \mathrm{FFN}(\mathbf{Y}).$$

Параметры $\mathbf{W}_1$,$\mathbf{W}_2$ входят только через FFN, а матрица $\mathbf{Y}$ от них не зависит. Поэтому

$$\mathbf{J}^{(1)} = \frac{\partial \operatorname{vec_r}(\mathbf{Z})}{\partial \mathbf{w}_1^\top} = \frac{\partial \operatorname{vec_r}(\mathbf{Z})}{\partial \operatorname{vec_r}(\mathbf{S})^\top} \cdot \frac{\partial \operatorname{vec_r}(\mathbf{S})}{\partial \mathbf{w}_1^\top} = \mathbf{J}_Z \frac{\partial \operatorname{vec_r}(\mathrm{FFN}(\mathbf{Y}))}{\partial \mathbf{w}_1^\top}.$$

По предложению A.1.4

$$\frac{\partial \operatorname{vec_r}(\mathrm{FFN}(\mathbf{Y}))}{\partial \mathbf{w}_1^\top} = \left(\mathbf{I}_T \otimes \mathbf{W}_2^\top\right) \mathbf{D}_\sigma(\mathbf{Y}\mathbf{W}_1) \left(\mathbf{Y} \otimes \mathbf{I}_{d_{\mathrm{ff}}}\right).$$

Тем самым получаем формулу для $\mathbf{J}^{(1)}$. Аналогично

$$\mathbf{J}^{(2)} = \frac{\partial \operatorname{vec_r}(\mathbf{Z})}{\partial \mathbf{w}_2^\top} = \mathbf{J}_Z \frac{\partial \operatorname{vec_r}(\mathrm{FFN}(\mathbf{Y}))}{\partial \mathbf{w}_2^\top} = \mathbf{J}_Z \left(\sigma(\mathbf{Y}\mathbf{W}_1) \otimes \mathbf{I}_d\right).$$

2. Якобианы по attention-параметрам. Пусть $k \in \{Q,K,V\}$. Тогда влияние параметра $\mathbf{w}_k$ на выход проходит по цепочке

$$\mathbf{w}_k \longmapsto \mathrm{SA}(\mathbf{X}) \longmapsto \mathbf{U} \longmapsto \mathbf{Y} \longmapsto \mathbf{S} \longmapsto \mathbf{Z}.$$

Следовательно, по правилу дифференцирования сложной функции

$$\mathbf{J}^{(k)} = \frac{\partial \operatorname{vec_r}(\mathbf{Z})}{\partial \mathbf{w}_k^\top} = \frac{\partial \operatorname{vec_r}(\mathbf{Z})}{\partial \operatorname{vec_r}(\mathbf{S})^\top} \cdot \frac{\partial \operatorname{vec_r}(\mathbf{S})}{\partial \operatorname{vec_r}(\mathbf{Y})^\top} \cdot \frac{\partial \operatorname{vec_r}(\mathbf{Y})}{\partial \operatorname{vec_r}(\mathbf{U})^\top} \cdot \frac{\partial \operatorname{vec_r}(\mathrm{SA}(\mathbf{X}))}{\partial \mathbf{w}_k^\top}.$$

Первый множитель равен $\mathbf{J}_Z$, третий — $\mathbf{J}_Y$, четвертый — $\mathbf{G}_k$. Остается вычислить

$$\mathbf{J}_{SY} = \frac{\partial \operatorname{vec_r}(\mathbf{S})}{\partial \operatorname{vec_r}(\mathbf{Y})^\top}.$$

Так как

$$\mathbf{S} = \mathbf{Y} + \mathrm{FFN}(\mathbf{Y}),$$

то

$$\mathbf{J}_{SY} = \mathbf{I}_{Td} + \frac{\partial \operatorname{vec_r}(\mathrm{FFN}(\mathbf{Y}))}{\partial \operatorname{vec_r}(\mathbf{Y})^\top}.$$

По лемме A.1.5

$$\frac{\partial \operatorname{vec_r}(\mathrm{FFN}(\mathbf{Y}))}{\partial \operatorname{vec_r}(\mathbf{Y})^\top} = \left(\mathbf{I}_T \otimes \mathbf{W}_2^\top\right) \mathbf{D}_\sigma(\mathbf{Y}\mathbf{W}_1) \left(\mathbf{I}_T \otimes \mathbf{W}_1^\top\right).$$

Подстановка завершает доказательство. □

A.1.5. Гаусс–ньютоновская компонента и ее спектральная оценка

Пусть

$$\mathbf{A}(\mathbf{w}) = \nabla^2_{\mathbf{z}}\ell(\mathbf{z},\mathbf{y}) \in \mathbb{R}^{Td\times Td}$$

— матрица кривизны функции потерь по выходу блока, а

$$\mathbf{J}(\mathbf{w}) = \left[\mathbf{J}^{(Q)}, \mathbf{J}^{(K)}, \mathbf{J}^{(V)}, \mathbf{J}^{(1)}, \mathbf{J}^{(2)}\right]$$

— полный якобиан выхода блока по всем параметрам.

Теорема A.1.8. *Пусть*

$$\|\mathbf{A}(\mathbf{w})\|_2 \leqslant M_{\mathbf{A}}.$$

Тогда

$$\|\mathbf{G}(\mathbf{w})\|_2 \leqslant M_{\mathbf{A}} \left(\|\mathbf{J}^{(Q)}\|_2^2 + \|\mathbf{J}^{(K)}\|_2^2 + \|\mathbf{J}^{(V)}\|_2^2 + \|\mathbf{J}^{(1)}\|_2^2 + \|\mathbf{J}^{(2)}\|_2^2\right), \qquad \text{(A.10)}$$

где

$$\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w})\mathbf{J}(\mathbf{w}).$$

Кроме того,

$$\|\mathbf{J}^{(1)}\|_2 \leqslant \|\mathbf{J}_Z\|_2\|\mathbf{W}_2\|_2\|\mathbf{Y}\|_2,$$

$$\|\mathbf{J}^{(2)}\|_2 \leqslant \|\mathbf{J}_Z\|_2\|\mathbf{Y}\|_2\|\mathbf{W}_1\|_2,$$

$$\|\mathbf{J}^{(k)}\|_2 \leqslant \|\mathbf{J}_Z\|_2 \left(\|\mathbf{W}_2\|_2\|\mathbf{W}_1\|_2 + 1\right) \|\mathbf{J}_Y\|_2\|\mathbf{G}_k\|_2, \qquad k \in \{Q,K,V\}.$$

Доказательство. По определению гаусс–ньютоновской компоненты

$$\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w})\mathbf{J}(\mathbf{w}),$$

поэтому

$$\|\mathbf{G}(\mathbf{w})\|_2 \leqslant \|\mathbf{A}(\mathbf{w})\|_2\|\mathbf{J}(\mathbf{w})\|_2^2 \leqslant M_{\mathbf{A}}\|\mathbf{J}(\mathbf{w})\|_2^2.$$

Так как

$$\mathbf{J}(\mathbf{w})\mathbf{J}(\mathbf{w})^\top = \sum_{i\in\{Q,K,V,1,2\}} \mathbf{J}^{(i)}\mathbf{J}^{(i)\top},$$

то

$$\|\mathbf{J}(\mathbf{w})\|_2^2 = \|\mathbf{J}(\mathbf{w})\mathbf{J}(\mathbf{w})^\top\|_2 \leqslant \sum_{i\in\{Q,K,V,1,2\}} \|\mathbf{J}^{(i)}\|_2^2.$$

Получаем (A.10).

Оценим теперь отдельные блоки.

1. Оценка $\mathbf{J}^{(1)}$. По теореме A.1.7

$$\mathbf{J}^{(1)} = \mathbf{J}_Z \left(\mathbf{I}_T \otimes \mathbf{W}_2^\top\right) \mathbf{D}_\sigma(\mathbf{Y}\mathbf{W}_1) \left(\mathbf{Y} \otimes \mathbf{I}_{d_{\text{ff}}}\right).$$

Следовательно,

$$\begin{aligned}\|\mathbf{J}^{(1)}\|_2 &\leqslant \|\mathbf{J}_Z\|_2 \|\mathbf{I}_T \otimes \mathbf{W}_2^\top\|_2 \|\mathbf{D}_\sigma(\mathbf{Y}\mathbf{W}_1)\|_2 \|\mathbf{Y} \otimes \mathbf{I}_{d_{\text{ff}}}\|_2 \\ &= \|\mathbf{J}_Z\|_2 \|\mathbf{W}_2\|_2 \cdot 1 \cdot \|\mathbf{Y}\|_2.\end{aligned}$$

2. Оценка $\mathbf{J}^{(2)}$. Аналогично

$$\mathbf{J}^{(2)} = \mathbf{J}_Z \left(\sigma(\mathbf{Y}\mathbf{W}_1) \otimes \mathbf{I}_d\right),$$

поэтому

$$\|\mathbf{J}^{(2)}\|_2 \leqslant \|\mathbf{J}_Z\|_2 \|\sigma(\mathbf{Y}\mathbf{W}_1)\|_2.$$

Так как ReLU является 1-липшицевой и $\sigma(\mathbf{0}) = \mathbf{0}$,

$$\|\sigma(\mathbf{Y}\mathbf{W}_1)\|_2 \leqslant \|\mathbf{Y}\mathbf{W}_1\|_2 \leqslant \|\mathbf{Y}\|_2 \|\mathbf{W}_1\|_2.$$

3. Оценка $\mathbf{J}^{(k)}$, $k \in \{Q,K,V\}$. Из теоремы A.1.7

$$\mathbf{J}^{(k)} = \mathbf{J}_Z \mathbf{J}_{SY} \mathbf{J}_Y \mathbf{G}_k.$$

Следовательно,

$$\|\mathbf{J}^{(k)}\|_2 \leqslant \|\mathbf{J}_Z\|_2 \|\mathbf{J}_{SY}\|_2 \|\mathbf{J}_Y\|_2 \|\mathbf{G}_k\|_2.$$

Оценим $\|\mathbf{J}_{SY}\|_2$:

$$\begin{aligned}\|\mathbf{J}_{SY}\|_2 &= \left\|\mathbf{I}_{Td} + \left(\mathbf{I}_T \otimes \mathbf{W}_2^\top\right) \mathbf{D}_\sigma(\mathbf{Y}\mathbf{W}_1) \left(\mathbf{I}_T \otimes \mathbf{W}_1^\top\right)\right\|_2 \\ &\leqslant 1 + \|\mathbf{W}_2\|_2 \|\mathbf{W}_1\|_2.\end{aligned}$$

Подстановка завершает доказательство. □

Теорема A.1.9. *Пусть выполнено*

$$\|\mathbf{A}(\mathbf{w})\|_2 \leqslant M_{\mathbf{A}}.$$

Тогда

$$\|\mathbf{G}(\mathbf{w})\|_2 \leqslant M_{\mathbf{A}} \|\mathbf{J}_Z\|_2^2 \Bigg[\|\mathbf{W}_2\|_2^2 \|\mathbf{Y}\|_2^2 + \|\mathbf{W}_1\|_2^2 \|\mathbf{Y}\|_2^2 +$$

$$+ (\|\mathbf{W}_2\|_2 \|\mathbf{W}_1\|_2 + 1)^2 \|\mathbf{J}_Y\|_2^2 \Bigg(T^2 \|\mathbf{X}\|_2^2 + \frac{C_{\text{sm}}^2}{d_k} \|\mathbf{W}_V\|_2^2 \|\mathbf{W}_K\|_2^2 \|\mathbf{X}\|_2^6 + \frac{C_{\text{sm}}^2}{d_k} \|\mathbf{W}_V\|_2^2 \|\mathbf{W}_Q\|$$

Доказательство. По теореме A.1.8

$$\|\mathbf{G}(\mathbf{w})\|_2 \leqslant M_{\mathbf{A}} \left(\|\mathbf{J}^{(Q)}\|_2^2 + \|\mathbf{J}^{(K)}\|_2^2 + \|\mathbf{J}^{(V)}\|_2^2 + \|\mathbf{J}^{(1)}\|_2^2 + \|\mathbf{J}^{(2)}\|_2^2 \right).$$

Для FFN-параметров имеем

$$\|\mathbf{J}^{(1)}\|_2^2 \leqslant \|\mathbf{J}_Z\|_2^2 \|\mathbf{W}_2\|_2^2 \|\mathbf{Y}\|_2^2,$$

$$\|\mathbf{J}^{(2)}\|_2^2 \leqslant \|\mathbf{J}_Z\|_2^2 \|\mathbf{W}_1\|_2^2 \|\mathbf{Y}\|_2^2.$$

Для attention-параметров, используя лемму A.1.6, получаем

$$\|\mathbf{J}^{(V)}\|_2^2 \leqslant \|\mathbf{J}_Z\|_2^2 \left(\|\mathbf{W}_2\|_2 \|\mathbf{W}_1\|_2 + 1\right)^2 \|\mathbf{J}_Y\|_2^2 T^2 \|\mathbf{X}\|_2^2,$$

$$\|\mathbf{J}^{(Q)}\|_2^2 \leqslant \|\mathbf{J}_Z\|_2^2 \left(\|\mathbf{W}_2\|_2 \|\mathbf{W}_1\|_2 + 1\right)^2 \|\mathbf{J}_Y\|_2^2 \frac{C_{\text{sm}}^2}{d_k} \|\mathbf{W}_V\|_2^2 \|\mathbf{W}_K\|_2^2 \|\mathbf{X}\|_2^6,$$

$$\|\mathbf{J}^{(K)}\|_2^2 \leqslant \|\mathbf{J}_Z\|_2^2 \left(\|\mathbf{W}_2\|_2 \|\mathbf{W}_1\|_2 + 1\right)^2 \|\mathbf{J}_Y\|_2^2 \frac{C_{\text{sm}}^2}{d_k} \|\mathbf{W}_V\|_2^2 \|\mathbf{W}_Q\|_2^2 \|\mathbf{X}\|_2^6.$$

Суммируя все пять слагаемых, приходим к (A.11). □

Следствие A.1.10. *Пусть*

$$\|\mathbf{A}(\mathbf{w})\|_2 \leqslant M_{\mathbf{A}}, \qquad \|\mathbf{X}\|_2 \leqslant M_{\mathbf{X}}, \qquad \|\mathbf{Y}\|_2 \leqslant M_{\mathbf{Y}},$$

$$\|\mathbf{W}_Q\|_2, \|\mathbf{W}_K\|_2, \|\mathbf{W}_V\|_2, \|\mathbf{W}_1\|_2, \|\mathbf{W}_2\|_2 \leqslant M_{\mathbf{W}},$$

$$\sigma_{\min}(\mathbf{U}) \geqslant \sigma_0, \qquad \sigma_{\min}(\mathbf{S}) \geqslant \sigma_0 > 0.$$

Обозначим

$$C_{\text{LN}}(M) := \frac{1}{\sigma_0} + \frac{M^2}{\sqrt{d}\,\sigma_0^3}.$$

Тогда

$$\|\mathbf{G}(\mathbf{w})\|_2 \leqslant M_{\mathbf{A}} C_{\text{LN}}(\|\mathbf{S}\|_2)^2 \Bigg[2M_{\mathbf{Y}}^2 M_{\mathbf{W}}^2 + \\ + \left(M_{\mathbf{W}}^2 + 1\right)^2 C_{\text{LN}}(\|\mathbf{U}\|_2)^2 \left(T^2 M_{\mathbf{X}}^2 + \frac{2C_{\text{sm}}^2}{d_k} M_{\mathbf{W}}^4 M_{\mathbf{X}}^6 \right) \Bigg].$$

Доказательство. По лемме A.1.2

$$\|\mathbf{J}_Y\|_2 \leqslant C_{\text{LN}}(\|\mathbf{U}\|_2), \qquad \|\mathbf{J}_Z\|_2 \leqslant C_{\text{LN}}(\|\mathbf{S}\|_2).$$

Далее в теореме A.1.9 подставляем равномерные оценки

$$\|\mathbf{W}_Q\|_2, \|\mathbf{W}_K\|_2, \|\mathbf{W}_V\|_2, \|\mathbf{W}_1\|_2, \|\mathbf{W}_2\|_2 \leqslant M_{\mathbf{W}},$$

$$\|\mathbf{X}\|_2 \leqslant M_{\mathbf{X}}, \qquad \|\mathbf{Y}\|_2 \leqslant M_{\mathbf{Y}}.$$

Первые два члена дают

$$\|\mathbf{W}_2\|_2^2 \|\mathbf{Y}\|_2^2 + \|\mathbf{W}_1\|_2^2 \|\mathbf{Y}\|_2^2 \leqslant 2M_{\mathbf{Y}}^2 M_{\mathbf{W}}^2.$$

Для attention-части получаем

$$\|\mathbf{W}_2\|_2 \|\mathbf{W}_1\|_2 + 1 \leqslant M_{\mathbf{W}}^2 + 1,$$

а сумма двух старших членов порядка $\|\mathbf{X}\|_2^6$ оценивается как

$$\frac{C_{\text{sm}}^2}{d_k} \|\mathbf{W}_V\|_2^2 \|\mathbf{W}_K\|_2^2 \|\mathbf{X}\|_2^6 + \frac{C_{\text{sm}}^2}{d_k} \|\mathbf{W}_V\|_2^2 \|\mathbf{W}_Q\|_2^2 \|\mathbf{X}\|_2^6 \leqslant \frac{2C_{\text{sm}}^2}{d_k} M_{\mathbf{W}}^4 M_{\mathbf{X}}^6.$$

Подстановка этих оценок в (A.11) завершает доказательство. □