

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский физико-технический институт
(национальный исследовательский университет)»
Физтех-школа прикладной математики и информатики
Кафедра интеллектуальных систем

На правах рукописи

Киселев Никита Сергеевич

**Законы масштабирования параметрических моделей
машинного обучения на основе локальных свойств
оптимизационной поверхности**

Специальность 1.2.1 —
«Искусственный интеллект и машинное обучение»

Диссертация на соискание учёной степени
кандидата физико-математических наук

Научный руководитель:
кандидат физико-математических наук
Грабовой Андрей Валериевич

Москва — 2026

Оглавление

	Стр.
Введение	4
Глава 1. Обзор проблемы и постановка задач исследования . . .	9
1.1. Параметрические модели машинного обучения и множество оптимальных параметров	9
1.2. Законы масштабирования параметрических моделей и достаточный размер выборки	11
1.3. Оптимизационная поверхность и матрица Гессе как ее ключевая характеристика	13
1.4. Постановка задач исследования	15
Глава 2. Спектральные свойства матриц Гессе нейронных сетей	16
2.1. Введение	16
2.2. Предварительные сведения	18
2.3. Матрично-представимые нейронные сети и факторизация гаусс—ньютоновской компоненты	20
2.4. Полносвязные нейронные сети	23
2.5. Сверточные нейронные сети	27
2.6. Вычислительные эксперименты	37
2.7. Обсуждение	40
Глава 3. Стабилизация ландшафта функции потерь в нейронных сетях	42
3.1. Введение	42
3.2. Предварительные сведения	44
3.3. Критерий сходимости поверхности функции потерь	46
3.4. Абсолютный однотоочечный критерий сходимости	48
3.5. Среднеквадратичный критерий сходимости	51
3.6. Среднеквадратичный критерий сходимости в подпространстве наибольшей кривизны	55
3.7. Вычислительные эксперименты	62

3.8. Обсуждение	66
Глава 4. Критерии достаточного размера выборки и интерпретация законов масштабирования для параметрических моделей	68
4.1. Введение	68
4.2. Обзор существующих подходов	69
4.3. Связь между архитектурно-зависимой кривизной и стабилизацией ландшафта	74
4.4. Критерии достаточного размера выборки	76
4.5. Интерпретация в терминах законов масштабирования	81
4.6. Вычислительные эксперименты	86
4.7. Обсуждение	92
Глава 5. Критерии достаточного размера выборки для вероятностных линейных моделей	94
5.1. Введение	94
5.2. Предварительные сведения	96
5.3. Критерии достаточности для линейных моделей	98
5.4. Асимптотическое поведение оптимизационной поверхности в вероятностной модели линейной регрессии	101
5.5. Доказательства теоретических результатов	104
5.6. Вычислительные эксперименты	110
5.7. Обсуждение	119
Заключение	120
Список сокращений и условных обозначений	123
Публикации автора по теме диссертации	125
Список литературы	127
Список рисунков	135
Список таблиц	138

Введение

В статистической теории обучения [1] обоснована принципиальная связь между сложностью семейства моделей, объемом обучающей выборки и способностью к обобщению: для надежного выбора модели требуется достаточное количество данных. Подавляющее большинство современных моделей машинного обучения являются параметрическими: они задаются конечным набором параметров, определяемых минимизацией эмпирической функции потерь на выборке. Поскольку функция потерь вычисляется по ограниченным данным и зависит от параметров модели, возникает фундаментальный вопрос о взаимосвязи объема выборки, структуры модели и свойств множества оптимальных параметров, а также о **минимальном объеме данных**, необходимом для успешного обучения [2; 3].

Эмпирические **законы масштабирования** показывают, что качество моделей закономерно зависит от размера данных и модели: в языковых моделях установлены степенные зависимости потерь от объема данных и числа параметров [2], а для вычислительно-оптимального обучения предложено согласованное масштабирование размера модели и объема данных [3]. Эти результаты опираются на масштабные эксперименты и не имеют пока единого теоретического обоснования.

Естественным объектом для такого анализа является **ландшафт функции потерь** в пространстве параметров. Его визуализация и анализ структуры минимумов [4], изучение локальной геометрии и связей с обобщающей способностью [5], а также доказательство связности множества решений [6] показывают, что геометрия поверхности функции потерь определяет как выбор решения методами градиентной оптимизации [7; 8], так и устойчивость к возмущениям данных. Спектральные свойства **матрицы Гессе** в окрестности минимума характеризуют кривизну оптимизационной поверхности и используются при анализе сходимости и обобщения [9]. Вместе с тем остается открытой задача систематического описания того, как ландшафт функции потерь стабилизируется при увеличении объема выборки и как связать эту стабилизацию с законами масштабирования и достаточным размером данных.

Таким образом, актуальной задачей является разработка теоретических методов, связывающих архитектуру параметрической модели, объем обучаю-

щей выборки и локальную геометрию множества оптимальных параметров, задаваемую ландшафтом функции потерь.

Целью данной работы является разработка теоретического подхода к описанию законов масштабирования параметрических моделей машинного обучения на основе анализа стабилизации распределения оптимальных параметров и локальных свойств оптимизационной поверхности. Для достижения цели были поставлены и решены следующие **задачи**:

1. Исследовать спектральные свойства матриц Гессе нейронных сетей и получить архитектурно-зависимые верхние оценки спектральных норм для полносвязных и сверточных архитектур.
2. Разработать критерии стабилизации оптимизационной поверхности при увеличении объема обучающей выборки.
3. Сформулировать законы масштабирования параметрических моделей машинного обучения, связывающие архитектуру модели, локальные свойства оптимизационной поверхности и объем обучающей выборки.
4. Построить критерии достаточного размера выборки для параметрических моделей на основе стабилизации ландшафта функции потерь.
5. Исследовать вероятностные линейные модели как частный случай параметрических моделей и построить для них критерии достаточного размера выборки на основе сходимости распределения оптимальных параметров.

Объектом исследования настоящей работы являются параметрические модели машинного обучения и возникающие при их обучении оптимизационные задачи на конечных обучающих выборках.

Предметом исследования данной работы являются локальные свойства оптимизационной поверхности функции потерь параметрических моделей машинного обучения, спектральные свойства матрицы Гессе, стабилизация множества оптимальных параметров при увеличении объема обучающей выборки и критерии достаточного размера выборки, основанные на этой стабилизации.

Научная новизна:

1. Получены верхние оценки спектральных норм гаусс-ньютоновской компоненты матрицы Гессе для полносвязных и сверточных архитектур нейронных сетей на основе ее блочной факторизации в классе матрично-представимых моделей.

2. Предложены критерии стабилизации оптимизационной поверхности в нейронных сетях, основанные на локальной квадратичной аппроксимации функции потерь и спектральных свойствах матрицы Гессе.
3. Предложена теоретическая схема законов масштабирования параметрических моделей машинного обучения, связывающая архитектуру модели, локальную геометрию оптимизационной поверхности и объем обучающей выборки.
4. Получены критерии достаточного размера выборки для параметрических моделей на основе стабилизации ландшафта функции потерь.
5. Для вероятностных линейных моделей построены критерии достаточного размера выборки, основанные на сходимости апостериорного распределения параметров и стабилизации вероятностных характеристик решения.

Теоретическая значимость полученных результатов состоит в том, что предложено обоснование связи между объемом обучающей выборки и стабилизацией оптимизационной поверхности (для линейных моделей — через правдоподобие и апостериорные распределения, для нейронных сетей — через спектр матрицы Гессе и сходимость ландшафта функции потерь), дополняющее известные эмпирические законы масштабирования строгими оценками и единой постановкой задачи.

Практическая значимость настоящей работы заключается в возможности применения разработанных методов для обоснованного определения достаточного объема данных при планировании экспериментов и сборе выборок для линейных и нейросетевых моделей, а также для формулировки критериев остановки сбора данных и интерпретации достаточности выборки в терминах геометрии поверхности функции потерь.

Методология и методы исследования. Для достижения поставленных в диссертационной работе целей используются:

1. Методы линейной алгебры, математического и функционального анализа: матричное дифференцирование, анализ функций многих переменных, спектральный анализ матриц (в том числе матрицы Гессе).
2. Методы теории вероятностей и математической статистики: байесовский вывод, анализ сходимости последовательностей случайных величин и распределений, элементы теории оптимизации.

3. Методы вычислительного эксперимента и анализа результатов: бутстрап, сэмплирование по Монте—Карло, воспроизводимая постановка экспериментов.

Основные положения, выносимые на защиту:

1. Теоремы о верхних оценках спектральной нормы гаусс-ньютоновской компоненты матрицы Гессе для полносвязных и сверточных архитектур нейронных сетей.
2. Критерии стабилизации ландшафта функции потерь в нейронных сетях, построенные для одной точки, для распределения точек в полном пространстве параметров и для подпространства главных собственных направлений матрицы Гессе.
3. Теоретическая схема законов масштабирования параметрических моделей машинного обучения, связывающая архитектуру модели, локальную кривизну оптимизационной поверхности и объем обучающей выборки.
4. Критерии достаточного размера выборки для параметрических моделей, основанные на стабилизации ландшафта функции потерь.
5. Критерии достаточного размера выборки для вероятностных линейных моделей, основанные на стабилизации распределения оптимальных параметров при увеличении объема данных.

Соответствие паспорту специальности. Диссертационная работа соответствует паспорту научной специальности 1.2.1 — «Искусственный интеллект и машинное обучение», а именно в наибольшей степени следующим направлениям исследований: п. 1 «Естественно-научные основы и методы искусственного интеллекта»; п. 2 «Исследования в области оценки качества и эффективности алгоритмических решений для систем искусственного интеллекта и машинного обучения»; п. 12 «Исследования в области надежности, устойчивости и переобучения систем класса ИИ»; п. 15 «Математические исследования в области статистики, логики, алгебры, топологии, анализа функций и других областях, ориентированные на решение задач искусственного интеллекта и машинного обучения»; п. 16 «Исследования в области специальных методов оптимизации, проблем сложности и снижения размерности»; п. 17 «Исследования в области многослойных алгоритмических конструкций, в том числе многослойных нейросетей».

Достоверность полученных результатов обеспечивается корректностью применения апробированного в научной практике математического аппарата теории вероятностей, математической статистики и других смежных теоретических областей, а также экспериментальной проверкой разработанных методов на большом количестве модельных и практических задач машинного обучения. Полученные теоретические результаты обосновываются математически строгими доказательствами, а для проведенных вычислительных экспериментов даются детальные описания, обеспечивающие их воспроизводимость. Результаты опубликованы в рецензируемых научных изданиях и в трудах рецензируемых российских и международных конференций по машинному обучению и искусственному интеллекту.

Апробация работы. Основные результаты работы докладывались и обсуждались на следующих научных конференциях:

1. Открытая конференция ИСП РАН, Москва, 9–10 декабря 2025 г.
2. 22-я Всероссийская конференция с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября 2025 г.
3. 67-я Всероссийская научная конференция МФТИ, Москва, 31 марта – 5 апреля 2025 г.
4. Открытая конференция ИСП РАН, Москва, 11–12 декабря 2024 г.
5. 66-я Всероссийская научная конференция МФТИ, Москва, 1–6 апреля 2024 г.

Личный вклад. Все приведенные результаты, кроме отдельно оговоренных случаев, получены диссертантом лично при научном руководстве к.ф.-м.н. А.В. Грабового.

Публикации. *Список публикаций приведен в конце диссертации.* Основные результаты по теме диссертации изложены в 8 научных работах, из которых 3 — в периодических научных журналах, индексируемых Web of Science и Scopus, а остальные 5 — в тезисах докладов российских и международных конференций.

Объем и структура работы. Диссертация состоит из введения, 5 глав и заключения. Полный объем диссертации составляет 138 страниц, включая 24 рисунка и 5 таблиц. Список литературы содержит 82 наименования.

Глава 1. Обзор проблемы и постановка задач исследования

В данной главе приводится введение в задачу определения достаточного размера обучающей выборки для параметрических моделей машинного обучения и постановка задач диссертационной работы. Сначала вводятся основные понятия: параметрическая модель, функция потерь, множество оптимальных параметров и его зависимость от выборки. Далее дается краткий обзор существующих подходов к оценке достаточного размера выборки и их ограничений для современных моделей. Затем вводится ключевой объект исследования — оптимизационная поверхность (ландшафт функции потерь) — и обсуждается, как ее стабилизация при увеличении объема данных может служить математическим описанием законов масштабирования. В заключение главы формулируются критерии достаточности для линейных моделей и нейронных сетей. Детальное обсуждение и доказательства приводятся в последующих главах, основанных на работах автора [A1—A8].

1.1. Параметрические модели машинного обучения и множество оптимальных параметров

Решение задачи машинного обучения с учителем предполагает выбор предсказательной модели из некоторого параметрического семейства. Объектом называется пара $(\mathbf{x}, y)$, где $\mathbf{x} \in \mathbb{X} \subseteq \mathbb{R}^n$ — вектор признакового описания, $y \in \mathbb{Y}$ — целевая переменная. В задаче регрессии $\mathbb{Y} = \mathbb{R}$, в задаче классификации $\mathbb{Y} = \{1, \dots, K\}$. Выборка размера m задается множеством $\mathfrak{D}_m = \{(\mathbf{x}_i, y_i)\}_{i=1}^m$ из m независимых реализаций пар $(\mathbf{x}, y)$, распределенных согласно неизвестному распределению $p(\mathbf{x}, y)$.

Параметрической моделью называется семейство функций $f_{\mathbf{w}} : \mathbb{X} \rightarrow \mathbb{Y}$, задаваемое вектором параметров $\mathbf{w} \in \mathbb{W} \subset \mathbb{R}^N$. Выбор модели из этого семейства проводится с помощью эмпирической функции потерь, вычисляемой на заданной выборке:

$$\mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \ell(f_{\mathbf{w}}(\mathbf{x}_i), y_i), \quad (1.1)$$

где $\ell : \mathbb{Y} \times \mathbb{Y} \rightarrow \mathbb{R}^+$ — функция потерь на одном объекте (например, квадратичная или кросс-энтропийная). Обучение модели таким образом есть решение оптимизационной задачи

$$\mathbf{w}_m^* \in \arg \min_{\mathbf{w} \in \mathbb{W}} \mathcal{L}_m(\mathbf{w}). \quad (1.2)$$

Отметим, что эмпирическая функция потерь вычисляется по конечной выборке и потому случайна: при другой реализации выборки $\mathfrak{D}'_m$ того же размера получается другая функция $\mathcal{L}'_m(\mathbf{w})$ и, как правило, другое множество минимизаторов (1.2). При малом m это множество может быть обширным или нестабильным: добавление или удаление нескольких объектов существенно меняет и значение минимума, и расположение оптимальных параметров. Однако поскольку при увеличении m эмпирическая функция потерь (1.1) согласно закону больших чисел (ЗБЧ) сходится к популяционной

$$\mathcal{L}(\mathbf{w}) = \mathbb{E}_{(\mathbf{x}, y) \sim p(\mathbf{x}, y)} [\ell(f_{\mathbf{w}}(\mathbf{x}), y)],$$

то естественно ожидать, что множество решений стабилизируется — сузится или перестанет заметно смещаться при добавлении новых данных.

В вероятностной постановке параметрическая модель вводится как совместное распределение

$$p(y, \mathbf{w} | \mathbf{x}) = p(y | \mathbf{x}, \mathbf{w}) p(\mathbf{w}) : \mathbb{Y} \times \mathbb{W} \times \mathbb{X} \rightarrow \mathbb{R}^+,$$

где $p(y | \mathbf{x}, \mathbf{w})$ задает правдоподобие объекта, а $p(\mathbf{w})$ — априорное распределение параметров. Оптимальные параметры описываются апостериорным распределением $p(\mathbf{w} | \mathfrak{D}_m)$. Как и в случае классической постановки, при увеличении количества данных множество оптимальных параметров концентрируется около «истинного» вектора, породившего заданную выборку.

В задачах машинного обучения оптимум функции потерь (1.2) часто не единствен. В линейной регрессии при невырожденной матрице признаков существует единственный глобальный минимум, но при мультиколлинеарности или при $m < n$ задача вырождена: множество решений образует аффинное подпространство [10—12]. В нейронных сетях функция потерь, как правило, невыпукла: существуют множественные локальные минимумы, седловые точки и плато [4; 13—15]. Более того, из-за симметрий (перестановка нейронов, знаковые преобразования) многие минимумы эквивалентны с точки зрения

предсказательной способности [6; 16; 17]. В таких условиях корректнее говорить не о единственной точке минимума, а о множестве оптимальных параметров модели.

1.2. Законы масштабирования параметрических моделей и достаточный размер выборки

Особенный интерес представляет вопрос о законах масштабирования параметрических моделей: по какому правилу следует совместно выбирать архитектуру модели и объем данных для ее обучения. В классических постановках задача определения достаточного размера выборки обычно рассматривается для линейных и обобщенно-линейных моделей, где модель задается конечномерным вектором параметров, а достаточность выборки формулируется через статистические критерии различимости гипотез о параметрах или через устойчивость вероятностной оценки модели [18–23]. Для обобщенно-линейных моделей используются, в частности, нормальная, логистическая и пуассоновская регрессии, объединяемые общей экспоненциальной формой распределения отклика и функцией связи между математическим ожиданием и линейным предиктором.

Классические статистические методы оценки размера выборки опираются на задание нулевой и альтернативной гипотез, допустимой вероятности ошибки первого рода и требуемой мощности теста. В наиболее общем виде достаточный размер выборки m^* определяется как минимальное значение m , при котором статистика критерия T_m обеспечивает требуемую мощность:

$$m^* : \quad \mathbb{P}(T_m > c_\alpha | H_1) \geq 1 - \beta,$$

где c_α — критическое значение уровня значимости α , а $(1 - \beta)$ — требуемая мощность. В этой постановке используются критерий отношения правдоподобия, статистика Вальда, метод множителей Лагранжа и их модификации [18–22]. Эти методы дают теоретически обоснованные оценки, но требуют явных предположений о распределении данных, структуре модели и величине эффекта при альтернативе. На практике такие предположения часто недоступны или труднопроверяемы, особенно для многопараметрических нелинейных моделей.

Наряду со статистическими существуют байесовские и информационно-теоретические подходы. В байесовской постановке достаточность выборки связывается со стабилизацией апостериорного распределения параметров, уменьшением апостериорной неопределенности или малостью расстояния между распределениями, полученными по соседним подвыборкам. Типичными критериями являются средняя апостериорная дисперсия, среднее покрытие, средняя длина доверительной области и дивергенция Кульбака–Лейблера между апостериорными распределениями [23–26]. Информационно-теоретические подходы близки к этой линии и также используют энтропийные и дивергентные характеристики для описания связи между моделью и данными. Однако для моделей большой размерности такие методы часто оказываются вычислительно сложными и требуют дополнительных модельных предположений.

В статистической теории обучения размер выборки связывается со сложностью класса моделей через VC-размерность и родственные меры емкости. Классические результаты этого типа лежат в основе PAC-анализа и дают оценки числа объектов, достаточного для гарантированного обобщения. Однако для нейронных сетей VC-размерность, как правило, очень велика, вследствие чего получаемые оценки оказываются грубыми и существенно завышенными. Более современные data-dependent меры, такие как радемахеровские сложности, позволяют получать более тонкие оценки обобщающей способности. В русскоязычной литературе существенный вклад в развитие этой линии внес К. В. Воронцов, развивший комбинаторную теорию переобучения, методы получения точных оценок вероятности переобучения и data-dependent оценки обобщающей способности, в том числе в связи с радемахеровской сложностью и комбинаторными оценками надежности обучения по прецедентам [12; 27; 28]. Для глубоких сетей были также предложены спектрально-нормированные margin bounds и другие refinement-подходы, учитывающие произведения операторных норм весовых матриц [29]. Тем не менее даже такие оценки далеки от объяснения наблюдаемой в практике высокой обобщающей способности сильно пере параметризованных сетей. Экспериментально показано, что современные глубокие сети способны точно аппроксимировать даже случайную разметку, что плохо согласуется с наивными комбинаторными оценками сложности [30].

Классические подходы плохо переносятся на современные нейронные сети по нескольким причинам. Во-первых, комбинаторные и асимптотические меры сложности дают нереалистично большие или трудно интерпретируемые оцен-

ки необходимого объема данных. Во-вторых, явные статистические гипотезы о параметрах нейросетей обычно неизвестны. В-третьих, многократное полное переобучение модели на подвыборках разного размера для построения кривых обучения вычислительно дорого для больших сетей.

В то же время эмпирические исследования последних лет показывают существование устойчивых законов масштабирования: качество моделей систематически улучшается с ростом числа параметров, объема данных и вычислительного бюджета. В работе [2] показано, что для языковых моделей значение функции потерь хорошо аппроксимируется степенными законами по размеру модели, размеру выборки и объему вычислений. В работе [3] предложена *compute-optimal* постановка, согласно которой при фиксированном вычислительном бюджете размер модели и число обучающих токенов должны масштабироваться согласованно; при этом многие крупные языковые модели оказались недообученными по данным. Эти результаты оказали значительное влияние на современное понимание компромисса между размером модели и объемом обучающей выборки, однако единого теоретического объяснения таких закономерностей для широкого класса параметрических моделей до сих пор нет.

Таким образом, возникает необходимость в развитии новых подходов к описанию достаточного размера выборки и законов масштабирования, опирающихся на свойства, доступные для анализа во всех параметрических моделях и инвариантные к выбору конкретного минимума. В настоящей диссертации в качестве такого объекта предлагается использовать локальную геометрию оптимизационной задачи (1.2), то есть свойства ландшафта функции потерь в окрестности точки минимума.

1.3. Оптимизационная поверхность и матрица Гессе как ее ключевая характеристика

Оптимизационной поверхностью или ландшафтом функции потерь (англ. *loss landscape*) называется график $\mathcal{L}_m(\mathbf{w})$ как функции от $\mathbf{w} \in \mathbb{W} \subset \mathbb{R}^N$. Анализ этой поверхности для нейронных сетей является ключевой задачей теории оптимизации, что связано с итерационной природой процесса обучения —

алгоритмы на основе стохастического градиентного спуска (англ. SGD) дают приближенное решение (1.2), опираясь на глобальные и локальные свойства.

Исследование ландшафта функции потерь позволило выявить ряд важных характеристик, определивших развитие современных методов численной оптимизации [31—33] — наличие множественных минимумов, седловых точек, многообразий меньшей размерности, содержащих множества оптимальных параметров [6; 7], и др. В теории генерализации нейронных сетей плоские минимумы (с малой кривизной) часто связывают с лучшей обобщающей способностью [8; 33; 34], а узкие и глубокие — наоборот. Форма поверхности при этом определяется как самой архитектурой модели, так и заданной обучающей выборкой. Глубина и ширина нейронной сети давно перестали быть определяющими факторами для достижения высокого качества [35], из-за чего возникают новые архитектурные решения, позволяющие снизить сложность модели при неухудшении ее обобщающих свойств [36—41].

Ключевой характеристикой для анализа оптимизационной поверхности является матрица Гессе функции потерь $\mathbf{H}^{(m)}(\mathbf{w}) = \nabla_{\mathbf{w}}^2 \mathcal{L}_m(\mathbf{w})$, которая содержит информацию о поведении ландшафта во втором порядке. Спектр матрицы Гессе характеризует нелинейность поверхности в окрестности минимума: большие собственные значения соответствуют «острым» направлениям, малые — «плоским» [4; 13; 34; 42]. Более того, для типичных нейросетей наблюдается характерная структура спектра: множество малых собственных значений и небольшое число выбросов [9; 43—45]. Множество работ посвящено еще более детальному анализу матрицы Гессе для различных архитектур моделей: выводу его явных выражений для полносвязных сетей [46—48] и даже механизмов внимания в трансформерных сетях [49].

Матрицы Гессе используются в задачах оптимизации методом Ньютона [50] и квазиньютоновскими методами [50; 51], среди которых наиболее известный — алгоритм Бroyдена—Флетчера—Гольдфарба—Шанно (англ. BFGS) [52; 53]. Матрица Гессе и произведения Гессе на вектор применяются не только для построения методов второго порядка, но и для анализа локальной кривизны ландшафта, оценки «остроты» и «плоскости» минимумов, спектрального исследования динамики обучения, приближенного вычисления доверительных характеристик параметров, pruning и low-rank аппроксимаций, а также для построения гаусс—ньютоновских и hessian-free методов в больших нейросетевых моделях [9; 48; 54; 55].

Несмотря на интерес научного сообщества к исследованию матрицы Гессе и ее применений в обучении нейронных сетей, вопрос о связи характеристик второго порядка оптимизационной поверхности с законами масштабирования остается открытым.

1.4. Постановка задач исследования

В диссертации рассматривается задача построения законов масштабирования параметрических моделей машинного обучения на основе локальных свойств оптимизационной поверхности и их стабилизации при увеличении объема обучающей выборки. На этой основе исследуется задача определения достаточного размера выборки.

В главе 2 изучаются спектральные свойства матрицы Гессе нейронных сетей. Для полносвязных и сверточных архитектур получают верхние оценки спектральной нормы гаусс—ньютоновской компоненты.

В главе 3 исследуется сходимость ландшафта функции потерь при увеличении размера выборки. На основе локальной квадратичной аппроксимации функции потерь вводятся критерии стабилизации поверхности в окрестности точки минимума, по распределению точек в полном пространстве параметров и в подпространстве главных собственных векторов матрицы Гессе.

В главе 4 полученные оценки локальной кривизны и критерии стабилизации ландшафта объединяются в схему законов масштабирования параметрических моделей. На этой основе формулируются критерии достаточного размера выборки.

В главе 5 вероятностные линейные модели рассматриваются как частный случай параметрических моделей. Для них исследуется стабилизация оценок максимума правдоподобия и апостериорных распределений параметров при увеличении объема выборки и строятся критерии достаточного размера выборки.

Глава 2. Спектральные свойства матриц Гессе нейронных сетей

В данной главе исследуются спектральные свойства матрицы Гессе функции потерь для нейронных сетей. Основное внимание уделяется гаусс—ньютоновской компоненте как спектрально значимой части второй производной в окрестности точки минимума. Сначала вводится общий класс матрично-представимых нейронных сетей и выводится блочная факторизация гаусс—ньютоновской компоненты. Затем на этой основе получаются верхние оценки ее спектральной нормы для полносвязных и сверточных архитектур. Эти оценки далее используются как архитектурно-зависимые характеристики локальной кривизны оптимизационной поверхности.

2.1. Введение

Анализ геометрии поверхности функции потерь является одним из основных подходов к исследованию обучения нейронных сетей. Для современных переопределенных моделей ландшафт функции потерь имеет сложную невыпуклую структуру, однако его локальные свойства в окрестности найденных решений оказываются тесно связаны с устойчивостью оптимизации, обобщающей способностью и чувствительностью к выбору гиперпараметров. В работах по визуализации и анализу loss landscape показано, что форма минимумов, наличие плоских направлений и связность областей малого значения функции потерь играют существенную роль в поведении обучаемых моделей. [4; 6; 7]

Ключевым локальным объектом такого анализа является матрица Гессе функции потерь по параметрам модели. Ее собственные значения описывают кривизну ландшафта вдоль различных направлений в пространстве параметров: большие собственные значения соответствуют направлениям высокой кривизны, а малые — почти плоским направлениям. Для глубоких сетей эмпирически наблюдается характерная структура спектра Гессе: основная масса собственных значений сосредоточена вблизи нуля, тогда как небольшое число выбросов определяет главные направления локальной геометрии. Такая струк-

тура подробно исследовалась в работах, посвященных спектру Гессе в задачах глубокого обучения. [43; 45; 56—58]

Для практического и теоретического анализа второй производной особенно важным является разложение Гаусса—Ньютона. Оно представляет матрицу Гессе как сумму гаусс—ньютоновской компоненты, определяемой якобианом выхода модели и кривизной функции потерь по выходу, и остаточного члена, связанного со вторыми производными самой параметризации. В задачах обучения нейронных сетей гаусс—ньютоновская часть часто рассматривается как основная спектрально значимая компонента, а также как естественный объект для построения вычислительно эффективных методов второго порядка. Это отражено как в работах по оптимизации, так и в исследованиях структуры Гессе в глубоких моделях. [54; 59—62]

В настоящей главе матрица Гессе рассматривается не только как инструмент локального анализа, но и как промежуточное звено между архитектурой модели и стабилизацией оптимизационной поверхности при увеличении объема обучающей выборки. Для этого требуется получить явные архитектурно-зависимые оценки спектральной нормы второй производной. Вместо прямого анализа полной матрицы Гессе далее исследуется ее гаусс—ньютоновская компонента, для которой удастся построить единое факторизованное представление в классе матрично-представимых нейронных сетей. Такой подход позволяет вывести оценки, непосредственно выражающие зависимость локальной кривизны от глубины сети, норм весовых операторов, свойств активаций и структуры слоя.

Далее в главе сначала вводятся общие обозначения и разложение Гаусса—Ньютона. Затем определяется класс матрично-представимых нейронных сетей и доказывается лемма о блочной факторизации гаусс—ньютоновской компоненты. После этого получаются верхние оценки спектральной нормы для полносвязных и сверточных архитектур. В заключение обсуждаются вычислительные эксперименты, показывающие, что на поздних этапах обучения гаусс—ньютоновская компонента действительно хорошо приближает спектрально значимую часть полной матрицы Гессе. [13; 43; 56; 63]

2.2. Предварительные сведения

Матрица Гессе функции потерь. Объектом называется пара $(\mathbf{x}, \mathbf{y})$, где $\mathbf{x} \in \mathbb{R}^n$ — вектор признакового описания, $\mathbf{y} \in \mathbb{R}^K$ — целевая переменная. В задаче регрессии $K = 1$, в задаче классификации $K > 1$ и $\mathbf{y} = [0, \dots, 1, \dots, 0]^\top$, где единица стоит на k -ой позиции, соответствуя истинной метке класса k . Выборка размера m задается множеством $\mathfrak{D}_m = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^m$ из m независимых реализаций пар $(\mathbf{x}, \mathbf{y})$.

Параметрической моделью называется семейство функций $f_{\mathbf{w}} : \mathbb{R}^n \rightarrow \mathbb{R}^K$, задаваемое вектором параметров $\mathbf{w} \in \mathbb{R}^N$. Выбор модели из этого семейства проводится с помощью эмпирической функции потерь, вычисляемой на заданной выборке:

$$\mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \ell(f_{\mathbf{w}}(\mathbf{x}_i), \mathbf{y}_i), \quad (2.1)$$

где $\ell : \mathbb{R}^K \times \mathbb{R}^K \rightarrow \mathbb{R}^+$ — функция потерь на одном объекте (например, квадратичная или кросс-энтропийная). Локальные свойства оптимизационной поверхности функции $\mathcal{L}_m(\mathbf{w})$ в точке $\mathbf{w}$ задаются ее производными первого и второго порядка. Вектор градиента

$$\mathbf{g}^{(m)}(\mathbf{w}) = \nabla_{\mathbf{w}} \mathcal{L}_m(\mathbf{w}) \in \mathbb{R}^N$$

определяет направление наискорейшего возрастания функции потерь, тогда как матрица Гессе

$$\mathbf{H}^{(m)}(\mathbf{w}) = \nabla_{\mathbf{w}}^2 \mathcal{L}_m(\mathbf{w}) \in \mathbb{R}^{N \times N}$$

характеризует локальную кривизну оптимизационной поверхности. Спектральные свойства матрицы $\mathbf{H}^{(m)}(\mathbf{w})$ определяют геометрию в окрестности точки минимума: большие собственные значения соответствуют направлениям высокой кривизны, а малые — направлениям слабой кривизны [4; 13; 64; 65].

Поскольку функция потерь (2.1) задается усреднением по объектам обучающей выборки, ее матрица Гессе также представляется в виде среднего:

$$\mathbf{H}^{(m)}(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \mathbf{H}_i(\mathbf{w}), \quad \mathbf{H}_i(\mathbf{w}) = \nabla_{\mathbf{w}}^2 \ell(f_{\mathbf{w}}(\mathbf{x}_i), \mathbf{y}_i) \in \mathbb{R}^{N \times N}.$$

Тем самым исследование спектральных свойств $\mathbf{H}^{(m)}(\mathbf{w})$ сводится к анализу $\mathbf{H}_i(\mathbf{w})$ на отдельных объектах $(\mathbf{x}_i, \mathbf{y}_i)$ выборки $\mathfrak{D}_m$.

Разложение Гаусса—Ньютона матрицы Гессе. Далее в главе мы опускаем индекс объекта i , переходя к анализу матрицы Гессе $\mathbf{H}(\mathbf{w})$ на одном объекте $(\mathbf{x}, \mathbf{y})$. Воспользуемся правилом дифференцирования сложной функции для матрицы Гессе. Обозначим

$$\mathbf{z} = f_{\mathbf{w}}(\mathbf{x}) \in \mathbb{R}^K, \quad \mathbf{J}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{w}} \in \mathbb{R}^{K \times N}, \quad \mathbf{A}(\mathbf{w}) = \nabla_{\mathbf{z}}^2 \ell(\mathbf{z}, \mathbf{y}) \in \mathbb{R}^{K \times K},$$

где $\mathbf{z}$ суть выход модели, $\mathbf{J}(\mathbf{w})$ есть якобиан выхода модели по параметрам, $\mathbf{A}(\mathbf{w})$ — матрица кривизны функции потерь по выходу модели. Тогда матрица Гессе на одном объекте допускает разложение

$$\mathbf{H}(\mathbf{w}) = \mathbf{G}(\mathbf{w}) + \mathbf{R}(\mathbf{w}), \quad (2.2)$$

где

$$\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w}) \quad (2.3)$$

есть гаусс—ньютоновская компонента, а

$$\mathbf{R}(\mathbf{w}) = \sum_{k=1}^K \frac{\partial \ell(\mathbf{z}, \mathbf{y})}{\partial z_k} \nabla_{\mathbf{w}}^2 z_k$$

есть остаточная компонента, связанная со вторыми производными выходов модели по параметрам.

Разложение (2.2) разделяет два источника кривизны оптимизационной поверхности. гаусс—ньютоновская компонента $\mathbf{G}(\mathbf{w})$ определяется кривизной функции потерь по выходу модели и якобианом отображения $\mathbf{w} \mapsto \mathbf{z}$. Остаточная компонента $\mathbf{R}(\mathbf{w})$ определяется нелинейностью самой параметризации модели и зависит от вторых производных выходов по параметрам. Для нейронных сетей спектр матрицы Гессе, как правило, имеет выраженную неоднородную структуру: основная масса собственных значений сосредоточена вблизи нуля, тогда как небольшое число выбросов задает главные направления кривизны [43; 45; 56; 58]. В рамках разложения Гаусса—Ньютона именно гаусс—ньютоновская компонента $\mathbf{G}(\mathbf{w})$ определяет спектрально значимую часть матрицы Гессе. Остаточная компонента $\mathbf{R}(\mathbf{w})$ вносит вклад преимущественно в область малых собственных значений и, кроме того, ослабевает в окрестности точки минимума, поскольку пропорциональна производным функции потерь по выходу модели. По этой причине в дальнейшем основное внимание будет уделено исследованию гаусс—ньютоновской компоненты.

2.3. Матрично-представимые нейронные сети и факторизация гаусс—ньютоновской компоненты

Для получения единых выражений для различных архитектур введем класс матрично-представимых нейронных сетей. Основная идея состоит в том, что каждый слой такой сети задается линейным оператором, зависящим от параметров слоя, а вся сеть представляется как композиция линейных преобразований и нелинейных активаций.

Определение. Нейронная сеть называется *матрично-представимой*, если ее выход $\mathbf{z} = f_{\mathbf{w}}(\mathbf{x})$ для входа $\mathbf{x}$ может быть записан в виде композиции

$$\mathbf{x}^{(1)} = \mathbf{x}, \quad \mathbf{z}^{(p)} = T_{\mathbf{w}^{(p)}}^{(p)}(\mathbf{x}^{(p)}), \quad \mathbf{x}^{(p+1)} = \sigma^{(p)}(\mathbf{z}^{(p)}), \quad p = 1, \dots, L-1,$$

$$f_{\mathbf{w}}(\mathbf{x}) = \mathbf{z}^{(L)} = T_{\mathbf{w}^{(L)}}^{(L)}(\mathbf{x}^{(L)}),$$

где

$$\mathbf{w} = \text{col}(\mathbf{w}^{(1)}, \dots, \mathbf{w}^{(L)}) = [\mathbf{w}^{(1)\top}, \dots, \mathbf{w}^{(L)\top}]^\top,$$

функции активации

$$\sigma^{(p)} : \mathbb{R}^{n_p} \rightarrow \mathbb{R}^{n_p}$$

задают нелинейные преобразования, а каждый оператор

$$T_{\mathbf{w}^{(p)}}^{(p)} : \mathbb{R}^{n_{p-1}} \rightarrow \mathbb{R}^{n_p} \tag{2.4}$$

линеен по входу $\mathbf{x}^{(p)}$, причем его зависимость от параметров $\mathbf{w}^{(p)} \in \mathbb{R}^{N_p}$ допускает матричное представление.

Замечание. К классу матрично-представимых нейронных сетей относятся, в частности, полносвязные сети, в которых $T_{\mathbf{w}^{(p)}}^{(p)}(\mathbf{x}) = \mathbf{W}^{(p)}\mathbf{x} + \mathbf{b}^{(p)}$, и сверточные сети после векторизации входов и матризации операции свертки, где свертка задается матрицей Тёплица или блочно-тёплицевой матрицей. Именно эти два класса архитектур будут подробно рассмотрены далее в настоящей главе. В то же время не всякая нейронная архитектура является матрично-представимой в смысле данного определения. В частности, стандартный блок self-attention в трансформере не входит в этот класс, поскольку веса внимания зависят от самого входа и преобразование перестает быть линейным по входу. По той же причине в данный класс не входят нормализационные слои типа LayerNorm или BatchNorm, а также операции максимума, например MaxPool.

Для каждого слоя введем два типа матриц. Во-первых, обозначим через

$$\mathbf{S}^{(p)}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{z}^{(p)}} \in \mathbb{R}^{K \times n_p} \quad (2.5)$$

матрицу распространения возмущения преактивации p -го слоя к выходу сети. Эта матрица аккумулирует влияние всех последующих слоев и нелинейностей. Во-вторых, обозначим через

$$\mathbf{P}^{(p)}(\mathbf{w}) = \frac{\partial \mathbf{z}^{(p)}}{\partial \mathbf{w}^{(p)}} \in \mathbb{R}^{n_p \times N_p} \quad (2.6)$$

параметрический якобиан p -го слоя, связывающий приращения параметров слоя с приращениями его выходов под действием соответствующего линейного оператора. Тогда якобиан выхода сети по параметрам p -го слоя по правилу дифференцирования сложной функции записывается в виде

$$\mathbf{J}^{(p)}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{w}^{(p)}} = \frac{\partial \mathbf{z}}{\partial \mathbf{z}^{(p)}} \cdot \frac{\partial \mathbf{z}^{(p)}}{\partial \mathbf{w}^{(p)}} = \mathbf{S}^{(p)}(\mathbf{w}) \mathbf{P}^{(p)}(\mathbf{w}) \in \mathbb{R}^{K \times N_p}. \quad (2.7)$$

Далее, поскольку вектор параметров имеет блочную структуру $\mathbf{w} = \text{col}(\mathbf{w}^{(1)}, \dots, \mathbf{w}^{(L)})$, полный якобиан выхода сети по всем параметрам представляется в виде горизонтальной конкатенации послойных якобианов:

$$\mathbf{J}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{w}} = \left[\mathbf{J}^{(1)}(\mathbf{w}), \dots, \mathbf{J}^{(L)}(\mathbf{w}) \right],$$

откуда с учетом (2.7) получаем

$$\mathbf{J}(\mathbf{w}) = \left[\mathbf{S}^{(1)}(\mathbf{w}) \mathbf{P}^{(1)}(\mathbf{w}), \dots, \mathbf{S}^{(L)}(\mathbf{w}) \mathbf{P}^{(L)}(\mathbf{w}) \right]. \quad (2.8)$$

Наконец, учитывая все введенные выше обозначения, мы можем сформулировать лемму о блочной факторизации гаусс—ньютоновской компоненты матрицы Гессе в матрично-представимых нейронных сетях. Графическая иллюстрация утверждения леммы приведена на рисунке 2.1.

Лемма 2.3.1. Пусть $f_{\mathbf{w}}$ является матрично-представимой нейронной сетью, тогда гаусс—ньютоновская компонента матрицы Гессе имеет блочную структуру

$$\mathbf{G}(\mathbf{w}) = \left[\mathbf{G}^{(p,q)}(\mathbf{w}) \right]_{p,q=1}^L, \quad (2.9)$$

где каждый блок $\mathbf{G}^{(p,q)}(\mathbf{w}) \in \mathbb{R}^{N_p \times N_q}$ задается выражением

$$\mathbf{G}^{(p,q)}(\mathbf{w}) = \mathbf{P}^{(p)}(\mathbf{w})^\top \mathbf{S}^{(p)}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{S}^{(q)}(\mathbf{w}) \mathbf{P}^{(q)}(\mathbf{w}). \quad (2.10)$$




Рисунок 2.1 — Блочная структура гаусс—ньютоновской компоненты для матрично-представимой нейронной сети. Каждый блок $\mathbf{G}^{(p,q)}(\mathbf{w})$ выражается через параметрические якобианы слоев и матрицы распространения возмущения.

Доказательство. По формуле (2.8) имеем выражение якобиана

$$\mathbf{J}(\mathbf{w}) = [\mathbf{S}^{(1)}(\mathbf{w})\mathbf{P}^{(1)}(\mathbf{w}), \dots, \mathbf{S}^{(L)}(\mathbf{w})\mathbf{P}^{(L)}(\mathbf{w})].$$

Следовательно, транспонированной якобиан задается формулой

$$\mathbf{J}(\mathbf{w})^\top = \begin{bmatrix} \mathbf{P}^{(1)}(\mathbf{w})^\top \mathbf{S}^{(1)}(\mathbf{w})^\top \\ \vdots \\ \mathbf{P}^{(L)}(\mathbf{w})^\top \mathbf{S}^{(L)}(\mathbf{w})^\top \end{bmatrix}.$$

Подставляя эти выражения в определение гаусс—ньютоновской компоненты (2.3),

$$\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w}),$$

получаем блочную матрицу, (p, q) -й блок которой имеет факторизованный вид

$$\mathbf{G}^{(p,q)}(\mathbf{w}) = \mathbf{P}^{(p)}(\mathbf{w})^\top \mathbf{S}^{(p)}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{S}^{(q)}(\mathbf{w}) \mathbf{P}^{(q)}(\mathbf{w}),$$

что и требовалось доказать. □

Лемма 2.3.1 показывает, что спектральные свойства гаусс—ньютоновской компоненты определяются тремя типами объектов. Матрица $\mathbf{A}(\mathbf{w})$ описывает кривизну функции потерь по выходу модели и не зависит от ее архитектуры. Матрицы $\mathbf{S}^{(p)}(\mathbf{w})$ характеризуют распространение возмущений от промежуточных слоев к выходу сети. Матрицы $\mathbf{P}^{(p)}(\mathbf{w})$ задают чувствительность выходов

отдельных слоев к их параметрам. Поэтому анализ $\mathbf{G}(\mathbf{w})$ для конкретных архитектур сводится к исследованию структуры этих матриц и получению оценок для блоков (2.10).

2.4. Полносвязные нейронные сети

Рассмотрим L -слойную полносвязную нейронную сеть, заданную рекуррентно:

$$\mathbf{x}^{(1)} = \mathbf{x}, \quad \mathbf{z}^{(p)} = \mathbf{W}^{(p)} \mathbf{x}^{(p)} + \mathbf{b}^{(p)}, \quad \mathbf{x}^{(p+1)} = \sigma^{(p)} \left(\mathbf{z}^{(p)} \right), \quad p = 1, \dots, L-1,$$

$$f_{\mathbf{w}}(\mathbf{x}) = \mathbf{z}^{(L)} = \mathbf{W}^{(L)} \mathbf{x}^{(L)} + \mathbf{b}^{(L)},$$

где $\mathbf{W}^{(p)} \in \mathbb{R}^{n_p \times n_{p-1}}$, $\mathbf{b}^{(p)} \in \mathbb{R}^{n_p}$, $\mathbf{w}^{(p)} = \text{col}(\text{vec}(\mathbf{W}^{(p)}), \mathbf{b}^{(p)})$. Она является матрично-представимой в смысле определения (2.4), т. к. для нее оператор $T_{\mathbf{w}^{(p)}}^{(p)}$ задается умножением на матрицу $\mathbf{W}^{(p)}$ и смещением на вектор $\mathbf{b}^{(p)}$. Следовательно, к ней применима лемма 2.3.1. Здесь мы ввели обозначение $\text{vec}(\cdot)$ для операции векторизации матрицы по столбцам. Существует и другой вариант векторизации, по строкам, который мы будем использовать в следующих разделах, его будем обозначать $\text{vec}_r(\cdot)$. Далее в этом разделе мы получим явные выражения для матриц $\mathbf{S}^{(p)}(\mathbf{w})$ и $\mathbf{P}^{(p)}(\mathbf{w})$, благодаря чему сформулируем теорему о верхней оценке на спектральную норму гаусс—ньютоновской компоненты матрицы Гессе полносвязной сети.

Матрица распространения возмущения $\mathbf{S}^{(p)}$ по определению (2.5) и правилу дифференцирования сложной функции записывается в виде

$$\mathbf{S}^{(p)}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{z}^{(p)}} = \frac{\partial \mathbf{z}^{(L)}}{\partial \mathbf{z}^{(L-1)}} \frac{\partial \mathbf{z}^{(L-1)}}{\partial \mathbf{z}^{(L-2)}} \cdots \frac{\partial \mathbf{z}^{(p+1)}}{\partial \mathbf{z}^{(p)}}, \quad (2.11)$$

откуда для явного выражения матрицы $\mathbf{S}^{(p)}(\mathbf{w})$ нам достаточно раскрыть формулу $\partial \mathbf{z}^{(p+1)} / \partial \mathbf{z}^{(p)}$. Поскольку $\mathbf{z}^{(p+1)} = \mathbf{W}^{(p+1)} \mathbf{x}^{(p+1)} + \mathbf{b}^{(p+1)}$ и $\mathbf{x}^{(p+1)} = \sigma^{(p)}(\mathbf{z}^{(p)})$, то вновь по правилу дифференцирования сложной функции получаем

$$\frac{\partial \mathbf{z}^{(p+1)}}{\partial \mathbf{z}^{(p)}} = \frac{\partial \mathbf{z}^{(p+1)}}{\partial \mathbf{x}^{(p+1)}} \cdot \frac{\partial \mathbf{x}^{(p+1)}}{\partial \mathbf{z}^{(p)}} = \mathbf{W}^{(p+1)} \mathbf{D}^{(p)}(\mathbf{w}),$$

где мы обозначили диагональные матрицы производных активации

$$\mathbf{D}^{(p)} = \text{diag} \left(\sigma^{(p)'} \left(\mathbf{z}^{(p)} \right) \right) \in \mathbb{R}^{n_p \times n_p}.$$

Таким образом, матрица распространения возмущения преактивации p -го слоя к выходу сети преобразуется в

$$\mathbf{S}^{(p)}(\mathbf{w}) = \mathbf{W}^{(L)} \mathbf{D}^{(L-1)} \dots \mathbf{W}^{(p+1)} \mathbf{D}^{(p)}, \quad p = 1, \dots, L-1,$$

а для последнего слоя отдельно записывается как $\mathbf{S}^{(L)}(\mathbf{w}) = \mathbf{I}_K$.

Параметрический якобиан $\mathbf{P}^{(p)}$. Для полносвязного слоя без смещения $\mathbf{z}^{(p)} = \mathbf{W}^{(p)} \mathbf{x}^{(p)}$ параметры естественно отождествляются с вектором $\mathbf{w}^{(p)} = \text{vec}(\mathbf{W}^{(p)})$. Тогда, используя стандартное тождество векторизации

$$\text{vec}(\mathbf{W}^{(p)} \mathbf{x}^{(p)}) = (\mathbf{x}^{(p)\top} \otimes \mathbf{I}_{n_p}) \text{vec}(\mathbf{W}^{(p)}),$$

получаем

$$\frac{\partial \mathbf{z}^{(p)}}{\partial \mathbf{w}^{(p)}} = \frac{\partial \mathbf{z}^{(p)}}{\partial \text{vec}(\mathbf{W}^{(p)})} = \mathbf{x}^{(p)\top} \otimes \mathbf{I}_{n_p}.$$

При добавлении вектора смещения $\mathbf{b}^{(p)}$ матрица $\partial \mathbf{z}^{(p)} / \partial \mathbf{w}^{(p)}$ дополняется справа столбцами единичной матрицы, а значит в результате имеем

$$\mathbf{P}^{(p)}(\mathbf{w}) = \frac{\partial \mathbf{z}^{(p)}}{\partial \mathbf{w}^{(p)}} = [\mathbf{x}^{(p)\top} \otimes \mathbf{I}_{n_p}, \mathbf{I}_{n_p}].$$

Спектральная норма блока гаусс—ньютоновской компоненты оценивается сверху исходя из выражения (2.10), для которого мы применяем свойство субмультипликативности спектральной нормы:

$$\|\mathbf{G}^{(p,q)}(\mathbf{w})\|_2 \leq \|\mathbf{P}^{(p)}(\mathbf{w})\|_2 \|\mathbf{S}^{(p)}(\mathbf{w})\|_2 \|\mathbf{A}(\mathbf{w})\|_2 \|\mathbf{S}^{(q)}(\mathbf{w})\|_2 \|\mathbf{P}^{(q)}(\mathbf{w})\|_2.$$

По тому же свойству для матриц $\mathbf{S}^{(p)}$ можем записать

$$\|\mathbf{S}^{(p)}\|_2 \leq \|\mathbf{W}^{(L)}\|_2 \|\mathbf{D}^{(L-1)}\|_2 \dots \|\mathbf{W}^{(p+1)}\|_2 \|\mathbf{D}^{(p)}\|_2. \quad (2.12)$$

Далее сформулируем теорему, которая объединяет все проведенные выкладки, и при условии ограничений на вход сети и архитектурные свойства дает оценку на спектральную норму всей гаусс—ньютоновской компоненты матрицы Гессе.

Теорема 2.4.1. Пусть $f_{\mathbf{w}}$ является L -слойной полносвязной нейронной сетью без смещений. Предположим, что существуют такие положительные константы, что для всех слоев $p = 1, \dots, L$ выполнены ограничения $\|\mathbf{x}\|_2 \leq M_{\mathbf{x}}$, $\|\mathbf{A}(\mathbf{w})\|_2 \leq M_{\mathbf{A}}$, $\|\mathbf{W}^{(p)}\|_2 \leq M_{\mathbf{W}}$ и $\|\mathbf{D}^{(p)}\|_2 \leq M_{\sigma}$. Тогда спектральная норма гаусс—ньютоновской компоненты матрицы Гессе удовлетворяет оценке

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq L M_{\mathbf{x}}^2 M_{\mathbf{A}} (M_{\mathbf{W}} M_{\sigma})^{2L-2}. \quad (2.13)$$

Доказательство. В условиях теоремы из (2.12) следует оценка

$$\|\mathbf{S}^{(p)}(\mathbf{w})\|_2 \leq M_{\mathbf{W}}^{L-p} M_{\sigma}^{L-p}, \quad p = 1, \dots, L.$$

Для параметрического якобиана в отсутствие смещений из формулы

$$\mathbf{P}^{(p)}(\mathbf{w}) = \mathbf{x}^{(p)\top} \otimes \mathbf{I}_{n_p}$$

и свойства спектральной нормы произведения Кронекера получаем

$$\|\mathbf{P}^{(p)}(\mathbf{w})\|_2 = \|\mathbf{x}^{(p)\top} \otimes \mathbf{I}_{n_p}\|_2 = \|\mathbf{x}^{(p)}\|_2. \quad (2.14)$$

Далее, поскольку сеть не содержит смещений, а активации $\sigma^{(p)}$ являются M_{σ} -липшицевыми, для промежуточных представлений имеем рекуррентную оценку

$$\|\mathbf{x}^{(p+1)}\|_2 = \|\sigma^{(p)}(\mathbf{z}^{(p)})\|_2 \leq M_{\sigma} \|\mathbf{z}^{(p)}\|_2 \leq M_{\sigma} \|\mathbf{W}^{(p)}\|_2 \|\mathbf{x}^{(p)}\|_2 \leq M_{\sigma} M_{\mathbf{W}} \|\mathbf{x}^{(p)}\|_2.$$

Итерируя это неравенство и используя условие $\|\mathbf{x}\|_2 \leq M_{\mathbf{x}}$, получаем

$$\|\mathbf{x}^{(p)}\|_2 \leq (M_{\mathbf{W}} M_{\sigma})^{p-1} M_{\mathbf{x}}, \quad p = 1, \dots, L. \quad (2.15)$$

Совмещая (2.14) и (2.15), выводим

$$\|\mathbf{P}^{(p)}(\mathbf{w})\|_2 \leq (M_{\mathbf{W}} M_{\sigma})^{p-1} M_{\mathbf{x}}, \quad p = 1, \dots, L.$$

Тогда для послойного якобиана $\mathbf{J}^{(p)}(\mathbf{w}) = \mathbf{S}^{(p)}(\mathbf{w}) \mathbf{P}^{(p)}(\mathbf{w})$ по субмультипликативности спектральной нормы имеем

$$\|\mathbf{J}^{(p)}(\mathbf{w})\|_2 \leq \|\mathbf{S}^{(p)}(\mathbf{w})\|_2 \|\mathbf{P}^{(p)}(\mathbf{w})\|_2 \leq M_{\mathbf{x}} (M_{\mathbf{W}} M_{\sigma})^{L-1}, \quad p = 1, \dots, L.$$

Далее, из блочного представления полного якобиана

$$\mathbf{J}(\mathbf{w}) = \begin{bmatrix} \mathbf{J}^{(1)}(\mathbf{w}), \dots, \mathbf{J}^{(L)}(\mathbf{w}) \end{bmatrix}$$

следует

$$\mathbf{J}(\mathbf{w}) \mathbf{J}(\mathbf{w})^{\top} = \sum_{p=1}^L \mathbf{J}^{(p)}(\mathbf{w}) \mathbf{J}^{(p)}(\mathbf{w})^{\top}, \quad \|\mathbf{J}(\mathbf{w})\|_2^2 = \|\mathbf{J}(\mathbf{w}) \mathbf{J}(\mathbf{w})^{\top}\|_2.$$

Поэтому

$$\|\mathbf{J}(\mathbf{w})\|_2^2 \leq \sum_{p=1}^L \|\mathbf{J}^{(p)}(\mathbf{w})\|_2^2 \leq \sum_{p=1}^L M_{\mathbf{x}}^2 (M_{\mathbf{W}} M_{\sigma})^{2L-2} = L M_{\mathbf{x}}^2 (M_{\mathbf{W}} M_{\sigma})^{2L-2}. \quad (2.16)$$

Наконец, по определению гаусс—ньютоновской компоненты

$$\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w}),$$

откуда

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq \|\mathbf{J}(\mathbf{w})^\top\|_2 \|\mathbf{A}(\mathbf{w})\|_2 \|\mathbf{J}(\mathbf{w})\|_2 = \|\mathbf{A}(\mathbf{w})\|_2 \|\mathbf{J}(\mathbf{w})\|_2^2.$$

Подставляя сюда (2.16) и условие $\|\mathbf{A}(\mathbf{w})\|_2 \leq M_{\mathbf{A}}$, получаем

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq LM_{\mathbf{x}}^2 M_{\mathbf{A}} (M_{\mathbf{w}} M_{\sigma})^{2L-2},$$

что и требовалось доказать. $\square$

Особенный интерес представляют более конкретные случаи применения полносвязных сетей, например, для задачи классификации на K классов с кросс-энтропийной функцией потерь:

$$\ell(\mathbf{z}, \mathbf{y}) = - \sum_{k=1}^K y_k \log p_k, \quad p_k = \frac{\exp(z_k)}{\sum_{j=1}^K \exp(z_j)},$$

где $\mathbf{p} = [p_1, \dots, p_K]^\top = \text{Softmax}(\mathbf{z})$. Если, кроме того, выбрать конкретную функцию активации, например, $\text{ReLU}(\mathbf{x}) = [\mathbf{x} \geq 0] \mathbf{x}$, то можно сформулировать следующее следствие из предыдущей теоремы.

Следствие 2.4.2. Пусть в условиях теоремы 2.4.1 в качестве функции активации выбрана ReLU, а обучение решает задачу K -классовой классификации с кросс-энтропийной функцией потерь. Тогда спектральная норма гаусс—ньютоновской компоненты матрицы Гессе удовлетворяет оценке

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq \sqrt{2} L M_{\mathbf{x}}^2 M_{\mathbf{w}}^{2L-2}. \quad (2.17)$$

Доказательство. Известным результатом является формула матрицы Гессе кросс-энтропийной функции потерь по логитам:

$$\mathbf{A}(\mathbf{w}) = \nabla_{\mathbf{z}}^2 \ell(\mathbf{z}, \mathbf{y}) = \text{diag}(\mathbf{p}) - \mathbf{p} \mathbf{p}^\top,$$

на основе которой мы и построим доказательство данного утверждения. По теореме об эквивалентности норм в конечномерном пространстве имеем ограничение спектральной нормы через Фробениусову:

$$\|\mathbf{A}\|_2 \leq \|\mathbf{A}\|_F, \quad (2.18)$$

для которой по определению записываем

$$\|\mathbf{A}\|_F^2 = \|\text{diag}(\mathbf{p}) - \mathbf{p}\mathbf{p}^\top\|_F^2 = \sum_{k=1}^K (p_k - p_k^2)^2 + \sum_{k \neq l} p_k^2 p_l^2 = \sum_{k=1}^K p_k^2 (1 - p_k)^2 + \sum_{k \neq l} p_k^2 p_l^2.$$

Далее, поскольку для всех $k = 1, \dots, K$ верно $0 \leq p_k \leq 1$, справедливо, что $0 \leq p_k^2 \leq p_k$ и потому $0 \leq (1 - p_k)^2 \leq (1 - p_k)$. Следовательно, имеем

$$\begin{aligned} \sum_{k=1}^K p_k^2 (1 - p_k)^2 &\leq \sum_{k=1}^K p_k (1 - p_k) \leq \sum_{k=1}^K p_k = 1, \\ \sum_{k \neq l} p_k^2 p_l^2 &\leq \sum_{k \neq l} p_k p_l = \left(\sum_{k=1}^K p_k \right)^2 - \sum_{k=1}^K p_k^2 \leq 1 - \sum_{k=1}^K p_k^2. \end{aligned}$$

Объединяя эти неравенства, получаем

$$\|\mathbf{A}\|_F^2 \leq 1 + 1 - \sum_{k=1}^K p_k^2 \leq 2, \quad (2.19)$$

откуда, подставляя (2.19) в (2.18), заключаем, что $\|\mathbf{A}\|_2 \leq \sqrt{2}$, то есть $M_{\mathbf{A}} = \sqrt{2}$. Для функции $\text{ReLU}(t) = \max\{0, t\}$ имеем липшицевость с константой 1, то есть $M_{\sigma} = 1$. Подставляя эти значения в оценку (2.13), получаем (2.17). $\square$

Теорема 2.4.1 показывает, что в полносвязной архитектуре спектральная норма гаусс—ньютоновской компоненты растет линейно по числу слоев и экспоненциально по глубине в терминах верхней границы на операторные нормы матриц весов. Причина заключается в том, что матрицы распространения $\mathbf{S}^{(p)}(\mathbf{w})$ содержат длинные произведения плотных матриц весов, а параметрические якобианы $\mathbf{P}^{(p)}(\mathbf{w})$ наследуют рост норм промежуточных представлений $\mathbf{x}^{(p)}$.

2.5. Сверточные нейронные сети

Рассмотрим L -слойную сверточную нейронную сеть (англ. CNN). В отличие от полносвязных сетей, где каждый параметр связывает конкретную пару нейронов, в CNN параметры — ядра свертки — используются совместно для обработки локальных областей входа. Тем не менее, при фиксированных размерах

входных данных операция свертки является линейным оператором и допускает точное матричное представление, что позволяет включить CNN в класс матрично-представимых сетей.

Матричное представление свертки. Для приведения CNN к виду матрично-представимой сети необходимо определить правило векторизации. Пусть вход p -го слоя представляет собой тензор $\mathcal{X}^{(p)} \in \mathbb{R}^{C_{p-1} \times H_{p-1} \times W_{p-1}}$, где C — число каналов, H, W — пространственные размеры. Вектор $\mathbf{x}^{(p)} \in \mathbb{R}^{n_{p-1}}$ получается развертыванием тензора $\mathcal{X}^{(p)}$ по каналам и пространственным координатам (например, в порядке C, H, W), где $n_{p-1} = C_{p-1}H_{p-1}W_{p-1}$. Аналогично векторизуются выходы $\mathcal{Z}^{(p)} \in \mathbb{R}^{C_p \times H_p \times W_p} \mapsto \mathbf{z}^{(p)} \in \mathbb{R}^{n_p}$ и ядра свертки $\mathcal{W}^{(p)} \mapsto \mathbf{w}^{(p)} \in \mathbb{R}^{N_p}$. Сеть задается рекуррентно:

$$\mathbf{x}^{(1)} = \mathbf{x}, \quad \mathbf{z}^{(p)} = C_{\mathbf{w}^{(p)}}^{(p)} \left(\mathbf{x}^{(p)} \right) + \mathbf{b}^{(p)}, \quad \mathbf{x}^{(p+1)} = \sigma^{(p)} \left(\mathbf{z}^{(p)} \right),$$

где $C_{\mathbf{w}^{(p)}}^{(p)}$ — оператор дискретной свертки p -го слоя. Далее для простоты полагаем $\mathbf{b}^{(p)} = 0$, так как смещения не влияют на оценку спектральной нормы весовой части, и рассматриваем свертку со страйдом $s = 1$ и без паддинга.

Ключевым свойством, позволяющим применить лемму 2.3.1 к сверточным сетям, является возможность записать оператор свертки двумя эквивалентными способами через матричное умножение. Эта двойственность критически важна для корректного вычисления матриц $\mathbf{S}^{(p)}$ и $\mathbf{P}^{(p)}$, так как они требуют дифференцирования по разным аргументам (входу и параметрам соответственно).

Оператор свертки по входу (матрица Тёплица). Для любого фиксированного ядра $\mathbf{w}^{(p)}$ существует структурированная матрица $\mathbf{T}^{(p)}(\mathbf{w}) \in \mathbb{R}^{n_p \times n_{p-1}}$, такая что:

$$\mathbf{z}^{(p)} = \mathbf{T}^{(p)}(\mathbf{w})\mathbf{x}^{(p)}. \quad (2.20)$$

Структура матрицы $\mathbf{T}^{(p)}$ определяется типом свертки [66]:

- **1D свертка.** Матрица $\mathbf{T}^{(p)}$ является ленточной матрицей Тёплица. Каждая строка содержит веса ядра, сдвинутые на одну позицию вправо относительно предыдущей строки.
- **2D свертка.** Матрица $\mathbf{T}^{(p)}$ является блочно-тёплицевой матрицей с тёплицевыми блоками (англ. BTTB, Block Toeplitz with Toeplitz Blocks). Блоки соответствуют сдвигам ядра по высоте, а структура внутри блоков — сдвигам по ширине.

– **Многоканальный случай.** Матрица $\mathbf{T}^{(p)}$ состоит из блоков, соответствующих парам входных и выходных каналов.

Пример (1D свертка и матрица Тёплица). Рассмотрим одномерную свертку без паддинга и со страйдом 1. Пусть входной вектор $\mathbf{x} = [x_1, x_2, x_3, x_4]^\top \in \mathbb{R}^4$, а ядро $\mathbf{w} = [w_1, w_2]^\top \in \mathbb{R}^2$. Результат свертки $\mathbf{z} \in \mathbb{R}^3$ имеет вид:

$$\mathbf{z} = \begin{bmatrix} w_1 x_1 + w_2 x_2 \\ w_1 x_2 + w_2 x_3 \\ w_1 x_3 + w_2 x_4 \end{bmatrix}.$$

Это выражение можно записать как $\mathbf{z} = \mathbf{T}(\mathbf{w})\mathbf{x}$, где матрица $\mathbf{T}(\mathbf{w}) \in \mathbb{R}^{3 \times 4}$ имеет вид:

$$\mathbf{T}(\mathbf{w}) = \begin{bmatrix} w_1 & w_2 & 0 & 0 \\ 0 & w_1 & w_2 & 0 \\ 0 & 0 & w_1 & w_2 \end{bmatrix}.$$

Заметим, что матрица зависит от весов $\mathbf{w}$, но не от входа $\mathbf{x}$.

Эта матрица используется для вычисления матрицы распространения возмущения $\mathbf{S}^{(p)}$, так как она описывает линейное отображение входа в выход при фиксированных весах.

Оператор свертки по весам (матрица патчей). Та же самая операция свертки может быть записана как линейная зависимость от параметров ядра при фиксированном входе. Существует матрица $\mathbf{X}^{(p)} (\mathbf{x}^{(p)}) \in \mathbb{R}^{n_p \times N_p}$, называемая матрицей патчей, составленная из локальных фрагментов входа $\mathbf{x}^{(p)}$, такая что:

$$\mathbf{z}^{(p)} = \mathbf{X}^{(p)} (\mathbf{x}^{(p)}) \mathbf{w}^{(p)}. \quad (2.21)$$

Структура $\mathbf{X}^{(p)}$ такова, что каждый ее столбец соответствует одному параметру ядра, а строки содержат значения входа, попадающие в рецептивное поле этого параметра при всех возможных сдвигах.

Пример (1D свертка и патч-матрица). Используем те же данные, что и в предыдущем примере: $\mathbf{x} = [x_1, x_2, x_3, x_4]^\top$, $\mathbf{w} = [w_1, w_2]^\top$. Выразим $\mathbf{z}$ через веса:

$$\mathbf{z} = \begin{bmatrix} x_1 & x_2 \\ x_2 & x_3 \\ x_3 & x_4 \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \end{bmatrix}.$$

Здесь матрица $\mathbf{X}(\mathbf{x}) \in \mathbb{R}^{3 \times 2}$ имеет вид:

$$\mathbf{X}(\mathbf{x}) = \begin{bmatrix} x_1 & x_2 \\ x_2 & x_3 \\ x_3 & x_4 \end{bmatrix}.$$

Заметим, что матрица зависит от входа $\mathbf{x}$, но не от весов $\mathbf{w}$.

Эта матрица патчей используется для вычисления параметрического якобиана $\mathbf{P}^{(p)}$. Действительно, по определению (2.6):

$$\mathbf{P}^{(p)}(\mathbf{w}) = \frac{\partial \mathbf{z}^{(p)}}{\partial \mathbf{w}^{(p)}}.$$

Поскольку зависимость $\mathbf{z}^{(p)}$ от $\mathbf{w}^{(p)}$ в уравнении (2.21) линейна, производная равна самой матрице коэффициентов:

$$\mathbf{P}^{(p)}(\mathbf{w}) = \mathbf{X}^{(p)}(\mathbf{x}^{(p)}).$$

Таким образом, параметрический якобиан сверточного слоя есть не что иное, как матрица патчей входа. Двойственность представлений (2.20) и (2.21) позволяет явно записать компоненты леммы 2.3.1 для CNN. Следовательно, анализ гаусс—ньютоновской компоненты $\mathbf{G}(\mathbf{w})$ для сверточных сетей сводится к оценке норм структурированных матриц $\mathbf{T}^{(p)}$ (зависящих от весов) и $\mathbf{X}^{(p)}$ (зависящих от активаций), что будет подробно выполнено в следующих подразделах.

Матрица распространения возмущения $\mathbf{S}^{(p)}$. Согласно (2.11), $\mathbf{S}^{(p)}$ есть произведение локальных якобианов $\partial \mathbf{z}^{(k+1)} / \partial \mathbf{z}^{(k)}$. Из (2.20) и правила дифференцирования сложной функции следует:

$$\frac{\partial \mathbf{z}^{(k+1)}}{\partial \mathbf{z}^{(k)}} = \frac{\partial \mathbf{z}^{(k+1)}}{\partial \mathbf{x}^{(k+1)}} \cdot \frac{\partial \mathbf{x}^{(k+1)}}{\partial \mathbf{z}^{(k)}} = \mathbf{T}^{(k+1)}(\mathbf{w}) \mathbf{D}^{(k)},$$

где $\mathbf{D}^{(k)} = \text{diag}(\sigma^{(k)'}(\mathbf{z}^{(k)}))$. Таким образом, $\mathbf{S}^{(p)}$ представляет собой произведение матриц Тёплица последующих слоев и диагональных матриц активаций:

$$\mathbf{S}^{(p)}(\mathbf{w}) = \mathbf{T}^{(L)} \mathbf{D}^{(L-1)} \dots \mathbf{T}^{(p+1)} \mathbf{D}^{(p)}. \quad (2.22)$$

Для последнего слоя $\mathbf{S}^{(L)}(\mathbf{w}) = \mathbf{I}_K$.

Параметрический якобиан $\mathbf{P}^{(p)}$. По определению (2.6), $\mathbf{P}^{(p)} = \partial \mathbf{z}^{(p)} / \partial \mathbf{w}^{(p)}$. Используя линейность свертки по параметрам (2.21), получаем:

$$\mathbf{P}^{(p)}(\mathbf{w}) = \mathbf{X}^{(p)}(\mathbf{x}^{(p)}). \quad (2.23)$$

Заметим, что $\mathbf{P}^{(p)}$ не зависит от весов $\mathbf{w}^{(p)}$ (так как свертка линейна по весам), но зависит от активаций предыдущих слоев через $\mathbf{x}^{(p)}$.

Для получения верхней оценки спектральной нормы $\|\mathbf{G}(\mathbf{w})\|_2$ необходимо оценить нормы $\|\mathbf{T}^{(p)}\|_2$ и $\|\mathbf{X}^{(p)}\|_2$.

Лемма 2.5.1 (Норма матрицы Тёплица). *Пусть $\mathbf{T}^{(p)}$ — матрица Тёплица (или блочно-тёплицева с тёплицевыми блоками), соответствующая операции свертки с ядром $\mathcal{W}^{(p)}$. Тогда ее спектральная норма ограничена сверху через ℓ_1 -норму ядра:*

$$\|\mathbf{T}^{(p)}\|_2 \leq \|\mathcal{W}^{(p)}\|_1 = \sum_{c_{in}, c_{out}, i, j} |W_{c_{out}, c_{in}, i, j}^{(p)}|.$$

В случае, если веса ограничены по модулю $|W_{ijkl}^{(p)}| \leq w_{\max}$, а размер ядра равен $k_h \times k_w$, то

$$\|\mathbf{T}^{(p)}\|_2 \leq C_{in} C_{out} k_h k_w w_{\max}.$$

Доказательство. По определению спектральной нормы матрицы, для любого вектора $\mathbf{x}^{(p)} \neq 0$:

$$\|\mathbf{T}^{(p)}\|_2 = \sup_{\mathbf{x}^{(p)} \neq 0} \frac{\|\mathbf{T}^{(p)} \mathbf{x}^{(p)}\|_2}{\|\mathbf{x}^{(p)}\|_2}.$$

Матрица $\mathbf{T}^{(p)}$ построена таким образом, что умножение $\mathbf{T}^{(p)} \mathbf{x}^{(p)}$ эквивалентно операции дискретной свертки входа $\mathcal{X}^{(p)}$ с ядром $\mathcal{W}^{(p)}$:

$$\mathbf{T}^{(p)} \mathbf{x}^{(p)} = \text{vec} \left(\mathcal{W}^{(p)} * \mathcal{X}^{(p)} \right).$$

Поскольку векторизация сохраняет ℓ_2 -норму, имеем:

$$\|\mathbf{T}^{(p)} \mathbf{x}^{(p)}\|_2 = \|\mathcal{W}^{(p)} * \mathcal{X}^{(p)}\|_2.$$

Для дискретной свертки справедливо неравенство Юнга [67]:

$$\|\mathcal{W}^{(p)} * \mathcal{X}^{(p)}\|_2 \leq \|\mathcal{W}^{(p)}\|_1 \cdot \|\mathcal{X}^{(p)}\|_2,$$

где $\|\mathcal{W}^{(p)}\|_1 = \sum_{c_{in}, c_{out}, i, j} |W_{c_{out}, c_{in}, i, j}^{(p)}|$ — ℓ_1 -норма ядра, а $\|\mathcal{X}^{(p)}\|_2 = \|\mathbf{x}^{(p)}\|_2$ — ℓ_2 -норма входа. Подставляя неравенство Юнга в определение спектральной нормы:

$$\|\mathbf{T}^{(p)}\|_2 = \sup_{\mathbf{x}^{(p)} \neq 0} \frac{\|\mathbf{T}^{(p)} \mathbf{x}^{(p)}\|_2}{\|\mathbf{x}^{(p)}\|_2} = \sup_{\mathbf{x}^{(p)} \neq 0} \frac{\|\mathcal{W}^{(p)} * \mathcal{X}^{(p)}\|_2}{\|\mathcal{X}^{(p)}\|_2} \leq \|\mathcal{W}^{(p)}\|_1.$$

Если все элементы ядра ограничены по модулю $|W_{ijkl}^{(p)}| \leq w_{\max}$, то:

$$\|\mathcal{W}^{(p)}\|_1 = \sum_{c_{\text{in}}=1}^{C_{\text{in}}} \sum_{c_{\text{out}}=1}^{C_{\text{out}}} \sum_{i=1}^{k_h} \sum_{j=1}^{k_w} |W_{c_{\text{out}}, c_{\text{in}}, i, j}^{(p)}| \leq C_{\text{in}} C_{\text{out}} k_h k_w w_{\max}.$$

Откуда следует окончательная оценка: $\|\mathbf{T}^{(p)}\|_2 \leq C_{\text{in}} C_{\text{out}} k_h k_w w_{\max}$. $\square$

Лемма 2.5.2 (Норма матрицы патчей). Пусть $\mathbf{X}^{(p)} \in \mathbb{R}^{n_p \times N_p}$ — матрица патчей, построенная по входу $\mathbf{x}^{(p)} \in \mathbb{R}^{n_{p-1}}$ для сверточного слоя p с ядром размера $k_h \times k_w$ и $C_{\text{out}}^{(p)}$ выходными каналами. Тогда спектральная норма матрицы патчей ограничена сверху:

$$\|\mathbf{X}^{(p)}\|_2 \leq \sqrt{K_p} \|\mathbf{x}^{(p)}\|_2,$$

где $K_p = C_{\text{out}}^{(p)} k_h k_w$ — число весов, участвующих в формировании одного выходного элемента (размер ядра с учетом каналов).

Доказательство. Матрица $\mathbf{X}^{(p)}$ строится следующим образом: каждый столбец соответствует одному параметру ядра свертки, а каждая строка соответствует одной пространственной позиции выхода. Элемент $X_{ij}^{(p)}$ содержит значение входа $\mathbf{x}^{(p)}$, которое умножается на j -й параметр ядра при вычислении i -го элемента выхода. Для свертки со страйдом $s = 1$ и без паддинга, каждый элемент входа $\mathbf{x}^{(p)}$ участвует в формировании нескольких элементов выхода $\mathbf{z}^{(p)}$. Конкретно, каждый элемент входа попадает в рецептивное поле ядра размером $k_h \times k_w$ для $K_p = C_{\text{out}}^{(p)} k_h k_w$ различных параметров.

Спектральная норма матрицы ограничена сверху через норму Фробениуса:

$$\|\mathbf{X}^{(p)}\|_2 \leq \|\mathbf{X}^{(p)}\|_F = \sqrt{\sum_{i,j} \left(X_{ij}^{(p)}\right)^2}.$$

Каждый элемент $x_m^{(p)}$ входа встречается в матрице $\mathbf{X}^{(p)}$ ровно столько раз, сколько различных позиций ядра могут его «накрыть» при свертке. Для страйда $s = 1$ это число равно произведению:

- числа выходных каналов $C_{\text{out}}^{(p)}$ (каждый канал имеет свое ядро),
- числа пространственных позиций ядра $k_h k_w$ (каждая позиция ядра использует данный элемент входа при соответствующем сдвиге).

Таким образом, каждый элемент $x_m^{(p)}$ входит в сумму квадратов элементов $\mathbf{X}^{(p)}$ не более чем K_p раз:

$$\sum_{i,j} \left(X_{ij}^{(p)} \right)^2 \leq \sum_{m=1}^{n_{p-1}} K_p \left(x_m^{(p)} \right)^2 = K_p \|\mathbf{x}^{(p)}\|_2^2.$$

Подставляя оценку нормы Фробениуса:

$$\|\mathbf{X}^{(p)}\|_2 \leq \|\mathbf{X}^{(p)}\|_F = \sqrt{\sum_{i,j} \left(X_{ij}^{(p)} \right)^2} \leq \sqrt{K_p \|\mathbf{x}^{(p)}\|_2^2} = \sqrt{K_p} \|\mathbf{x}^{(p)}\|_2.$$

□

Теперь сформулируем основную теорему для сверточных сетей, объединяющую лемму 2.3.1 и полученные оценки норм. Структура теоремы полностью аналогична теореме 2.4.1 для полносвязных сетей.

Теорема 2.5.3. Пусть $f_{\mathbf{w}}$ является L -слойной сверточной нейронной сетью без смещений. Предположим, что существуют такие положительные константы, что для всех слоев $p = 1, \dots, L$ выполнены ограничения: $\|\mathbf{x}\|_2 \leq M_{\mathbf{x}}$, $\|\mathbf{A}(\mathbf{w})\|_2 \leq M_{\mathbf{A}}$, $\|\mathcal{W}^{(p)}\|_1 \leq M_{\mathcal{W}}$ и $\|\mathbf{D}^{(p)}\|_2 \leq M_{\sigma}$. Пусть $K_{\max} = \max_p \left(C_{out}^{(p)} k_h k_w \right)$ — максимальный «размер» ядра. Тогда спектральная норма гаусс—ньютоновской компоненты удовлетворяет оценке:

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq L M_{\mathbf{x}}^2 M_{\mathbf{A}} K_{\max} (M_{\mathcal{W}} M_{\sigma})^{2L-2}. \quad (2.24)$$

Доказательство. Воспользуемся блочной структурой (2.9) и оценкой нормы блока по субмультипликативности:

$$\|\mathbf{G}^{(p,q)}(\mathbf{w})\|_2 \leq \|\mathbf{P}^{(p)}(\mathbf{w})\|_2 \|\mathbf{S}^{(p)}(\mathbf{w})\|_2 \|\mathbf{A}(\mathbf{w})\|_2 \|\mathbf{S}^{(q)}(\mathbf{w})\|_2 \|\mathbf{P}^{(q)}(\mathbf{w})\|_2.$$

Далее применим те же свойства для оценки $\|\mathbf{S}^{(p)}\|_2$, из (2.22) имеем

$$\|\mathbf{S}^{(p)}\|_2 \leq \prod_{k=p+1}^L \|\mathbf{T}^{(k)}\|_2 \cdot \prod_{k=p}^{L-1} \|\mathbf{D}^{(k)}\|_2.$$

Используя лемму 2.5.1 о том, что $\|\mathbf{T}\|_2 \leq M_{\mathcal{W}}$, и условие на функцию активации, получаем

$$\|\mathbf{S}^{(p)}\|_2 \leq M_{\mathcal{W}}^{L-p} M_{\sigma}^{L-p}.$$

Затем перейдем к оценке $\|\mathbf{P}^{(p)}\|_2$ из (2.23) и леммы 2.5.2:

$$\|\mathbf{P}^{(p)}\|_2 \leq \sqrt{K_p} \|\mathbf{x}^{(p)}\|_2 \leq \sqrt{K_{\max}} \|\mathbf{x}^{(p)}\|_2.$$

Оценим норму промежуточного представления $\|\mathbf{x}^{(p)}\|_2$. Поскольку $\mathbf{x}^{(p+1)} = \sigma(\mathbf{T}^{(p)} \mathbf{x}^{(p)})$, то:

$$\|\mathbf{x}^{(p+1)}\|_2 \leq M_\sigma \|\mathbf{T}^{(p)}\|_2 \|\mathbf{x}^{(p)}\|_2 \leq M_\sigma M_{\mathcal{W}} \|\mathbf{x}^{(p)}\|_2.$$

Итерируя от входа $\mathbf{x}^{(1)} = \mathbf{x}$,

$$\|\mathbf{x}^{(p)}\|_2 \leq (M_\sigma M_{\mathcal{W}})^{p-1} M_{\mathbf{x}}.$$

Следовательно:

$$\|\mathbf{P}^{(p)}\|_2 \leq \sqrt{K_{\max}} (M_\sigma M_{\mathcal{W}})^{p-1} M_{\mathbf{x}}.$$

Подставим оценки в выражение для блока $\mathbf{G}^{(p,q)}$:

$$\begin{aligned} \|\mathbf{G}^{(p,q)}\|_2 &\leq M_{\mathbf{A}} \cdot \left[\sqrt{K_{\max}} (M_\sigma M_{\mathcal{W}})^{p-1} M_{\mathbf{x}} \cdot M_{\mathcal{W}}^{L-p} M_{\sigma}^{L-p} \right] \\ &\quad \times \left[\sqrt{K_{\max}} (M_\sigma M_{\mathcal{W}})^{q-1} M_{\mathbf{x}} \cdot M_{\mathcal{W}}^{L-q} M_{\sigma}^{L-q} \right] \\ &= M_{\mathbf{A}} K_{\max} M_{\mathbf{x}}^2 (M_\sigma M_{\mathcal{W}})^{p-1+L-p+q-1+L-q} \\ &= M_{\mathbf{A}} K_{\max} M_{\mathbf{x}}^2 (M_\sigma M_{\mathcal{W}})^{2L-2}. \end{aligned}$$

Заметим, что степень не зависит от конкретных индексов p, q .

Матрица $\mathbf{G}$ состоит из $L \times L$ блоков. Используя оценку нормы блочной матрицы через норму якобиана, как в теореме 2.4.1:

$$\|\mathbf{G}\|_2 \leq M_{\mathbf{A}} \|\mathbf{J}\|_2^2.$$

Якобиан $\mathbf{J} = [\mathbf{S}^{(1)} \mathbf{P}^{(1)}, \dots, \mathbf{S}^{(L)} \mathbf{P}^{(L)}]$. Норма каждого блочного столбца $\mathbf{J}^{(p)} = \mathbf{S}^{(p)} \mathbf{P}^{(p)}$:

$$\|\mathbf{J}^{(p)}\|_2 \leq M_{\mathcal{W}}^{L-p} M_{\sigma}^{L-p} \cdot \sqrt{K_{\max}} (M_\sigma M_{\mathcal{W}})^{p-1} M_{\mathbf{x}} = \sqrt{K_{\max}} M_{\mathbf{x}} (M_\sigma M_{\mathcal{W}})^{L-1}.$$

Тогда $\|\mathbf{J}\|_2^2 \leq \sum_{p=1}^L \|\mathbf{J}^{(p)}\|_2^2 = L \cdot K_{\max} M_{\mathbf{x}}^2 (M_\sigma M_{\mathcal{W}})^{2L-2}$. Умножая на $M_{\mathbf{A}}$, получаем искомую оценку (2.24). $\square$

Сравнение оценки (2.24) с оценкой для полносвязной сети (2.13) показывает качественное сходство экспоненциальной зависимости от глубины L . Однако константа $M_{\mathcal{W}}$ для сверточных сетей (норма ядра) обычно значительно меньше

нормы полной матрицы весов полносвязного слоя той же размерности из-за разреженности связей и разделения весов. Множитель $K_{\max}$ отражает локальность связей: он пропорционален размеру ядра, а не полной размерности входа, что делает оценку для CNN существенно точнее в реальных сценариях.

Рассмотренный подход матричного представления легко обобщается на другие стандартные архитектурные элементы сверточных сетей. Рассмотрим влияние операций пулинга и остаточных связей на структуру матриц $\mathbf{S}^{(p)}$ и итоговые оценки спектральной нормы.

Пулинг (Pooling). Операции пулинга (MaxPool, AvgPool) обычно применяются после сверточных слоев для уменьшения пространственной размерности представлений. В контексте матрично-представимых сетей оператор пулинга p -го слоя $\mathcal{M}^{(p)}$ может быть записан как умножение на матрицу $\mathbf{M}^{(p)} \in \mathbb{R}^{n'_p \times n_p}$, где $n'_p < n_p$ — уменьшенная размерность выхода.

- **AvgPool.** Для усреднения по окну размера k_{pool} без перекрытия, матрица $\mathbf{M}^{(p)}$ состоит из блоков, содержащих значения $1/k_{\text{pool}}$ (с нормировкой) или 1 (без нормировки). Спектральная норма такой матрицы оценивается как:

$$\|\mathbf{M}^{(p)}\|_2 \leq 1 \quad (\text{без нормировки}), \quad \|\mathbf{M}^{(p)}\|_2 \leq \frac{1}{\sqrt{k_{\text{pool}}}} \quad (\text{с нормировкой}).$$

- **MaxPool.** Операция максимума является кусочно-линейной. В областях дифференцируемости ее якобиан представляет собой матрицу выбора (субматрицу единичной матрицы), содержащую ровно одну единицу в каждой строке. Следовательно, ее спектральная норма равна единице:

$$\|\mathbf{M}^{(p)}\|_2 = 1.$$

Включение пулинга слегка модифицирует рекуррентную формулу для матрицы распространения (2.22). Если пулинг применяется после слоя p , то в произведение добавляется множитель $\mathbf{M}^{(p)}$:

$$\mathbf{S}^{(p)}(\mathbf{w}) = \mathbf{T}^{(L)} \mathbf{D}^{(L-1)} \mathbf{M}^{(L-1)} \dots \mathbf{T}^{(p+1)} \mathbf{D}^{(p)}.$$

Поскольку $\|\mathbf{M}^{(p)}\|_2 \leq 1$, наличие пулинга не увеличивает верхнюю оценку нормы $\|\mathbf{S}^{(p)}\|_2$. Более того, уменьшение размерности n_p снижает размерность последующих матриц Тёплица $\mathbf{T}^{(k)}$, что может косвенно уменьшить константу $K_{\max}$ в оценке теоремы 2.5.3.

Остаточные связи (Residual Connections). В архитектурах типа ResNet выход блока задается суммой входа и нелинейного преобразования:

$$\mathbf{x}^{(p+B)} = \mathbf{x}^{(p)} + \mathcal{F}^{(p)}(\mathbf{x}^{(p)}),$$

где $\mathcal{F}^{(p)}$ — последовательность сверток и активаций внутри блока, B — глубина блока. Дифференцирование этого выражения по входу блока дает:

$$\frac{\partial \mathbf{x}^{(p+B)}}{\partial \mathbf{x}^{(p)}} = \mathbf{I}_{n_p} + \frac{\partial \mathcal{F}^{(p)}(\mathbf{x}^{(p)})}{\partial \mathbf{x}^{(p)}}.$$

В терминах матрицы распространения $\mathbf{S}^{(p)} = \partial \mathbf{z} / \partial \mathbf{z}^{(p)}$, это означает, что рекуррентный шаг через остаточный блок включает сумму путей распространения градиента. Пусть $\mathbf{S}_{\text{main}}^{(p)}$ — матрица распространения через сверточные слои блока, тогда полная матрица распространения от начала блока удовлетворяет соотношению:

$$\mathbf{S}_{\text{res}}^{(p)} = \mathbf{S}^{(p+B)} \left(\mathbf{I}_{n_p} + \mathbf{S}_{\text{main}}^{(p)} \right).$$

Используя неравенство треугольника для спектральной нормы, получаем оценку:

$$\|\mathbf{S}_{\text{res}}^{(p)}\|_2 \leq \|\mathbf{S}^{(p+B)}\|_2 \left(1 + \|\mathbf{S}_{\text{main}}^{(p)}\|_2 \right).$$

В отличие от последовательной сети, где нормы перемножаются, в остаточной сети они суммируются внутри блока. Это меняет характер зависимости от глубины. Если нормы слоев внутри блока малы ($\|\mathbf{S}_{\text{main}}^{(p)}\|_2 < 1$), то остаточные связи способствуют стабилизации нормы $\mathbf{S}^{(p)}$ и предотвращают экспоненциальный рост (или затухание) градиентов.

Для оценки гаусс—ньютоновской компоненты $\mathbf{G}(\mathbf{w})$ в сети с N_{res} остаточными блоками, оценка теоремы 2.5.3 модифицируется заменой множителя $(M_{\mathcal{W}} M_{\sigma})^{2L-2}$ на сумму вкладов путей. В худшем случае (используя субмультипликативность для суммы), константа L в оценке (2.24) может быть заменена на эффективную глубину с учетом числа блоков, однако на практике наличие единичной матрицы $\mathbf{I}$ в якобиане часто приводит к более обусловленным матрицам Гессе по сравнению с чистыми сетями той же глубины.

2.6. Вычислительные эксперименты

В данном разделе проводится эмпирическая проверка теоретически мотивированных соотношений между полной матрицей Гессе и ее гаусс—ньютоновской компонентой на ряде обучаемых нейронных сетей. Программный код реализован на фреймворке **PyTorch** и доступен в репозитории диссертации по адресу

<https://github.com/kisnikser/PhD-Thesis/code/hessian>.

Постановка эксперимента. Эксперименты проводятся на двух архитектурах: полносвязной нейронной сети (MLP) и сверточной нейронной сети (CNN). В качестве задачи используется 10-классовая классификация рукописных цифр на датасете MNIST [68]. Для каждой архитектуры варьируются глубина L и ширина h скрытых слоев, как это продемонстрировано в таблице 1.

Таблица 1 — Архитектуры, используемые в экспериментах по оценке спектральных норм: полносвязная и сверточная

Архитектура	Глубина L	Ширина h
MLP	[2, 4, 8]	[64, 128, 256]
CNN	[2, 4, 8]	[64, 128, 256]

В используемой реализации MLP параметр глубины L означает общее число линейных слоев, включая выходной слой, так что случай $L = 2$ соответствует одному скрытому слою и выходному классификатору. Для CNN параметр L задает число сверточных слоев перед финальным глобальным усреднением и линейным классификатором.

Во всех экспериментах обучение выполняется на полном обучающем наборе MNIST в течение 10 эпох с использованием оптимизатора Adam, learning rate 10^{-3} и batch size 256. Спектральные характеристики оцениваются не на каждой эпохе, а в четырех контрольных состояниях модели: сразу после инициализации, после первой и пятой эпох, а также по завершении десятой эпохи. Для этого из обучающей выборки формируется отдельный оценочный батч размера 128, на котором методом степенных итераций с числом шагов 25 и порогом остановки 10^{-4} вычисляются следующие величины:

- спектральная норма матрицы Гессе $\|\mathbf{H}\|_2$, оцениваемая методом степенных итераций [69; 70];
- спектральная норма гаусс—ньютоновской компоненты $\|\mathbf{G}\|_2$;
- отношение $\rho = \|\mathbf{G}\|_2/\|\mathbf{H}\|_2$.

Все приведенные ниже результаты соответствуют одному фиксированному запуску с seed 37.

Полносвязная нейронная сеть (MLP). На рисунке 2.2 представлена динамика величины $\rho = \|\mathbf{G}\|_2/\|\mathbf{H}\|_2$ в контрольных точках обучения. Уже после первой эпохи для большей части рассмотренных конфигураций значения $\|\mathbf{G}\|_2$ и $\|\mathbf{H}\|_2$ оказываются близкими, а к поздним этапам обучения различие между ними в большинстве случаев остается малым по сравнению с абсолютным масштабом самих норм.




Рисунок 2.2 — Слева: отношение $\|\mathbf{G}\|_2/\|\mathbf{H}\|_2$ в контрольных точках обучения для MLP. Справа: сопоставление эмпирически измеренных значений $\|\mathbf{G}\|_2$ с верхней оценкой, вычисляемой в экспериментальном коде

Правая часть рисунка демонстрирует соотношение между эмпирически измеренными значениями $\|\mathbf{G}\|_2$ и теоретически мотивированной грубой-оценкой, которая в коде строится по глубине сети, максимальной норме входного вектора на оценочном батче и максимальной спектральной норме матриц весов. Эта оценка остается заведомо консервативной и используется здесь прежде всего как качественный ориентир для сравнения различных конфигураций, а не как точное количественное предсказание.

Сверточная нейронная сеть (CNN). Аналогичные эксперименты проведены для сверточной нейронной сети. Результаты представлены на рисунке 2.3. Как и в случае MLP, после первых эпох обучения величины $\|\mathbf{G}\|_2$

и $\|\mathbf{H}\|_2$ для большинства рассмотренных конфигураций оказываются близкими. При этом различия между отдельными глубинами и ширинами заметны сильнее, чем различия между двумя классами архитектур в целом.




Рисунок 2.3 — Результаты для CNN. Слева: отношение $\|\mathbf{G}\|_2 / \|\mathbf{H}\|_2$ в контрольных точках обучения; при визуализации значения также ограничиваются диапазоном $[0, 1]$. Справа: сопоставление эмпирических значений $\|\mathbf{G}\|_2$ с проху-оценкой, вычисляемой в экспериментальном коде

Полученные для CNN результаты качественно согласуются с наблюдениями для MLP: в контрольных точках поздних эпох отношение ρ в большинстве конфигураций близко к единице. На текущем наборе запусков различия между MLP и CNN носят скорее качественный, чем статистически устойчивый характер, поэтому делать отдельный вывод о более быстрой или более медленной сходимости одной из архитектур по этим данным преждевременно.

Таким образом, проведенные вычисления показывают, что для рассмотренных MLP- и CNN-конфигураций на поздних этапах обучения спектральные нормы $\|\mathbf{G}\|_2$ и $\|\mathbf{H}\|_2$ оказываются близкими. Это поддерживает использование гаусс—ньютоновской компоненты как практически удобного приближения спектрально значимой части полной матрицы Гессе при дальнейшем анализе локальной кривизны.

2.7. Обсуждение

В данной главе получены верхние оценки спектральной нормы гаусс—ньютоновской компоненты матрицы Гессе для полносвязных и сверточных нейронных сетей. Основные результаты задаются теоремой 2.4.1 для полносвязного случая и теоремой 2.5.3 для сверточного случая.

Для L -слойной полносвязной сети в теореме 2.4.1 получена оценка

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq LM_{\mathbf{x}}^2 M_{\mathbf{A}} (M_{\mathbf{W}} M_{\sigma})^{2L-2}.$$

Она показывает, что при фиксированных ограничениях на вход, кривизну функции потерь по выходу и нормы весовых матриц локальная кривизна может расти экспоненциально по глубине. Это связано с тем, что в полносвязной архитектуре матрицы распространения возмущения содержат длинные произведения плотных линейных операторов.

Для сверточной сети в теореме 2.5.3 доказана аналогичная по структуре оценка

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq LM_{\mathbf{x}}^2 M_{\mathbf{A}} K_{\max} (M_{\mathcal{W}} M_{\sigma})^{2L-2}.$$

По сравнению с полносвязным случаем здесь появляется множитель $K_{\max}$, зависящий от размера сверточного ядра. Это отражает фундаментальное отличие сверточной архитектуры: локальность связей и разделение весов приводят к тому, что верхняя граница определяется размером рецептивного поля, а не полной размерностью входа.

Дополнительный частный результат для полносвязной сети с функцией активации ReLU и кросс-энтропийной функцией потерь приведен в следствии 2.4.2:

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq \sqrt{2} LM_{\mathbf{x}}^2 M_{\mathbf{W}}^{2L-2}.$$

Он показывает, что в стандартной задаче многоклассовой классификации архитектурная часть оценки может быть выписана в особенно явном виде.

Проведенные вычислительные эксперименты на MLP- и CNN-архитектурах показывают, что на поздних этапах обучения спектральные нормы полной матрицы Гессе и ее гаусс—ньютоновской компоненты оказываются близкими,

то есть

$$\|\mathbf{G}(\mathbf{w})\|_2 \approx \|\mathbf{H}(\mathbf{w})\|_2.$$

Это согласуется с разложением

$$\mathbf{H}(\mathbf{w}) = \mathbf{G}(\mathbf{w}) + \mathbf{R}(\mathbf{w}),$$

в котором остаточная компонента $\mathbf{R}(\mathbf{w})$ в окрестности минимума оказывается существенно менее значимой в спектральном смысле.

Таким образом, результаты главы обосновывают использование гаусс—ньютоновской компоненты как архитектурно-зависимой характеристики локальной кривизны оптимизационной поверхности. В последующих главах именно эти оценки используются при построении критериев стабилизации ландшафта функции потерь и критериев достаточного размера выборки.

Глава 3. Стабилизация ландшафта функции потерь в нейронных сетях

В данной главе исследуется изменение поверхности функции потерь в нейронных сетях при увеличении объема обучающей выборки. Сперва формулируется проблема оценки сходимости ландшафта функции потерь. Далее предлагается общий критерий стабилизации поверхности с функцией предпочтения точек в пространстве параметров. Затем рассматриваются частные случаи этого критерия с оценкой сходимости в одной точке минимума, в наборе точек по распределению, и в наборе точек по распределению в пространстве меньшей размерности, натянутом на главные собственные векторы матрицы Гессе. Доказываются теоремы о сходимости предложенного критерия.

3.1. Введение

В современных нейронных сетях свойства решения определяются не только значением функции потерь в одной найденной точке минимума, но и локальной геометрией всей поверхности функции потерь в ее окрестности. Форма ландшафта влияет на устойчивость обучения, чувствительность к вариациям данных, поведение численных методов оптимизации и свойства обобщения [4; 6; 7; 15; 33; 34]. Поэтому при исследовании зависимости между объемом обучающей выборки и поведением модели естественно рассматривать не только сходимость эмпирического риска как скалярной величины, но и стабилизацию самой поверхности функции потерь.

Классические результаты теории статистического обучения гарантируют сходимость эмпирической функции потерь к популяционной при увеличении размера выборки [71; 72]. Однако из этого не следует автоматически, как меняются локальные геометрические характеристики ландшафта, в частности градиент, кривизна и спектральная структура матрицы Гессе в окрестности точек минимума. Между тем именно эти величины определяют локальную форму поверхности и играют существенную роль в анализе обучения глубоких моделей [13; 43; 56; 58].

Эмпирические исследования показывают, что в глубоких нейронных сетях спектр матрицы Гессе обычно имеет выраженно неоднородную структуру: большая часть собственных значений сосредоточена вблизи нуля, тогда как небольшое число выбросов задает основные направления локальной кривизны [43; 45; 56—58]. Это делает естественным рассмотрение не только глобальных характеристик изменения ландшафта, но и их ограничений на маломерные подпространства, натянутые на главные собственные векторы матрицы Гессе.

В данной главе предлагается подход к анализу стабилизации ландшафта функции потерь при увеличении объема обучающей выборки, основанный на сравнении эмпирических функций потерь на выборках размеров k и $k + 1$. В качестве исходного объекта рассматривается разность $\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})$, которая затем исследуется в окрестности точки локального минимума с помощью квадратичной аппроксимации. Такой переход позволяет выразить изменение ландшафта через три составляющие: сдвиг значения функции потерь в точке минимума, градиентное рассогласование и разность матриц Гессе. На этой основе вводится общий критерий p -сходимости с функцией предпочтения точек в пространстве параметров, а затем рассматриваются его частные случаи, допускающие явные теоретические оценки.

Основные результаты главы состоят в следующем. Во-первых, для абсолютного одноточечного критерия, измеряющего изменение функции потерь в фиксированной точке окрестности минимума, доказывается оценка порядка $\mathcal{O}(k^{-1})$. Во-вторых, для среднеквадратичного критерия, усредняющего квадрат изменения ландшафта по гауссовскому распределению в полном пространстве параметров, устанавливается оценка $\mathcal{O}(k^{-2})$. В-третьих, строится аналогичный критерий в подпространстве наибольшей кривизны, натянутом на главные собственные векторы матрицы Гессе, и для него доказывается оценка того же порядка при меньшей эффективной размерности. Тем самым в главе формируется единая схема количественного анализа стабилизации ландшафта функции потерь при росте объема обучающей выборки.

3.2. Предварительные сведения

Оптимизационная поверхность. Объектом называется пара $(\mathbf{x}, \mathbf{y})$, где $\mathbf{x} \in \mathbb{X}$ — признаковое описание, $\mathbf{y} \in \mathbb{Y}$ — целевая переменная. Выборка размера m задается множеством $\mathfrak{D}_m = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^m$ из m независимых реализаций пар $(\mathbf{x}, \mathbf{y})$, распределенных согласно неизвестному распределению $p(\mathbf{x}, \mathbf{y})$. Параметрической моделью называется семейство функций $f_{\mathbf{w}} : \mathbb{X} \rightarrow \mathbb{Y}$, задаваемое вектором параметров $\mathbf{w} \in \mathbb{R}^N$. Выбор модели из этого семейства проводится с помощью эмпирической функции потерь, вычисляемой на заданной выборке:

$$\mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \ell(f_{\mathbf{w}}(\mathbf{x}_i), \mathbf{y}_i) = \frac{1}{m} \sum_{i=1}^m \ell_i(\mathbf{w}), \quad (3.1)$$

где $\ell : \mathbb{Y} \times \mathbb{Y} \rightarrow \mathbb{R}^+$ — функция потерь на одном объекте. Обучение модели таким образом есть решение оптимизационной задачи

$$\mathbf{w}_m^* \in \arg \min_{\mathbf{w} \in \mathbb{R}^N} \mathcal{L}_m(\mathbf{w}). \quad (3.2)$$

Оптимизационной поверхностью или ландшафтом функции потерь (англ. loss landscape) называется график $\mathcal{L}_m(\mathbf{w})$ как функции от $\mathbf{w} \in \mathbb{R}^N$. Поскольку эмпирическая функция потерь (3.1) вычисляется по конечной выборке, она случайна, и при другой реализации выборки $\mathfrak{D}'_m$ множество минимизаторов (3.2), как правило, поменяется. Однако согласно закону больших чисел (ЗБЧ) эмпирическая функция потерь сходится к популяционной

$$\mathcal{L}(\mathbf{w}) = \mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim p(\mathbf{x}, \mathbf{y})} [\ell(f_{\mathbf{w}}(\mathbf{x}), \mathbf{y})],$$

поэтому естественно ожидать, что множество решений (3.2) стабилизируется. Таким образом, изменение оптимизационной поверхности вблизи точек минимума (3.2) при добавлении обучающих объектов является ключевым объектом исследования настоящей главы.

Формула Тейлора для функции потерь. Рассмотрим точку $\mathbf{w}_0 \in \mathbb{R}^N$, в окрестности $\mathcal{U}_R(\mathbf{w}_0)$ радиуса $R > 0$ которой эмпирическая функция потерь $\mathcal{L}_m(\mathbf{w})$ дважды непрерывно дифференцируема. На практике это условие выполнено практически для всех параметрических моделей машинного обучения. По

формуле Тейлора с остаточным членом в форме Пеано при $\mathbf{w} \rightarrow \mathbf{w}_0$ имеем

$$\begin{aligned} \mathcal{L}_m(\mathbf{w}) = \mathcal{L}_m(\mathbf{w}_0) + \nabla_{\mathbf{w}} \mathcal{L}_m(\mathbf{w}_0)^\top (\mathbf{w} - \mathbf{w}_0) + \\ + \frac{1}{2} (\mathbf{w} - \mathbf{w}_0)^\top \nabla_{\mathbf{w}}^2 \mathcal{L}_m(\mathbf{w}_0) (\mathbf{w} - \mathbf{w}_0) + o(\|\mathbf{w} - \mathbf{w}_0\|_2^2). \end{aligned} \quad (3.3)$$

Далее, если не оговорено иное, работаем в рамках квадратичной аппроксимации и опускаем остаточный член более высокого порядка. Обозначим вектор градиента и матрицу Гессе функции потерь на выборке размера m через

$$\begin{aligned} \mathbf{g}^{(m)}(\mathbf{w}) = \nabla_{\mathbf{w}} \mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \nabla_{\mathbf{w}} \ell_i(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \mathbf{g}_i(\mathbf{w}) \in \mathbb{R}^N, \\ \mathbf{H}^{(m)}(\mathbf{w}) = \nabla_{\mathbf{w}}^2 \mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \nabla_{\mathbf{w}}^2 \ell_i(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \mathbf{H}_i(\mathbf{w}) \in \mathbb{R}^{N \times N}, \end{aligned}$$

в таком случае формула (3.3) перепишется в виде

$$\mathcal{L}_m(\mathbf{w}) = \mathcal{L}_m(\mathbf{w}_0) + \mathbf{g}^{(m)}(\mathbf{w}_0)^\top (\mathbf{w} - \mathbf{w}_0) + \frac{1}{2} (\mathbf{w} - \mathbf{w}_0)^\top \mathbf{H}^{(m)}(\mathbf{w}_0) (\mathbf{w} - \mathbf{w}_0). \quad (3.4)$$

Добавление одного объекта $(\mathbf{x}_{k+1}, \mathbf{y}_{k+1})$ к обучающей выборке $\mathfrak{D}_k = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^k$ размера k влечет изменение значения функции потерь, которое выражается формулой

$$\begin{aligned} \mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) &= \frac{1}{k+1} \sum_{i=1}^{k+1} \ell_i(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) \\ &= \frac{1}{k+1} \left(k \cdot \mathcal{L}_k(\mathbf{w}) + \ell_{k+1}(\mathbf{w}) \right) - \mathcal{L}_k(\mathbf{w}) \\ &= \frac{1}{k+1} \left(\ell_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) \right) \end{aligned} \quad (3.5)$$

Дальнейшее исследование сходимости ландшафта построено на анализе этой разности. Воспользуемся выражением (3.4) и перепишем разность (3.5) в условиях аппроксимации второго порядка:

$$\begin{aligned} \mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) &= \mathcal{L}_{k+1}(\mathbf{w}_0) - \mathcal{L}_k(\mathbf{w}_0) + \\ &+ \left(\mathbf{g}^{(k+1)}(\mathbf{w}_0) - \mathbf{g}^{(k)}(\mathbf{w}_0) \right)^\top (\mathbf{w} - \mathbf{w}_0) + \\ &+ \frac{1}{2} (\mathbf{w} - \mathbf{w}_0)^\top \left(\mathbf{H}^{(k+1)}(\mathbf{w}_0) - \mathbf{H}^{(k)}(\mathbf{w}_0) \right) (\mathbf{w} - \mathbf{w}_0). \end{aligned} \quad (3.6)$$

Рассмотрим точку минимума $\mathbf{w}_k^* \in \mathbb{R}^N$ эмпирической функции потерь $\mathcal{L}_k(\mathbf{w})$ на k объектах. В точке $\mathbf{w} \in \mathcal{U}_R(\mathbf{w}_k^*)$ из ее окрестности справедливо представление (3.6). В силу необходимого условия локального минимума $\mathbf{g}^{(k)}(\mathbf{w}_k^*) = \mathbf{0}$, а значит

$$\begin{aligned} \mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) &= \mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*) + \mathbf{g}^{(k+1)}(\mathbf{w}_k^*)^\top (\mathbf{w} - \mathbf{w}_k^*) + \\ &+ \frac{1}{2}(\mathbf{w} - \mathbf{w}_k^*)^\top \left(\mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*) \right) (\mathbf{w} - \mathbf{w}_k^*), \end{aligned} \quad (3.7)$$

причем

$$\mathbf{g}^{(k+1)}(\mathbf{w}_k^*) = \frac{1}{k+1} \left(k \cdot \nabla_{\mathbf{w}} \mathcal{L}_k(\mathbf{w}_k^*) + \nabla_{\mathbf{w}} \ell_{k+1}(\mathbf{w}_k^*) \right) = \frac{1}{k+1} \mathbf{g}_{k+1}(\mathbf{w}_k^*).$$

Таким образом, вопрос о стабилизации оптимизационной поверхности в окрестности точек оптимума сводится к анализу выражения (3.7) и формулировке конкретных критериев на его основе. Введем предположение, проиллюстрированное на рисунке 3.1, которое позволит сформулировать ряд теоретических утверждений о сходимости.

Предположение 3.2.1 (О слабом градиентном рассогласовании). Пусть в точке $\mathbf{w}_k^* \in \mathbb{R}^N$ минимума эмпирической функции потерь $\mathcal{L}_k(\mathbf{w})$ справедлива ограниченность нормы градиента функции потерь на $(k+1)$ -м объекте:

$$\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_g.$$

3.3. Критерий сходимости поверхности функции потерь

В предыдущем разделе мы показали, что по ряду причин есть основание полагать сходимость поверхности эмпирической функции потерь при увеличении объема обучающей выборки. Кроме того, мы получили аппроксимацию (3.7) явного выражения изменения этой поверхности в одной точке при добавлении одного объекта. Сформулируем общий критерий, измеряющий это изменение в наборе точек.

Определение. Критерием p -сходимости ландшафта функции потерь при добавлении одного объекта в выборку $\mathfrak{D}_k$ называется величина

$$\Delta_p(k+1) = \int |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|^p q(\mathbf{w}) d\mathbf{w}, \quad (3.8)$$




Рисунок 3.1 — Иллюстрация предположения 3.2.1 о слабом градиентном рассогласовании для эмпирических функций потерь на k и $k + 1$ объектах

где функция $q : \mathbb{R}^N \rightarrow \mathbb{R}^+$ задает предпочтение по выбору точек в пространстве параметров модели для оценки сходимости.

Замечание. Отметим, что функция предпочтения $q(\mathbf{w})$ является неотрицательнозначной. Это позволяет перейти к рассмотрению вероятностного распределения на множестве параметров, заданному этой функцией. Далее без ограничения общности полагаем, что $q(\mathbf{w})$ есть плотность этого вероятностного распределения, т. е. $\int q(\mathbf{w}) d\mathbf{w} = 1$.

Введенный критерий (3.8) задает достаточно общий способ измерения изменения ландшафта функции потерь при добавлении одного нового объекта в обучающую выборку. Выбор степени p определяет способ агрегации локальных изменений поверхности, а функция предпочтения $q(\mathbf{w})$ позволяет выделить те области пространства параметров, которые представляют наибольший интерес в конкретной задаче. В частности, можно исследовать поведение ландшафта в одной фиксированной точке, усреднять изменение по распределению в полной параметрической области или ограничивать анализ подпространствами

меньшей размерности, связанными с наиболее существенными направлениями кривизны.

Далее мы рассмотрим несколько частных случаев критерия (3.8). Они построены таким образом, чтобы, с одной стороны, сохранить связь с локальной геометрией ландшафта, а с другой стороны, допускать явные теоретические оценки скорости сходимости при увеличении объема выборки.

3.4. Абсолютный однотоочечный критерий сходимости

Наиболее простым частным случаем критерия (3.8) является ситуация, когда изменение ландшафта измеряется в одной фиксированной точке пространства параметров. Такой подход позволяет получить наиболее прозрачную теоретическую оценку и служит отправной точкой для дальнейших обобщений. Поскольку нас интересует локальная геометрия поверхности функции потерь, естественно рассматривать точки из окрестности локального минимума $\mathbf{w}_k^*$, где справедлива квадратичная аппроксимация (3.7). Иллюстрация предлагаемого критерия приведена на рисунке 3.2, а формальное определение дано ниже.

Определение. *Абсолютным однотоочечным критерием сходимости ландшафта функции потерь при добавлении одного объекта в выборку $\mathfrak{D}_k$ называется величина*

$$\Delta_1(k+1) = |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|,$$

где $\mathbf{w} \in \mathcal{U}_R(\mathbf{w}_k^*)$ — точка из окрестности радиуса $R > 0$ минимума $\mathbf{w}_k^*$.

Замечание. Отметим, что определение выше есть частный случай общего критерия (3.8) при $p = 1$ и $q(\tilde{\mathbf{w}}) = \delta(\tilde{\mathbf{w}} - \mathbf{w})$, где $\delta(\mathbf{w})$ суть дельта-функция Дирака.

В силу формулы (3.7) абсолютный однотоочечный критерий сходимости в общем случае определяется тремя вкладками: разностью значений функций потерь в точке минимума $\mathbf{w}_k^*$, линейным членом, задаваемым градиентом функции $\mathcal{L}_{k+1}$ в этой точке, и квадратичным членом, задаваемым разностью матриц Гессе. Поэтому его оценка сводится к последовательному ограничению каждого из этих вкладов. Это позволяет получить явную верхнюю оценку критерия и, при дополнительных предположениях о зависимости соответствующих констант от k , установить скорость его убывания при росте объема выборки.




Рисунок 3.2 — Иллюстрация абсолютного одноточечного критерия сходимости $\Delta_1(k)$

Теорема 3.4.1. Пусть существует окрестность $\mathcal{U}_R(\mathbf{w}_k^*)$ радиуса $R > 0$ точки локального минимума $\mathbf{w}_k^* \in \mathbb{R}^N$ эмпирической функции потерь $\mathcal{L}_k(\mathbf{w})$, такая что в этой окрестности справедлива квадратичная аппроксимация (3.7). Предположим, что

$$\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{g}}$$

и для всех $i = 1, \dots, k+1$ выполнены оценки

$$|\ell_i(\mathbf{w}_k^*)| \leq M_{\ell},$$

$$\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{H}}. \quad (3.9)$$

Тогда для абсолютного одноточечного критерия сходимости верна оценка

$$\Delta_1(k+1) \leq \frac{2M_{\ell} + M_{\mathbf{g}}R + M_{\mathbf{H}}R^2}{k+1} = \mathcal{O}(k^{-1}),.$$

Доказательство. Для точки $\mathbf{w} \in \mathcal{U}_R(\mathbf{w}_k^*)$ из квадратичной аппроксимации (3.7) имеем

$$\begin{aligned} \mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) &= \mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*) + \\ &+ \mathbf{g}^{(k+1)}(\mathbf{w}_k^*)^\top (\mathbf{w} - \mathbf{w}_k^*) + \frac{1}{2}(\mathbf{w} - \mathbf{w}_k^*)^\top \left(\mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*) \right) (\mathbf{w} - \mathbf{w}_k^*). \end{aligned}$$

Переходя к модулю и применяя неравенство треугольника, получаем

$$\begin{aligned} \Delta_1(k+1) &\leq |\mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*)| + \left| \mathbf{g}^{(k+1)}(\mathbf{w}_k^*)^\top (\mathbf{w} - \mathbf{w}_k^*) \right| + \\ &+ \frac{1}{2} \left| (\mathbf{w} - \mathbf{w}_k^*)^\top \left(\mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*) \right) (\mathbf{w} - \mathbf{w}_k^*) \right|. \end{aligned}$$

Оценим по отдельности все три слагаемых.

Нулевой член. Из формулы для разности эмпирических функций потерь в точке $\mathbf{w}_k^*$ имеем

$$\mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*) = \frac{1}{k+1} \left(\ell_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*) \right).$$

Следовательно,

$$|\mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*)| \leq \frac{1}{k+1} (|\ell_{k+1}(\mathbf{w}_k^*)| + |\mathcal{L}_k(\mathbf{w}_k^*)|). \quad (3.10)$$

Но

$$|\mathcal{L}_k(\mathbf{w}_k^*)| = \left| \frac{1}{k} \sum_{i=1}^k \ell_i(\mathbf{w}_k^*) \right| \leq \frac{1}{k} \sum_{i=1}^k |\ell_i(\mathbf{w}_k^*)| \leq M_\ell.$$

Поэтому из (3.10) получаем

$$|\mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*)| \leq \frac{2M_\ell}{k+1}. \quad (3.11)$$

Линейный член. По неравенству Коши—Буняковского имеем

$$\left| \mathbf{g}^{(k+1)}(\mathbf{w}_k^*)^\top (\mathbf{w} - \mathbf{w}_k^*) \right| \leq \|\mathbf{g}^{(k+1)}(\mathbf{w}_k^*)\|_2 \|\mathbf{w} - \mathbf{w}_k^*\|_2. \quad (3.12)$$

Так как $\mathbf{g}^{(k)}(\mathbf{w}_k^*) = \mathbf{0}$, то

$$\mathbf{g}^{(k+1)}(\mathbf{w}_k^*) = \frac{1}{k+1} \mathbf{g}_{k+1}(\mathbf{w}_k^*),$$

а значит

$$\|\mathbf{g}^{(k+1)}(\mathbf{w}_k^*)\|_2 \leq \frac{M_{\mathbf{g}}}{k+1}. \quad (3.13)$$

Подставляя (3.13) в (3.12), получаем

$$\left| \mathbf{g}^{(k+1)}(\mathbf{w}_k^*)^\top (\mathbf{w} - \mathbf{w}_k^*) \right| \leq \frac{M_{\mathbf{g}}}{k+1} \|\mathbf{w} - \mathbf{w}_k^*\|_2. \quad (3.14)$$

Квадратичный член. По согласованности спектральной нормы имеем

$$\begin{aligned} \left| (\mathbf{w} - \mathbf{w}_k^*)^\top \left(\mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*) \right) (\mathbf{w} - \mathbf{w}_k^*) \right| &\leq \\ &\leq \left\| \mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*) \right\|_2 \|\mathbf{w} - \mathbf{w}_k^*\|_2^2. \end{aligned} \quad (3.15)$$

Для разности матриц Гессе справедливо

$$\mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*) = \frac{1}{k+1} \left(\mathbf{H}_{k+1}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*) \right),$$

поэтому

$$\left\| \mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*) \right\|_2 \leq \frac{1}{k+1} \left(\|\mathbf{H}_{k+1}(\mathbf{w}_k^*)\|_2 + \|\mathbf{H}^{(k)}(\mathbf{w}_k^*)\|_2 \right).$$

Из (3.9) следует

$$\|\mathbf{H}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{H}}$$

и

$$\|\mathbf{H}^{(k)}(\mathbf{w}_k^*)\|_2 = \left\| \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\mathbf{w}_k^*) \right\|_2 \leq \frac{1}{k} \sum_{i=1}^k \|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{H}}.$$

Следовательно,

$$\left\| \mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*) \right\|_2 \leq \frac{2M_{\mathbf{H}}}{k+1}. \quad (3.16)$$

Подставляя (3.16) в (3.15), получаем

$$\frac{1}{2} \left| (\mathbf{w} - \mathbf{w}_k^*)^\top \left(\mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*) \right) (\mathbf{w} - \mathbf{w}_k^*) \right| \leq \frac{M_{\mathbf{H}}}{k+1} \|\mathbf{w} - \mathbf{w}_k^*\|_2^2. \quad (3.17)$$

Собирая оценки (3.11), (3.14) и (3.17), имеем

$$\Delta_1(k+1) \leq \frac{2M_\ell}{k+1} + \frac{M_{\mathbf{g}}}{k+1} \|\mathbf{w} - \mathbf{w}_k^*\|_2 + \frac{M_{\mathbf{H}}}{k+1} \|\mathbf{w} - \mathbf{w}_k^*\|_2^2.$$

Так как $\mathbf{w} \in \mathcal{U}_R(\mathbf{w}_k^*)$, то $\|\mathbf{w} - \mathbf{w}_k^*\|_2 \leq R$, и потому

$$\Delta_1(k+1) \leq \frac{2M_\ell + M_{\mathbf{g}}R + M_{\mathbf{H}}R^2}{k+1} = \mathcal{O}(k^{-1}),$$

что и требовалось доказать. $\square$

Таким образом, в общем случае абсолютное изменение функции потерь в фиксированной точке локальной окрестности минимума определяется тремя составляющими: смещением значения функции потерь в точке $\mathbf{w}_k^*$, градиентным рассогласованием и квадратичным вкладом разности матриц Гессе. При пообъектной ограниченности функции потерь, градиента и матрицы Гессе все три слагаемых имеют порядок $\mathcal{O}(k^{-1})$, а значит и абсолютный однотоочечный критерий убывает как $\mathcal{O}(k^{-1})$.

3.5. Среднеквадратичный критерий сходимости

Однотоочечный критерий удобен для получения первичной локальной оценки, однако на практике изменение ландшафта представляет интерес не в

одной фиксированной точке, а в некоторой области пространства параметров. Естественным способом учесть такую зависимость является усреднение квадрата разности функций потерь по распределению точек. В отличие от абсолютного одноточечного критерия, такой подход позволяет анализировать не только типичную величину изменения ландшафта, но и чувствительность поверхности к направлениям отклонения от точки минимума. Иллюстрация предлагаемого критерия приведена на рисунке 3.3, а формальное определение дано ниже.

Определение. *Среднеквадратичным критерием сходимости* ландшафта функции потерь при добавлении одного объекта в выборку $\mathfrak{D}_k$ называется величина

$$\Delta_2(k+1) = \int (\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 q(\mathbf{w}) d\mathbf{w} = \mathbb{E}_{q(\mathbf{w})} \left[(\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 \right]. \quad (3.18)$$




Рисунок 3.3 — Иллюстрация среднеквадратичного критерия сходимости $\Delta_2(k)$

В общем случае поведение критерия (3.18) зависит от выбора функции предпочтения $q(\mathbf{w})$. Для получения явной аналитической формулы естественно рассмотреть гауссовское распределение с центром в точке локального минимума $q(\mathbf{w}) = \mathcal{N}(\mathbf{w}_k^*, \sigma^2 \mathbf{I}_N)$. Такой выбор согласуется с локальным характером квадратичной аппроксимации и позволяет использовать известные формулы для моментов квадратичных форм гауссовских векторов.

Теорема 3.5.1. *Пусть существует окрестность $\mathcal{U}_R(\mathbf{w}_k^*)$ радиуса $R > 0$ точки локального минимума $\mathbf{w}_k^* \in \mathbb{R}^N$ эмпирической функции потерь $\mathcal{L}_k(\mathbf{w})$, такая что в этой окрестности справедлива квадратичная аппроксимация (3.7). Предположим, что*

$$\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_g$$

и для всех $i = 1, \dots, k+1$ выполнены оценки

$$|\ell_i(\mathbf{w}_k^*)| \leq M_\ell,$$

$$\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{H}}.$$

Тогда для среднеквадратичного критерия сходимости с

$$q(\mathbf{w}) = \mathcal{N}(\mathbf{w}_k^*, \sigma^2 \mathbf{I}_N), \quad \sigma > 0,$$

верна оценка

$$\Delta_2(k+1) \leq \frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(N^2 + 2N)M_{\mathbf{H}}^2}{(k+1)^2} = \mathcal{O}(k^{-2}).$$

Доказательство. Обозначим

$$\mathbf{v} = \mathbf{w} - \mathbf{w}_k^*, \quad a_k = \mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*), \quad \mathbf{b}_k = \mathbf{g}^{(k+1)}(\mathbf{w}_k^*),$$

$$\mathbf{A}_k = \mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*).$$

Тогда при $\mathbf{w} \sim \mathcal{N}(\mathbf{w}_k^*, \sigma^2 \mathbf{I}_N)$ имеем $\mathbf{v} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_N)$, и из квадратичной аппроксимации (3.7) следует

$$\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) = a_k + \mathbf{b}_k^\top \mathbf{v} + \frac{1}{2} \mathbf{v}^\top \mathbf{A}_k \mathbf{v}.$$

Следовательно,

$$\Delta_2(k+1) = \mathbb{E} \left[\left(a_k + \mathbf{b}_k^\top \mathbf{v} + \frac{1}{2} \mathbf{v}^\top \mathbf{A}_k \mathbf{v} \right)^2 \right]. \quad (3.19)$$

Используем неравенство

$$(x + y + z)^2 \leq 3(x^2 + y^2 + z^2), \quad x, y, z \in \mathbb{R}.$$

Тогда из (3.19) получаем

$$\Delta_2(k+1) \leq 3a_k^2 + 3\mathbb{E}[(\mathbf{b}_k^\top \mathbf{v})^2] + \frac{3}{4}\mathbb{E}[(\mathbf{v}^\top \mathbf{A}_k \mathbf{v})^2]. \quad (3.20)$$

Нулевой член. По формуле для разности эмпирических функций потерь в точке $\mathbf{w}_k^*$ имеем

$$a_k = \frac{1}{k+1} \left(\ell_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*) \right).$$

Поэтому

$$|a_k| \leq \frac{1}{k+1} (|\ell_{k+1}(\mathbf{w}_k^*)| + |\mathcal{L}_k(\mathbf{w}_k^*)|).$$

Но

$$|\mathcal{L}_k(\mathbf{w}_k^*)| = \left| \frac{1}{k} \sum_{i=1}^k \ell_i(\mathbf{w}_k^*) \right| \leq \frac{1}{k} \sum_{i=1}^k |\ell_i(\mathbf{w}_k^*)| \leq M_\ell,$$

откуда

$$|a_k| \leq \frac{2M_\ell}{k+1}, \quad a_k^2 \leq \frac{4M_\ell^2}{(k+1)^2}. \quad (3.21)$$

Линейный член. Поскольку $\mathbf{g}^{(k)}(\mathbf{w}_k^*) = \mathbf{0}$, имеем

$$\mathbf{b}_k = \mathbf{g}^{(k+1)}(\mathbf{w}_k^*) = \frac{1}{k+1} \mathbf{g}_{k+1}(\mathbf{w}_k^*).$$

Тогда

$$\|\mathbf{b}_k\|_2 \leq \frac{M_{\mathbf{g}}}{k+1}.$$

Для второго момента линейной формы гауссовского вектора получаем

$$\mathbb{E}[(\mathbf{b}_k^\top \mathbf{v})^2] = \mathbf{b}_k^\top \mathbb{E}[\mathbf{v} \mathbf{v}^\top] \mathbf{b}_k = \sigma^2 \|\mathbf{b}_k\|_2^2 \leq \frac{\sigma^2 M_{\mathbf{g}}^2}{(k+1)^2}. \quad (3.22)$$

Квадратичный член. Так как матрица $\mathbf{A}_k$ симметрична, а $\mathbf{v} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_N)$, то

$$\mathbb{E}[(\mathbf{v}^\top \mathbf{A}_k \mathbf{v})^2] = 2\sigma^4 \text{Tr}(\mathbf{A}_k^2) + \sigma^4 \text{Tr}(\mathbf{A}_k)^2.$$

Для симметричной матрицы $\mathbf{A}_k$ с собственными значениями $\lambda_1, \dots, \lambda_N$ имеем

$$\text{Tr}(\mathbf{A}_k^2) = \sum_{i=1}^N \lambda_i^2 \leq N \|\mathbf{A}_k\|_2^2$$

и

$$|\text{Tr}(\mathbf{A}_k)| \leq N \|\mathbf{A}_k\|_2,$$

откуда

$$\mathbb{E}[(\mathbf{v}^\top \mathbf{A}_k \mathbf{v})^2] \leq \sigma^4 (N^2 + 2N) \|\mathbf{A}_k\|_2^2. \quad (3.23)$$

Далее,

$$\mathbf{A}_k = \mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*) = \frac{1}{k+1} \left(\mathbf{H}_{k+1}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*) \right),$$

поэтому

$$\|\mathbf{A}_k\|_2 \leq \frac{1}{k+1} \left(\|\mathbf{H}_{k+1}(\mathbf{w}_k^*)\|_2 + \|\mathbf{H}^{(k)}(\mathbf{w}_k^*)\|_2 \right).$$

Из ограниченности гессианов на отдельных объектах следует

$$\|\mathbf{H}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{H}}$$

и

$$\|\mathbf{H}^{(k)}(\mathbf{w}_k^*)\|_2 = \left\| \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\mathbf{w}_k^*) \right\|_2 \leq \frac{1}{k} \sum_{i=1}^k \|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{H}}.$$

Следовательно,

$$\|\mathbf{A}_k\|_2 \leq \frac{2M_{\mathbf{H}}}{k+1}. \quad (3.24)$$

Подставляя (3.24) в (3.23), получаем

$$\mathbb{E}[(\mathbf{v}^\top \mathbf{A}_k \mathbf{v})^2] \leq \frac{4\sigma^4(N^2 + 2N)M_{\mathbf{H}}^2}{(k+1)^2}. \quad (3.25)$$

Подставляя оценки (3.21), (3.22) и (3.25) в (3.20), получаем

$$\Delta_2(k+1) \leq \frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(N^2 + 2N)M_{\mathbf{H}}^2}{(k+1)^2},$$

что и требовалось доказать. $\square$

Итак, в общем случае среднеквадратичный критерий определяется тремя источниками рассогласования: разностью значений функций потерь в точке $\mathbf{w}_k^*$, градиентным рассогласованием и квадратичным вкладом, связанным с разностью матриц Гессе. При пообъектной ограниченности функции потерь, градиента и матрицы Гессе все три слагаемых имеют порядок $\mathcal{O}(k^{-2})$ после усреднения квадрата по гауссовскому распределению, а значит и сам среднеквадратичный критерий убывает как $\mathcal{O}(k^{-2})$.

3.6. Среднеквадратичный критерий сходимости в подпространстве наибольшей кривизны

Во многих задачах существенное изменение ландшафта функции потерь происходит не по всем направлениям в пространстве параметров, а преимущественно вдоль направлений наибольшей локальной кривизны. Такие направления задаются собственными векторами матрицы Гессе, соответствующими ее наибольшему собственному значению. Поэтому наряду с критерием (3.18)

естественно рассмотреть его аналог в подпространстве меньшей размерности, натянутом на главные собственные векторы матрицы Гессе в точке локального минимума $\mathbf{w}_k^*$.

Определение. Пусть

$$\mathbf{H}^{(k)}(\mathbf{w}_k^*)\mathbf{u}_i = \lambda_i^{(k)}\mathbf{u}_i, \quad i = 1, \dots, N,$$

где собственные значения упорядочены по невозрастанию:

$$\lambda_1^{(k)} \geq \lambda_2^{(k)} \geq \dots \geq \lambda_N^{(k)},$$

а собственные векторы $\mathbf{u}_1, \dots, \mathbf{u}_N$ образуют ортонормированный базис в $\mathbb{R}^N$. Обозначим через

$$\mathbf{U}_D = [\mathbf{u}_1, \dots, \mathbf{u}_D] \in \mathbb{R}^{N \times D}$$

матрицу, столбцы которой составлены из D собственных векторов, отвечающих D наибольшим собственным значениям матрицы $\mathbf{H}^{(k)}(\mathbf{w}_k^*)$. Подпространство

$$\mathcal{S}_D = \text{Im}(\mathbf{U}_D)$$

будем называть *подпространством наибольшей кривизны* размерности D .

Основная идея предлагаемого критерия состоит в том, чтобы выбирать точки для оценки стабилизации поверхности именно в подпространстве наибольшей кривизны. Иллюстрация этого приведена на рисунке 3.4, а формальное определение дано ниже.

Определение. *Среднеквадратичным критерием сходимости в подпространстве наибольшей кривизны* размерности D называется величина

$$\Delta_2^{(D)}(k+1) = \int (\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 q(\mathbf{w}) d\mathbf{w}, \quad (3.26)$$

где функция $q(\mathbf{w})$ задает плотность вероятностного распределения на аффинном подпространстве $\mathbf{w}_k^* + \mathcal{S}_D$.

Замечание. Любая точка $\mathbf{w} \in \mathbf{w}_k^* + \mathcal{S}_D$ единственным образом представима в виде

$$\mathbf{w} = \mathbf{w}_k^* + \mathbf{U}_D \mathbf{z}, \quad \mathbf{z} \in \mathbb{R}^D.$$

Поэтому критерий (3.26) можно эквивалентно записать в координатах $\mathbf{z} \in \mathbb{R}^D$:

$$\Delta_2^{(D)}(k+1) = \int (\mathcal{L}_{k+1}(\mathbf{w}_k^* + \mathbf{U}_D \mathbf{z}) - \mathcal{L}_k(\mathbf{w}_k^* + \mathbf{U}_D \mathbf{z}))^2 \tilde{q}(\mathbf{z}) d\mathbf{z}, \quad (3.27)$$

где $\tilde{q}(\mathbf{z})$ — плотность распределения в координатах подпространства, индуцированная функцией предпочтения $q(\mathbf{w})$.




Рисунок 3.4 — Иллюстрация среднеквадратичного критерия сходимости в подпространстве наибольшей кривизны $\Delta_2^{(D)}(k)$

Лемма 3.6.1. Пусть $\text{supp } q \subset (\mathbf{w}_k^* + \mathcal{S}_D) \cap \mathcal{U}_R(\mathbf{w}_k^*)$. Обозначим

$$\begin{aligned} a_k &= \mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*), & \mathbf{b}_k &= \mathbf{g}^{(k+1)}(\mathbf{w}_k^*), \\ \mathbf{A}_k &= \mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*), & \mathbf{B}_k &= \mathbf{U}_D^\top \mathbf{A}_k \mathbf{U}_D \in \mathbb{R}^{D \times D}, \\ \mathbf{c}_k &= \mathbf{U}_D^\top \mathbf{b}_k \in \mathbb{R}^D. \end{aligned}$$

Тогда в рамках квадратичной аппроксимации (3.7) критерий (3.27) представим в виде

$$\Delta_2^{(D)}(k+1) = \int \left(a_k + \mathbf{c}_k^\top \mathbf{z} + \frac{1}{2} \mathbf{z}^\top \mathbf{B}_k \mathbf{z} \right)^2 \tilde{q}(\mathbf{z}) d\mathbf{z}. \quad (3.28)$$

Доказательство. Для любой точки $\mathbf{w} \in \mathbf{w}_k^* + \mathcal{S}_D$ имеем представление

$$\mathbf{w} = \mathbf{w}_k^* + \mathbf{U}_D \mathbf{z}, \quad \mathbf{z} \in \mathbb{R}^D.$$

Тогда из квадратичной аппроксимации (3.7) следует

$$\begin{aligned} \mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) &= a_k + \mathbf{b}_k^\top (\mathbf{w} - \mathbf{w}_k^*) + \frac{1}{2} (\mathbf{w} - \mathbf{w}_k^*)^\top \mathbf{A}_k (\mathbf{w} - \mathbf{w}_k^*) \\ &= a_k + \mathbf{b}_k^\top \mathbf{U}_D \mathbf{z} + \frac{1}{2} (\mathbf{U}_D \mathbf{z})^\top \mathbf{A}_k (\mathbf{U}_D \mathbf{z}) \\ &= a_k + (\mathbf{U}_D^\top \mathbf{b}_k)^\top \mathbf{z} + \frac{1}{2} \mathbf{z}^\top \mathbf{U}_D^\top \mathbf{A}_k \mathbf{U}_D \mathbf{z} \\ &= a_k + \mathbf{c}_k^\top \mathbf{z} + \frac{1}{2} \mathbf{z}^\top \mathbf{B}_k \mathbf{z}. \end{aligned}$$

Возводя в квадрат и усредняя по распределению $\tilde{q}(\mathbf{z})$, получаем (3.28). $\square$

Замечание. По определению

$$\mathbf{B}_k = \mathbf{U}_D^\top \mathbf{H}^{(k+1)}(\mathbf{w}_k^*) \mathbf{U}_D - \mathbf{U}_D^\top \mathbf{H}^{(k)}(\mathbf{w}_k^*) \mathbf{U}_D.$$

Поскольку столбцы матрицы $\mathbf{U}_D$ являются собственными векторами матрицы $\mathbf{H}^{(k)}(\mathbf{w}_k^*)$, имеем

$$\mathbf{U}_D^\top \mathbf{H}^{(k)}(\mathbf{w}_k^*) \mathbf{U}_D = \text{diag} \left(\lambda_1^{(k)}, \dots, \lambda_D^{(k)} \right).$$

Если, кроме того, векторы $\mathbf{u}_1, \dots, \mathbf{u}_D$ являются также собственными векторами матрицы $\mathbf{H}^{(k+1)}(\mathbf{w}_k^*)$, то

$$\mathbf{U}_D^\top \mathbf{H}^{(k+1)}(\mathbf{w}_k^*) \mathbf{U}_D = \text{diag} \left(\lambda_1^{(k+1)}, \dots, \lambda_D^{(k+1)} \right),$$

а следовательно,

$$\mathbf{B}_k = \text{diag} \left(\lambda_1^{(k+1)} - \lambda_1^{(k)}, \dots, \lambda_D^{(k+1)} - \lambda_D^{(k)} \right).$$

Таким образом, в этом случае собственные значения матрицы $\mathbf{B}_k$ совпадают с приращениями соответствующих собственных значений матриц Гессе.

Предположение 3.6.2. Пусть векторы $\mathbf{u}_1, \dots, \mathbf{u}_D$, отвечающие D наибольшим собственным значениям матрицы $\mathbf{H}^{(k)}(\mathbf{w}_k^*)$, являются также собственными векторами матрицы $\mathbf{H}^{(k+1)}(\mathbf{w}_k^*)$:

$$\mathbf{H}^{(k+1)}(\mathbf{w}_k^*) \mathbf{u}_i = \lambda_i^{(k+1)} \mathbf{u}_i, \quad i = 1, \dots, D.$$

Данное предположение означает, что при переходе от выборки размера k к выборке размера $k + 1$ главные направления локальной кривизны в рассматриваемом подпространстве не меняются. Именно оно позволяет выразить критерий сходимости через приращения соответствующих собственных значений матриц Гессе.

Замечание. В важном для практического применения частном случае функция предпочтения $q(\mathbf{w})$ может быть выбрана так, чтобы индуцированное распределение в координатах подпространства было нормальным:

$$\tilde{q}(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D), \quad \mathbf{w} = \mathbf{w}_k^* + \mathbf{U}_D \mathbf{z}.$$

Тогда критерий (3.27) принимает вид математического ожидания по гауссовскому распределению в пространстве $\mathbb{R}^D$, что позволяет получить явную формулу через спектральные характеристики матриц Гессе.

Теорема 3.6.3. Пусть выполнены условия леммы 3.6.1. Предположим, что

$$\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{g}}$$

и для всех $i = 1, \dots, k+1$ выполнены оценки

$$|\ell_i(\mathbf{w}_k^*)| \leq M_{\ell},$$

$$\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{H}}.$$

Пусть, кроме того, функция предпочтения $q(\mathbf{w})$ индуцирует в координатах подпространства наибольшей кривизны распределение

$$\tilde{q}(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D).$$

Тогда для среднеквадратичного критерия сходимости в подпространстве наибольшей кривизны верно

$$\Delta_2^{(D)}(k+1) \leq \frac{12M_{\ell}^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(D^2 + 2D)M_{\mathbf{H}}^2}{(k+1)^2} = \mathcal{O}(k^{-2}).$$

Доказательство. По лемме 3.6.1 имеем

$$\Delta_2^{(D)}(k+1) = \mathbb{E}_{\tilde{q}(\mathbf{z})} \left[\left(a_k + \mathbf{c}_k^{\top} \mathbf{z} + \frac{1}{2} \mathbf{z}^{\top} \mathbf{B}_k \mathbf{z} \right)^2 \right], \quad \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D).$$

Используя неравенство

$$(x + y + z)^2 \leq 3(x^2 + y^2 + z^2), \quad x, y, z \in \mathbb{R},$$

получаем

$$\Delta_2^{(D)}(k+1) \leq 3a_k^2 + 3\mathbb{E}[(\mathbf{c}_k^{\top} \mathbf{z})^2] + \frac{3}{4}\mathbb{E}[(\mathbf{z}^{\top} \mathbf{B}_k \mathbf{z})^2]. \quad (3.29)$$

Нулевой член. Как и в доказательстве теоремы для полного среднеквадратичного критерия,

$$|a_k| = |\mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*)| \leq \frac{2M_{\ell}}{k+1},$$

а значит

$$a_k^2 \leq \frac{4M_{\ell}^2}{(k+1)^2}. \quad (3.30)$$

Линейный член. Так как

$$\mathbf{c}_k = \mathbf{U}_D^{\top} \mathbf{b}_k, \quad \mathbf{b}_k = \mathbf{g}^{(k+1)}(\mathbf{w}_k^*) = \frac{1}{k+1} \mathbf{g}_{k+1}(\mathbf{w}_k^*),$$

то

$$\|\mathbf{c}_k\|_2 \leq \|\mathbf{U}_D^\top\|_2 \|\mathbf{b}_k\|_2 \leq \frac{M_{\mathbf{g}}}{k+1},$$

поскольку $\mathbf{U}_D$ имеет ортонормированные столбцы и $\|\mathbf{U}_D^\top\|_2 = 1$. Следовательно,

$$\mathbb{E}[(\mathbf{c}_k^\top \mathbf{z})^2] = \sigma^2 \|\mathbf{c}_k\|_2^2 \leq \frac{\sigma^2 M_{\mathbf{g}}^2}{(k+1)^2}. \quad (3.31)$$

Квадратичный член. Так как матрица $\mathbf{B}_k \in \mathbb{R}^{D \times D}$ симметрична, а $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D)$, то

$$\mathbb{E}[(\mathbf{z}^\top \mathbf{B}_k \mathbf{z})^2] = 2\sigma^4 \text{Tr}(\mathbf{B}_k^2) + \sigma^4 \text{Tr}(\mathbf{B}_k)^2.$$

Для симметричной матрицы $\mathbf{B}_k$ имеем

$$\text{Tr}(\mathbf{B}_k^2) \leq D \|\mathbf{B}_k\|_2^2, \quad |\text{Tr}(\mathbf{B}_k)| \leq D \|\mathbf{B}_k\|_2,$$

откуда

$$\mathbb{E}[(\mathbf{z}^\top \mathbf{B}_k \mathbf{z})^2] \leq \sigma^4 (D^2 + 2D) \|\mathbf{B}_k\|_2^2. \quad (3.32)$$

Далее,

$$\|\mathbf{B}_k\|_2 = \|\mathbf{U}_D^\top \mathbf{A}_k \mathbf{U}_D\|_2 \leq \|\mathbf{U}_D^\top\|_2 \|\mathbf{A}_k\|_2 \|\mathbf{U}_D\|_2 \leq \|\mathbf{A}_k\|_2.$$

Как и ранее,

$$\mathbf{A}_k = \mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*) = \frac{1}{k+1} \left(\mathbf{H}_{k+1}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*) \right),$$

поэтому

$$\|\mathbf{A}_k\|_2 \leq \frac{2M_{\mathbf{H}}}{k+1},$$

а значит

$$\|\mathbf{B}_k\|_2 \leq \frac{2M_{\mathbf{H}}}{k+1}. \quad (3.33)$$

Подставляя (3.33) в (3.32), получаем

$$\mathbb{E}[(\mathbf{z}^\top \mathbf{B}_k \mathbf{z})^2] \leq \frac{4\sigma^4 (D^2 + 2D) M_{\mathbf{H}}^2}{(k+1)^2}. \quad (3.34)$$

Подставляя (3.30), (3.31) и (3.34) в (3.29), получаем

$$\Delta_2^{(D)}(k+1) \leq \frac{12M_{\ell}^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4 (D^2 + 2D) M_{\mathbf{H}}^2}{(k+1)^2} = \mathcal{O}(k^{-2}),$$

что и требовалось доказать. □

Теорема 3.6.4. Пусть выполнено предположение 3.6.2, и пусть

$$a_k = 0, \quad \mathbf{c}_k = \mathbf{0}.$$

Пусть, кроме того,

$$\tilde{q}(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D).$$

Тогда для среднеквадратичного критерия сходимости в подпространстве наибольшей кривизны верно

$$\Delta_2^{(D)}(k+1) = \frac{\sigma^4}{4} \left(2 \sum_{i=1}^D \left(\lambda_i^{(k+1)} - \lambda_i^{(k)} \right)^2 + \left(\sum_{i=1}^D \left(\lambda_i^{(k+1)} - \lambda_i^{(k)} \right) \right)^2 \right). \quad (3.35)$$

Доказательство. По лемме 3.6.1 при $a_k = 0$ и $\mathbf{c}_k = \mathbf{0}$ имеем

$$\Delta_2^{(D)}(k+1) = \frac{1}{4} \mathbb{E}_{\tilde{q}(\mathbf{z})} [(\mathbf{z}^\top \mathbf{B}_k \mathbf{z})^2], \quad \tilde{q}(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D).$$

Далее

$$\mathbb{E}[(\mathbf{z}^\top \mathbf{B}_k \mathbf{z})^2] = 2\sigma^4 \text{Tr}(\mathbf{B}_k^2) + \sigma^4 \text{Tr}(\mathbf{B}_k)^2.$$

В силу предположения 3.6.2 и замечания 3.6

$$\mathbf{B}_k = \text{diag} \left(\lambda_1^{(k+1)} - \lambda_1^{(k)}, \dots, \lambda_D^{(k+1)} - \lambda_D^{(k)} \right).$$

Поэтому

$$\begin{aligned} \text{Tr}(\mathbf{B}_k) &= \sum_{i=1}^D \left(\lambda_i^{(k+1)} - \lambda_i^{(k)} \right), \\ \text{Tr}(\mathbf{B}_k^2) &= \sum_{i=1}^D \left(\lambda_i^{(k+1)} - \lambda_i^{(k)} \right)^2. \end{aligned}$$

Подстановка дает (3.35). □

Полученный результат показывает, что ограничение рассмотрения подпространством наибольшей кривизны сохраняет порядок сходимости среднеквадратичного критерия, равный $\mathcal{O}(k^{-2})$. В общей постановке критерий в подпространстве, как и в полном пространстве параметров, определяется тремя источниками рассогласования: разностью значений функций потерь в точке $\mathbf{w}_k^*$, градиентным рассогласованием и квадратичным вкладом, связанным с разностью матриц Гессе. При этом размерностный множитель в квадратичном члене зависит уже не от полной размерности пространства параметров N , а только от размерности выбранного подпространства D . В частном случае, когда нулевой и линейный члены отсутствуют, критерий выражается непосредственно через приращения ведущих собственных значений матрицы Гессе.

3.7. Вычислительные эксперименты

В данном разделе проводится эмпирическая проверка полученных теоретических оценок на скорость стабилизации ландшафта функции потерь. Программный код реализован на фреймворке **PyTorch** и доступен в репозитории диссертации по адресу

<https://github.com/kisnikser/PhD-Thesis/code/landscape>.

Постановка эксперимента. Эксперименты проводятся на полносвязной нейронной сети (MLP) для классификации рукописных цифр на датасете MNIST. В используемой реализации параметр `num_layers = 2` соответствует одному скрытому слою ширины 64 и выходному линейному классификатору. Размеры обучающей выборки рассматриваются на сетке

$$k \in \{100, 150, 200, 300, 400, 500, 700, 1000, 1500, 2000, 3000, 5000, 7000, 10000\}.$$

Для каждого размера выборки k модель обучается в течение 100 эпох оптимизатором Adam с learning rate 10^{-3} , после чего в параметрах полученной модели вычисляются критерии:

- абсолютный однотоочечный критерий $\Delta_1(k)$ — усреднение по 100 случайным направлениям с радиусом $\varepsilon = 0.5$;
- среднеквадратичный критерий $\Delta_2(k)$ — 200 точек Монте-Карло с $\sigma = 0.5$;
- подпространственный критерий $\Delta_2^{(D)}(k)$ для $D \in \{5, 10, 20\}$.

Для вычисления подпространственных критериев дополнительно находятся ведущие собственные векторы матрицы Гессе. Эксперименты повторяются для трех независимых инициализаций с seed 42, 43 и 44, после чего результаты усредняются по запускам.

Скорость сходимости критериев. На рисунке 3.5 представлена зависимость критериев $\Delta_1(k)$, $\Delta_2(k)$ и $\Delta_2^{(D)}(k)$ от размера выборки k в логарифмических координатах.

Результаты показывают следующее:

- Критерий Δ_1 демонстрирует существенно более высокую дисперсию, чем усредненные квадратичные критерии. Степенная аппроксимация




Рисунок 3.5 — Зависимость критериев $\Delta_1(k)$, $\Delta_2(k)$ и $\Delta_2^{(D)}(k)$ от размера выборки k в логарифмических координатах. Пунктирные линии соответствуют теоретическим показателям $\propto k^{-1}$ и $\propto k^{-2}$

для него оказывается заметно менее устойчивой, поэтому этот критерий удобнее интерпретировать качественно.

- Критерий Δ_2 убывает гладко и хорошо описывается степенным законом с показателем, близким к 2, что согласуется с теоретической оценкой $\mathcal{O}(k^{-2})$.
- Подпространственные критерии $\Delta_2^{(D)}$ для $D = 5, 10, 20$ также убывают близко к квадратичному закону, однако остаются систематически меньше полного критерия Δ_2 . Это указывает на существенную, но не полную концентрацию кривизны в маломерном подпространстве ведущих направлений.

Для качественного понимания геометрии ландшафта строятся дополнительные визуализации.

Спектр матрицы Гессе. На рисунке 3.6 представлены ведущие собственные значения матрицы Гессе для модели, обучаемой на подвыборке размера $k = 1000$, в контрольных точках обучения 10, 20, 50 и 100 эпох. Спектры по-

Таблица 2 — Оцененные показатели степенного закона $\Delta(k) \sim k^{-\alpha}$

Критерий	Оценка α	R^2	Теоретическое значение
Δ_1	2,33	0,63	≥ 1
Δ_2	1,94	1,00	≈ 2
$\Delta_2^{(D=5)}$	1,80	0,96	≈ 2
$\Delta_2^{(D=10)}$	1,83	0,99	≈ 2
$\Delta_2^{(D=20)}$	1,84	0,99	≈ 2

строены в полулогарифмической шкале и показывают быстрое убывание по индексу собственного значения; по мере обучения уменьшается и общий масштаб ведущих собственных значений.




Рисунок 3.6 — Собственные значения матрицы Гессе λ_i (логарифмическая шкала) на разных эпохах обучения. Убывание близко к экспоненциальному

Двумерные сечения ландшафта. На рисунке 3.7 представлены контурные графики функции потерь для модели, обученной на подвыборке размера $k = 1000$ в течение 100 эпох. Слева показано сечение вдоль двух случайных ортогональных направлений в пространстве параметров, справа — вдоль двух ведущих собственных векторов матрицы Гессе.

Сечение вдоль собственных векторов демонстрирует более выраженную анизотропию: в этих направлениях изменение функции потерь происходит неравномерно и значительно быстрее, чем в произвольных ортогональных




Рисунок 3.7 — Двумерные сечения ландшафта функции потерь: случайные направления (слева) и направления максимальной кривизны (справа)

направлениях. В случайных направлениях поверхность выглядит более сглаженной.

Трехмерная иллюстрация. На рисунке 3.8 представлены трехмерные поверхности функции потерь $\mathcal{L}(\mathbf{w} + \alpha \mathbf{d}_1 + \beta \mathbf{d}_2)$ для той же обученной модели и тех же пар направлений.




Рисунок 3.8 — Трехмерная иллюстрация ландшафта функции потерь в окрестности минимума

Вычислительные эксперименты подтверждают основные качественные выводы главы:

1. Среднеквадратичный критерий Δ_2 убывает со скоростью, близкой к $\mathcal{O}(k^{-2})$.

2. Подпространственные критерии $\Delta_2^{(D)}$ также демонстрируют близкий порядок убывания, но принимают меньшие значения, чем полный критерий Δ_2 .
3. Абсолютный однотоочечный критерий Δ_1 также уменьшается с ростом k , однако из-за высокой вариативности его степенная аппроксимация менее надежна.
4. Дополнительные спектральные и поверхностные визуализации для случая $k = 1000$ показывают выраженную анизотропию ландшафта вдоль ведущих собственных направлений матрицы Гессе.

3.8. Обсуждение

В данной главе предложен подход к исследованию стабилизации ландшафта функции потерь при увеличении объема обучающей выборки, основанный на локальной квадратичной аппроксимации функции потерь в окрестности точки минимума и анализе разности соответствующих матриц Гессе. Такой подход позволяет перейти от сходимости эмпирического риска как скалярной величины к исследованию сходимости локальной геометрии поверхности функции потерь. В результате были введены критерии, измеряющие изменение ландшафта в одной точке, по распределению точек в полном пространстве параметров и по распределению в подпространстве наибольшей кривизны.

Основной теоретический вывод состоит в том, что скорость убывания критерия зависит от способа агрегации локальных изменений поверхности. Для абсолютного однотоочечного критерия получена оценка порядка $\mathcal{O}(k^{-1})$, тогда как для среднеквадратичного критерия в полном пространстве параметров и в подпространстве наибольшей кривизны установлена оценка порядка $\mathcal{O}(k^{-2})$. При этом подпространственный критерий сохраняет тот же порядок сходимости, но позволяет сосредоточить анализ на направлениях, соответствующих наибольшей локальной кривизне, что особенно важно для моделей большой размерности.

Проведенные вычислительные эксперименты дополняют теоретический анализ и демонстрируют сходимость введенных критериев при увеличении объема обучающей выборки, а также позволяют получить эмпирические оценки

скоростей их убывания. В целом полученные результаты показывают, что стабилизация ландшафта функции потерь может быть описана через поведение матрицы Гессе и ее спектральных характеристик, что делает предложенный подход удобным как для теоретического анализа, так и для практического исследования современных нейронных сетей.

Глава 4. Критерии достаточного размера выборки и интерпретация законов масштабирования для параметрических моделей

В данной главе результаты глав 2 и 3 объединяются в единую схему. Сначала из ранее полученных архитектурно-зависимых оценок локальной кривизны и критериев стабилизации ландшафта выводятся критерии достаточного размера выборки для параметрических моделей. Эти утверждения являются прямыми следствиями результатов предыдущих глав. Затем рассматривается более общая интерпретация полученных оценок в терминах законов масштабирования. Эта часть главы носит структурный характер и опирается на дополнительные предположения, связывающие локальные свойства оптимизационной поверхности с вкладом конечности обучающей выборки в итоговое значение функции потерь.

4.1. Введение

В главах 2 и 3 были получены два класса результатов, непосредственно связанных между собой. В главе 2 получены архитектурно-зависимые верхние оценки спектральной нормы гаусс—ньютоновской компоненты матрицы Гессе для ряда нейросетевых архитектур. В главе 3 введены критерии стабилизации ландшафта функции потерь при увеличении объема обучающей выборки и получены оценки скорости их убывания.

Настоящая глава посвящена объединению этих результатов. Основная идея состоит в следующем. Если локальная кривизна оптимизационной поверхности контролируется архитектурно-зависимой величиной, а скорость стабилизации ландшафта определяется верхней границей на спектральную норму матрицы Гессе, то эти два факта можно объединить и получить критерии достаточного размера выборки, зависящие от архитектуры модели.

Таким образом, в строгом виде в данной главе выводятся критерии достаточного размера выборки на основе локальных свойств оптимизационной поверхности. Наряду с этим далее рассматривается более общая интерпретация полученных результатов в терминах законов масштабирования параметри-

ческих моделей. Эта интерпретация не является прямым следствием всех предыдущих теорем и поэтому требует дополнительных структурных предположений, которые будут явно сформулированы в тексте.

Задача определения достаточного размера выборки имеет длительную историю и рассматривалась в нескольких существенно различных постановках. Прежде чем перейти к развиваемому в диссертации подходу, основанному на стабилизации ландшафта функции потерь, целесообразно кратко рассмотреть основные существующие методы определения достаточного размера выборки. В классической литературе можно выделить три большие группы таких методов: статистические, эвристические и байесовские. Несмотря на различие в используемых предположениях и вычислительных процедурах, все они в той или иной форме опираются на общую идею стабилизации — параметров модели, значений критериев качества или вероятностных характеристик оценки — при увеличении объема данных.

В следующем разделе приводится краткий обзор указанных подходов и обсуждается место предлагаемого в диссертации критерия достаточности. После этого формализуется связь между архитектурно-зависимой локальной кривизной и критериями стабилизации ландшафта, а затем выводятся соответствующие оценки достаточного размера выборки для параметрических моделей.

4.2. Обзор существующих подходов

Общая постановка задачи. Пусть $\mathfrak{D}_m = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^m$ обозначает обучающую выборку объема m , а $f_{\mathbf{w}} : \mathbb{R}^n \rightarrow \mathbb{R}^K$ — параметрическую модель с вектором параметров $\mathbf{w} \in \mathbb{R}^N$.

В наиболее общем виде задача определения достаточного размера выборки состоит в нахождении минимального значения m^* , начиная с которого дальнейшее увеличение числа объектов в выборке не приводит к существенному изменению некоторой выбранной характеристики модели. В качестве такой характеристики могут выступать статистика критерия, ошибка обобщения, доверительный интервал, апостериорная неопределенность или расстояние между оценками параметров, полученными на соседних подвыборках.

Эту идею удобно формализовать следующим образом. Пусть $\Psi(m)$ обозначает некоторую меру нестабильности модели, неопределенности оценки или чувствительности результата обучения к увеличению объема данных. Тогда достаточный размер выборки можно записать в абстрактной форме:

$$m^* = \inf\{m \in \mathbb{N} : \Psi(m) \leq \varepsilon\}, \quad (4.1)$$

где $\varepsilon > 0$ есть заранее заданный уровень точности.

Конкретный смысл величины $\Psi(m)$ зависит от выбранной методологии. В статистических методах она связана с различимостью параметров в задаче проверки гипотез, в эвристических — со стабилизацией наблюдаемых характеристик качества обучения, а в байесовских — с уменьшением неопределенности апостериорного распределения или его изменчивости при добавлении новых данных.

Статистические методы. Статистические методы определения достаточного размера выборки основаны на асимптотической теории проверки гипотез и чаще всего рассматриваются для параметрических и обобщенных линейных моделей [18—22]. В рамках данного подхода достаточный размер выборки определяется как минимальный объем данных, обеспечивающий заданный уровень значимости α и требуемую статистическую мощность $1 - \beta$.

Пусть T_m обозначает статистику критерия, построенную по выборке объема m , а c_α — критическое значение, соответствующее уровню значимости α . Тогда в общей форме достаточный размер выборки определяется условием

$$m^* : \quad \mathbb{P}(T_m > c_\alpha | H_1) \geq 1 - \beta.$$

Иными словами, выбирается минимальный объем данных, при котором вероятность отклонить нулевую гипотезу при справедливости альтернативы не меньше заданной мощности.

Типичными примерами статистик, используемых в этой постановке, являются статистика отношения правдоподобия, статистика множителей Лагранжа и статистика Вальда. Так, статистика отношения правдоподобия имеет вид

$$LR = 2(l(\mathfrak{D}, \hat{\mathbf{w}}) - l(\mathfrak{D}, \hat{\mathbf{w}}^0)),$$

где $l(\mathfrak{D}, \mathbf{w})$ — логарифм функции правдоподобия, $\hat{\mathbf{w}}$ — оценка максимального правдоподобия без ограничений, а $\hat{\mathbf{w}}^0$ — оценка при фиксированных параметрах, соответствующих нулевой гипотезе.

Статистика Вальда записывается в виде

$$W = (\hat{\mathbf{w}}_u - \mathbf{w}_u^0)^\top \hat{\mathbf{V}}_u^{-1} (\hat{\mathbf{w}}_u - \mathbf{w}_u^0),$$

где $\hat{\mathbf{w}}_u$ — оцениваемый подвектор параметров, $\mathbf{w}_u^0$ — его значение при нулевой гипотезе, а $\hat{\mathbf{V}}_u$ — оценка ковариационной матрицы.

В асимптотическом режиме подобные статистики при справедливости альтернативной гипотезы часто имеют нецентральное распределение хи-квадрат с параметром нецентральности γ , линейно растущим по m . В результате достаточный размер выборки принимает форму

$$m^* = \frac{\gamma^*}{\gamma^0},$$

где γ^* определяется из условий на α и β , а γ^0 характеризует различимость гипотез в расчете на один объект выборки.

Основное достоинство статистических методов состоит в том, что они позволяют оценивать необходимый объем данных до проведения полного эксперимента. Однако их применение обычно требует знания дисперсий оценок, параметров нецентральности или других априорных характеристик модели и данных. Для моделей большой размерности, а тем более для глубоких нейронных сетей, такие величины, как правило, недоступны в явном виде или вычислительно сложны для надежной оценки.

Эвристические методы. Эвристические методы определения достаточного размера выборки основаны не на асимптотической схеме проверки гипотез, а на наблюдении за изменением характеристик процесса обучения при увеличении объема данных [23; 73]. Их основная идея состоит в том, что выборка может считаться достаточной, если некоторое наблюдаемое свойство модели стабилизируется и его дальнейшее изменение становится малым.

Одним из наиболее естественных примеров является критерий, основанный на сравнении качества модели на обучающей и тестовой подвыборках. Если обозначить через $\mathfrak{D}_{\mathcal{L}(m)}$ и $\mathfrak{D}_{\mathcal{T}(m)}$ обучающую и тестовую части выборки объема m , то можно рассматривать величину

$$RS(m) = \ln \frac{L(\mathfrak{D}_{\mathcal{L}(m)}, \hat{\mathbf{w}})}{L(\mathfrak{D}_{\mathcal{T}(m)}, \hat{\mathbf{w}})},$$

где $L(\mathfrak{D}, \hat{\mathbf{w}})$ — правдоподобие или иная характеристика качества модели на соответствующей выборке. Тогда размер выборки считается достаточным, если

для всех $m \geq m^*$ выполняется

$$\mathbb{E} RS(m) \leq \varepsilon.$$

Другой распространенный класс эвристических методов основан на бутстрапе. В этом случае для каждого m строятся доверительные интервалы для оцениваемых параметров модели, и достаточный размер выборки определяется через их ширину. Если

$$(a_i^m, b_i^m), \quad i = 1, \dots, n,$$

обозначают доверительные интервалы для параметров модели, то можно использовать критерий

$$m^* : \quad \forall m \geq m^* \quad \max_i (b_i^m - a_i^m) < l,$$

где $l > 0$ — заранее заданный допустимый размер интервала.

Преимущество эвристических методов состоит в их гибкости и применимости в ситуациях, когда строгие статистические предположения плохо обоснованы или недоступны для проверки. Однако такие методы обычно зависят от выбора конкретной характеристики порога ε , а также не предоставляют строгих универсальных гарантий.

Байесовские методы. Байесовские методы определения достаточного размера выборки рассматривают задачу в терминах апостериорного распределения параметров модели [24–26]. В этой постановке обучающая выборка считается достаточной, если неопределенность в апостериорной оценке параметров становится достаточно малой либо если соседние апостериорные распределения оказываются достаточно близкими.

Один из базовых вариантов состоит в контроле средней апостериорной дисперсии. Если $p(\mathbf{w}|\mathfrak{D}_m)$ — апостериорное распределение параметров модели по выборке объема m , то достаточный размер выборки может быть определен условием

$$m^* : \quad \forall m \geq m^* \quad \mathbb{E}_{\mathfrak{D}_m} D[\mathbf{w}|\mathfrak{D}_m] \leq l,$$

где $l > 0$ задает допустимый уровень неопределенности.

Другой вариант связан с вероятностью покрытия некоторой доверительной области. Пусть

$$A(\mathfrak{D}_m) = \{\mathbf{w} : \|\mathbf{w} - \hat{\mathbf{w}}\| \leq r_m\},$$

где $\hat{\mathbf{w}}$ — точечная оценка параметров, а r_m — радиус соответствующей области. Тогда критерием достаточности может служить условие

$$m^* : \quad \forall m \geq m^* \quad \mathbb{E}_{\mathfrak{D}_m} \mathbf{P}\{\mathbf{w} \in A(\mathfrak{D}_m)\} \geq 1 - \alpha.$$

Наконец, возможен подход, основанный на близости апостериорных распределений, построенных по соседним подвыборкам. Пусть $\mathfrak{D}_{\mathcal{B}_1}$ и $\mathfrak{D}_{\mathcal{B}_2}$ — две соседние подвыборки, отличающиеся одним объектом, а p_1 и p_2 — соответствующие апостериорные распределения параметров. Тогда можно потребовать

$$m^* : \quad \forall |\mathfrak{D}_{\mathcal{B}_1}| \geq m^* \quad \mathbb{E}_{\mathfrak{D}_{\mathcal{B}_2}} D_{\text{KL}}(p_1 \| p_2) \leq \varepsilon,$$

где

$$D_{\text{KL}}(p_1 \| p_2) = \int p_1(\mathbf{w}) \log \frac{p_1(\mathbf{w})}{p_2(\mathbf{w})} d\mathbf{w}.$$

Байесовские методы обладают важным достоинством: они непосредственно описывают неопределенность параметров модели и естественным образом интерпретируют достаточный размер выборки как размер, при котором дальнейшее обновление апостериорного распределения становится малым. Однако в многопараметрических моделях, особенно в моделях глубокого обучения, такие методы часто оказываются вычислительно сложными.

Положение предлагаемого подхода. Рассмотренные выше подходы используют разные математические объекты, однако все они основаны на одной и той же общей идее: выборка является достаточной, если увеличение объема данных перестает существенно изменять некоторую значимую характеристику модели. В статистических методах такой характеристикой является различимость параметров в задаче проверки гипотез, в эвристических — наблюдаемая метрика качества обучения, а в байесовских — апостериорная неопределенность или расстояние между апостериорными распределениями.

Подход, развиваемый в настоящей диссертации, также относится к классу методов стабилизационного типа, однако в качестве основного объекта анализа рассматривается не статистика критерия и не апостериорное распределение, а локальная геометрия функции потерь. Иными словами, достаточный размер выборки определяется через стабилизацию ландшафта функции потерь в окрестности минимума.

Это позволяет положить в качестве меры $\Psi(m)$ из (4.1) один из критериев стабилизации ландшафта, введенных в главе 3. Соответственно, достаточный

размер выборки будет определяться условием вида

$$m^* = \inf\{m \in \mathbb{N} : \Delta(m) \leq \varepsilon\},$$

где $\Delta(m)$ обозначает выбранный критерий сходимости ландшафта функции потерь.

Принципиальное отличие данного подхода от классических методов состоит в том, что критерий достаточности выводится из оценок локальной кривизны и скорости стабилизации оптимизационной поверхности. Благодаря этому в последующих разделах удастся получить архитектурно-зависимые оценки достаточного размера выборки, непосредственно выраженные через верхние границы на спектральную норму гаусс—ньютоновской компоненты матрицы Гессе.

4.3. Связь между архитектурно-зависимой кривизной и стабилизацией ландшафта

Эмпирическая функция потерь имеет вид

$$\mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \ell(f_{\mathbf{w}}(\mathbf{x}_i), \mathbf{y}_i),$$

а матрица Гессе на одном объекте допускает разложение Гаусса—Ньютона

$$\mathbf{H}_i(\mathbf{w}) = \mathbf{G}_i(\mathbf{w}) + \mathbf{R}_i(\mathbf{w}),$$

где $\mathbf{G}_i(\mathbf{w})$ есть гаусс—ньютоновская компонента, а $\mathbf{R}_i(\mathbf{w})$ — остаточный член.

Для фиксированной архитектуры $\mathcal{A}$, фиксированного режима ограничений на нормы входов, параметров и промежуточных представлений, а также фиксированной локальной окрестности точки минимума $\mathcal{U}_R(\mathbf{w}^*)$ введем величину

$$M_{\mathbf{G}}(\mathcal{A}) = \sup_{\mathbf{w} \in \mathcal{U}_R(\mathbf{w}^*)} \sup_i \|\mathbf{G}_i(\mathbf{w})\|_2, \quad (4.2)$$

которую будем называть *локальной архитектурно-зависимой константой кривизны*.

Она зависит не только от формальной структуры архитектуры, но и от режима масштабирования, ограничений на нормы весов и активаций, а также

от выбранной окрестности минимума. Тем не менее именно эта величина аккумулирует в себе архитектурную часть оценок главы 2.

Для учета вклада остаточного члена введем аналогично величину

$$\delta_R = \sup_{\mathbf{w} \in \mathcal{U}_R(\mathbf{w}^*)} \sup_i \|\mathbf{R}_i(\mathbf{w})\|_2. \quad (4.3)$$

Тогда для любой точки $\mathbf{w} \in \mathcal{U}_R(\mathbf{w}^*)$ и любого объекта выборки справедливо

$$\|\mathbf{H}_i(\mathbf{w})\|_2 \leq \|\mathbf{G}_i(\mathbf{w})\|_2 + \|\mathbf{R}_i(\mathbf{w})\|_2 \leq M_{\mathbf{G}}(\mathcal{A}) + \delta_R. \quad (4.4)$$

Следовательно, верхняя граница на полную матрицу Гессе в локальной окрестности минимума может быть выражена через гаусс—ньютоновскую компоненту и остаточный член.

Предложение 4.3.1. Пусть для рассматриваемой архитектуры $\mathcal{A}$ введена локальная архитектурно-зависимая константа кривизны $M_{\mathbf{G}}(\mathcal{A})$ по формуле (4.2), а остаточный член δ_R задан формулой (4.3). Тогда во всех оценках главы 3, содержащих константу $M_{\mathbf{H}}$ как верхнюю границу спектральной нормы пообъектной матрицы Гессе, можно положить

$$M_{\mathbf{H}} = M_{\mathbf{G}}(\mathcal{A}) + \delta_R.$$

Доказательство. Утверждение непосредственно следует из неравенства (4.4). $\square$

Теперь выпишем архитектурно-зависимые выражения для $M_{\mathbf{G}}(\mathcal{A})$, следующие из результатов главы 2.

Для L -слойной полносвязной сети без смещений при условиях теоремы 2.4.1 имеем

$$M_{\mathbf{G}}^{\text{FC}} = LM_{\mathbf{x}}^2 M_{\mathbf{A}} (M_{\mathbf{W}} M_{\sigma})^{2L-2}. \quad (4.5)$$

Для L -слойной сверточной сети без смещений при условиях теоремы 2.5.3 получаем

$$M_{\mathbf{G}}^{\text{CNN}} = LM_{\mathbf{x}}^2 M_{\mathbf{A}} K_{\max} (M_{\mathcal{W}} M_{\sigma})^{2L-2}.$$

Таким образом, величина $M_{\mathbf{H}}$ в критериях стабилизации ландшафта может быть непосредственно выражена через архитектурно-зависимые характеристики модели.

4.4. Критерии достаточного размера выборки

Наиболее прямым следствием результатов главы 3 является возможность определить достаточный размер обучающей выборки через стабилизацию оптимизационной поверхности. В рамках настоящей главы под достаточным размером выборки понимается минимальный объем данных, начиная с которого дальнейшее увеличение выборки не приводит к изменению ландшафта функции потерь, превышающему заранее заданный уровень точности по выбранному критерию.

Определение. Пусть $\Delta(m)$ обозначает один из критериев сходимости ландшафта функции потерь, введенных в главе 3. Назовем размер выборки m^* ε -достаточным по критерию Δ , если для всех $m \geq m^*$ выполнено

$$\Delta(m) \leq \varepsilon,$$

где $\varepsilon > 0$ есть заданный уровень точности стабилизации.

Далее будут рассмотрены три соответствующих понятия достаточности: одноточечное, среднеквадратичное в полном пространстве параметров и среднеквадратичное в подпространстве наибольшей кривизны.

Одноточечный критерий достаточного размера выборки. Напомним, что для абсолютного одноточечного критерия в главе 3 была получена оценка порядка $\mathcal{O}(m^{-1})$. Подстановка в нее архитектурно-зависимой верхней границы на матрицу Гессе приводит к следующему утверждению.

Теорема 4.4.1. Пусть выполнены условия теоремы 3.4.1, и пусть в рассматриваемой окрестности точки минимума выполнено

$$\|\mathbf{H}_i(\mathbf{w})\|_2 \leq M_{\mathbf{G}}(\mathcal{A}) + \delta_R.$$

Тогда для абсолютного одноточечного критерия сходимости размер выборки

$$m_1^*(\varepsilon, \mathcal{A}) = \frac{2M_\ell + M_{\mathbf{g}}R + (M_{\mathbf{G}}(\mathcal{A}) + \delta_R) R^2}{\varepsilon} \quad (4.6)$$

является ε -достаточным.

Доказательство. По теореме 3.4.1

$$\Delta_1(m) \leq \frac{2M_\ell + M_g R + M_H R^2}{m}.$$

По утверждению 4.3.1 можно положить

$$M_H = M_G(\mathcal{A}) + \delta_R.$$

Тогда

$$\Delta_1(m) \leq \frac{2M_\ell + M_g R + (M_G(\mathcal{A}) + \delta_R) R^2}{m}.$$

Условие $\Delta_1(m) \leq \varepsilon$ выполняется при

$$m \geq \frac{2M_\ell + M_g R + (M_G(\mathcal{A}) + \delta_R) R^2}{\varepsilon},$$

что и дает формулу (4.6). □

Данная оценка является наиболее локальной и наиболее консервативной: она контролирует изменение ландшафта в одной фиксированной точке окрестности минимума.

Среднеквадратичный критерий достаточного размера выборки. Перейдем к среднеквадратичному критерию в полном пространстве параметров. Согласно главе 3, скорость его убывания равна $\mathcal{O}(m^{-2})$.

Теорема 4.4.2. Пусть выполнены условия теоремы 3.5.1, и пусть

$$\|\mathbf{H}_i(\mathbf{w})\|_2 \leq M_G(\mathcal{A}) + \delta_R.$$

Тогда для среднеквадратичного критерия с гауссовской функцией предпочтения

$$q(\mathbf{w}) = \mathcal{N}(\mathbf{w}^*, \sigma^2 \mathbf{I}_N)$$

размер выборки

$$m_2^*(\varepsilon, \mathcal{A}) = \sqrt{\frac{12M_\ell^2 + 3\sigma^2 M_g^2 + 3\sigma^4(N^2 + 2N)(M_G(\mathcal{A}) + \delta_R)^2}{\varepsilon}} \quad (4.7)$$

является ε -достаточным.

Доказательство. По теореме 3.5.1

$$\Delta_2(m) \leq \frac{12M_\ell^2 + 3\sigma^2 M_g^2 + 3\sigma^4(N^2 + 2N)M_H^2}{m^2}.$$

Подставляя

$$M_{\mathbf{H}} = M_{\mathbf{G}}(\mathcal{A}) + \delta_R,$$

получаем

$$\Delta_2(m) \leq \frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(N^2 + 2N)(M_{\mathbf{G}}(\mathcal{A}) + \delta_R)^2}{m^2}.$$

Неравенство $\Delta_2(m) \leq \varepsilon$ эквивалентно

$$m^2 \geq \frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(N^2 + 2N)(M_{\mathbf{G}}(\mathcal{A}) + \delta_R)^2}{\varepsilon},$$

что и дает формулу (4.7). $\square$

По сравнению с одноточечным критерием эта оценка имеет более высокий порядок сходимости, однако содержит явную зависимость от полной размерности пространства параметров N .

Подпространственный критерий достаточного размера выборки.

Во многих задачах наиболее существенная часть динамики ландшафта сосредоточена в подпространстве, натянутом на главные собственные векторы матрицы Гессе. В этом случае естественно использовать среднеквадратичный критерий не во всем пространстве параметров, а лишь в его информативной низкоразмерной части.

Теорема 4.4.3. Пусть выполнены условия теоремы 3.6.3, и пусть

$$\|\mathbf{H}_i(\mathbf{w})\|_2 \leq M_{\mathbf{G}}(\mathcal{A}) + \delta_R.$$

Тогда для среднеквадратичного критерия сходимости в подпространстве наибольшей кривизны размерности D размер выборки

$$m_3^*(\varepsilon, \mathcal{A}, D) = \sqrt{\frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(D^2 + 2D)(M_{\mathbf{G}}(\mathcal{A}) + \delta_R)^2}{\varepsilon}} \quad (4.8)$$

является ε -достаточным.

Доказательство. По теореме 3.6.3

$$\Delta_2^{(D)}(m) \leq \frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(D^2 + 2D)M_{\mathbf{H}}^2}{m^2}.$$

Подставляя

$$M_{\mathbf{H}} = M_{\mathbf{G}}(\mathcal{A}) + \delta_R,$$

получаем формулу (4.8). $\square$

Главное отличие оценки (4.8) от оценки (4.7) состоит в том, что размерностный множитель зависит не от полной размерности пространства параметров N , а лишь от размерности выбранного подпространства D . При $D \ll N$ это дает существенно более экономичный критерий достаточности.

Подстановка конкретных оценок $M_{\mathbf{G}}(\mathcal{A})$ в формулы (4.6), (4.7), (4.8) дает архитектурно-зависимые критерии достаточного размера выборки. Именно эти утверждения представляют собой наиболее прямой итог объединения результатов предыдущих глав.

Полносвязные нейронные сети. Для полносвязной архитектуры из (4.5) следует

$$M_{\mathbf{G}}^{\text{FC}} = LM_{\mathbf{x}}^2 M_{\mathbf{A}} (M_{\mathbf{W}} M_{\sigma})^{2L-2}.$$

Следовательно, из теорем 4.4.1–4.4.3 получаем следующие оценки.

Следствие 4.4.4. *Для L -слойной полносвязной сети при выполнении условий глав 2 и 3 достаточный размер выборки по одноточечному критерию удовлетворяет*

$$m_{1,\text{FC}}^* = \frac{2M_{\ell} + M_{\mathbf{g}}R + (LM_{\mathbf{x}}^2 M_{\mathbf{A}} (M_{\mathbf{W}} M_{\sigma})^{2L-2} + \delta_R) R^2}{\varepsilon},$$

по среднеквадратичному критерию

$$m_{2,\text{FC}}^* = \left[\frac{12M_{\ell}^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4 (N^2 + 2N) (LM_{\mathbf{x}}^2 M_{\mathbf{A}} (M_{\mathbf{W}} M_{\sigma})^{2L-2} + \delta_R)^2}{\varepsilon} \right]^{1/2},$$

а по подпространственному критерию

$$m_{3,\text{FC}}^* = \left[\frac{12M_{\ell}^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4 (D^2 + 2D) (LM_{\mathbf{x}}^2 M_{\mathbf{A}} (M_{\mathbf{W}} M_{\sigma})^{2L-2} + \delta_R)^2}{\varepsilon} \right]^{1/2}.$$

Эти формулы показывают, что при фиксированных прочих параметрах достаточный объем данных для полносвязной сети растет с глубиной и чувствителен к произведению $M_{\mathbf{W}} M_{\sigma}$, отражающему накопление локальной кривизны при последовательном перемножении плотных операторов.

Сверточные нейронные сети. Для сверточной архитектуры имеем

$$M_{\mathbf{G}}^{\text{CNN}} = LM_{\mathbf{x}}^2 M_{\mathbf{A}} K_{\max} (M_{\mathcal{W}} M_{\sigma})^{2L-2}.$$

Следствие 4.4.5. Для L -слойной сверточной сети при выполнении условий глав 2 и 3 достаточный размер выборки по однотоочечному критерию удовлетворяет

$$m_{1,\text{CNN}}^* = \frac{2M_\ell + M_{\mathbf{g}}R + (LM_{\mathbf{x}}^2 M_{\mathbf{A}} K_{\max}(M_{\mathcal{W}} M_{\sigma})^{2L-2} + \delta_R) R^2}{\varepsilon},$$

по среднеквадратичному критерию

$$m_{2,\text{CNN}}^* = \left[\frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(N^2 + 2N) (LM_{\mathbf{x}}^2 M_{\mathbf{A}} K_{\max}(M_{\mathcal{W}} M_{\sigma})^{2L-2} + \delta_R)^2}{\varepsilon} \right]^{1/2},$$

а по подпространственному критерию

$$m_{3,\text{CNN}}^* = \left[\frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(D^2 + 2D) (LM_{\mathbf{x}}^2 M_{\mathbf{A}} K_{\max}(M_{\mathcal{W}} M_{\sigma})^{2L-2} + \delta_R)^2}{\varepsilon} \right]^{1/2}.$$

В отличие от полносвязных сетей, здесь дополнительный множитель определяется локальностью рецептивного поля через $K_{\max}$, а не полной размерностью входа. Это означает, что при сопоставимой глубине сверточные сети используют данные более эффективно в терминах полученных верхних оценок.

Качественное сравнение архитектур. Полученные выше формулы позволяют сформулировать несколько качественных выводов.

Во-первых, локальность свертки приводит к замене полной размерности связей на размер рецептивного поля. Поэтому при прочих равных сверточные сети должны требовать меньшего объема данных для стабилизации ландшафта, чем полносвязные сети сопоставимой глубины.

Во-вторых, в полносвязных сетях глубина входит в архитектурную константу через длинные произведения операторных норм, что при $M_{\mathbf{W}} M_{\sigma} > 1$ ведет к быстрому росту достаточного объема данных.

Таким образом, полученные критерии достаточного размера выборки позволяют интерпретировать архитектуру модели не только как класс функций, но и как фактор, определяющий скорость стабилизации локальной геометрии оптимизационной задачи.

4.5. Интерпретация в терминах законов масштабирования

До настоящего момента в главе рассматривались утверждения, непосредственно следующие из результатов глав 2 и 3. Далее предлагается более общая интерпретация полученных результатов в терминах законов масштабирования параметрических моделей. Эта интерпретация опирается на дополнительные структурные предположения о связи между локальной геометрией оптимизационной поверхности и вкладом конечности обучающей выборки в итоговое значение функции потерь. Поэтому последующие утверждения следует рассматривать не как прямые следствия ранее доказанных теорем, а как теоретически мотивированную схему, согласованную с полученными результатами.

Эмпирические законы масштабирования современных моделей машинного обучения показывают, что качество обучения систематически зависит как от числа параметров модели, так и от объема обучающих данных. В наиболее известных работах устанавливаются степенные зависимости между размером модели, размером выборки и значением функции потерь. В рамках настоящей диссертации предлагается интерпретация аналогичного типа, в которой вклад объема данных выражается через локальные свойства оптимизационной поверхности.

Декомпозиция ошибки обучения. Обозначим через $\mathcal{W}_N \subset \mathbb{R}^N$ множество параметров модели с фиксированным числом параметров N . Популяционная функция потерь имеет вид

$$\mathcal{L}(\mathbf{w}) = \mathbb{E}_{(\mathbf{x}, \mathbf{y})}[\ell(f_{\mathbf{w}}(\mathbf{x}), \mathbf{y})].$$

Пусть $\mathbf{w}_{\infty}^*$ есть глобальный минимизатор популяционного риска в предельном классе допустимых моделей. Введем *ошибку выразимости*

$$\Phi(N) = \inf_{\mathbf{w} \in \mathcal{W}_N} \mathcal{L}(\mathbf{w}) - \mathcal{L}(\mathbf{w}_{\infty}^*).$$

Эта величина характеризует ограниченность класса моделей конечной размерности и убывает при увеличении числа параметров.

Пусть $\mathbf{w}_m^*$ обозначает параметр, полученный обучением на выборке размера m . Тогда эмпирическая функция потерь в этой точке допускает естественную

декомпозицию

$$\mathcal{L}_m(\mathbf{w}_m^*) = \underbrace{\mathcal{L}(\mathbf{w}_\infty^*)}_E + \underbrace{(\mathcal{L}(\mathbf{w}_m^*) - \mathcal{L}(\mathbf{w}_\infty^*))}_{\text{ошибка модели}} + \underbrace{(\mathcal{L}_m(\mathbf{w}_m^*) - \mathcal{L}(\mathbf{w}_m^*))}_{\mathcal{E}(m)}. \quad (4.9)$$

Здесь E есть неустранимая ошибка задачи, второе слагаемое отражает ограниченность класса моделей, а третье слагаемое соответствует отклонению эмпирической функции потерь от популяционной в найденной точке.

Замечание. Среднее слагаемое в (4.9) зависит не только от числа параметров N , но и от алгоритма оптимизации, инициализации и конкретной выборки. В дальнейшем оно рассматривается как величина, мажорируемая ошибкой вариационности $\Phi(N)$ при достаточно эффективной оптимизации.

Структурное предположение о data term. Результаты главы 3 показывают, что при добавлении одного объекта к выборке размером k изменение ландшафта функции потерь в локальной окрестности минимума убывает как $\mathcal{O}(k^{-1})$ для одноточечного критерия и как $\mathcal{O}(k^{-2})$ для усредненных квадратов. Все эти оценки контролируются величиной $M_{\mathbf{G}}(\mathcal{A}) + \delta_R$.

Это наблюдение не дает прямой теоремы о скорости убывания ошибки оценивания $\mathcal{E}(m)$, однако мотивирует следующее структурное предположение: если ландшафт функции потерь стабилизируется по мере увеличения объема данных, то и вклад конечности выборки в итоговое значение функции потерь должен уменьшаться с тем же геометрическим масштабом.

Предположение 4.5.1 (Локальный статистический режим). Пусть обучение модели происходит в режиме, при котором:

1. точка $\mathbf{w}_m^*$ принадлежит области, где квадратичная аппроксимация функции потерь информативна;
2. остаточная компонента δ_R мала по сравнению с $M_{\mathbf{G}}(\mathcal{A})$;
3. локальный минимум $\mathbf{w}_m^*$ является достаточно устойчивым, так что влияние конечности выборки на значение функции потерь определяется локальной геометрией поверхности.

Тогда существуют показатель $\rho \in (0, 1]$ и константа $C > 0$ такие, что

$$|\mathcal{E}(m)| \leq \frac{C(M_{\mathbf{G}}(\mathcal{A}) + \delta_R)}{m^\rho}.$$

Замечание. Предположение 4.5.1 не является прямым следствием предыдущих глав и должно рассматриваться как структурное. Его смысл состоит в том, что

вклад конечности обучающей выборки в итоговое качество наследует тот же геометрический масштаб, который определяет стабилизацию локального ландшафта функции потерь.

Схема локального закона масштабирования. В рамках предположения 4.5.1 естественно получается следующая оценка.

Предложение 4.5.2. Пусть выполнено предположение 4.5.1. Тогда для значения эмпирической функции потерь в точке решения $\mathbf{w}_m^*$ справедлива оценка

$$\mathcal{L}_m(\mathbf{w}_m^*) \leq E + \Phi(N) + \frac{C(M_{\mathbf{G}}(\mathcal{A}) + \delta_R)}{m^\rho}. \quad (4.10)$$

Доказательство. Из (4.9) имеем

$$\mathcal{L}_m(\mathbf{w}_m^*) = E + (\mathcal{L}(\mathbf{w}_m^*) - \mathcal{L}(\mathbf{w}_\infty^*)) + \mathcal{E}(m).$$

По определению ошибки выразимости и при предположении о достаточно эффективной оптимизации получаем

$$\mathcal{L}(\mathbf{w}_m^*) - \mathcal{L}(\mathbf{w}_\infty^*) \leq \Phi(N).$$

Далее по предположению 4.5.1

$$|\mathcal{E}(m)| \leq \frac{C(M_{\mathbf{G}}(\mathcal{A}) + \delta_R)}{m^\rho}.$$

Подстановка этих двух оценок завершает доказательство. $\square$

Формула (4.10) задает теоретически мотивированную схему закона масштабирования: итоговое значение функции потерь представляется как сумма трех вкладов — неустранимой ошибки, ошибки выразимости и data term, определяемого локальными свойствами оптимизационной поверхности.

В режиме хорошей подгонки, когда $\delta_R \ll M_{\mathbf{G}}(\mathcal{A})$, формула (4.10) упрощается до

$$\mathcal{L}_m(\mathbf{w}_m^*) \lesssim E + \Phi(N) + \frac{CM_{\mathbf{G}}(\mathcal{A})}{m^\rho}. \quad (4.11)$$

Степенной режим ошибки выразимости. Для перехода от общей схемы (4.11) к явным зависимостям от числа параметров введем стандартное степенное предположение.

Предположение 4.5.3 (Степенной закон ошибки выразимости). *Существуют константы $A > 0$ и $\alpha > 0$ такие, что*

$$\Phi(N) \sim \frac{A}{N^\alpha}.$$

Тогда из (4.11) получаем

$$\mathcal{L}_m(\mathbf{w}_m^*) \lesssim E + \frac{A}{N^\alpha} + \frac{CM_{\mathbf{G}}(\mathcal{A})}{m^\rho}. \quad (4.12)$$

Эта формула уже имеет вид закона масштабирования: одно слагаемое убывает с ростом размера модели, другое — с ростом объема данных. Однако в отличие от purely empirical аппроксимаций, здесь коэффициент при data term зависит от архитектуры через локальную кривизну оптимизационной поверхности.

Режимы масштабирования архитектуры. Существенным обстоятельством является то, что величина $M_{\mathbf{G}}(\mathcal{A})$ зависит не только от числа параметров N , но и от режима роста архитектуры. Поэтому необходимо различать по крайней мере два типичных сценария.

Масштабирование по ширине. Пусть глубина сети фиксирована, а число параметров растет за счет увеличения ширины слоев. В этом случае при нормировке весов, сохраняющей ограниченность операторных норм, величина $M_{\mathbf{G}}(\mathcal{A})$ может оставаться ограниченной или расти медленно. Тогда основной эффект увеличения N определяется убыванием ошибки выразимости.

Масштабирование по глубине. Если число параметров растет за счет увеличения глубины, то в полносвязных и сверточных архитектурах $M_{\mathbf{G}}(\mathcal{A})$ содержит длинные произведения операторных норм. Это может приводить к значительно более быстрому росту data term, чем в режиме width scaling.

Следовательно, один и тот же формальный параметр N может соответствовать различным геометрическим режимам, а значит и различным законам зависимости качества от данных.

Вычислительно-оптимальное соотношение модели и данных. Рассмотрим стандартную постановку вычислительно-ограниченного обучения, в которой общий вычислительный бюджет пропорционален произведению числа параметров модели на размер обучающей выборки:

$$\mathcal{C} \propto Nm.$$

Подставляя

$$m = \frac{\mathcal{C}}{N}$$

в (4.12), получаем задачу минимизации функции

$$F(N) = E + \frac{A}{N^\alpha} + \frac{CM_{\mathbf{G}}(N)}{(\mathcal{C}/N)^\rho}. \quad (4.13)$$

Для дальнейшего анализа предположим, что в фиксированном режиме масштабирования существует показатель $\gamma \geq 0$, такой что

$$M_{\mathbf{G}}(N) \sim BN^\gamma. \quad (4.14)$$

Предложение 4.5.4. Пусть выполнены предположения 4.5.1, 4.5.3 и (4.14). Тогда оптимальный размер модели при фиксированном вычислительном бюджете $\mathcal{C}$ удовлетворяет асимптотике

$$N^* \propto \mathcal{C}^{\frac{\rho}{\alpha+\gamma+\rho}},$$

а оптимальный размер выборки

$$m^* = \frac{\mathcal{C}}{N^*} \propto \mathcal{C}^{\frac{\alpha+\gamma}{\alpha+\gamma+\rho}}.$$

Доказательство. При (4.14) функция (4.13) принимает вид

$$\tilde{F}(N) = \frac{A}{N^\alpha} + \frac{CB}{\mathcal{C}^\rho} N^{\gamma+\rho}.$$

Ее производная равна

$$\tilde{F}'(N) = -\alpha AN^{-\alpha-1} + \frac{CB(\gamma+\rho)}{\mathcal{C}^\rho} N^{\gamma+\rho-1}.$$

Приравнивая ее к нулю, получаем

$$\alpha AN^{-\alpha-1} = \frac{CB(\gamma+\rho)}{\mathcal{C}^\rho} N^{\gamma+\rho-1},$$

откуда

$$N^{\alpha+\gamma+\rho} \propto \mathcal{C}^\rho.$$

Следовательно,

$$N^* \propto \mathcal{C}^{\frac{\rho}{\alpha+\gamma+\rho}},$$

а тогда

$$m^* = \frac{\mathcal{C}}{N^*} \propto \mathcal{C}^{\frac{\alpha+\gamma}{\alpha+\gamma+\rho}}.$$

□

Предложение 4.5.4 показывает, что оптимальное соотношение между моделью и данными определяется не только скоростью убывания ошибки выразимости, но и тем, насколько быстро растет локальная кривизна архитектуры в выбранном режиме масштабирования.

4.6. Вычислительные эксперименты

В данном разделе проводится эмпирическая проверка двух групп утверждений главы. В первом эксперименте исследуется связь между стабилизацией ландшафта функции потерь и достаточным размером выборки. Во втором эксперименте рассматривается более общая структурная интерпретация в терминах закона масштабирования для обобщающего разрыва. Программный код реализован на фреймворке **PyTorch** и доступен в репозитории диссертации по адресу

<https://github.com/kisnikser/PhD-Thesis/code/scaling>.

Эксперименты проводятся на задаче многоклассовой классификации датасета MNIST. Во всех запусках используется оптимизатор Adam с learning rate 10^{-3} , batch size 128 и число эпох обучения 100. Все приводимые ниже величины усредняются по трем независимым запускам с различными случайными seed.

Архитектуры. В эксперименты включены два класса моделей: полносвязные и сверточные сети с различной глубиной и шириной. Для полносвязных сетей используется обозначение MLP- L - h , где L — число линейных слоев, h — ширина скрытых слоев. Для сверточных сетей используется обозначение CNN- L - c , где L — число сверточных слоев, c — число каналов. Во всех CNN используется ядро 3×3 , шаг 1, ReLU-активация и глобальный average pooling перед классификатором.

Такой набор позволяет варьировать глубину, ширину и тип архитектуры, что необходимо для проверки архитектурно-зависимых оценок.

Эксперимент 1: стабилизация ландшафта и достаточный размер выборки. Для каждой архитектуры и каждого размера обучающей выборки

$$m \in \{100, \dots, 30000\}$$

Таблица 3 — Архитектуры для экспериментов

Название	Глубина L	Ширина/Каналы	Тип
MLP-2-64	2	64	полносвязная
MLP-2-128	2	128	полносвязная
MLP-4-64	4	64	полносвязная
MLP-4-128	4	128	полносвязная
MLP-8-64	8	64	полносвязная
CNN-2-32	2	32	сверточная
CNN-2-64	2	64	сверточная
CNN-4-32	4	32	сверточная
CNN-4-64	4	64	сверточная
CNN-8-32	8	32	сверточная

модель обучается с нуля на подвыборке соответствующего объема. После обучения вычисляется среднеквадратичный критерий стабилизации ландшафта $\Delta_2(m)$, а для фиксированных порогов

$$\varepsilon \in \{10^{-1}, 5 \cdot 10^{-2}, 10^{-2}\}$$

определяется достаточный размер выборки

$$m^*(\varepsilon, \mathcal{A}) = \min\{m : \Delta_2(m) \leq \varepsilon\}.$$

На рисунке 4.1 представлена зависимость критерия $\Delta_2(m)$ от размера выборки для всех рассматриваемых архитектур в логарифмических координатах. Штриховой линией показана эталонная скорость убывания $\propto m^{-2}$, соответствующая оценкам главы 3.

Результаты показывают, что для большинства рассматриваемых архитектур критерий $\Delta_2(m)$ убывает с ростом m по закону, близкому к эталонной зависимости $\propto m^{-2}$. В частности, для полносвязных моделей оценки логарифмического наклона находятся вблизи значения 2, а для сверточных архитектур наблюдается та же качественная тенденция, хотя разброс между отдельными конфигурациями больше. При фиксированном размере выборки более глубокие модели, как правило, демонстрируют большие значения $\Delta_2(m)$, что согласуется с архитектурно-зависимыми оценками, содержащими множитель глубины L .

Влияние глубины на достаточный размер выборки. Из теоретических результатов главы следует, что достаточный размер выборки растет с




Рисунок 4.1 — Сходимость критерия $\Delta_2(m)$ для различных архитектур. Штриховая линия показывает теоретическую скорость $\propto m^{-2}$

увеличением глубины архитектуры. Для проверки этого предсказания анализируется зависимость $m^*(\epsilon, \mathcal{A})$ от числа слоев L отдельно для полносвязных и сверточных архитектур.

Таблица 4 — Достаточный размер выборки $m^*(\epsilon)$ для критерия Δ_2

Архитектура	Глубина L	$m^*(0.1)$	$m^*(0.05)$	$m^*(0.01)$
MLP-2-64	2	200	300	750
MLP-2-128	2	200	500	750
MLP-4-64	4	2000	3000	7500
MLP-4-128	4	5000	7500	15000
MLP-8-64	8	> 30000	> 30000	> 30000
CNN-2-32	2	100	100	300
CNN-2-64	2	200	200	500
CNN-4-32	4	5000	5000	10000
CNN-4-64	4	7500	10000	20000
CNN-8-32	8	> 30000	> 30000	> 30000

На рисунке 4.2 представлена зависимость $m^*(\epsilon)$ от глубины архитектуры при $\epsilon = 0.05$. В текущем наборе точек внутри каждого семейства архитектур

наблюдается строгая монотонная зависимость: с ростом глубины L достаточный размер выборки возрастает как для MLP, так и для CNN.




Рисунок 4.2 — Влияние глубины на достаточный размер выборки. Слева: зависимость m^* от L для MLP и CNN. Справа: сравнение MLP и CNN при одинаковой глубине

Сравнение полносвязных и сверточных архитектур. Согласно теоретическим результатам, локальность рецептивного поля в сверточных сетях должна уменьшать эффективную архитектурную константу кривизны по сравнению с полносвязными моделями сопоставимой глубины. Однако на конечном наборе конкретных архитектур это преимущество может проявляться неравномерно.

Правая часть рисунка 4.2 показывает, что преимущество CNN наиболее отчетливо проявляется в мелких архитектурах. Так, при $\varepsilon = 0.05$ для MLP глубины $L = 2$ получаем $m^* = 300$ и 500, тогда как для сопоставимых по глубине CNN достаточно $m^* = 100$ и 200. Для моделей глубины $L = 4$ однозначного преимущества сверточных архитектур уже не наблюдается: в текущем наборе конфигураций значения m^* для CNN оказываются не меньше, а в ряде случаев больше, чем для MLP той же глубины.

На рисунке 4.3 представлена зависимость достаточного размера выборки от числа параметров модели. Видно, что само по себе число параметров не определяет m^* однозначно: при близких значениях N существенную роль продолжает играть архитектурная организация модели и прежде всего ее глубина.

Таким образом, первый вычислительный эксперимент подтверждает следующие теоретические предсказания главы:




Рисунок 4.3 — Достаточный размер выборки $m^*(\varepsilon)$ в зависимости от числа параметров для MLP и CNN

1. критерий $\Delta_2(m)$ убывает с ростом m по закону, согласующемуся с оценкой порядка $\mathcal{O}(m^{-2})$;
2. внутри каждого семейства архитектур достаточный размер выборки монотонно возрастает с глубиной;
3. преимущество сверточных архитектур по m^* отчетливо проявляется для мелких моделей, но не является универсальным для всех рассмотренных конфигураций.

Эксперимент 2: структурная интерпретация в терминах закона масштабирования. Во втором эксперименте для того же набора архитектур и тех же размеров выборки измеряются обучение и тестовая ошибка, а также обобщающий разрыв

$$\hat{\mathcal{E}}(m) = \mathcal{L}_{\text{test}} - \mathcal{L}_{\text{train}}.$$

Дополнительно для каждой архитектуры вычисляется curvature proxy $\widehat{M}_{\mathbf{G}}$. Далее рассматриваются две аппроксимации вида

$$\hat{\mathcal{E}}(m) \approx \frac{C_A}{m^{\mathbf{p}}},$$

где либо показатель $\mathbf{p}$ подбирается индивидуально для каждой архитектуры, либо фиксируется общим для всех моделей. В соответствии с используемой

реализацией аппроксимация строится по тем значениям m , для которых усредненный по seed обобщающий разрыв остается положительным.

На рисунке 4.4 показано убывание положительной части обобщающего разрыва с ростом объема обучающей выборки. Во всех рассматриваемых архитектурах на малых и средних размерах выборки наблюдается выраженное уменьшение гар, однако скорость этого уменьшения зависит от семейства моделей и глубины.




Рисунок 4.4 — Обобщающий разрыв $\hat{\mathcal{E}}(m)$ в зависимости от размера выборки.

На графике показаны только положительные средние значения гар

Результаты аппроксимации представлены на рисунке 4.5. Для индивидуальных степенных законов получаются достаточно высокие значения R^2 для большинства архитектур, что указывает на наличие устойчивого степенного режима в положительной части гар. При этом показатели степени заметно различаются между моделями: для неглубоких и средних MLP они лежат примерно в диапазоне 0.25–0.32, для CNN — в диапазоне 0.67–0.79, а для наиболее глубоких моделей принимают промежуточные значения. Общий показатель, оптимальный в смысле усредненного качества аппроксимации, равен $\rho_{\text{shared}} \approx 0.349$ и дает лишь грубое описание всех архитектур одновременно.

Таким образом, второй эксперимент согласуется со структурной схемой раздела 4.5: для фиксированных архитектур положительная часть обобщающе-




Рисунок 4.5 — Аппроксимация обобщающего разрыва степенным законом. Слева: индивидуальные показатели степени для каждой архитектуры. Справа: аппроксимация с общим показателем ρ_{shared}

го разрыва допускает степенную аппроксимацию по m с архитектурно-зависимыми коэффициентом и показателем степени.

4.7. Обсуждение

В данной главе строгие результаты глав 2 и 3 были использованы для построения архитектурно-зависимых критериев достаточного размера выборки. Эти критерии представляют собой прямые следствия полученных ранее оценок локальной кривизны и оценок скорости стабилизации ландшафта функции потерь.

Наиболее строгий результат главы состоит в том, что достаточный размер выборки может быть выражен через архитектурно-зависимую верхнюю границу на спектральную норму гаусс—ньютоновской компоненты матрицы Гессе. Для полносвязных и сверточных сетей это приводит к явным формулам, связывающим объем данных с глубиной, нормами весовых операторов, свойствами функций активации и, в сверточном случае, размером рецептивного поля.

Наряду с этим в главе предложена более общая интерпретация полученных результатов в терминах законов масштабирования параметрических моделей. Эта часть носит структурный характер: она опирается на дополнительные предположения о связи между локальной геометрией оптимизационной

поверхности и вкладом конечности обучающей выборки в итоговое значение функции потерь. Поэтому ее следует рассматривать не как строго доказанную в полной общности теорию, а как теоретически мотивированную схему, согласованную с результатами предыдущих глав.

Тем самым глава выполняет двойную роль. С одной стороны, она завершает строгую линию диссертации, связывая оценки локальной кривизны с критериями достаточного размера выборки. С другой стороны, она показывает, как эти результаты могут быть интерпретированы в более широкой задаче описания законов масштабирования параметрических моделей машинного обучения.

Глава 5. Критерии достаточного размера выборки для вероятностных линейных моделей

В данной главе рассматриваются методы определения достаточного размера обучающей выборки для линейных моделей. Сначала вводится вероятностная постановка линейной регрессии и описывается зависимость апостериорного распределения параметров и оценки максимального правдоподобия от размера выборки. Далее формулируются четыре критерия достаточности: D-достаточность (дисперсия правдоподобия), M-достаточность (изменение математического ожидания правдоподобия), KL-достаточность (дивергенция Кульбака—Лейблера между апостериорами) и S-достаточность (метрика близости s-score). Для каждого критерия приводятся теоремы о корректности и условия сходимости в вероятностной модели линейной регрессии. Вычислительный эксперимент демонстрирует применимость предложенных методов для предварительной оценки необходимого числа обучающих данных. В заключение обсуждается обобщение на логистическую регрессию и обобщенные линейные модели.

5.1. Введение

Особенный интерес представляет вопрос о законах масштабирования параметрических моделей: по какому правилу стоит совместно выбирать архитектуру модели и число данных для ее обучения. Существующие работы покрывают лишь небольшую часть всего параметрического семейства — в них рассматриваются линейные и обобщенно-линейные модели, в которых отклик задается распределением из экспоненциального семейства

$$p(y|\mathbf{x}, \mathbf{w}, \varphi) = \exp\left(\frac{y\theta - b(\theta)}{a(\varphi)} + c(y, \varphi)\right),$$

а математическое ожидание $\mu = \mathbb{E}[y|\mathbf{x}]$ связано с линейным предиктором $\mathbf{w}^\top \mathbf{x}$ через функцию связи $g(\mu) = \mathbf{w}^\top \mathbf{x}$. Линейная, логистическая и пуассоновская регрессии являются частными случаями этой конструкции [74]. Для них формулируются преимущественно статистические критерии [18—22], направленные на

определение достаточного размера выборки в предположении единственности решения оптимизационной задачи (1.2).

Классические статистические методы оценки размера выборки опираются на задание нулевой и альтернативной гипотез, допустимой вероятности ошибки первого рода и требуемой мощности теста. К ним относятся метод множителей Лагранжа [18], отношение правдоподобия [19; 20], критерий Вальда [21] и др. Эти методы дают теоретически обоснованные оценки, но требуют явных предположений о распределении данных и параметрах модели, а также информации о величине эффекта при альтернативе. На практике такие предположения часто недоступны или труднопроверяемы.

В общей статистической постановке достаточный размер выборки m^* определяется как минимальное значение m , при котором статистика критерия T_m обеспечивает заданную мощность при уровне значимости α :

$$m^* : \quad \mathbb{P}(T_m > c_\alpha | H_1) \geq 1 - \beta,$$

где c_α — критическое значение, соответствующее нулевой гипотезе H_0 , а $(1 - \beta)$ — требуемая мощность теста. В зависимости от выбора статистики T_m получаются различные критерии. При справедливости альтернативной гипотезы такие статистики асимптотически имеют известное распределение, что и позволяет выразить достаточный размер выборки через параметры такого распределения [18–21].

Информационно-теоретические и байесовские подходы характеризуют связь между данными и моделью через дивергенции между распределениями, апостериорную неопределенность и функции полезности [23–26]. Байесовские методы используют апостериорное распределение параметров и критерии вроде средней апостериорной дисперсии, среднего покрытия или дивергенции Кульбака—Лейблера между апостериорными распределениями на разных подвыборках [23–26]. Так, в работе [75] для логистической регрессии предложено использовать KL-дивергенцию между апостериорными распределениями на «схожих» подвыборках (отличающихся одним объектом) для оценки достаточного размера выборки.

5.2. Предварительные сведения

Вероятностная модель линейной регрессии. Объектом называется пара $(\mathbf{x}, y)$, где $\mathbf{x} \in \mathbb{R}^n$ — вектор признакового описания, $y \in \mathbb{R}$ — целевая переменная. Выборка размера m задается множеством $\mathfrak{D}_m = \{(\mathbf{x}_i, y_i)\}_{i=1}^m$ из m независимых реализаций пар $(\mathbf{x}, y)$. Вводятся матрица объекты-признаки $\mathbf{X}_m = [\mathbf{x}_1, \dots, \mathbf{x}_m]^\top \in \mathbb{R}^{m \times n}$ и вектор значений целевой переменной $\mathbf{y}_m = [y_1, \dots, y_m]^\top \in \mathbb{R}^m$. Вероятностная модель линейной регрессии задается правдоподобием

$$p(y|\mathbf{x}, \mathbf{w}) = \mathcal{N}(y|\mathbf{w}^\top \mathbf{x}, \sigma^2 \mathbf{I}), \quad (5.1)$$

где $\mathbf{w} \in \mathbb{R}^n$ — вектор параметров, $\sigma^2 > 0$ — дисперсия шума. Для простой выборки функция правдоподобия имеет вид

$$L(\mathfrak{D}_m, \mathbf{w}) = p(\mathbf{y}_m|\mathbf{X}_m, \mathbf{w}) = (2\pi\sigma^2)^{-m/2} \exp\left(-\frac{1}{2\sigma^2} \|\mathbf{y}_m - \mathbf{X}_m \mathbf{w}\|_2^2\right), \quad (5.2)$$

а логарифмическая функция правдоподобия записывается в виде

$$l(\mathfrak{D}_m, \mathbf{w}) = \log L(\mathfrak{D}_m, \mathbf{w}) = -\frac{m}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \|\mathbf{y}_m - \mathbf{X}_m \mathbf{w}\|_2^2.$$

Оценкой максимума правдоподобия (ОМП) по подвыборке $\mathfrak{D}_k \subseteq \mathfrak{D}_m$ размера k называется

$$\hat{\mathbf{w}}_k = \arg \max_{\mathbf{w} \in \mathbb{R}^n} L(\mathfrak{D}_k, \mathbf{w}) = \arg \min_{\mathbf{w} \in \mathbb{R}^n} \|\mathbf{y}_k - \mathbf{X}_k \mathbf{w}\|_2^2,$$

которая задается формулой

$$\hat{\mathbf{w}}_k = (\mathbf{X}_k^\top \mathbf{X}_k)^{-1} \mathbf{X}_k^\top \mathbf{y}_k$$

и при условии полного столбцового ранга матрицы $\mathbf{X}_k$ является единственной.

Асимптотическое поведение ОМП. Для частотного подхода важна сходимость ОМП $\hat{\mathbf{w}}_k$. Из асимптотической теории известно, что при стандартных условиях регулярности (ограниченность информационной матрицы Фишера, непрерывность и т. д.) выполняется

$$\sqrt{k}(\hat{\mathbf{w}}_k - \mathbf{w}^*) \xrightarrow{d} \mathcal{N}(0, \mathcal{I}^{-1}(\mathbf{w}^*)),$$

где $\mathbf{w}^*$ — истинный вектор параметров, а $\mathcal{I}(\mathbf{w})$ — информационная матрица Фишера:

$$[\mathcal{I}(\mathbf{w})]_{ij} = -\mathbb{E} \left[\frac{\partial^2 \log p(y|\mathbf{x}, \mathbf{w})}{\partial w_i \partial w_j} \right].$$

Таким образом, ОМП состоятельна и асимптотически нормальна, что наводит нас на идею о стабилизации ее статистик, например, функции правдоподобия на всей выборке (5.2). В следующем разделе мы вводим критерии достаточности размера выборки на основе этой идеи.

Апостериорное распределение параметров. При заданном априорном распределении $p(\mathbf{w})$ апостериорное распределение параметров по формуле Байеса имеет вид

$$p(\mathbf{w}|\mathfrak{D}_k) = \frac{p(\mathfrak{D}_k|\mathbf{w})p(\mathbf{w})}{p(\mathfrak{D}_k)} \propto L(\mathfrak{D}_k, \mathbf{w})p(\mathbf{w}).$$

Для гауссовского априорного распределения $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{m}_0, \Sigma_0)$ и правдоподобия (5.1) апостериорное распределение сопряжено и также является гауссовским [76]:

$$p(\mathbf{w}|\mathfrak{D}_k) = \mathcal{N}(\mathbf{w}|\mathbf{m}_k, \Sigma_k),$$

где

$$\Sigma_k^{-1} = \Sigma_0^{-1} + \frac{1}{\sigma^2} \mathbf{X}_k^\top \mathbf{X}_k, \quad \mathbf{m}_k = \Sigma_k \left(\Sigma_0^{-1} \mathbf{m}_0 + \frac{1}{\sigma^2} \mathbf{X}_k^\top \mathbf{y}_k \right).$$

Математическое ожидание $\mathbf{m}_k$ и матрица ковариации Σ_k апостериорного распределения зависят от подвыборки $\mathfrak{D}_k$. При увеличении размера выборки k матрица $\mathbf{X}_k^\top \mathbf{X}_k$ накапливает информацию о признаках, дисперсия апостериора Σ_k уменьшается, а апостериорное среднее $\mathbf{m}_k$ приближается к истинным параметрам при выполнении стандартных условий идентифицируемости и регулярности модели, невырожденности предельной информационной матрицы и корректной спецификации вероятностной модели. В конечномерных параметрических моделях такие условия обеспечивают асимптотическую нормальность и концентрацию апостериорного распределения вокруг истинного значения параметра, например, результат Бернштейна—фон Мизеса [77; 78]. В следующем разделе мы предлагаем критерий достаточности размера выборки, вдохновленный этими предельными свойствами.

5.3. Критерии достаточности для линейных моделей

В данном разделе мы зафиксируем полную выборку $\mathfrak{D}_m$ и рассмотрим подвыборки $\mathfrak{D}_k \subseteq \mathfrak{D}_m$ размера $k \leq m$. Пусть $\hat{\mathbf{w}}_k$ — ОМП по $\mathfrak{D}_k$, а $p_k(\mathbf{w}) = p(\mathbf{w}|\mathfrak{D}_k)$ — апостериорное распределение параметров.

Определение. Размер выборки m^* называется *достаточным* согласно критерию T , если T выполняется для всех $k \geq m^*$.

Введенное выше определение является наиболее общим для всех рассматриваемых в настоящей работе критериев. Оно универсально и подходит также под уже известные критерии достаточного размера выборки, сформулированные в разделе 1.2. Ниже вводятся четыре критерия, различающиеся тем, какую характеристику стабильности модели они используют.

Стабилизация функции правдоподобия в точке ОМП. В этом разделе мы предлагаем критерии достаточности для вероятностной модели линейной регрессии, основанные на сходимости функции правдоподобия в точке максимума правдоподобия, оцененной по подвыборке. Основная идея методов заключается в том, что поскольку ОМП состоятельна и асимптотически нормальна, мы ожидаем такого же поведения и от функции правдоподобия всей обучающей выборки (или функции потерь на практике). Визуализация подходов представлена на рисунке 5.1.




Рисунок 5.1 — Визуализация критериев D-достаточности (уменьшение дисперсии функции правдоподобия) и M-достаточности (уменьшение изменения функции правдоподобия при добавлении новых объектов) размера выборки в вероятностной модели линейной регрессии

Сперва мы введем критерий на основе дисперсии функции правдоподобия. Его идея состоит в следующем: при достаточном размере выборки оценка параметров мало меняется от одной реализации подвыборки к другой, поэтому дисперсия значения правдоподобия (или его логарифма) в точке оценки по подвыборкам не должна превышать порога. Формально, это записывается в виде следующего определения.

Определение. Зафиксируем $\varepsilon > 0$. Размер выборки m^* называется *D-достаточным*, если для всех $k \geq m^*$

$$D(k) = \mathbb{D}_{\mathfrak{D}_k} L(\mathfrak{D}_m, \hat{\mathbf{w}}_k) \leq \varepsilon. \quad (5.3)$$

Вместо $L(\mathfrak{D}_m, \hat{\mathbf{w}}_k)$ можно рассматривать логарифм $l(\mathfrak{D}_m, \hat{\mathbf{w}}_k)$ — выбор той или иной формы влияет на масштаб порога ε и ни на что больше. Далее в экспериментах мы увидим, какие свойства имеет введенная нами функция $D(k)$, но сейчас перейдем к следующему определению, использующему математическое ожидание функции правдоподобия.

Идея М-критерия в том, что мы фиксируем изменение математического ожидания правдоподобия при добавлении одного объекта в подвыборку, и начиная с определенного размера выборки это изменение перестает быть существенным. На математическом языке мы можем это записать следующим образом.

Определение. Зафиксируем $\varepsilon > 0$. Размер выборки m^* называется *M-достаточным*, если для всех $k \geq m^*$

$$M(k+1) = |\mathbb{E}_{\mathfrak{D}_{k+1}} L(\mathfrak{D}_m, \hat{\mathbf{w}}_{k+1}) - \mathbb{E}_{\mathfrak{D}_k} L(\mathfrak{D}_m, \hat{\mathbf{w}}_k)| \leq \varepsilon. \quad (5.4)$$

Для критерия М-достаточности в настоящей работе формулируется теоретическое утверждение в следующем разделе. Кроме того, проводимый в настоящей работе вычислительный эксперимент исследует также и зависимость критерия от введенного гиперпараметра ε . Однако сперва мы введем еще два определения, которые основываются на анализе апостериорных распределений параметров модели.

Апостериорные распределения на схожих подвыборках. В то время как введенные в предыдущем разделе определения используют точечную оценку параметров — ОМП, в работе [75] для логистической регрессии было предложено использовать близость апостериорных распределений на «схожих»

подвыборках как меру достаточного размера выборки. Эта идея легла в основу критериев KL-достаточности и S-достаточности, которые мы формулируем далее. Нам потребуется формально определить, что такое схожие подвыборки. Рассмотрим две подвыборки $\mathfrak{D}^1 \subseteq \mathfrak{D}_m$ и $\mathfrak{D}^2 \subseteq \mathfrak{D}_m$. Пусть $\mathcal{I}_1 \subseteq \mathcal{I} = \{1, \dots, m\}$ и $\mathcal{I}_2 \subseteq \mathcal{I} = \{1, \dots, m\}$ — соответствующие им подмножества индексов.

Определение. Подвыборки $\mathfrak{D}^1$ и $\mathfrak{D}^2$ называются *схожими*, если $\mathcal{I}_2$ может быть получено из $\mathcal{I}_1$ удалением, заменой или добавлением одного элемента, т. е.

$$|\mathcal{I}_1 \Delta \mathcal{I}_2| = |(\mathcal{I}_1 \setminus \mathcal{I}_2) \cup (\mathcal{I}_2 \setminus \mathcal{I}_1)| = 1.$$

Для таких подвыборок интуитивно ясно следующее: если мы посчитаем апостериорные распределения параметров модели на них, то они должны быть тем ближе, чем на большем числе данных мы их оценили. Визуализация предлагаемых подходов представлена на рисунке 5.2.




Рисунок 5.2 — Визуализация критериев KL-достаточности и S-достаточности (близость апостериорных распределений параметров на схожих подвыборках) размера выборки в вероятностной модели линейной регрессии

Близость вероятностных распределений может измеряться различными способами. Наиболее распространены дивергенция Кульбака—Лейблера, симметризованная дивергенция Йенсена—Шеннона, расстояние Вассерштейна, а также интегральные меры перекрытия плотностей. Эти функции различаются чувствительностью к сдвигу математических ожиданий, изменению ковариационной структуры и хвостов распределений. В настоящей работе используются две наиболее удобные для аналитического и вычислительного исследования характеристики: KL-дивергенция и функция близости s-score [79—81].

Определение. Зафиксируем $\varepsilon > 0$. Размер выборки m^* называется *KL-достаточным*, если для всех $k \geq m^*$ при схожих подвыборках $\mathfrak{D}_k$ и $\mathfrak{D}_{k+1}$ выполняется

$$\text{KL}(k+1) = D_{\text{KL}}(p_k || p_{k+1}) = \int p_k(\mathbf{w}) \log \frac{p_k(\mathbf{w})}{p_{k+1}(\mathbf{w})} d\mathbf{w} \leq \varepsilon.$$

В качестве альтернативы KL-дивергенции можно использовать функцию s-score [81], задающую меру близости двух плотностей:

$$\text{s-score}(g_1, g_2) = \frac{\int g_1(\mathbf{w})g_2(\mathbf{w}) d\mathbf{w}}{\max_{\mathbf{b}} \int g_1(\mathbf{w} - \mathbf{b})g_2(\mathbf{w}) d\mathbf{w}}.$$

Числитель — интеграл произведения плотностей; знаменатель нормирует значение. Для идентичных распределений s-score равно 1.

Определение. Зафиксируем $\varepsilon > 0$. Размер выборки m^* называется S-достаточным, если для всех $k \geq m^*$

$$S(k+1) = \text{s-score}(p_k, p_{k+1}) \geq 1 - \varepsilon.$$

Таким образом, введенные определения демонстрируют условия, при которых размер выборки m^* может считаться достаточным в терминах того или иного критерия. Важно отметить, что из приведенных выше эвристических соображений корректность определений никак не следует. Таким образом, мы переходим к следующему разделу, в котором сфокусируемся на исследовании теоретических свойств предложенных подходов.

5.4. Асимптотическое поведение оптимизационной поверхности в вероятностной модели линейной регрессии

В настоящем разделе мы приводим теоретическое обоснование корректности предложенных определений. Сперва введем понятие этой корректности.

Определение. Критерий достаточности называется *корректным*, если при увеличении размера выборки соответствующая функция сходится к предельному значению.

Отметим, что по сути корректность критерия позволяет гарантированно достичь заданного порога ε , ограничивающего целевую функцию, при достаточно большом k . Такое определение позволяет заключить, что введенный критерий непротиворечив и при ряде предположений имеет место быть в заданной постановке задачи.

Сходимость распределения параметров модели. Обозначим $\mathbb{E}\hat{\mathbf{w}}_k = \mathbf{m}_k$ и $\mathbb{D}\hat{\mathbf{w}}_k = \mathbf{\Sigma}_k$. Следующая теорема дает достаточное условие для сходимости функции $M(k)$ к нулю при увеличении размера обучающей выборки.

Теорема 5.4.1. Пусть $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$ и $\|\mathbf{\Sigma}_{k+1} - \mathbf{\Sigma}_k\|_F \rightarrow 0$ при $k \rightarrow \infty$. Тогда в модели линейной регрессии определение M -достаточного размера выборки корректно: для любого $\varepsilon > 0$ существует t^* такое, что для всех $k \geq t^*$ выполняется $M(k) \leq \varepsilon$.

Важно отметить, что условия теоремы не являются чрезмерно сильными. В конечномерных параметрических моделях они естественно согласуются с асимптотической нормальностью и концентрацией оценок, однако сами по себе не следуют автоматически только из слабой сходимости распределений и потому в дальнейшем проверяются отдельно для рассматриваемой вероятностной модели линейной регрессии.

Для моделей с нормальным апостериорным распределением параметров (в том числе линейной регрессии с гауссовским априором) KL-дивергенция и s-score допускают явные выражения. Благодаря этому формулируются две следующих теоремы.

Теорема 5.4.2. Пусть апостериорные распределения p_k, p_{k+1} нормальны и $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$, $\|\mathbf{\Sigma}_{k+1} - \mathbf{\Sigma}_k\|_F \rightarrow 0$ при $k \rightarrow \infty$. Тогда определение KL-достаточного размера выборки корректно: для любого $\varepsilon > 0$ существует t^* такое, что $\text{KL}(k) \leq \varepsilon$ для всех $k \geq t^*$.

Теорема 5.4.3. Пусть апостериорные распределения p_k, p_{k+1} нормальны и $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$ при $k \rightarrow \infty$. Тогда определение S -достаточного размера выборки корректно: для любого $\varepsilon > 0$ существует t^* такое, что $S(k) \geq 1 - \varepsilon$ для всех $k \geq t^*$.

Утверждения выше, как и теорема 5.4.1, не предполагают слишком многого о распределении параметров модели. Как мы увидим далее в экспериментах, и как это известно из раздела 5.2, эти предположения практически всегда выполняются на практике. Отметим, что для S -достаточности сходимости ковариационных матриц не требуется — достаточно сходимости средних. Для применения теорем 5.4.1, 5.4.2, и 5.4.3 необходимо проверить выполнение условий на моменты. В линейной регрессии с гауссовским априором апостериор

нормален, и моменты задаются явными формулами. Следующий результат таким образом обеспечивает сходимость в модели линейной регрессии, переходя к еще более простым условиям.

Теорема 5.4.4. *Пусть множества значений признаков и целевой переменной ограничены, т. е. $\exists M > 0 : \|\mathbf{x}\|_2 \leq M, |y| \leq M$. Пусть минимальное собственное значение матрицы $\mathbf{X}_k^\top \mathbf{X}_k$ удовлетворяет условию $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k) = \omega(\sqrt{k})$ при $k \rightarrow \infty$. Тогда в линейной регрессии с нормальным априорным распределением параметров $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$ и $\|\Sigma_{k+1} - \Sigma_k\|_F \rightarrow 0$ при $k \rightarrow \infty$.*

Условие $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k) = \omega(\sqrt{k})$ означает, что минимальное собственное значение растет быстрее $\sqrt{k}$ и гарантирует отсутствие сильной мультиколлинеарности при росте выборки. На практике это условие часто выполняется для «хорошо обусловленных» данных.

Сходимость полного байесовского прогноза. В предыдущем разделе было показано, что при увеличении используемого размера выборки в модели линейной регрессии наблюдается сходимость апостериорных распределений параметров на схожих подвыборках. Однако на практике нас больше интересует прогноз, который можно сделать на тестовой выборке, предварительно настроив модель на обучающей. Пусть предварительно было произведено разбиение выборки $\mathfrak{D}_m$ на обучающую и тестовую, т. е.

$$\mathfrak{D}_m = \mathfrak{D}_{m_1}^{\text{train}} \sqcup \mathfrak{D}_{m_2}^{\text{test}},$$

где $\mathfrak{D}_{m_1}^{\text{train}} = (\mathbf{X}_{\text{train}}, \mathbf{y}_{\text{train}})$ и $\mathfrak{D}_{m_2}^{\text{test}} = (\mathbf{X}_{\text{test}}, \mathbf{y}_{\text{test}})$.

Рассмотрим подвыборку $(\mathbf{X}_k, \mathbf{y}_k) \subset \mathfrak{D}_{m_1}^{\text{train}}$ и сформулируем теорему о близости полных байесовских прогнозов, сделанных на схожих подвыборках обучающей выборки.

Теорема 5.4.5. *Пусть множества значений признаков и целевой переменной ограничены, т. е. $\exists M > 0 : \|\mathbf{x}\|_2 \leq M, |y| \leq M$. Если $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k) = \omega(\sqrt{k})$ при $k \rightarrow \infty$, то в модели линейной регрессии с нормальным априорным распределением параметров при $k \rightarrow \infty$ верно, что*

$$D_{\text{KL}}(p(\mathbf{y}_{\text{test}} | \mathbf{X}_{\text{test}}, \mathbf{X}_k, \mathbf{y}_k) \| p(\mathbf{y}_{\text{test}} | \mathbf{X}_{\text{test}}, \mathbf{X}_{k+1}, \mathbf{y}_{k+1})) \rightarrow 0.$$

Сформулированное выше утверждение заключает, что в модели вероятностной линейной регрессии определения KL-достаточности и S-достаточности

связаны не просто со сходимостью оптимизационной поверхности, но и со стабилизацией прогноза на отложенной тестовой выборке. Именно это и является ключевым фактором, который дополняет все полученные выше теоретические результаты их применимостью в практических задачах.

5.5. Доказательства теоретических результатов

В данном приводятся доказательства основных теорем настоящей главы: 5.4.1, 5.4.2, 5.4.3, 5.4.4 и 5.4.5. Начнем с доказательства теоремы 5.4.1 о корректности определения М-достаточного размера выборки.

Доказательство теоремы 5.4.1. Рассмотрим определение М-достаточного размера выборки в терминах логарифма функции правдоподобия. В модели линейной регрессии

$$\begin{aligned} L(\mathfrak{D}_m, \hat{\mathbf{w}}_k) &= p(\mathbf{y}|\mathbf{X}, \hat{\mathbf{w}}_k) = \prod_{i=1}^m p(y_i|\mathbf{x}_i, \hat{\mathbf{w}}_k) = \prod_{i=1}^m \mathcal{N}(y_i|\hat{\mathbf{w}}_k^\top \mathbf{x}_i, \sigma^2) \\ &= (2\pi\sigma^2)^{-m/2} \exp\left(-\frac{1}{2\sigma^2}\|\mathbf{y} - \mathbf{X}\hat{\mathbf{w}}_k\|_2^2\right). \end{aligned} \quad (5.5)$$

Логарифмируя (5.5), получаем

$$l(\mathfrak{D}_m, \hat{\mathbf{w}}_k) = \log p(\mathbf{y}|\mathbf{X}, \hat{\mathbf{w}}_k) = -\frac{m}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\|\mathbf{y} - \mathbf{X}\hat{\mathbf{w}}_k\|_2^2. \quad (5.6)$$

Возьмем математическое ожидание (5.6) по $\mathfrak{D}_k$, учитывая, что $\mathbb{E}_{\mathfrak{D}_k} \hat{\mathbf{w}}_k = \mathbf{m}_k$ и $\text{cov}(\hat{\mathbf{w}}_k) = \mathbf{\Sigma}_k$, тогда имеем

$$\mathbb{E}_{\mathfrak{D}_k} l(\mathfrak{D}_m, \hat{\mathbf{w}}_k) = -\frac{m}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \left(\|\mathbf{y} - \mathbf{X}\mathbf{m}_k\|_2^2 + \text{tr}(\mathbf{X}^\top \mathbf{X} \mathbf{\Sigma}_k) \right). \quad (5.7)$$

Используя (5.7) для размеров k и $k + 1$, запишем выражение для разности математических ожиданий, в таком случае получим

$$\begin{aligned} \mathbb{E}_{\mathcal{D}_{k+1}} l(\mathcal{D}_m, \hat{\mathbf{w}}_{k+1}) - \mathbb{E}_{\mathcal{D}_k} l(\mathcal{D}_m, \hat{\mathbf{w}}_k) &= \\ &= \frac{1}{2\sigma^2} \left(\|\mathbf{y} - \mathbf{X}\mathbf{m}_k\|_2^2 - \|\mathbf{y} - \mathbf{X}\mathbf{m}_{k+1}\|_2^2 \right) + \frac{1}{2\sigma^2} \text{tr} \left(\mathbf{X}^\top \mathbf{X} (\boldsymbol{\Sigma}_k - \boldsymbol{\Sigma}_{k+1}) \right) \\ &= \frac{1}{\sigma^2} \mathbf{y}^\top \mathbf{X} (\mathbf{m}_{k+1} - \mathbf{m}_k) \end{aligned} \quad (5.8)$$

$$+ \frac{1}{2\sigma^2} (\mathbf{m}_k - \mathbf{m}_{k+1})^\top \mathbf{X}^\top \mathbf{X} (\mathbf{m}_k + \mathbf{m}_{k+1}) \quad (5.9)$$

$$+ \frac{1}{2\sigma^2} \text{tr} \left(\mathbf{X}^\top \mathbf{X} (\boldsymbol{\Sigma}_k - \boldsymbol{\Sigma}_{k+1}) \right). \quad (5.10)$$

Значение функции $M(k + 1)$ есть модуль от выражения выше. Применим неравенство треугольника для модуля, а затем оценим каждое слагаемое. Первое слагаемое (5.8) оценим, используя неравенство Коши–Буняковского:

$$|\mathbf{y}^\top \mathbf{X} (\mathbf{m}_{k+1} - \mathbf{m}_k)| \leq \|\mathbf{X}^\top \mathbf{y}\|_2 \|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2. \quad (5.11)$$

Второе слагаемое (5.9) оценим, используя неравенство Коши–Буняковского, свойство согласованности спектральной матричной нормы, а также ограниченность последовательности векторов $\mathbf{w}_k$, которая следует из предъявленной в условии сходимости:

$$\begin{aligned} |(\mathbf{m}_k - \mathbf{m}_{k+1})^\top \mathbf{X}^\top \mathbf{X} (\mathbf{m}_k + \mathbf{m}_{k+1})| &\leq \|\mathbf{X}(\mathbf{m}_k - \mathbf{m}_{k+1})\|_2 \|\mathbf{X}(\mathbf{m}_k + \mathbf{m}_{k+1})\|_2 \\ &\leq \|\mathbf{X}\|_2^2 \|\mathbf{m}_k - \mathbf{m}_{k+1}\|_2 \|\mathbf{m}_k + \mathbf{m}_{k+1}\|_2 \\ &\leq C \|\mathbf{X}\|_2^2 \|\mathbf{m}_k - \mathbf{m}_{k+1}\|_2. \end{aligned} \quad (5.12)$$

Последнее слагаемое (5.10) оценим, используя неравенство Гёльдера для нормы Фробениуса:

$$\left| \text{tr} \left(\mathbf{X}^\top \mathbf{X} (\boldsymbol{\Sigma}_k - \boldsymbol{\Sigma}_{k+1}) \right) \right| \leq \|\mathbf{X}^\top \mathbf{X}\|_F \|\boldsymbol{\Sigma}_k - \boldsymbol{\Sigma}_{k+1}\|_F. \quad (5.13)$$

Наконец, поскольку по условию теоремы $\|\mathbf{m}_k - \mathbf{m}_{k+1}\|_2 \rightarrow 0$ и $\|\boldsymbol{\Sigma}_k - \boldsymbol{\Sigma}_{k+1}\|_F \rightarrow 0$ при $k \rightarrow \infty$, то выражения (5.11), (5.12) и (5.13) стремятся к 0 при $k \rightarrow \infty$, а следовательно и $M(k) \rightarrow 0$ при $k \rightarrow \infty$, что доказывает теорему. $\square$

Теорема 5.4.1 показывает, что при достаточном объеме выборки добавление очередного объекта практически не изменяет ожидаемое значение функции правдоподобия на полной выборке. Тем не менее, особый интерес представляют результаты, полученные для полных апостериорных распределений параметров.

Доказательство теоремы 5.4.2. Дивергенция Кульбака—Лейблера для пары нормальных апостериорных распределений имеет вид

$$D_{\text{KL}}(p_k \| p_{k+1}) = \frac{1}{2} \left(\text{tr}(\Sigma_{k+1}^{-1} \Sigma_k) + (\mathbf{m}_{k+1} - \mathbf{m}_k)^\top \Sigma_{k+1}^{-1} (\mathbf{m}_{k+1} - \mathbf{m}_k) - n + \log \left(\frac{\det \Sigma_{k+1}}{\det \Sigma_k} \right) \right). \quad (5.14)$$

Представим Σ_{k+1} как $\Sigma_{k+1} = \Sigma_k + \Delta \Sigma$. Рассмотрим в отдельности каждое слагаемое в (5.14). Для первого слагаемого получаем

$$\text{tr}(\Sigma_{k+1}^{-1} \Sigma_k) = \text{tr}((\Sigma_k + \Delta \Sigma)^{-1} \Sigma_k) \rightarrow \text{tr}(\mathbf{I}_n) = n \quad (5.15)$$

при $\|\Delta \Sigma\|_F \rightarrow 0$. Для второго слагаемого имеем

$$|(\mathbf{m}_{k+1} - \mathbf{m}_k)^\top \Sigma_{k+1}^{-1} (\mathbf{m}_{k+1} - \mathbf{m}_k)| \leq \|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2^2 \|\Sigma_{k+1}^{-1}\|_2 \rightarrow 0 \quad (5.16)$$

при $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$. Наконец, для последнего слагаемого можем записать

$$\log \left(\frac{\det \Sigma_{k+1}}{\det \Sigma_k} \right) = \log \left(\frac{\det(\Sigma_k + \Delta \Sigma)}{\det \Sigma_k} \right) \rightarrow \log \det \mathbf{I}_n = \log 1 = 0 \quad (5.17)$$

при $\|\Delta \Sigma\|_F \rightarrow 0$. Объединяя предельные соотношения (5.15), (5.16) и (5.17), получаем требуемое в условиях теоремы. $\square$

Доказательство теоремы 5.4.3. Воспользуемся выражением s-score для пары нормальных априорных распределений из [81]:

$$\text{s-score}(p_k, p_{k+1}) = \exp \left(-\frac{1}{2} (\mathbf{m}_{k+1} - \mathbf{m}_k)^\top (\Sigma_k + \Sigma_{k+1})^{-1} (\mathbf{m}_{k+1} - \mathbf{m}_k) \right). \quad (5.18)$$

Поскольку

$$\begin{aligned} \left| (\mathbf{m}_{k+1} - \mathbf{m}_k)^\top (\Sigma_k + \Sigma_{k+1})^{-1} (\mathbf{m}_{k+1} - \mathbf{m}_k) \right| &\leq \\ &\leq \|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2^2 \|(\Sigma_k + \Sigma_{k+1})^{-1}\|_2 \rightarrow 0 \end{aligned}$$

при $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$, то значение квадратичной формы внутри экспоненты (5.18) стремится к нулю. Следовательно, $\text{s-score}(p_k, p_{k+1}) \rightarrow 1$ при устремлении $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$, что и требовалось доказать. $\square$

В вероятностной модели линейной регрессии с гауссовским априорным распределением доказывается следующая теорема, определяющая достаточные условия для сходимостей из предыдущих теорем 5.4.2 и 5.4.3.

Доказательство теоремы 5.4.4. Пусть задано нормальное априорное распределение параметров $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{0}, \alpha^{-1}\mathbf{I})$. В модели линейной регрессии правдоподобие является нормальным, а именно

$$p(\mathbf{y}|\mathbf{X}, \mathbf{w}) = \mathcal{N}(\mathbf{y}|\mathbf{X}\mathbf{w}, \sigma^2\mathbf{I}) = (2\pi\sigma^2)^{-m/2} \exp\left(-\frac{1}{2\sigma^2}\|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2\right).$$

Используя сопряженность априорного распределения и правдоподобия, легко найти параметры апостериорного распределения:

$$p(\mathbf{w}|\mathbf{X}, \mathbf{y}) = \mathcal{N}(\mathbf{w}|\mathbf{m}, \Sigma),$$

где

$$\Sigma = \left(\alpha\mathbf{I} + \frac{1}{\sigma^2}\mathbf{X}^\top\mathbf{X}\right)^{-1}, \quad \mathbf{m} = (\mathbf{X}^\top\mathbf{X} + \alpha\sigma^2\mathbf{I})^{-1}\mathbf{X}^\top\mathbf{y}. \quad (5.19)$$

Рассмотрим выражение $\|\Sigma_{k+1} - \Sigma_k\|_2$ нормы разности матриц ковариации для подвыборок размера k и $k+1$. Введем обозначение $\mathbf{A}_k = \frac{1}{\sigma^2}\mathbf{X}_k^\top\mathbf{X}_k$. Учитывая формулы моментов (5.19), имеем

$$\begin{aligned} \|\Sigma_{k+1} - \Sigma_k\|_2 &= \\ &= \left\|(\alpha\mathbf{I} + \mathbf{A}_{k+1})^{-1} - (\alpha\mathbf{I} + \mathbf{A}_k)^{-1}\right\|_2 \\ &= \left\|(\alpha\mathbf{I} + \mathbf{A}_{k+1})^{-1}(\mathbf{A}_{k+1} - \mathbf{A}_k)(\alpha\mathbf{I} + \mathbf{A}_k)^{-1}\right\|_2 \\ &\leq \left\|(\alpha\mathbf{I} + \mathbf{A}_{k+1})^{-1}\right\|_2 \left\|(\alpha\mathbf{I} + \mathbf{A}_k)^{-1}\right\|_2 \|\mathbf{A}_{k+1} - \mathbf{A}_k\|_2 \end{aligned} \quad (5.20)$$

$$= \frac{1}{\lambda_{\min}(\alpha\mathbf{I} + \mathbf{A}_{k+1})} \frac{1}{\lambda_{\min}(\alpha\mathbf{I} + \mathbf{A}_k)} \|\mathbf{A}_{k+1} - \mathbf{A}_k\|_2 \quad (5.21)$$

$$\begin{aligned} &\leq \frac{1}{\lambda_{\min}(\mathbf{A}_{k+1})} \frac{1}{\lambda_{\min}(\mathbf{A}_k)} \|\mathbf{A}_{k+1} - \mathbf{A}_k\|_2 \\ &= \sigma^2 \frac{1}{\lambda_{\min}(\mathbf{X}_{k+1}^\top\mathbf{X}_{k+1})} \frac{1}{\lambda_{\min}(\mathbf{X}_k^\top\mathbf{X}_k)} \|\mathbf{X}_{k+1}^\top\mathbf{X}_{k+1} - \mathbf{X}_k^\top\mathbf{X}_k\|_2. \end{aligned} \quad (5.22)$$

Здесь в (5.20) мы воспользовались субмультипликативностью спектральной матричной нормы, а в (5.21) — выражением спектральной матричной нормы через максимальное собственное значение. Далее, поскольку по условию $\|\mathbf{x}\|_2 \leq M$, то мы оцениваем норму разности матриц из (5.22) следующим образом:

$$\begin{aligned} \|\mathbf{X}_{k+1}^\top\mathbf{X}_{k+1} - \mathbf{X}_k^\top\mathbf{X}_k\|_2 &= \left\|\sum_{i=1}^{k+1} \mathbf{x}_i\mathbf{x}_i^\top - \sum_{i=1}^k \mathbf{x}_i\mathbf{x}_i^\top\right\|_2 = \|\mathbf{x}_{k+1}\mathbf{x}_{k+1}^\top\|_2 \\ &= \lambda_{\max}(\mathbf{x}_{k+1}\mathbf{x}_{k+1}^\top) = \mathbf{x}_{k+1}^\top\mathbf{x}_{k+1} = \|\mathbf{x}_{k+1}\|_2^2 \leq M^2 \end{aligned} \quad (5.23)$$

где переход к (5.23) имеет место потому, что матрица единичного ранга имеет единственное ненулевое собственное значение. По условию $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k) = \omega(\sqrt{k})$, тогда $\|\Sigma_{k+1} - \Sigma_k\|_2 = o(k^{-1})$ при $k \rightarrow \infty$. Пользуясь эквивалентностью матричных норм, получаем требуемую сходимость для матриц ковариации:

$$\|\Sigma_{k+1} - \Sigma_k\|_F \leq \sqrt{k} \|\Sigma_{k+1} - \Sigma_k\|_2 = o(k^{-1/2}), \quad k \rightarrow \infty.$$

Теперь оценим норму разности математических ожиданий. Пользуясь формулой (5.19), получаем

$$\begin{aligned} \|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 &= \\ &= \left\| (\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1} + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{X}_{k+1}^\top \mathbf{y}_{k+1} - (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{X}_k^\top \mathbf{y}_k \right\|_2 \\ &= \left\| (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I} + \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top)^{-1} (\mathbf{X}_k^\top \mathbf{y}_k + \mathbf{x}_{k+1} y_{k+1}) \right. \\ &\quad \left. - (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{X}_k^\top \mathbf{y}_k \right\|_2 \\ &= \left\| \left[\left(\mathbf{I} + (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top \right)^{-1} - \mathbf{I} \right] (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{X}_k^\top \mathbf{y}_k \right. \\ &\quad \left. + (\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1} + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} y_{k+1} \right\|_2 \end{aligned} \quad (5.24)$$

$$\begin{aligned} &\leq \left\| \left(\mathbf{I} + (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top \right)^{-1} - \mathbf{I} \right\|_2 \left\| (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \right\|_2 \|\mathbf{X}_k^\top \mathbf{y}_k\|_2 \\ &\quad + \left\| (\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1} + \alpha \sigma^2 \mathbf{I})^{-1} \right\|_2 \|\mathbf{x}_{k+1} y_{k+1}\|_2 \end{aligned} \quad (5.25)$$

Здесь мы учли, что $\mathbf{X}_{k+1}^\top = [\mathbf{X}_k^\top, \mathbf{x}_{k+1}]$ и $\mathbf{y}_{k+1} = [\mathbf{y}_k, y_{k+1}]^\top$, тогда $\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1} = \mathbf{X}_k^\top \mathbf{X}_k + \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top$ и $\mathbf{X}_{k+1}^\top \mathbf{y}_{k+1} = \mathbf{X}_k^\top \mathbf{y}_k + \mathbf{x}_{k+1} y_{k+1}$. Для перехода к (5.24) мы вынесли множитель в первом слагаемом, после чего вынесли общий множитель у обоих слагаемых. Далее для получения (5.25) мы применили неравенство треугольника, а также свойства согласованности и субмультипликативности спектральной нормы. Оценим по отдельности каждое слагаемое в (5.25). В первом множителе первого слагаемого применим формулу для разности обратных

матриц, как мы делали с ковариационными матрицами:

$$\begin{aligned} & \left\| \left(\mathbf{I} + (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top \right)^{-1} - \mathbf{I} \right\|_2 \leq \\ & \leq \left\| \left(\mathbf{I} + (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top \right)^{-1} \right\|_2 \|\mathbf{I}\|_2 \left\| (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top \right\|_2 \leq \\ & \leq \frac{1}{\lambda_{\min} \left(\mathbf{I} + (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top \right)} \frac{\|\mathbf{x}_{k+1}\|_2^2}{\lambda_{\min} (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})} \end{aligned} \quad (5.26)$$

$$\begin{aligned} & \leq \frac{1}{1 + \lambda_{\min} \left((\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top \right)} \frac{M^2}{\lambda_{\min} (\mathbf{X}_k^\top \mathbf{X}_k)} \\ & \leq \frac{1}{1 + \lambda_{\max} (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I}) \lambda_{\min} (\mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top)} \frac{M^2}{\lambda_{\min} (\mathbf{X}_k^\top \mathbf{X}_k)} \\ & = \frac{M^2}{\lambda_{\min} (\mathbf{X}_k^\top \mathbf{X}_k)}. \end{aligned} \quad (5.27)$$

Выше, при переходе к (5.26), мы снова использовали субмультипликативность, а также выражение для нормы матрицы единичного ранга. Наконец, для получения (5.27) мы применили, что минимальное собственное значение произведения матриц оценивается произведением их минимальных собственных значений, а минимальное собственное значение матрицы единичного ранга $\mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top$ равно нулю. Второй и третий множители первого слагаемого оцениваются следующим образом:

$$\begin{aligned} \left\| (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \right\|_2 \left\| \mathbf{X}_k^\top \mathbf{y}_k \right\|_2 & \leq \frac{\left\| \mathbf{X}_k^\top \mathbf{y}_k \right\|_2}{\lambda_{\min} (\mathbf{X}_k^\top \mathbf{X}_k)} = \frac{\left\| \sum_{i=1}^k \mathbf{x}_i y_i \right\|_2}{\lambda_{\min} (\mathbf{X}_k^\top \mathbf{X}_k)} \\ & \leq \frac{k M^2}{\lambda_{\min} (\mathbf{X}_k^\top \mathbf{X}_k)}. \end{aligned} \quad (5.28)$$

Наконец, оценим второе слагаемое.

$$\left\| (\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1} + \alpha \sigma^2 \mathbf{I})^{-1} \right\|_2 \left\| \mathbf{x}_{k+1} y_{k+1} \right\|_2 \leq \frac{M^2}{\lambda_{\min} (\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1})} \quad (5.29)$$

Итого, собирая воедино (5.27), (5.28) и (5.29), имеем следующую оценку:

$$\begin{aligned} \|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 & \leq \frac{k M^3}{\lambda_{\min}^2 (\mathbf{X}_k^\top \mathbf{X}_k)} + \frac{M^2}{\lambda_{\min} (\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1})} \\ & = k \cdot o(k^{-1}) + o(k^{-1/2}) = o(1) \end{aligned}$$

при $k \rightarrow \infty$. Таким образом, получили требуемую сходимость. $\square$

Наконец, докажем теорему о сходимости полного байесовского прогноза на отложенной выборке.

Доказательство теоремы 5.4.5. Полный байесовский прогноз для одиночной модели выражается по формуле

$$\begin{aligned} p(\mathbf{y}_{\text{test}}|\mathbf{X}_{\text{test}}, \mathbf{X}_k, \mathbf{y}_k) &= \int p(\mathbf{y}_{\text{test}}|\mathbf{X}_{\text{test}}, \mathbf{w})p(\mathbf{w}|\mathbf{X}_k, \mathbf{y}_k)d\mathbf{w} \\ &= \int \mathcal{N}(\mathbf{y}_{\text{test}}|\mathbf{X}_{\text{test}}\mathbf{w}, \sigma^2\mathbf{I})\mathcal{N}(\mathbf{w}|\mathbf{m}_k, \Sigma_k)d\mathbf{w} \end{aligned} \quad (5.30)$$

$$= \mathcal{N}(\mathbf{y}_{\text{test}}|\mathbf{X}_{\text{test}}\mathbf{m}_k, \sigma^2\mathbf{I} + \mathbf{X}_{\text{test}}\Sigma_k\mathbf{X}_{\text{test}}^\top). \quad (5.31)$$

Здесь при переходе от (5.30) к (5.31) мы воспользовались известным выражением из [76]. В условиях настоящей теоремы справедливы результаты теоремы 5.4.4. Следовательно, $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$ и $\|\Sigma_{k+1} - \Sigma_k\|_F \rightarrow 0$ при $k \rightarrow \infty$. Далее, остается показать сходимость математического ожидания и ковариационной матрицы нормального распределения прогноза модели. Для математического ожидания при $k \rightarrow \infty$ выполнено

$$\|\mathbf{X}_{\text{test}}\mathbf{m}_{k+1} - \mathbf{X}_{\text{test}}\mathbf{m}_k\|_2 \leq \|\mathbf{X}_{\text{test}}\|_2\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0. \quad (5.32)$$

Для ковариационной матрицы, ввиду субмультипликативности нормы Фробениуса, при $k \rightarrow \infty$ справедливо следующее:

$$\|\sigma^2\mathbf{I} + \mathbf{X}_{\text{test}}\Sigma_{k+1}\mathbf{X}_{\text{test}}^\top - \sigma^2\mathbf{I} - \mathbf{X}_{\text{test}}\Sigma_k\mathbf{X}_{\text{test}}^\top\|_F \leq \|\mathbf{X}_{\text{test}}\|_F^2\|\Sigma_{k+1} - \Sigma_k\|_F \rightarrow 0. \quad (5.33)$$

Наконец, имея сходимость математического ожидания (5.32) и ковариационной матрицы (5.33), действуем аналогично доказательству теоремы 5.4.2 и получаем, что

$$D_{\text{KL}}(p(\mathbf{y}_{\text{test}}|\mathbf{X}_{\text{test}}, \mathbf{X}_k, \mathbf{y}_k) \| p(\mathbf{y}_{\text{test}}|\mathbf{X}_{\text{test}}, \mathbf{X}_{k+1}, \mathbf{y}_{k+1})) \rightarrow 0$$

при $k \rightarrow \infty$, завершая доказательство данной теоремы. $\square$

5.6. Вычислительные эксперименты

В данном разделе мы проводим эмпирический анализ сходимости распределения оптимальных параметров в линейных моделях. Программный код, реализованный на фреймворке **PyTorch**, доступен публично по адресам

<https://github.com/kisnikser/Likelihood-Bootstrapping>,
<https://github.com/kisnikser/Posterior-Distributions-Proximity>.

Эксперимент состоит из нескольких частей. Сперва, мы строим графики апостериорных распределений и показываем их сходимость на модельном примере. Далее, мы проверяем сходимость предложенных критериев достаточности. Затем, мы исследуем их зависимость от гиперпараметра-порога. Раздел завершается тем, что мы сравниваем критерии на наборе реальных выборок с задачей регрессии.

Близость апостериорных распределений. Используется синтетическая выборка, сгенерированная из модели линейной регрессии

$$y = \mathbf{w}^{*\top} \mathbf{x} + \varepsilon, \quad \mathbf{x} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_n), \quad \varepsilon \sim \mathcal{N}(0, \sigma^2),$$

где в одномерном случае $n = 1$, в двумерном случае $n = 2$, истинный вектор параметров выбирается как $\mathbf{w}^* = 1$ или $\mathbf{w}^* = [1, 1]^\top$ соответственно, число объектов $m = 100$, стандартное отклонение шума $\sigma = 1$, а априорное распределение параметров задается как $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{0}, \mathbf{I})$. Далее представлены рисунки 5.3 и 5.4, на которых изображено сходство апостериорных распределений, определенных на схожих подвыборках размера k и $k + 1$ при варьировании числа k .




Рисунок 5.3 — Изменение апостериорных распределений параметров на схожих подвыборках по мере увеличения их размера. Одномерный случай, где на графиках изображены плотности распределений

По построенные графикам видно, что при увеличении числа обучающих объектов оптимизационная поверхность линейных моделей (апостериорное распределение параметров) перестает меняться. Эти результаты подкрепляют




Рисунок 5.4 — Изменение апостериорных распределений параметров на схожих подвыборке по мере увеличения их размера. Двумерный случай, где на графиках изображены линии уровня

идеи, на основе которых построены определения достаточного размера выборки.

Корректность определений D- и M-достаточности. Прежде чем перейти к вычислительным экспериментам, сделаем важное замечание. Поскольку на практике нет возможности посчитать указанные в определениях (5.3), (5.4) математическое ожидание и дисперсию, для их оценки предлагается воспользоваться техникой бутстрап. А именно, сгенерируем из заданной $\mathfrak{D}_m$ некоторое число B подвыборок размера k с возвращением. Для каждой из них получим оценку параметров $\hat{\mathbf{w}}_k$ и посчитаем значение $L(\mathfrak{D}_m, \hat{\mathbf{w}}_k)$. Для оценки будем использовать выборочное среднее и несмещенную выборочную дисперсию (по бутстрап-подвыборкам). Предложенные выше определения можно применять и в тех задачах, когда минимизируется произвольная функция потерь, а не максимизируется функция правдоподобия. Мы не приводим никаких теоретических обоснований этого, однако на практике такая эвристика оказывается достаточно удачной.

Перейдем к эксперименту. Синтетические данные сгенерированы из моделей линейной и логистической регрессий. Число объектов $m = 1000$, число признаков $n = 20$. Используется $B = 1000$ бутстрапированных подвыборок для оценки математического ожидания и дисперсии функции ошибки. Подсчитываются значения функций $D(k)$ и $M(k)$. Датасет с задачей регрессии Liver Disorders из UCI [82] содержит $m = 345$ объектов и $n = 5$ признаков. Мы также используем $B = 1000$ бутстрапированных подвыборок.

На рисунке 5.5 (а) можно видеть полученные зависимости между используемым размером подвыборки k и рассматриваемыми функциями $D(k)$ и $M(k)$ для синтетической выборки с задачей регрессии. Результаты для синтетической выборки с задачей классификации представлены на рисунке 5.5 (б). В то же время, на рисунке 5.5 (в) мы видим аналогичные графики для датасета Liver Disorders. Видно, что во всех случаях значения функций $D(k)$ и $M(k)$ стремятся к нулю при увеличении размера выборки. Эти эмпирические результаты подтверждают теоретические, полученные ранее.

Асимптотическое поведение минимального собственного значения матрицы $\mathbf{X}_k^\top \mathbf{X}_k$. Используются синтетические данные, сгенерированные из модели линейной регрессии. Число объектов $m = 500$, число признаков $n = 10$. Один объект последовательно удаляется из данной выборки, пока число объектов в подвыборке не станет равно числу признаков. Для каждого размера выборки k подсчитывается минимальное собственное значение матрицы $\mathbf{X}_k^\top \mathbf{X}_k$. Такой процесс повторяется $B = 100$ раз. Аналогичные действия проводятся и на датасете Liver Disorders с $m = 345$ объектами и $n = 5$ признаками. Результаты представлены на рисунке 5.6. Видно, что при стремлении размера выборки к бесконечности минимальное собственное значение также стремится к бесконечности. Помимо этого, как и требуется в теореме 5.4.4, этот график лежит выше, чем $\sqrt{k}$.

Корректность определений KL- и S-достаточности. На рисунке 5.7 (а) мы можем наблюдать полученные зависимости между доступным размером выборки k и предложенными функциями $KL(k)$ и $S(k)$ для синтетической выборки с задачей регрессии. В то же время, на рисунке 5.7 (б) можно видеть аналогичные графики для датасета Liver Disorders. Для обеих выборок значения функции $KL(k)$ стремятся к нулю при увеличении размера выборки, а значения $S(k)$ стремятся к единице. Эти эмпирические результаты подтверждают теоретические, представленные ранее.

Зависимость критериев от гиперпараметра ε . В определениях достаточности по каждому из критериев: D, M, KL, S участвует гиперпараметр ε , который отвечает за порог для достаточного размера выборки m^* . С целью изучения зависимости между ними, мы представляем графики на рисунке 5.8, которые демонстрируют, какой размер выборки следует выбрать, чтобы обеспечить определенный уровень уверенности.


По результатам эксперимента видно, что все четыре критерия обладают примерно одинаковой зависимостью от значения ϵ . Таким образом, важно правильно подбирать значение гиперпараметра для корректного определения достаточного размера выборки.

Сравнение критериев на множестве выборок. Чтобы оценить эффективность предложенных методов на разных наборах данных, были выбраны выборки из открытой библиотеки UCI [82]. Подробная информация о каждом наборе данных, количество наблюдений и количество признаков представлены в таблице 5. Для демонстрационных целей были выбраны такие значения гиперпараметра ϵ , при которых значения функций $D(k)$ и $M(k)$ уменьшаются в 1000 раз, а значения функций $KL(k)$ и $S(k)$ приближаются к предельным вдвое. Соответствующие результаты приведены в таблице 5. Пропуски означают, что первоначальный размер выборки недостаточен.


Таблица 5 — Сравнение предложенных критериев достаточного размера выборки на множестве реальных выборок с задачей регрессии. Пропуски означают, что первоначальный размер выборки недостаточен

Название выборки	Объектов m	Признаков n	D	M	KL	S
rule Abalone	4177	8	96	96	3921	4091
Auto MPG	392	8	15	15	62	—
Automobile	159	25	70	156	156	—
Liver Disorders	345	6	12	19	—	—
Servo	167	4	41	—	163	163
Forest fires	517	12	208	—	507	—
Wine Quality	6497	12	144	144	5305	6099
Energy Efficiency	768	9	24	442	—	—
Student Performance	649	32	129	177	636	—
Facebook Metrics	495	18	31	388	475	—
Real Estate Valuation	414	7	15	23	—	—
Heart Failure	299	12	63	224	276	293
BMT: children	142	36	—	—	109	—


По результатам видно, что критерии D- и M-достаточности часто говорят о схожем значении достаточного размера выборки. Тем временем, критерий S-достаточности часто оказывается более консервативным по сравнению с KL-достаточностью.



а) Синтетическая выборка (линейная регрессия)



б) Синтетическая выборка (логистическая регрессия)



в) Выборка Liver Disorders (регрессия)

Рисунок 5.5 — Сходимость функций $D(k)$ и $M(k)$ в различных задачах и на различных выборках. Значения обоих критериев стремятся к нулю при увеличении размера выборки






Рисунок 5.6 — Изменение минимального собственного значения матрицы $\mathbf{X}_k^\top \mathbf{X}_k$ при увеличении размера выборки в задачах синтетической линейной регрессии и регрессии на датасете Liver Disorders



а) Синтетическая выборка (линейная регрессия)



б) Выборка Liver Disorders (регрессия)

Рисунок 5.7 — Сходимость функций $KL(k)$ и $S(k)$ в различных задачах и на различных выборках. Оба критерия стремятся к предельным значениям при увеличении размера выборки




Рисунок 5.8 — Зависимость достаточного размера выборки согласно введенным критериям от гиперпараметра ϵ . Рассматриваются три задачи: синтетическая регрессия и классификация, а также регрессия на датасете Liver Disorders. Чем больше значение гиперпараметра ϵ , тем меньше требуется обучающих объектов

5.7. Обсуждение

Логистическая регрессия. В задаче бинарной классификации с метками $y \in \{0, 1\}$ логистическая регрессия задается правдоподобием

$$p(y|\mathbf{x}, \mathbf{w}) = \sigma(\mathbf{w}^\top \mathbf{x})^y (1 - \sigma(\mathbf{w}^\top \mathbf{x}))^{1-y}, \quad \sigma(z) = \frac{1}{1 + e^{-z}}.$$

Апостериорное распределение параметров уже не является нормальным; сопряженного априора не существует. Тем не менее при достаточно большом размере выборки апостериор асимптотически нормален (результат Бернштейна—фон Мизеса). На практике критерии KL и S применяются к логистической регрессии, а порог достаточности выбирается эмпирически [75]. Теоретическое обоснование сходимости для логистической регрессии требует дополнительного анализа.

Обобщенные линейные модели (GLM). Обобщенные линейные модели включают линейную и логистическую регрессию как частные случаи [74]. Модель задается линейным предиктором $\eta = \mathbf{w}^\top \mathbf{x}$, функцией связи и распределением из экспоненциального семейства. Для GLM с канонической функцией связи оценка ММП существует при определенных условиях на данные. Сходимость апостериора и применимость критериев D, M, KL, S зависят от конкретного вида модели; для ряда GLM (например, регрессии Пуассона) возможны аналоги теорем 5.4.1, 5.4.2, 5.4.3 при дополнительных предположениях.

Сравнительный анализ критериев. Критерии D и M основаны на бутстрапировании подвыборок и вычислении правдоподобия в точке ОМП. Их преимущество — простота вычислений: не требуется полное апостериорное распределение. Критерии KL и S требуют знания апостериора на схожих подвыборках; для линейной регрессии с сопряженным априором они вычисляются аналитически. Эмпирические исследования показывают, что KL-достаточный размер, как правило, оказывается наименьшим, а S-достаточный — наибольшим при фиксированном пороге ε . Это объясняется различной чувствительностью KL-дивергенции и s-score к различиям распределений. Выбор критерия зависит от задачи: при необходимости консервативной оценки предпочтителен S; при ограничениях на объем данных может быть достаточен критерий KL.

Заключение

В диссертационной работе решена научная задача разработки теоретического подхода к анализу связи между объемом обучающей выборки, локальными свойствами оптимизационной поверхности и достаточным размером данных в параметрических моделях машинного обучения, а также предложена интерпретация полученных результатов в терминах законов масштабирования.

Основные результаты работы заключаются в следующем.

1. Для нейронных сетей исследованы спектральные свойства матрицы Гессе функции потерь. Показано, что в окрестности точки минимума спектрально значимая часть второй производной естественным образом описывается гаусс—ньютоновской компонентой. В классе матрично-представимых нейронных сетей получена ее блочная факторизация, на основе которой выведены архитектурно-зависимые верхние оценки спектральной нормы для полносвязных и сверточных архитектур.
2. Разработан подход к анализу стабилизации ландшафта функции потерь при увеличении объема обучающей выборки. На основе локальной квадратичной аппроксимации функции потерь в окрестности точки минимума введен общий критерий p -сходимости, а также рассмотрены его частные случаи: абсолютный одноточечный критерий, среднеквадратичный критерий в полном пространстве параметров и среднеквадратичный критерий в подпространстве наибольшей кривизны.
3. Для введенных критериев стабилизации получены теоретические оценки скорости сходимости. Показано, что абсолютный одноточечный критерий убывает с порядком $\mathcal{O}(k^{-1})$, тогда как среднеквадратичный критерий в полном пространстве параметров и его подпространственный аналог убывают с порядком $\mathcal{O}(k^{-2})$ при увеличении объема выборки.
4. Построены критерии достаточного размера выборки для параметрических моделей машинного обучения, основанные на стабилизации ландшафта функции потерь. Показано, что верхние оценки локальной кривизны оптимизационной поверхности, выраженные через спектральную норму гаусс—ньютоновской компоненты, позволяют получить

архитектурно-зависимые оценки достаточного объема данных для полносвязных и сверточных моделей.

5. Предложена теоретическая схема интерпретации связи между архитектурой модели, локальной геометрией оптимизационной поверхности и объемом обучающей выборки в терминах законов масштабирования. Показано, что вклад конечности обучающей выборки в итоговое значение функции потерь может быть связан с локальной кривизной поверхности, а оптимальное соотношение между размером модели и размером выборки зависит не только от ошибки выразимости, но и от режима роста архитектурно-зависимой кривизны.
6. Для вероятностных линейных моделей исследована стабилизация распределения оптимальных параметров при увеличении объема обучающей выборки. Введены и проанализированы критерии достаточного размера выборки, основанные на дисперсии и математическом ожидании функции правдоподобия, дивергенции Кульбака—Лейблера между апостериорными распределениями и метрике близости s -score. Для линейной регрессии с гауссовским априорным распределением получены условия корректности этих критериев и исследовано асимптотическое поведение соответствующих вероятностных характеристик.
7. Проведенные вычислительные эксперименты для нейросетевых и линейных моделей качественно согласуются с полученными теоретическими результатами. Для нейронных сетей подтверждена близость спектральных норм полной матрицы Гессе и ее гаусс—ньютоновской компоненты на поздних этапах обучения, а также наблюдаемая стабилизация введенных критериев при увеличении объема выборки. Для линейных моделей подтверждена сходимость предложенных вероятностных критериев достаточности.

Полученные результаты имеют теоретическое значение для развития математических основ машинного обучения и анализа параметрических моделей, поскольку связывают локальную геометрию оптимизационной поверхности, спектральные свойства матрицы Гессе и достаточный размер обучающей выборки в рамках единой постановки. Практическая значимость работы состоит в возможности использования разработанных критериев и оценок при теоретически обоснованной оценке достаточного объема данных, при анализе

чувствительности моделей к увеличению выборки, а также при интерпретации достаточности выборки в терминах стабилизации ландшафта функции потерь.

К числу перспектив дальнейшего развития темы относятся:

1. распространение полученных результатов на более широкий класс архитектур, включая трансформерные и гибридные нейросетевые модели;
2. уточнение связи между стабилизацией ландшафта функции потерь и обобщающей способностью моделей;
3. развитие более точных архитектурно-зависимых оценок локальной кривизны с учетом нормализаций, остаточных связей и современных механизмов внимания;
4. исследование критериев достаточного размера выборки для обобщенно-линейных и нелинейных вероятностных моделей;
5. разработка вычислительно эффективных процедур практической оценки достаточности выборки для больших моделей машинного обучения.

Таким образом, в работе предложен теоретический подход к исследованию достаточного размера обучающей выборки на основе анализа локальных свойств оптимизационной поверхности, получены строгие результаты для нейросетевых и линейных моделей и намечены направления дальнейшего развития этой тематики в рамках специальности 1.2.1 — «Искусственный интеллект и машинное обучение».

В заключение автор выражает благодарность и глубокую признательность научному руководителю к.ф.-м.н. Грабовому А. В. за поддержку, помощь, обсуждение результатов и научное руководство.

Список сокращений и условных обозначений

$\mathbb{R}$	множество вещественных чисел
$\mathbb{X} \subset \mathbb{R}^n$	пространство исходной переменной
$\mathbf{x} \in \mathbb{X}$	вектор признакового описания
$\mathbb{Y} \subset \mathbb{R}^K$	пространство целевой переменной
$\mathbf{y} \in \mathbb{Y}$	целевая переменная (вектор)
$y \in \mathbb{Y}$	целевая переменная (скаляр)
$p(\mathbf{x}, \mathbf{y})$	неизвестное распределение данных
$\mathfrak{D}_m = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^m$	выборка из m независимых реализаций пар $(\mathbf{x}, \mathbf{y})$ согласно неизвестному распределению $p(\mathbf{x}, \mathbf{y})$
$\mathbb{W} \subset \mathbb{R}^N$	пространство параметров модели
$\mathbf{w} \in \mathbb{W}$	вектор параметров модели
$f_{\mathbf{w}} : \mathbb{X} \rightarrow \mathbb{Y}$	параметрическая модель
$\ell : \mathbb{Y} \times \mathbb{Y} \rightarrow \mathbb{R}$	функция ошибки
$\mathcal{L}_m : \mathbb{W} \rightarrow \mathbb{R}$	эмпирическая функция потерь на выборке $\mathfrak{D}_m$
$\mathcal{L} : \mathbb{W} \rightarrow \mathbb{R}$	популяционная функция потерь
$p(\mathbf{w})$	априорное распределение параметров модели
$\mathbf{g}_i(\mathbf{w}) \in \mathbb{R}^N$	вектор градиента эмпирической функции потерь на i -м объекте
$\mathbf{g}^{(m)}(\mathbf{w}) \in \mathbb{R}^N$	вектор градиента эмпирической функции потерь на выборке $\mathfrak{D}_m$
$\mathbf{H}_i(\mathbf{w}) \in \mathbb{R}^{N \times N}$	матрица Гессе эмпирической функции потерь на i -м объекте
$\mathbf{H}^{(m)}(\mathbf{w}) \in \mathbb{R}^{N \times N}$	матрица Гессе эмпирической функции потерь на выборке $\mathfrak{D}_m$
$\mathbf{w}_m^* \in \mathbb{W}$	точка локального минимума функции потерь на выборке $\mathfrak{D}_m$
$\mathbf{z} = f_{\mathbf{w}}(\mathbf{x}) \in \mathbb{R}^K$	выход модели
$\mathbf{J}(\mathbf{w}) \in \mathbb{R}^{K \times N}$	якобиан выхода модели по параметрам
$\mathbf{A}(\mathbf{w}) \in \mathbb{R}^{K \times K}$	матрица кривизны функции потерь по выходу модели
$\mathbf{G}(\mathbf{w}) \in \mathbb{R}^{N \times N}$	гаусс-ньютоновская компонента матрицы Гессе
$\mathbf{R}(\mathbf{w}) \in \mathbb{R}^{N \times N}$	остаточная компонента матрицы Гессе

$\mathbf{G}^{(p,q)}(\mathbf{w}) \in \mathbb{R}^{N_p \times N_q}$	блок гаусс-ньютоновской матрицы, соответствующий параметрам p -го и q -го слоев
$\mathbf{S}^{(p)}(\mathbf{w}) \in \mathbb{R}^{K \times n_p}$	матрица распространения возмущения преактивации p -го слоя к выходу сети
N_p	число параметров p -го слоя
n_p	размерность пространства преактивации p -го слоя
$\mathbf{P}^{(p)}(\mathbf{w}) \in \mathbb{R}^{n_p \times N_p}$	параметрический якобиан p -го слоя
$\text{vec}(\cdot)$	оператор векторизации
$\text{vec}_r(\cdot)$	оператор векторизации (по строкам)
$\mathbf{D}^{(p)}(\mathbf{w}) \in \mathbb{R}^{n_p \times n_p}$	диагональная матрица производных активации
$q(\mathbf{w})$	функция предпочтения по выбору точек для оценки сходимости ландшафта функции потерь
$\Delta_p(k)$	критерий p -сходимости ландшафта функции потерь
$\Delta_1(k)$	абсолютный одноточечный критерий сходимости ландшафта функции потерь
$\Delta_2(k)$	среднеквадратичный критерий сходимости ландшафта функции потерь
$\Delta_2^{(D)}(k)$	среднеквадратичный критерий сходимости в подпространстве наибольшей кривизны размерности D
$\mathcal{S}_D \subset \mathbb{R}^N$	подпространство наибольшей кривизны размерности D
λ_i	собственное значение матрицы Гессе
$\mathbf{u}_i \in \mathbb{R}^N$	собственный вектор матрицы Гессе
$M_G(\mathcal{A})$	локальная архитектурно-зависимая константа кривизны
$\mathbf{X}_m = [\mathbf{x}_1, \dots, \mathbf{x}_m]^\top \in \mathbb{R}^{m \times n}$	матрица объекты-признаки
$\mathbf{y}_m = [y_1, \dots, y_m]^\top \in \mathbb{R}^m$	вектор значений целевой переменной
$L(\mathfrak{D}_m, \mathbf{w})$	функция правдоподобия выборки
$l(\mathfrak{D}_m, \mathbf{w})$	логарифмическая функция правдоподобия выборки
$\hat{\mathbf{w}}_k \in \mathbb{R}^n$	оценка максимума правдоподобия по подвыборке $\mathfrak{D}_k$
$\mathcal{I}(\mathbf{w}) \in \mathbb{R}^{n \times n}$	информационная матрица Фишера
s-score	функция близости распределений s-score

Публикации автора по теме диссертации

В рецензируемых научных журналах

- A1. *Kiselev, N.* Sample Size Determination: Likelihood Bootstrapping / N. Kiselev, A. Grabovoy // Computational Mathematics and Mathematical Physics. — 2025. — Vol. 65, no. 2. — P. 416—423.
- A2. *Kiselev, N.* Sample Size Determination: Posterior Distributions Proximity / N. Kiselev, A. Grabovoy // Computational Management Science. — 2025. — Vol. 22, no. 1. — P. 1.
- A3. *Kiselev, N.* Unraveling the Hessian: A Key to Smooth Convergence in Loss Function Landscapes / N. Kiselev, A. Grabovoy // Doklady Mathematics. — 2024. — Vol. 110, S1. — S49—S61.

В сборниках трудов конференций

- A4. *Киселев, Н. С.* Определение достаточного размера выборки по апостериорному распределению параметров модели / Н. С. Киселев, А. В. Грабовой // Труды 66-й Всероссийской научной конференции МФТИ, 1–6 апреля 2024 г. — 2024. — С. 141.
- A5. *Meshkov, V.* ConvNets Landscape Convergence: Hessian-Based Analysis of Matricized Networks / V. Meshkov, N. Kiselev, A. Grabovoy // 2024 Ivannikov Ispras Open Conference (ISPRAS). — 2024. — P. 1—10.
- A6. *Киселев, Н. С.* Сходимость поверхности функции потерь как признак достаточного размера выборки / Н. С. Киселев, А. В. Грабовой // Труды 67-й Всероссийской научной конференции МФТИ. — 2025.
- A7. *Мешков, В. С.* Сходимость ландшафта сверточных нейронных сетей: анализ матричных сетей на основе гессиана / В. С. Мешков, Н. С. Киселев, А. В. Грабовой // Труды 67-й Всероссийской научной конференции МФТИ. — 2025.

- A8. *Киселев, Н. С.* Достаточный размер обучающей выборки и его связь со сходимостью поверхности функции потерь / Н. С. Киселев, В. С. Мешков, А. В. Грабовой // Тезисы докладов 22-й всероссийской конференции с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября, 2025 г. — 2025. — С. 73—76.

Список литературы

1. *Vapnik, V. N.* The Nature of Statistical Learning Theory / V. N. Vapnik. — New York : Springer, 1995.
2. Scaling Laws for Neural Language Models / J. Kaplan [et al.] // arXiv preprint arXiv:2001.08361. — 2020.
3. Training Compute-Optimal Large Language Models / J. Hoffmann [et al.] // Advances in Neural Information Processing Systems. — 2022.
4. Visualizing the Loss Landscape of Neural Nets / H. Li [et al.] // Advances in Neural Information Processing Systems. — 2018. — P. 6389—6399.
5. *Fort, S.* Emergent Properties of the Local Geometry of Neural Loss Landscapes / S. Fort, S. Ganguli // arXiv preprint arXiv:1910.05929. — 2019.
6. Essentially No Barriers in Neural Network Energy Landscape / F. Draxler [et al.] // Proceedings of the 35th International Conference on Machine Learning. Vol. 80. — 2018. — P. 1309—1318. — (Proceedings of Machine Learning Research).
7. Loss Surfaces, Mode Connectivity, and Fast Ensembling of DNNs / T. Garipov [et al.] // Advances in Neural Information Processing Systems. — 2018. — P. 8803—8812.
8. Entropy-SGD: Biasing Gradient Descent into Wide Valleys / P. Chaudhari [et al.] // Journal of Statistical Mechanics: Theory and Experiment. — 2019. — Vol. 2019, no. 12. — P. 124018.
9. *Papayan, V.* Measurements of Three-Level Hierarchical Structure in the Outliers in the Spectrum of Deepnet Hessians / V. Papayan // Proceedings of the 36th International Conference on Machine Learning. Vol. 97. — 2019. — P. 5012—5021. — (Proceedings of Machine Learning Research).
10. *Seber, G. A. F.* Linear Regression Analysis / G. A. F. Seber, A. J. Lee. — 2nd ed. — Wiley, 2003.
11. *Strang, G.* Linear Algebra and Its Applications / G. Strang. — 4th ed. — Cengage Learning, 2006.

12. *Воронцов, К. В.* Комбинаторная теория надёжности обучения по прецедентам : дис. ... канд. / Воронцов Константин Вячеславович. — МГУ имени М. В. Ломоносова, 2010.
13. Identifying and Attacking the Saddle Point Problem in High-Dimensional Non-Convex Optimization / Y. N. Dauphin [et al.] // Advances in Neural Information Processing Systems. — 2014.
14. The Loss Surfaces of Multilayer Networks / A. Choromanska [et al.] // Artificial Intelligence and Statistics. — 2015.
15. *Goodfellow, I. J.* Qualitatively Characterizing Neural Network Optimization Problems / I. J. Goodfellow, O. Vinyals, A. M. Saxe // International Conference on Learning Representations. — 2015.
16. The Role of Permutation Invariance in Linear Mode Connectivity of Neural Networks / R. Entezari [et al.] // International Conference on Learning Representations. — 2022.
17. *Ainsworth, S. K.* Git Re-Basin: Merging Models modulo Permutation Symmetries / S. K. Ainsworth, J. Hayase, S. Srinivasa // International Conference on Learning Representations. — 2023.
18. *Self, S. G.* Power/Sample Size Calculations for Generalized Linear Models / S. G. Self, R. H. Mauritsen // Biometrics. — 1988. — Vol. 44, no. 1. — P. 79—86.
19. *Self, S. G.* Power Calculations for Likelihood Ratio Tests in Generalized Linear Models / S. G. Self, R. H. Mauritsen, J. Ohara // Biometrics. — 1992. — Vol. 48, no. 1. — P. 31—39.
20. *Shieh, G.* On Power and Sample Size Calculations for Likelihood Ratio Tests in Generalized Linear Models / G. Shieh // Biometrics. — 2000. — Vol. 56, no. 4. — P. 1192—1196.
21. *Shieh, G.* On Power and Sample Size Calculations for Wald Tests in Generalized Linear Models / G. Shieh // Statistics in Medicine. — 2005. — Vol. 24, no. 10. — P. 1559—1578.
22. *Demidenko, E.* Sample Size Determination for Logistic Regression Revisited / E. Demidenko // Statistics in Medicine. — 2007. — Vol. 26, no. 18. — P. 3385—3397.

23. *Motrenko, A.* Sample Size Determination for Logistic Regression / A. Motrenko, V. Strijov // Expert Systems with Applications. — 2014. — Vol. 41, no. 16. — P. 7432—7439.
24. *Lindley, D. V.* The Choice of Sample Size / D. V. Lindley // The Statistician. — 1997. — Vol. 46, no. 2. — P. 129—138.
25. *Rubin, D. B.* Sample Size Determination Using Posterior Predictive Distribution / D. B. Rubin, H. S. Stern, V. Vehovar // Journal of the American Statistical Association. — 1998. — Vol. 93, no. 441. — P. 291—300.
26. *Wang, F.* A Simulation-Based Approach to Bayesian Sample Size Determination for Performance Under a Given Model and for Separating Models / F. Wang, A. E. Gelfand // Statistical Science. — 2002. — Vol. 17, no. 2. — P. 193—208.
27. *Vorontsov, K. V.* Combinatorial Probability and the Tightness of Generalization Bounds / K. V. Vorontsov // Pattern Recognition and Image Analysis. — 2008. — Vol. 18, no. 2. — P. 243—259.
28. *Воронцов, К. В.* Комбинаторная теория переобучения и её применения / К. В. Воронцов. — 2012. — Обзорные материалы и курс лекций.
29. *Bartlett, P. L.* Spectrally-Normalized Margin Bounds for Neural Networks / P. L. Bartlett, D. J. Foster, M. Telgarsky // Advances in Neural Information Processing Systems. — 2017.
30. Understanding Deep Learning Requires Rethinking Generalization / C. Zhang [et al.] // International Conference on Learning Representations. — 2017.
31. *Kingma, D. P.* Adam: A Method for Stochastic Optimization / D. P. Kingma, J. Ba // International Conference on Learning Representations. — 2015.
32. Entropy-SGD: Biasing Gradient Descent into Wide Valleys / P. Chaudhari [et al.] // Journal of Statistical Mechanics: Theory and Experiment. — 2019. — No. 12. — P. 124018.
33. Sharpness-Aware Minimization for Efficiently Improving Generalization / P. Foret [et al.] // International Conference on Learning Representations. — 2021.

34. On Large-Batch Training for Deep Learning: Generalization Gap and Sharp Minima / N. S. Keskar [et al.] // International Conference on Learning Representations. — 2017.
35. Deep Residual Learning for Image Recognition / K. He [et al.] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. — 2016.
36. *Ioffe, S.* Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift / S. Ioffe, C. Szegedy // Proceedings of the 32nd International Conference on Machine Learning. — 2015.
37. *Ba, J. L.* Layer Normalization / J. L. Ba, J. R. Kiros, G. E. Hinton // arXiv preprint arXiv:1607.06450. — 2016.
38. *Ulyanov, D.* Instance Normalization: The Missing Ingredient for Fast Stylization / D. Ulyanov, A. Vedaldi, V. Lempitsky // arXiv preprint arXiv:1607.08022. — 2016.
39. *Wu, Y.* Group Normalization / Y. Wu, K. He // Proceedings of the European Conference on Computer Vision. — 2018.
40. Dropout: A Simple Way to Prevent Neural Networks from Overfitting / N. Srivastava [et al.] // Journal of Machine Learning Research. — 2014. — Vol. 15, no. 56. — P. 1929—1958.
41. Query-Key Normalization for Transformers / A. Henry [et al.] // Findings of the Association for Computational Linguistics: EMNLP. — 2020.
42. *Hochreiter, S.* Flat Minima / S. Hochreiter, J. Schmidhuber // Neural Computation. — 1997. — Vol. 9, no. 1. — P. 1—42.
43. *Ghorbani, B.* An Investigation into Neural Net Optimization via Hessian Eigenvalue Density / B. Ghorbani, S. Krishnan, Y. Xiao // Proceedings of the 36th International Conference on Machine Learning. — 2019.
44. A Deeper Look at the Hessian Eigenspectrum of Deep Neural Networks and Its Applications to Regularization / A. R. Sankar [et al.] // Proceedings of the AAAI Conference on Artificial Intelligence. — 2021.
45. *Singh, S. P.* Analytic Insights into Structure and Rank of Neural Network Hessian Maps / S. P. Singh, G. Bachmann, T. Hofmann // Advances in Neural Information Processing Systems. — 2021.

46. *Bishop, C. M.* Exact Calculation of the Hessian Matrix for the Multilayer Perceptron / C. M. Bishop // Neural Computation. — 1992. — Vol. 4, no. 4. — P. 494—501.
47. *Pearlmutter, B. A.* Fast Exact Multiplication by the Hessian / B. A. Pearlmutter // Neural Computation. — 1994. — Vol. 6, no. 1. — P. 147—160.
48. *Martens, J.* Estimating the Hessian by Back-Propagating Curvature / J. Martens, I. Sutskever, K. Swersky // Proceedings of the 29th International Conference on Machine Learning. — 2012.
49. *Ormaniec, W.* What Does It Mean to Be a Transformer? Insights from a Theoretical Hessian Analysis / W. Ormaniec, F. Dangel, S. P. Singh // arXiv preprint arXiv:2410.10986. — 2024.
50. *Nocedal, J.* Numerical Optimization / J. Nocedal, S. J. Wright. — 2nd ed. — Springer, 2006.
51. *Dennis, J. E.* Numerical Methods for Unconstrained Optimization and Non-linear Equations / J. E. Dennis, R. B. Schnabel. — Prentice-Hall, 1983.
52. *Broyden, C. G.* The Convergence of a Class of Double-Rank Minimization Algorithms. I. General Considerations / C. G. Broyden // IMA Journal of Applied Mathematics. — 1970. — Vol. 6, no. 1. — P. 76—90.
53. *Fletcher, R.* A New Approach to Variable Metric Algorithms / R. Fletcher // The Computer Journal. — 1970. — Vol. 13, no. 3. — P. 317—322.
54. *Martens, J.* Deep Learning via Hessian-Free Optimization / J. Martens // Proceedings of the 27th International Conference on Machine Learning. — 2010.
55. Why Transformers Need Adam: A Hessian Perspective / Y. Zhang [et al.] // Advances in Neural Information Processing Systems. — 2024.
56. Empirical Analysis of the Hessian of Over-Parametrized Neural Networks / L. Sagun [et al.] // arXiv preprint arXiv:1706.04454. — 2017.
57. *Papayan, V.* Measurements of Three-Level Hierarchical Structure in the Outliers in the Spectrum of Deepnet Hessians / V. Papayan // Proceedings of the 36th International Conference on Machine Learning. Vol. 97. — 2019. — P. 5012—5021. — (Proceedings of Machine Learning Research).

58. *Papayan, V.* Traces of Class/Cross-Class Structure Pervade Deep Learning Spectra / V. Papayan // Journal of Machine Learning Research. — 2020. — Vol. 21, no. 252. — P. 1—67.
59. *Pearlmutter, B. A.* Fast Exact Multiplication by the Hessian / B. A. Pearlmutter // Neural Computation. — 1994. — Vol. 6, no. 1. — P. 147—160.
60. *Martens, J.* Optimizing Neural Networks with Kronecker-factored Approximate Curvature / J. Martens, R. Grosse // Proceedings of the 32nd International Conference on Machine Learning. — 2015.
61. *Botev, A.* Practical Gauss-Newton Optimisation for Deep Learning / A. Botev, H. Ritter, D. Barber // Proceedings of the 34th International Conference on Machine Learning. — 2017.
62. *Zhao, J.* Theoretical Characterisation of the Gauss-Newton Conditioning in Neural Networks / J. Zhao, S. P. Singh, A. Lucchi // Advances in Neural Information Processing Systems. — 2024.
63. Understanding Optimisation Methods for Deep Neural Networks through Spectral Hessian Analyses / R. Xin, B. Zhao, [et al.] // arXiv preprint. — 2018.
64. *Hochreiter, S.* Flat Minima / S. Hochreiter, J. Schmidhuber // Neural Computation. — 1997. — Vol. 9, no. 1. — P. 1—42.
65. *Arjevani, Y.* Analytic Characterization of the Hessian in Shallow ReLU Networks: Generalization and Symmetry Breaking / Y. Arjevani, M. Field, N. Srebro // Advances in Neural Information Processing Systems. — 2020.
66. The Hessian Perspective into the Nature of Convolutional Neural Networks / S. P. Singh [et al.] // Proceedings of Machine Learning Research. — 2023. — Vol. 202. — P. 31584—31631.
67. *Young, W. H.* On the Multiplication of Successions of Fourier Constants / W. H. Young // Proceedings of the Royal Society of London. Series A, Containing Papers of a Mathematical and Physical Character. — 1912. — Vol. 87, no. 596. — P. 331—339.
68. Gradient-Based Learning Applied to Document Recognition / Y. LeCun [et al.] // Proceedings of the IEEE. — 1998. — Vol. 86, no. 11. — P. 2278—2324.

69. *Golub, G. H.* Matrix Computations / G. H. Golub, C. F. Van Loan. — 4th ed. — Johns Hopkins University Press, 2013.
70. *Yoshida, Y.* Spectral Norm Regularization for Improving the Generalizability of Deep Learning / Y. Yoshida, T. Miyato // arXiv preprint arXiv:1705.10941. — 2017.
71. *Vapnik, V. N.* Statistical Learning Theory / V. N. Vapnik. — Wiley, 1998.
72. *Shalev-Shwartz, S.* Understanding Machine Learning: From Theory to Algorithms / S. Shalev-Shwartz, S. Ben-David. — Cambridge University Press, 2014.
73. *Qumsiyeh, M.* Using the Bootstrap for Estimating the Sample Size in Statistical Experiments / M. Qumsiyeh // Journal of Modern Applied Statistical Methods. — 2013. — Vol. 12, no. 1. — P. 45—53.
74. *McCullagh, P.* Generalized Linear Models / P. McCullagh, J. A. Nelder. — 2nd ed. — London : Chapman, Hall, 1989.
75. *Motrenko, A.* Sample Size Estimation for Logistic Regression Using Cross-Validation and Kullback–Leibler Divergence / A. Motrenko, V. Strijov // Journal of Machine Learning Research. — 2014. — Vol. 15. — P. 743—761.
76. *Bishop, C. M.* Pattern Recognition and Machine Learning / C. M. Bishop. — New York : Springer, 2006.
77. *Vaart, A. W. van der.* Asymptotic Statistics / A. W. van der Vaart. — Cambridge : Cambridge University Press, 1998. — (Cambridge Series in Statistical and Probabilistic Mathematics).
78. *Kleijn, B. J. K.* The Bernstein–Von–Mises Theorem under Misspecification / B. J. K. Kleijn, A. W. van der Vaart // Electronic Journal of Statistics. — 2012. — Vol. 6. — P. 354—381.
79. *Cover, T. M.* Elements of Information Theory / T. M. Cover, J. A. Thomas. — 2nd ed. — Hoboken, NJ : Wiley-Interscience, 2006.
80. *Villani, C.* Optimal Transport: Old and New. Vol. 338 / C. Villani. — Berlin : Springer, 2009. — (Grundlehren der mathematischen Wissenschaften).
81. *Aduenko, A.* Selection of Multimodels in Classification Tasks : дис. ... канд. / Aduenko Alexander. — Moscow Institute of Physics, Technology, 2017.

82. *UCI Machine Learning Repository*. Liver Disorders / UCI Machine Learning Repository. — 2016. — Dataset. DOI: 10.24432/C54G67. URL: <https://archive.ics.uci.edu/ml/datasets/liver+disorders>.

Список рисунков

2.1	Блочная структура гаусс—ньютоновской компоненты	22
2.2	Слева: отношение $\ \mathbf{G}\ _2/\ \mathbf{H}\ _2$ в контрольных точках обучения для MLP. Справа: сопоставление эмпирически измеренных значений $\ \mathbf{G}\ _2$ с верхней оценкой, вычисляемой в экспериментальном коде . .	38
2.3	Результаты для CNN. Слева: отношение $\ \mathbf{G}\ _2/\ \mathbf{H}\ _2$ в контрольных точках обучения; при визуализации значения также ограничиваются диапазоном $[0, 1]$. Справа: сопоставление эмпирических значений $\ \mathbf{G}\ _2$ с грубой-оценкой, вычисляемой в экспериментальном коде	39
3.1	Иллюстрация предположения 3.2.1 о слабом градиентном рассогласовании для эмпирических функций потерь на k и $k + 1$ объектах	47
3.2	Иллюстрация абсолютного одноточечного критерия сходимости $\Delta_1(k)$	49
3.3	Иллюстрация среднеквадратичного критерия сходимости $\Delta_2(k)$. . .	52
3.4	Иллюстрация среднеквадратичного критерия сходимости в подпространстве наибольшей кривизны $\Delta_2^{(D)}(k)$	57
3.5	Зависимость критериев $\Delta_1(k)$, $\Delta_2(k)$ и $\Delta_2^{(D)}(k)$ от размера выборки k в логарифмических координатах. Пунктирные линии соответствуют теоретическим показателям $\propto k^{-1}$ и $\propto k^{-2}$	63
3.6	Собственные значения матрицы Гессе λ_i (логарифмическая шкала) на разных эпохах обучения. Убывание близко к экспоненциальному .	64
3.7	Двумерные сечения ландшафта функции потерь: случайные направления (слева) и направления максимальной кривизны (справа)	65
3.8	Трехмерная иллюстрация ландшафта функции потерь в окрестности минимума	65
4.1	Сходимость критерия $\Delta_2(m)$ для различных архитектур. Штриховая линия показывает теоретическую скорость $\propto m^{-2}$	88
4.2	Влияние глубины на достаточный размер выборки. Слева: зависимость m^* от L для MLP и CNN. Справа: сравнение MLP и CNN при одинаковой глубине	89

4.3	Достаточный размер выборки $m^*(\epsilon)$ в зависимости от числа параметров для MLP и CNN	90
4.4	Обобщающий разрыв $\hat{\mathcal{E}}(m)$ в зависимости от размера выборки. На графике показаны только положительные средние значения гар . . .	91
4.5	Аппроксимация обобщающего разрыва степенным законом. Слева: индивидуальные показатели степени для каждой архитектуры. Справа: аппроксимация с общим показателем ρ_{shared}	92
5.1	Визуализация критериев D-достаточности (уменьшение дисперсии функции правдоподобия) и M-достаточности (уменьшение изменения функции правдоподобия при добавлении новых объектов) размера выборки в вероятностной модели линейной регрессии	98
5.2	Визуализация критериев KL-достаточности и S-достаточности (близость апостериорных распределений параметров на схожих подвыборках) размера выборки в вероятностной модели линейной регрессии	100
5.3	Изменение апостериорных распределений параметров на схожих подвыборках по мере увеличения их размера. Одномерный случай, где на графиках изображены плотности распределений	111
5.4	Изменение апостериорных распределений параметров на схожих подвыборках по мере увеличения их размера. Двумерный случай, где на графиках изображены линии уровня	112
5.5	Сходимость функций $D(k)$ и $M(k)$ в различных задачах и на различных выборках. Значения обоих критериев стремятся к нулю при увеличении размера выборки	115
5.6	Изменение минимального собственного значения матрицы $\mathbf{X}_k^T \mathbf{X}_k$ при увеличении размера выборки в задачах синтетической линейной регрессии и регрессии на датасете Liver Disorders	116
5.7	Сходимость функций $KL(k)$ и $S(k)$ в различных задачах и на различных выборках. Оба критерия стремятся к предельным значениям при увеличении размера выборки	117

- 5.8 Зависимость достаточного размера выборки согласно введенным критериям от гиперпараметра ϵ . Рассматриваются три задачи: синтетическая регрессия и классификация, а также регрессия на датасете Liver Disorders. Чем больше значение гиперпараметра ϵ , тем меньше требуется обучающих объектов 118

Список таблиц

1	Архитектуры, используемые в экспериментах по оценке спектральных норм: полносвязная и сверточная	37
2	Оцененные показатели степенного закона $\Delta(k) \sim k^{-\alpha}$	64
3	Архитектуры для экспериментов	87
4	Достаточный размер выборки $m^*(\epsilon)$ для критерия Δ_2	88
5	Сравнение предложенных критериев достаточного размера выборки на множестве реальных выборок с задачей регрессии. Пропуски означают, что первоначальный размер выборки недостаточен	114