

Законы масштабирования параметрических моделей машинного обучения на основе локальных свойств оптимизационной поверхности

Киселев Никита Сергеевич
Научный руководитель: к.ф.-м.н. Грабовой А. В.

68-я Всероссийская научная конференция МФТИ
ФПМИ — Секция проблем интеллектуального анализа данных,
распознавания и прогнозирования

4 апреля 2026 г.

Законы масштабирования и достаточный размер выборки

Исследуется связь между архитектурой параметрической модели, локальной геометрией оптимизационной поверхности и объемом данных для устойчивого обучения.

Проблема

Эмпирические законы масштабирования для современных моделей хорошо наблюдаются на практике, однако не имеют общего теоретического объяснения. При этом множество оптимальных параметров зависит от конечной обучающей выборки.

Требуется

Построить теоретическую схему, связывающую архитектуру модели, локальную кривизну поверхности функции потерь и достаточный размер обучающей выборки.

Метод решения

Предлагается анализировать **стабилизацию ландшафта функции потерь** при увеличении объема выборки. Для линейных моделей используются апостериорные распределения параметров, для нейросетей — локальная геометрия поверхности и спектральные свойства матрицы Гессе.

Разложение Гаусса—Ньютона матрицы Гессе

Эмпирическая функция потерь

$$\mathfrak{D}_m = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^m, \quad \mathbf{x} \in \mathbb{R}^n, \quad \mathbf{y} \in \mathbb{R}^K$$

$$\mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \ell(f_{\mathbf{w}}(\mathbf{x}_i), \mathbf{y}_i)$$

Матрица Гессе

$$\mathbf{H}^{(m)}(\mathbf{w}) = \nabla_{\mathbf{w}}^2 \mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \mathbf{H}_i(\mathbf{w}) \in \mathbb{R}^{N \times N}$$

Обозначения на одном объекте

$$\mathbf{z} = f_{\mathbf{w}}(\mathbf{x}) \in \mathbb{R}^K, \quad \mathbf{J}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{w}} \in \mathbb{R}^{K \times N},$$

$$\mathbf{A}(\mathbf{w}) = \nabla_{\mathbf{z}}^2 \ell(\mathbf{z}, \mathbf{y}) \in \mathbb{R}^{K \times K}$$

Разложение Гаусса—Ньютона

$$\mathbf{H}(\mathbf{w}) = \mathbf{G}(\mathbf{w}) + \mathbf{R}(\mathbf{w})$$


$$\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w})$$

$$\mathbf{R}(\mathbf{w}) = \sum_{k=1}^K \frac{\partial \ell(\mathbf{z}, \mathbf{y})}{\partial z_k} \nabla_{\mathbf{w}}^2 z_k$$

Ключевая идея

В окрестности минимума $\|\mathbf{G}(\mathbf{w})\|_2 \approx \|\mathbf{H}(\mathbf{w})\|_2$, поэтому далее локальная кривизна анализируется через **гаусс—ньютоновскую компоненту** $\|\mathbf{G}(\mathbf{w})\|_2$.

Блочная факторизация гаусс—ньютоновская компоненты $\mathbf{G}(\mathbf{w})$



Лемма (Киселев, 2026)

Для нейронной сети $f_{\mathbf{w}}$ с архитектурой $\mathbf{z}^{(p)} = T_{\mathbf{w}^{(p)}}^{(p)}(\mathbf{x}^{(p)})$, $\mathbf{x}^{(p+1)} = \sigma^{(p)}(\mathbf{z}^{(p)})$, где операторы $T_{\mathbf{w}^{(p)}}^{(p)}$ линейны по входу, каждый блок $\mathbf{G}^{(p,q)}(\mathbf{w})$ выражается через параметрические якобианы слоев $\mathbf{P}^{(p)}(\mathbf{w}) = \partial \mathbf{z}^{(p)} / \partial \mathbf{w}^{(p)}$ и матрицы распространения возмущения $\mathbf{S}^{(p)}(\mathbf{w}) = \partial \mathbf{z} / \partial \mathbf{z}^{(p)}$ по формуле $\mathbf{G}^{(p,q)}(\mathbf{w}) = \mathbf{P}^{(p)\top} \mathbf{S}^{(p)\top} \mathbf{A}(\mathbf{w}) \mathbf{S}^{(q)} \mathbf{P}^{(q)}$.

Спектральные оценки и вычислительный эксперимент 1

Теорема (Киселев, 2024)

Пусть $f_{\mathbf{w}}$ является L -слойной

полносвязной нейронной сетью,

$\|\mathbf{x}\|_2 \leq M_{\mathbf{x}}$, $\|\mathbf{A}(\mathbf{w})\|_2 \leq M_{\mathbf{A}}$, и для всех

$p = 1, \dots, L$ верно $\|\mathbf{W}^{(p)}\|_2 \leq M_{\mathbf{W}}$,

$\|\mathbf{D}^{(p)}\|_2 \leq M_{\sigma}$, тогда

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq LM_{\mathbf{x}}^2 M_{\mathbf{A}} (M_{\mathbf{W}} M_{\sigma})^{2L-2}$$

Теорема (Мешков, Киселев, 2024)

Пусть $f_{\mathbf{w}}$ является L -слойной **сверточной**

нейронной сетью, $K_{\max} = \max_p(C_{\text{out}})$,


$\|\mathbf{x}\|_2 \leq M_{\mathbf{x}}$, $\|\mathbf{A}(\mathbf{w})\|_2 \leq M_{\mathbf{A}}$, и для всех

$p = 1, \dots, L$ верно $\|\mathcal{W}^{(p)}\|_1 \leq M_{\mathcal{W}}$,

$\|\mathbf{D}^{(p)}\|_2 \leq M_{\sigma}$, тогда

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq LM_{\mathbf{x}}^2 M_{\mathbf{A}} K_{\max} (M_{\mathcal{W}} M_{\sigma})^{2L-2}$$

- 1) 10-классовая классификация MNIST;
- 2) Архитектура CNN, варьируются L и h ;
- 3) Спектральная норма численно оценивается методом степенных итераций.




Критерий сходимости поверхности функции потерь

Критерий p -сходимости ландшафта функции потерь при добавлении одного объекта в выборку $\mathfrak{D}_k$:

$$\Delta_p(k+1) = \int |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|^p q(\mathbf{w}) d\mathbf{w},$$

где функция $q : \mathbb{R}^N \rightarrow \mathbb{R}_+$ задает предпочтение по выбору точек в пространстве параметров модели для оценки сходимости.




- 1) Без ограничения общности, $\int q(\mathbf{w}) d\mathbf{w} = 1$, т.е. $q(\mathbf{w})$ суть плотность распределения;
- 2) Нас интересует локальная геометрия в окрестности минимума $\rightarrow$ определяем $q(\mathbf{w})$ с основной массой возле минимума.

Абсолютный одноточечный критерий сходимости

Абсолютный одноточечный критерий сходимости:

$$\Delta_1(k+1) = |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|,$$

где $\mathbf{w} \in \mathcal{U}_R(\mathbf{w}_k^*)$ — точка из окрестности радиуса $R > 0$ минимума $\mathbf{w}_k^*$, т.е. $p = 1$ и $q(\tilde{\mathbf{w}}) = \delta(\tilde{\mathbf{w}} - \mathbf{w})$.



Теорема (Киселев, 2024)

Пусть в $\mathcal{U}_R(\mathbf{w}_k^*)$ справедлива квадратичная аппроксимация, $\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{g}}$ и для всех $i = 1, \dots, k+1$ верно $|\ell_i(\mathbf{w}_k^*)| \leq M_{\ell}$, $\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{H}}$, тогда

$$\Delta_1(k+1) \leq \frac{2M_{\ell} + M_{\mathbf{g}}R + M_{\mathbf{H}}R^2}{k+1} = \mathcal{O}(k^{-1}).$$

Среднеквадратичный критерий сходимости

Среднеквадратичный критерий сходимости:

$$\Delta_2(k+1) = \mathbb{E}_{q(\mathbf{w})} \left[(\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 \right],$$


т.е. $p = 2$, для теоретического анализа удобно выбрать $q(\mathbf{w}) = \mathcal{N}(\mathbf{w}_k^*, \sigma^2 \mathbf{I}_N)$, а на практике вычисляется методом Монте—Карло через $\mathbf{w}_s \sim q(\mathbf{w})$:

$$\hat{\Delta}_2(k+1) = \frac{1}{S} \sum_{s=1}^S (\mathcal{L}_{k+1}(\mathbf{w}_s) - \mathcal{L}_k(\mathbf{w}_s))^2.$$

Теорема (Киселев, 2025)

Пусть в $\mathcal{U}_R(\mathbf{w}_k^*)$ справедлива квадратичная аппроксимация, $\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{g}}$ и для всех $i = 1, \dots, k+1$ верно $|\ell_i(\mathbf{w}_k^*)| \leq M_{\ell}$, $\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{H}}$, тогда

$$\Delta_2(k+1) \leq \frac{12M_{\ell}^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(N^2 + 2N)M_{\mathbf{H}}}{(k+1)^2} = \mathcal{O}(k^{-2}).$$



Среднеквадратичный критерий сходимости в подпространстве наибольшей кривизны размерности D

Обозначим $\mathbf{H}^{(k)}(\mathbf{w}_k^*)\mathbf{u}_i = \lambda_i^{(k)}\mathbf{u}_i$, $\lambda_1^{(k)} \geq \dots \geq \lambda_N^{(k)}$, $\mathbf{U}_D = [\mathbf{u}_1, \dots, \mathbf{u}_D] \in \mathbb{R}^{N \times D}$, $\mathcal{S}_D = \text{Im}(\mathbf{U}_D)$, тогда среднеквадратичный критерий с $\text{supp } q \subset \mathbf{w}_k^* + \mathcal{S}_D$:


$$\Delta_2^{(D)}(k+1) = \mathbb{E}_{q(\mathbf{w})} \left[(\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 \right],$$

На практике вычисляется методом Монте—Карло через $\mathbf{w}_s = \mathbf{w}_k^* + \mathbf{U}_D \mathbf{z}_s$, где $\mathbf{z}_s \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D)$.

Теорема (Киселев, 2026)

Пусть в $\mathcal{U}_R(\mathbf{w}_k^*)$ справедлива квадратичная аппроксимация, $\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_g$ и для всех $i = 1, \dots, k+1$ верно $|\ell_i(\mathbf{w}_k^*)| \leq M_\ell$, $\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_H$, тогда




$$\Delta_2^{(D)}(k+1) \leq \frac{12M_\ell^2 + 3\sigma^2 M_g^2 + 3\sigma^4 (D^2 + 2D)M_H}{(k+1)^2} = \mathcal{O}(k^{-2}).$$



Вычислительный эксперимент 2

- 1) 10-классовая классификация на MNIST;
- 2) Архитектура MLP, варьируются L и h ;
- 3) Численные значения критериев вычисляются методом Монте—Карло со 100 точками;
- 4) Собственные значения и векторы матрицы Гессе вычисляются методом степенной итерации.

Критерий	Оценка α	R^2	Теория
Δ_1	2,33	0,63	1
Δ_2	1,94	1,00	2
$\Delta_2^{(D=5)}$	1,80	0,96	2
$\Delta_2^{(D=10)}$	1,83	0,99	2
$\Delta_2^{(D=20)}$	1,84	0,99	2



Достаточный размер выборки и законы масштабирования

Достаточный размер выборки

$$\Delta(m) \in \left\{ \Delta_1(m), \Delta_2(m), \Delta_2^{(D)}(m) \right\}$$

$$\forall m \geq m^* \quad \Delta(m) \leq \varepsilon$$

Архитектурно-зависимая локальная кривизна

$$M_{\mathbf{G}}(\mathcal{A}) = \sup_{\mathbf{w} \in \mathcal{U}_R(\mathbf{w}^*)} \sup_i \|\mathbf{G}_i(\mathbf{w})\|_2$$

$$\|\mathbf{H}_i(\mathbf{w})\|_2 \leq M_{\mathbf{G}}(\mathcal{A}) + \delta_R$$

Ключевой вывод

Архитектура модели влияет на достаточный размер выборки через **локальную кривизну** и скорость **стабилизации ландшафта** функции потерь.

Теоретическая схема законов масштабирования

$$\mathcal{L}_m(\mathbf{w}_m^*) \lesssim E + \Phi(N) + \frac{C(M_{\mathbf{G}}(\mathcal{A}) + \delta_R)}{m^\rho}$$

Следствия

- 1) Рост N уменьшает ошибку выразимости $\Phi(N)$;
- 2) Рост m уменьшает вклад конечности выборки как $m^{-\rho}$;
- 3) Коэффициент при $m^{-\rho}$ определяется архитектурой через $M_{\mathbf{G}}(\mathcal{A})$.

Стабилизация правдоподобия линейной регрессии в точке ОМП

Вероятностная линейная регрессия

$$\mathbf{x} \in \mathbb{R}^n, \quad \mathbf{X}_m = [\mathbf{x}_1, \dots, \mathbf{x}_m]^\top \in \mathbb{R}^{m \times n}$$

$$y \in \mathbb{R}, \quad \mathbf{y}_m = [y_1, \dots, y_m]^\top \in \mathbb{R}^m$$

$$L(\mathfrak{D}_m, \mathbf{w}) = p(\mathbf{y}_m | \mathbf{X}_m, \mathbf{w}) = \prod_{i=1}^m \mathcal{N}(y_i | \mathbf{w}^\top \mathbf{x}_i, \sigma^2)$$


$$\hat{\mathbf{w}}_k = \arg \max_{\mathbf{w} \in \mathbb{R}^n} L(\mathfrak{D}_k, \mathbf{w}), \quad \mathbb{E} \hat{\mathbf{w}}_k = \mathbf{m}_k, \quad \mathbb{D} \hat{\mathbf{w}}_k = \Sigma_k$$

M -достаточный размер: $\forall k \geq m^*$

$$M(k+1) = |\mathbb{E}_{\mathfrak{D}_{k+1}} L(\mathfrak{D}_m, \hat{\mathbf{w}}_{k+1}) - \mathbb{E}_{\mathfrak{D}_k} L(\mathfrak{D}_m, \hat{\mathbf{w}}_k)| \leq \varepsilon$$

Теорема (Киселев, 2024)

Пусть $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$ и $\|\Sigma_{k+1} - \Sigma_k\|_F \rightarrow 0$ при $k \rightarrow \infty$, тогда определение M -достаточности корректно, то есть $\forall \varepsilon > 0 \exists m^* \in \mathbb{N} : \forall k \geq m^* M(k) \leq \varepsilon$.



D -достаточный размер: $\forall k \geq m^*$

$$D(k) = \mathbb{D}_{\mathfrak{D}_k} L(\mathfrak{D}_m, \hat{\mathbf{w}}_k) \leq \varepsilon$$

Апостериорные распределения линейной регрессии на подвыборках

Апостериоры на схожих подвыборках $|\mathfrak{D}_k \triangle \mathfrak{D}_{k+1}| = 1$

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w} | \mathbf{m}_0, \Sigma_0), \quad p_k(\mathbf{w}) = p(\mathbf{w} | \mathfrak{D}_k) = \mathcal{N}(\mathbf{w} | \mathbf{m}_k, \Sigma_k)$$

$$\Sigma_k^{-1} = \Sigma_0^{-1} + \frac{1}{\sigma^2} \mathbf{X}_k^\top \mathbf{X}_k, \quad \mathbf{m}_k = \Sigma_k \left(\Sigma_0^{-1} \mathbf{m}_0 + \frac{1}{\sigma^2} \mathbf{X}_k^\top \mathbf{y}_k \right)$$


$$D_{\text{KL}}(p \| q) = \int p(\mathbf{w}) \log \frac{p(\mathbf{w})}{q(\mathbf{w})} d\mathbf{w}, \quad \text{s-score}(p, q) = \frac{\int p(\mathbf{w}) q(\mathbf{w}) d\mathbf{w}}{\max_{\mathbf{b}} \int p(\mathbf{w} - \mathbf{b}) q(\mathbf{w}) d\mathbf{w}},$$

KL -достаточный размер: $\forall k \geq m^*$

S -достаточный размер: $\forall k \geq m^*$

$$KL(k+1) = D_{\text{KL}}(p_k \| p_{k+1}) \leq \varepsilon$$

$$S(k+1) = \text{s-score}(p_k, p_{k+1}) \leq \varepsilon$$




Теорема (Киселев, 2024)

Пусть для всех $i = 1, \dots, k+1$ верно $\|\mathbf{x}_i\|_2 \leq M_{\mathbf{x}}$, $|y_i| \leq M_y$ и $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k) = \omega(\sqrt{k})$ при $k \rightarrow \infty$, тогда определения KL - и S -достаточности корректны, а для разбиения выборки $\mathfrak{D}_m = \mathfrak{D}_{m_1}^{\text{train}} \sqcup \mathfrak{D}_{m_2}^{\text{test}}$ верно $D_{\text{KL}}(p(\mathbf{y}_{\text{test}} | \mathbf{X}_{\text{test}}, \mathbf{X}_k, \mathbf{y}_k) \| p(\mathbf{y}_{\text{test}} | \mathbf{X}_{\text{test}}, \mathbf{X}_{k+1}, \mathbf{y}_{k+1})) \rightarrow 0$.

Вычислительный эксперимент 3

- 1) Рассматриваются задачи регрессии и классификации на синтетических и реальных данных из библиотеки UCI;
- 2) Варьируется значение гиперпараметра ε для исследования зависимости критериев M -, D -, KL - и S -достаточности от него;



По графикам видно, что M - и S -достаточные размеры выборки более консервативны по сравнению с их аналогами D - и KL -достаточности, соответственно.

Выносятся на защиту

- 1) Теоремы о верхних оценках спектральной нормы гаусс-ньютоновской компоненты матрицы Гессе для полносвязных и сверточных архитектур нейронных сетей.
- 2) Критерии стабилизации ландшафта функции потерь в нейронных сетях, построенные для одной точки, для распределения точек в полном пространстве параметров и для подпространства главных собственных направлений матрицы Гессе.
- 3) Теоретическая схема законов масштабирования параметрических моделей машинного обучения, связывающая архитектуру модели, локальную кривизну оптимизационной поверхности и объем обучающей выборки.
- 4) Критерии достаточного размера выборки для параметрических моделей, основанные на стабилизации ландшафта функции потерь.
- 5) Критерии достаточного размера выборки для вероятностных линейных моделей, основанные на стабилизации распределения оптимальных параметров при увеличении объема данных.

Список работ автора по теме диссертации

Публикации в рецензируемых научных журналах (BAK, Web of Science, Scopus)

- 1) **Kiselev N.**, Meshkov V., Grabovoy A. Robust Convergence of Loss Landscapes through Distributional Averaging // *Proceedings of the ISP RAS*, 2025.
- 2) Meshkov V., **Kiselev N.**, Grabovoy A. ConvNets Landscape Convergence: Hessian-Based Analysis of Matricized Networks // *Ivannikov ISPRAS Open Conference*, 2024.
- 3) **Kiselev N.**, Grabovoy A. Unraveling the Hessian: A Key to Smooth Convergence in Loss Function Landscapes // *Doklady Mathematics*, 2024.
- 4) **Kiselev N.**, Grabovoy A. Sample Size Determination: Posterior Distributions Proximity // *Computational Management Science*, 2025.
- 5) **Kiselev N.**, Grabovoy A. Sample Size Determination: Likelihood Bootstrapping // *Computational Mathematics and Mathematical Physics*, 2025.

Выступления с докладом

- 1) Устойчивая сходимость поверхности функции потерь через усреднение по распределению // Открытая конференция ИСП РАН, 2025.
- 2) Достаточный размер выборки и его связь со сходимостью поверхности функции потерь // 22-я Всероссийская конференция с международным участием «Математические методы распознавания образов», 2025.
- 3) Сходимость поверхности функции потерь как признак достаточного размера выборки // 67-я Всероссийская научная конференция МФТИ, 2025.
- 4) Определение достаточного размера выборки по апостериорному распределению параметров модели // 66-я Всероссийская научная конференция МФТИ, 2024.