

Ландшафтный метод оценки масштабируемости параметрических моделей машинного обучения

Киселев Никита Сергеевич

Научный руководитель: к.ф.-м.н. Грабовой А. В.

Диссертация на соискание ученой степени кандидата физико-математических наук
1.2.1 — Искусственный интеллект и машинное обучение

Москва — 2026

Ландшафтный метод оценки масштабируемости параметрических моделей машинного обучения

Проблема

Эмпирические законы масштабирования воспроизводятся на практике, но не имеют общего теоретического объяснения. Множество оптимальных параметров зависит от конечной обучающей выборки.

Требуется

Описать зависимость качества параметрической модели заданной архитектуры от ее размера и объема обучающих данных для их совместного выбора и определить достаточный размер выборки.

Метод решения

Анализ локальной геометрии **ландшафта функции потерь** и ее стабилизации при росте выборки: для нейронных сетей — через спектр матрицы Гессе, для линейных моделей — через правдоподобие и апостериорные распределения.

Выборка и модель

Объект $(\mathbf{x}, \mathbf{y})$: $\mathbf{x} \in \mathbb{R}^n$ — признаковое описание, $\mathbf{y} \in \mathbb{R}^K$ — целевая переменная. Выборка $\mathfrak{D}_m = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^m$ состоит из m независимых реализаций пары $(\mathbf{x}, \mathbf{y})$ из неизвестного распределения $p(\mathbf{x}, \mathbf{y})$. Параметрическая модель $f_{\mathbf{w}}: \mathbb{R}^n \rightarrow \mathbb{R}^K$, $\mathbf{w} \in \mathbb{R}^N$, аппроксимирует зависимость $\mathbf{y}$ от $\mathbf{x}$.

Задача обучения

$$\mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \underbrace{\ell(f_{\mathbf{w}}(\mathbf{x}_i), \mathbf{y}_i)}_{\ell_i(\mathbf{w})} \rightarrow \min_{\mathbf{w} \in \mathbb{R}^N}, \quad \mathbf{w}_m^* \in \arg \min_{\mathbf{w} \in \mathbb{R}^N} \mathcal{L}_m(\mathbf{w}),$$

$\mathcal{L}(\mathbf{w}) = \mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim p} \ell(f_{\mathbf{w}}(\mathbf{x}), \mathbf{y})$ — популяционный риск.

Локальная геометрия ландшафта

$$\mathbf{g}^{(m)}(\mathbf{w}) = \nabla_{\mathbf{w}} \mathcal{L}_m(\mathbf{w}) \in \mathbb{R}^N, \quad \mathbf{H}^{(m)}(\mathbf{w}) = \nabla_{\mathbf{w}}^2 \mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \mathbf{H}_i(\mathbf{w}) \in \mathbb{R}^{N \times N}.$$

Обозначения на одном объекте $(\mathbf{x}, \mathbf{y})$

$$\mathbf{z} = f_{\mathbf{w}}(\mathbf{x}) \in \mathbb{R}^K, \quad \mathbf{J}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{w}} \in \mathbb{R}^{K \times N}, \quad \mathbf{A}(\mathbf{w}) = \nabla_{\mathbf{z}}^2 \ell(\mathbf{z}, \mathbf{y}) \in \mathbb{R}^{K \times K}.$$

Разложение матрицы Гессе на одном объекте


$$\mathbf{H}(\mathbf{w}) = \mathbf{G}(\mathbf{w}) + \mathbf{R}(\mathbf{w}), \quad \mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w}), \quad \mathbf{R}(\mathbf{w}) = \sum_{c=1}^K \frac{\partial \ell(\mathbf{z}, \mathbf{y})}{\partial z_c} \nabla_{\mathbf{w}}^2 z_c.$$

Ключевая идея

Остаточная компонента $\mathbf{R}(\mathbf{w})$ пропорциональна производным $\partial \ell / \partial z_c$ и **ослабевает в окрестности минимума**, а также вносит вклад преимущественно в область малых собственных значений. Спектрально значимую часть матрицы Гессе задает **гаусс—ньютоновская компонента $\mathbf{G}(\mathbf{w})$** : через нее в кривизну входит архитектура модели.

Определение

Сеть **матрично-представима**, если $\mathbf{x}^{(1)} = \mathbf{x}$, $\mathbf{z}^{(p)} = T_{\mathbf{w}^{(p)}}^{(p)}(\mathbf{x}^{(p)})$, $\mathbf{x}^{(p+1)} = \sigma^{(p)}(\mathbf{z}^{(p)})$, $f_{\mathbf{w}}(\mathbf{x}) = \mathbf{z}^{(L)}$, где оператор $T_{\mathbf{w}^{(p)}}^{(p)}$ линеен по входу и допускает матричное представление по параметрам $\mathbf{w}^{(p)} \in \mathbb{R}^{N_p}$.



Лемма (Киселев, 2026)

Пусть $f_{\mathbf{w}}$ — матрично-представимая сеть. Тогда $\mathbf{G}(\mathbf{w}) = [\mathbf{G}^{(p,q)}(\mathbf{w})]_{p,q=1}^L$, где

$$\mathbf{G}^{(p,q)}(\mathbf{w}) = \mathbf{P}^{(p)\top} \mathbf{S}^{(p)\top} \mathbf{A}(\mathbf{w}) \mathbf{S}^{(q)} \mathbf{P}^{(q)}, \quad \mathbf{P}^{(p)} = \frac{\partial \mathbf{z}^{(p)}}{\partial \mathbf{w}^{(p)}}, \quad \mathbf{S}^{(p)} = \frac{\partial \mathbf{z}}{\partial \mathbf{z}^{(p)}}.$$

Теорема (Киселев, 2024)

Пусть $f_{\mathbf{w}}$ — L -слойная **полносвязная** сеть без смещений и для всех $p = 1, \dots, L$

$$\|\mathbf{x}\|_2 \leq M_{\mathbf{x}}, \quad \|\mathbf{A}(\mathbf{w})\|_2 \leq M_{\mathbf{A}}, \quad \|\mathbf{W}^{(p)}\|_2 \leq M_{\mathbf{W}}, \quad \|\mathbf{D}^{(p)}\|_2 \leq M_{\sigma},$$

где $\mathbf{D}^{(p)}$ — матрица производных активации. Тогда

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq LM_{\mathbf{x}}^2 M_{\mathbf{A}} (M_{\mathbf{W}} M_{\sigma})^{2L-2}.$$


Если, кроме того, $\sigma = \text{ReLU}$, а ℓ — кросс-энтропия, то $\|\mathbf{G}(\mathbf{w})\|_2 \leq \sqrt{2} LM_{\mathbf{x}}^2 M_{\mathbf{W}}^{2L-2}$.

Теорема (Мешков, Киселев, 2024)


Пусть $f_{\mathbf{w}}$ — L -слойная **сверточная** сеть без смещений, для всех $p = 1, \dots, L$ выполнено $\|\mathbf{x}\|_2 \leq M_{\mathbf{x}}, \|\mathbf{A}(\mathbf{w})\|_2 \leq M_{\mathbf{A}}, \|\mathcal{W}^{(p)}\|_1 \leq M_{\mathcal{W}}, \|\mathbf{D}^{(p)}\|_2 \leq M_{\sigma}$ и $K_{\max} = \max_p C_{\text{out}}^{(p)} k_h k_w$. Тогда

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq LM_{\mathbf{x}}^2 M_{\mathbf{A}} K_{\max} (M_{\mathcal{W}} M_{\sigma})^{2L-2}.$$

Цель: проверить, что $\|\mathbf{G}\|_2$ близка к $\|\mathbf{H}\|_2$, и сравнить верхние оценки с измеренными нормами. **Постановка:** MNIST, 10 классов; MLP (L линейных слоев) и CNN (L сверточных слоев, глобальное усреднение, линейный классификатор), $L \in \{2, 4, 8\}$, ширина $h \in \{64, 128, 256\}$; Adam, 10 эпох. Нормы вычисляются степенным методом на мини-пакете 128 после инициализации и эпох 1, 5, 10.



MLP: (a) $\|\mathbf{G}\|_2 / \|\mathbf{H}\|_2$; (б) оценка/измерение



CNN: (a) $\|\mathbf{G}\|_2 / \|\mathbf{H}\|_2$; (б) оценка/измерение

Вывод

На поздних эпохах $\|\mathbf{G}\|_2 \approx \|\mathbf{H}\|_2$: компонента $\mathbf{G}$ приближает спектрально значимую часть $\mathbf{H}$. Превышение оценки над измерением растет с глубиной, как множитель $(M_{\mathbf{W}} M_{\sigma})^{2L-2}$: оценка передает структуру зависимости от архитектуры, а не точное значение нормы.

Критерий сходимости поверхности функции потерь

Критерий p -сходимости ландшафта функции потерь при добавлении одного объекта в выборку $\mathfrak{D}_k$ с минимумом $\mathbf{w}_k^*$ функции $\mathcal{L}_k$:

$$\Delta_p(k+1) = \int |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|^p q(\mathbf{w}) d\mathbf{w},$$


где плотность q с основной массой вблизи $\mathbf{w}_k^*$ задает **функцию предпочтения** точек в пространстве параметров.

Утверждение (тождество усреднения)

Для любой точки $\mathbf{w}$

$$\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) = \frac{\ell_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})}{k+1}.$$

Поэтому если $|\ell_i(\mathbf{w})| \leq M_\ell$ для всех i , то $\Delta_p(k+1) \leq (2M_\ell)^p / (k+1)^p$: порядок k^{-p} задается усреднением по объектам, а локальная геометрия ландшафта определяет константу.



Шаг 1. Квадратичная аппроксимация в $\mathcal{U}_R(\mathbf{w}_k^*)$

С учетом $\mathbf{g}^{(k)}(\mathbf{w}_k^*) = \mathbf{0}$ и $\mathbf{d} = \mathbf{w} - \mathbf{w}_k^*$:

$$\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) = a_k + \mathbf{b}_k^\top \mathbf{d} + \frac{1}{2} \mathbf{d}^\top \mathbf{A}_k \mathbf{d},$$

$$a_k = \mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*), \quad \mathbf{b}_k = \mathbf{g}^{(k+1)}(\mathbf{w}_k^*) = \frac{\mathbf{g}_{k+1}(\mathbf{w}_k^*)}{k+1},$$

$$\mathbf{A}_k = \mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*).$$


Шаг 2. Слабое градиентное рассогласование

$\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_g$, т.е. $\|\nabla \mathcal{L}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_g/(k+1)$: новый объект почти не нарушает стационарность точки $\mathbf{w}_k^*$.

Шаг 3. Оценка слагаемых и интегрирование по q

При $|\ell_i(\mathbf{w}_k^*)| \leq M_\ell$ и $\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_H$


$$|a_k| \leq \frac{2M_\ell}{k+1}, \quad \|\mathbf{b}_k\|_2 \leq \frac{M_g}{k+1}, \quad \|\mathbf{A}_k\|_2 \leq \frac{2M_H}{k+1}.$$



Абсолютный одноточечный критерий сходимости:

$$\Delta_1(k+1) = |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|,$$

где $\mathbf{w} \in \mathcal{U}_R(\mathbf{w}_k^*)$ — точка из окрестности радиуса $R > 0$ минимума $\mathbf{w}_k^*$, т. е. $p = 1$ и $q(\tilde{\mathbf{w}}) = \delta(\tilde{\mathbf{w}} - \mathbf{w})$.



Теорема (Киселев, 2024)


Пусть в $\mathcal{U}_R(\mathbf{w}_k^*)$ справедлива квадратичная аппроксимация, $\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{g}}$ и для всех $i = 1, \dots, k+1$ верно $|\ell_i(\mathbf{w}_k^*)| \leq M_{\ell}$, $\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{H}}$. Тогда

$$\Delta_1(k+1) \leq \frac{2M_{\ell} + M_{\mathbf{g}}R + M_{\mathbf{H}}R^2}{k+1} = \mathcal{O}(k^{-1}).$$

Среднеквадратичный критерий сходимости:

$$\Delta_2(k+1) = \mathbb{E}_{q(\mathbf{w})} \left[(\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 \right],$$

т. е. $p = 2$ и $q(\mathbf{w}) = \mathcal{N}(\mathbf{w}_k^*, \sigma^2 \mathbf{I}_N)$; на практике критерий оценивается методом Монте—Карло по точкам $\mathbf{w}_s \sim q(\mathbf{w})$.



Теорема (Киселев, 2025)

Пусть выполнены условия предыдущей теоремы. Тогда

$$\Delta_2(k+1) \leq \frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4 (\mathbf{N}^2 + 2N) M_{\mathbf{H}}^2}{(k+1)^2} = \mathcal{O}(k^{-2}).$$

Критерий в подпространстве наибольшей кривизны

Обозначим $\mathbf{H}^{(k)}(\mathbf{w}_k^*)\mathbf{u}_i = \lambda_i^{(k)}\mathbf{u}_i$, $\lambda_1^{(k)} \geq \dots \geq \lambda_N^{(k)}$,
 $\mathbf{U}_D = [\mathbf{u}_1, \dots, \mathbf{u}_D]$, $\mathcal{S}_D = \text{Im } \mathbf{U}_D$. Критерий
с $\text{supp } q \subset \mathbf{w}_k^* + \mathcal{S}_D$:


$$\Delta_2^{(D)}(k+1) = \mathbb{E}_{q(\mathbf{w})} \left[(\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 \right],$$

где $\mathbf{w} = \mathbf{w}_k^* + \mathbf{U}_D \mathbf{z}$, $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D)$.

Теорема (Киселев, 2026)


Пусть выполнены условия теоремы об одноточечном критерии. Тогда

$$\Delta_2^{(D)}(k+1) \leq \frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(D^2 + 2D)M_{\mathbf{H}}^2}{(k+1)^2} = \mathcal{O}(k^{-2}).$$



Эксперимент: скорость стабилизации ландшафта

Цель: проверить, что критерии убывают с ростом выборки с предсказанным порядком, и сравнить полный критерий с подпространственным. **Постановка:** MNIST, MLP с одним скрытым слоем ширины 64. Для каждого k от 100 до 10 000 сеть обучается 100 эпох Adam, затем вычисляются Δ_1 (100 направлений радиуса 0,5), Δ_2 (200 точек Монте—Карло, $\sigma = 0,5$) и $\Delta_2^{(D)}$, $D \in \{5, 10, 20\}$. Три инициализации.




Штриховая линия — теоретический наклон -2 через одну точку ряда Δ_2

Вывод


Δ_2 убывает со скоростью, близкой к $\mathcal{O}(k^{-2})$; $\Delta_2^{(D)}$ имеет близкий порядок и меньшие значения: кривизна в значительной, но не полной мере сосредоточена в маломерном подпространстве. Степенная аппроксимация Δ_1 ненадежна из-за высокой вариативности.

Критерий	$\hat{\alpha}$ в $k^{-\alpha}$	R^2	Теория
Δ_1	2,33	0,63	≥ 1
Δ_2	1,94	1,00	≈ 2
$\Delta_2^{(5)}$	1,80	0,96	≈ 2
$\Delta_2^{(10)}$	1,83	0,99	≈ 2
$\Delta_2^{(20)}$	1,84	0,99	≈ 2

Цель: показать анизотропию ландшафта — рост функции потерь вдоль ведущих собственных направлений матрицы Гессе. **Постановка:** та же сеть, $k = 1000$, 100 эпох. Сечения $\mathcal{L}(\mathbf{w} + \alpha \mathbf{d}_1 + \beta \mathbf{d}_2)$, $\alpha, \beta \in [-1, 1]$, $\|\mathbf{d}_i\| = 1$: (а) случайные ортогональные направления, (б) два ведущих собственных вектора.



Линии уровня; шкалы цвета различны



Те же сечения, общая вертикальная ось

Вывод

Вдоль случайных направлений функция потерь остается в пределах 0,0032–0,0037, вдоль ведущих собственных векторов ($\lambda_1 \approx 1,74$, $\lambda_2 \approx 1,58$) поднимается примерно до 25: ландшафт выраженно анизотропен.

Достаточный размер выборки

Определение

Пусть $\Delta(m)$ — один из критериев $\Delta_1, \Delta_2, \Delta_2^{(D)}$.

Размер m^* называется **ε -достаточным** по критерию Δ , если

$$\Delta(m) \leq \varepsilon \quad \text{для всех } m \geq m^*.$$


Архитектурно-зависимая кривизна

$$M_G(\mathcal{A}) = \sup_{\mathbf{w} \in \mathcal{U}_R(\mathbf{w}^*)} \sup_i \|\mathbf{G}_i(\mathbf{w})\|_2,$$

$$\delta_R = \sup_{\mathbf{w} \in \mathcal{U}_R(\mathbf{w}^*)} \sup_i \|\mathbf{R}_i(\mathbf{w})\|_2.$$

Утверждение

Во всех оценках главы 2 можно положить $M_H = M_G(\mathcal{A}) + \delta_R$: достаточный размер выборки зависит от архитектуры через $M_G(\mathcal{A})$.



Оценка сверху на критерий дает явный ε -достаточный размер $m^*(\varepsilon, \mathcal{A})$; он не меньше наименьшего m^* .

Явные оценки достаточного размера выборки

Пусть в окрестности минимума $\|\mathbf{H}_i(\mathbf{w})\|_2 \leq M_{\mathbf{G}}(\mathcal{A}) + \delta_R$.

Теорема (Киселев, 2026)

Пусть выполнены условия теоремы об одноточечном критерии. Тогда размер

$$m_1^*(\varepsilon, \mathcal{A}) = \frac{2M_\ell + M_{\mathbf{g}}R + (M_{\mathbf{G}}(\mathcal{A}) + \delta_R)R^2}{\varepsilon}$$

является ε -достаточным по критерию Δ_1 .

Теорема (Киселев, 2026)




Пусть выполнены условия теорем о среднеквадратичных критериях. Тогда размеры

$$m_2^*(\varepsilon, \mathcal{A}) = \sqrt{\frac{C(N)}{\varepsilon}}, \quad m_3^*(\varepsilon, \mathcal{A}, D) = \sqrt{\frac{C(D)}{\varepsilon}}, \quad C(d) = 12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(d^2 + 2d)(M_{\mathbf{G}}(\mathcal{A}) + \delta_R)^2,$$

являются ε -достаточными по критериям Δ_2 и $\Delta_2^{(D)}$ соответственно.

Следствие. Для L -слойной полносвязной сети $M_{\mathbf{G}}(\mathcal{A}) \leq LM_{\mathbf{x}}^2 M_{\mathbf{A}} (M_{\mathbf{W}} M_{\sigma})^{2L-2}$, для сверточной — $LM_{\mathbf{x}}^2 M_{\mathbf{A}} K_{\max} (M_{\mathbf{W}} M_{\sigma})^{2L-2}$, поэтому достаточный размер явно зависит от глубины.

Цель: проверить предсказание теории — достаточный размер выборки растет с глубиной архитектуры. **Постановка:** MNIST; MLP- $L-h$ (L линейных слоев ширины h) и CNN- $L-c$ (L сверточных слоев с c каналами, ядро 3×3), $L \in \{2, 4, 8\}$. Для каждого m от 100 до 30 000 модель обучается с нуля (100 эпох Adam, три запуска), затем вычисляется $\Delta_2(m)$ и $m^*(\varepsilon, \mathcal{A}) = \min\{m : \Delta_2(m) \leq \varepsilon\}$.



$\Delta_2(m)$; штриховая линия — наклон -2

m^* при $\varepsilon = 0,05$; пустой треугольник — порог не достигнут

Вывод

$\Delta_2(m)$ убывает с порядком, близким к $\mathcal{O}(m^{-2})$. Внутри каждого семейства m^* монотонно растет с глубиной; для $L = 8$ порог $\varepsilon = 0,05$ не достигнут до 30 000. Преимущество CNN отчетливо для мелких моделей ($m^* = 100, 200$ против 300, 500 при $L = 2$), но не универсально.

Популяционный риск $\mathcal{L}(\mathbf{w}) = \mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim p} \ell(f_{\mathbf{w}}(\mathbf{x}), \mathbf{y})$; $\mathcal{W}_N \subset \mathbb{R}^N$ — модели с N параметрами, $\mathbf{w}_{\infty}^*$ — минимизатор риска в предельном классе, $\mathbf{w}_m^*$ — решение по выборке $\mathcal{D}_m$.

Декомпозиция (тождество)

$$\mathbb{E}_{\mathcal{D}_m} \mathcal{L}(\mathbf{w}_m^*) = \underbrace{\mathcal{L}(\mathbf{w}_{\infty}^*)}_{E \text{ — неустраняемая}} + \underbrace{\inf_{\mathbf{w} \in \mathcal{W}_N} \mathcal{L}(\mathbf{w}) - E}_{\Phi(N) \text{ — выразимость}} + \underbrace{\mathbb{E}_{\mathcal{D}_m} \mathcal{L}(\mathbf{w}_m^*) - \inf_{\mathbf{w} \in \mathcal{W}_N} \mathcal{L}(\mathbf{w})}_{\mathcal{E}(m) \geq 0 \text{ — оценивание}}.$$

Предположение (локальный статистический режим)

Пусть $\mathbf{w}_m^*$ лежит в области, где квадратичная аппроксимация информативна, δ_R мало по сравнению с $M_{\mathbf{G}}(\mathcal{A})$, а минимум устойчив. Тогда существуют $\rho \in (0, 1]$ и $C > 0$ такие, что $\mathcal{E}(m) \leq C(M_{\mathbf{G}}(\mathcal{A}) + \delta_R)m^{-\rho}$.

Утверждение (Киселев, 2026)

Пусть выполнено предположение о локальном режиме. Тогда

$$\mathbb{E}_{\mathcal{D}_m} \mathcal{L}(\mathbf{w}_m^*) \leq E + \Phi(N) + \frac{C(M_{\mathbf{G}}(\mathcal{A}) + \delta_R)}{m^{\rho}}.$$

Утверждение (Киселев, 2026)

Пусть $y = \mathbf{w}_*^\top \mathbf{x} + \varepsilon$, где $\mathbf{x} \sim \mathcal{N}(\mathbf{0}, \Sigma)$, $\Sigma \succ 0$, шум $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ не зависит от $\mathbf{x}$, $\ell = \frac{1}{2}(y - \mathbf{w}^\top \mathbf{x})^2$, а $\hat{\mathbf{w}}_m$ — оценка наименьших квадратов по $m > n + 1$ объектам. Тогда

$$\mathcal{E}(m) = \mathbb{E}_{\mathfrak{D}_m} \mathcal{L}(\hat{\mathbf{w}}_m) - \mathcal{L}(\mathbf{w}_*) = \frac{\sigma^2 n}{2(m - n - 1)} = \frac{\text{tr}(\mathbf{H}^{-1} \mathbf{C})}{2m} \left(1 + \frac{n + 1}{m - n - 1}\right),$$

где $\mathbf{H} = \Sigma$ — матрица Гессе, $\mathbf{C} = \text{Cov} \nabla \ell(\mathbf{w}_*) = \sigma^2 \Sigma$ — ковариация градиентов.

Лемма


Пусть $\mathbf{H} \succ 0$, $\mathbf{C} \succeq 0$, $\nabla \ell_i = \mathbf{J}_i^\top \mathbf{s}_i$, $\mathbf{A}_i \succeq a_{\min} \mathbf{I}$, $a_{\min} > 0$, и $\|\mathbf{G}_i(\mathbf{w}^*)\|_2 \leq M_{\mathbf{G}}(\mathcal{A})$. Тогда

$$\text{tr}(\mathbf{H}^{-1} \mathbf{C}) \leq \|\mathbf{C}\|_2 \text{tr}(\mathbf{H}^{-1}) \leq \frac{\mathbb{E} \|\mathbf{s}\|^2}{a_{\min}} M_{\mathbf{G}}(\mathcal{A}) \text{tr}(\mathbf{H}^{-1}).$$

Следствие

Пусть, кроме того, $\|\mathbf{x}\| \leq M_{\mathbf{x}}$ и $m \geq 2(n + 1)$. Тогда предположение о локальном режиме выполнено **точно**: $\rho = 1$, $\delta_R = 0$, $M_{\mathbf{G}} = M_{\mathbf{x}}^2$, $C = \sigma^2 \text{tr}(\Sigma^{-1})$.

Цель: проверить асимптотику $\mathbb{E} \mathcal{E}(k) = \text{tr}(\mathbf{H}^{-1}\mathbf{C})/(2k) + o(k^{-1})$ с константой, вычисленной по популяционным матрицам, а не подобранной по кривой обучения. **Постановка:** линейная и логистическая регрессия, $n = 20$, $k \in \{100, 200, 400, 800, 1600\}$, 2 000 повторений на точку; отложено $k \cdot \mathbb{E} \mathcal{E}(k)$, отрезки — две стандартные ошибки; штриховая линия — $\text{tr}(\mathbf{H}^{-1}\mathbf{C})/2$.



Вывод

(а) В линейной регрессии Монте—Карло совпадает с точной формулой. (б) Логистическая регрессия выходит на константу из спектра; замена 15% меток ее почти не сдвигает. Где минимум невырожден и модель не интерполирует выборку, константа совпадает с расчетом.

Постановка

Объект $(\mathbf{x}, y)$: $\mathbf{x} \in \mathbb{R}^n$, $y \in \mathbb{R}$; выборка $\mathfrak{D}_m$ из m независимых реализаций, $\mathbf{X}_m = [\mathbf{x}_1, \dots, \mathbf{x}_m]^\top \in \mathbb{R}^{m \times n}$, $\mathbf{y}_m \in \mathbb{R}^m$. Модель задается правдоподобием

$$p(y | \mathbf{x}, \mathbf{w}) = \mathcal{N}(y | \mathbf{w}^\top \mathbf{x}, \sigma^2), \quad L(\mathfrak{D}_m, \mathbf{w}) = p(\mathbf{y}_m | \mathbf{X}_m, \mathbf{w}) = \prod_{i=1}^m \mathcal{N}(y_i | \mathbf{w}^\top \mathbf{x}_i, \sigma^2).$$

ОМП по подвыборке $\mathfrak{D}_k \subseteq \mathfrak{D}_m$: $\hat{\mathbf{w}}_k = \arg \max_{\mathbf{w}} L(\mathfrak{D}_k, \mathbf{w}) = (\mathbf{X}_k^\top \mathbf{X}_k)^{-1} \mathbf{X}_k^\top \mathbf{y}_k$.

Апостериорное распределение


При $p(\mathbf{w}) = \mathcal{N}(\mathbf{w} | \mathbf{m}_0, \Sigma_0)$: $p_k(\mathbf{w}) = p(\mathbf{w} | \mathfrak{D}_k) = \mathcal{N}(\mathbf{w} | \mathbf{m}_k, \Sigma_k)$,

$$\Sigma_k^{-1} = \Sigma_0^{-1} + \frac{1}{\sigma^2} \mathbf{X}_k^\top \mathbf{X}_k, \quad \mathbf{m}_k = \Sigma_k \left(\Sigma_0^{-1} \mathbf{m}_0 + \frac{1}{\sigma^2} \mathbf{X}_k^\top \mathbf{y}_k \right).$$

Теорема (Киселев, 2025)

Пусть $\|\mathbf{x}\|_2 \leq M$, $|y| \leq M$ и $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k) = \omega(\sqrt{k})$ при $k \rightarrow \infty$. Тогда в линейной регрессии с нормальным априорным распределением $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$ и $\|\Sigma_{k+1} - \Sigma_k\|_F \rightarrow 0$.

Подвыборки $\mathfrak{D}_k \subseteq \mathfrak{D}_m$; правдоподобие на всей выборке $L(\mathfrak{D}_m, \cdot)$ вычисляется в точке ОМП $\hat{\mathbf{w}}_k$. Математическое ожидание и дисперсия по $\mathfrak{D}_k$ оцениваются бутстрапом.



D -достаточность: $\forall k \geq m^*$

$$D(k) = \mathbb{D}_{\mathfrak{D}_k} L(\mathfrak{D}_m, \hat{\mathbf{w}}_k) \leq \varepsilon$$

M -достаточность: $\forall k \geq m^*$

$$M(k+1) = |\mathbb{E}_{\mathfrak{D}_{k+1}} L(\mathfrak{D}_m, \hat{\mathbf{w}}_{k+1}) - \mathbb{E}_{\mathfrak{D}_k} L(\mathfrak{D}_m, \hat{\mathbf{w}}_k)| \leq \varepsilon$$


Теорема (Киселев, 2025)

Пусть $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$ и $\|\Sigma_{k+1} - \Sigma_k\|_F \rightarrow 0$ при $k \rightarrow \infty$. Тогда в модели линейной регрессии определение M -достаточности корректно: $\forall \varepsilon > 0 \exists m^* \forall k \geq m^* M(k) \leq \varepsilon$.

Подвыборки $\mathfrak{D}_k$ и $\mathfrak{D}_{k+1}$ **схожи**, если $|\mathfrak{D}_k \triangle \mathfrak{D}_{k+1}| = 1$.

Близость апостериоров p_k, p_{k+1} измеряется KL-дивергенцией и функцией

$$\text{s-score}(g_1, g_2) = \frac{\int g_1(\mathbf{w})g_2(\mathbf{w}) d\mathbf{w}}{\max_{\mathbf{b}} \int g_1(\mathbf{w} - \mathbf{b})g_2(\mathbf{w}) d\mathbf{w}}.$$



KL-достаточность: $\forall k \geq m^*$

$$KL(k+1) = D_{\text{KL}}(p_k \| p_{k+1}) \leq \varepsilon$$


S-достаточность: $\forall k \geq m^*$

$$S(k+1) = \text{s-score}(p_k, p_{k+1}) \geq 1 - \varepsilon$$

Теорема (Киселев, 2025)

Пусть в модели линейной регрессии с нормальным априорным распределением $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$ при $k \rightarrow \infty$. Тогда определение *S*-достаточности корректно; если, кроме того, $\|\Sigma_{k+1} - \Sigma_k\|_F \rightarrow 0$, то корректно и определение *KL*-достаточности.

Цель: показать, как порог ε переводится в достаточный размер выборки по каждому из критериев. **Постановка:** синтетические регрессия и классификация ($m = 500$, $n = 10$, $B = 100$ бутстрап-подвыборок) и набор Liver Disorders ($m = 345$, $n = 5$, $B = 1000$). Для каждого ε вычисляется m^* по критериям D , M , KL , S (для классификации — D и M).



Вывод

Чем больше ε , тем меньше требуется объектов; все четыре критерия имеют примерно одинаковую зависимость от ε , поэтому порог нужно выбирать обоснованно. На 13 выборках UCI критерии D и M часто дают близкий m^* , а S часто консервативнее KL .

Структура работы



Положения, выносимые на защиту

- 1) Теоремы о верхних оценках спектральной нормы гаусс—ньютоновской компоненты матрицы Гессе для полносвязных и сверточных архитектур нейронных сетей.
- 2) Критерии стабилизации ландшафта функции потерь: порядок $\mathcal{O}(k^{-1})$ и $\mathcal{O}(k^{-2})$ следует из усреднения по объектам, а оценки констант получены по локальной квадратичной аппроксимации в одной точке, в полном пространстве параметров и в подпространстве главных собственных направлений матрицы Гессе.
- 3) Схема законов масштабирования, в которой ошибка оценивания задается отношением шума градиентов к кривизне, и ее точный вид для линейной модели с неполным набором признаков.
- 4) Критерии достаточного размера выборки для параметрических моделей, основанные на стабилизации ландшафта функции потерь.
- 5) Критерии достаточного размера выборки для вероятностных линейных моделей, основанные на стабилизации распределения оптимальных параметров при увеличении объема данных.

Публикации и апробация

Публикации в рецензируемых журналах (BAK, Web of Science, Scopus)

- 1) Kiselev N., Meshkov V., Grabovoy A. Robust Convergence of Loss Landscapes through Distributional Averaging // *Proceedings of the ISP RAS*, 2026.
- 2) Kiselev N., Grabovoy A. Sample Size Determination: Posterior Distributions Proximity // *Computational Management Science*, 2025.
- 3) Kiselev N., Grabovoy A. Sample Size Determination: Likelihood Bootstrapping // *Computational Mathematics and Mathematical Physics*, 2025.
- 4) Kiselev N., Grabovoy A. Unraveling the Hessian: A Key to Smooth Convergence in Loss Function Landscapes // *Doklady Mathematics*, 2024.

Выступления с докладом

- 1) Подпространство наибольшей кривизны в задаче стабилизации ландшафта функции потерь // 16-я Международная конференция «Интеллектуализация обработки информации» (ИОИ-2026), Витебск, 28 сентября—2 октября 2026 г.
- 2) Адаптивный выбор дисперсии гауссовского сэмплирования для оценки сходимости ландшафта потерь методом Монте-Карло // Международная конференция «Иванниковские чтения», Этномир, 28–30 мая 2026 г.
- 3) Среднеквадратичный критерий сходимости ландшафта функции потерь на основе перехода к подпространству главных собственных векторов матрицы Гессе // 68-я Всероссийская научная конференция МФТИ, Москва, 30 марта—4 апреля 2026 г.
- 4) Устойчивая сходимость поверхности функции потерь через усреднение по распределению // Открытая конференция ИСП РАН, Москва, 9–10 декабря 2025 г.
- 5) Достаточный размер выборки и его связь со сходимостью поверхности функции потерь // 22-я Всероссийская конференция с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября 2025 г.
- 6) Сходимость поверхности функции потерь как признак достаточного размера выборки // 67-я Всероссийская научная конференция МФТИ, Москва, 31 марта—5 апреля 2025 г.
- 7) Анализ сходимости поверхности функции потерь сверточных нейросетевых моделей на основе гессиана // Открытая конференция ИСП РАН, Москва, 11–12 декабря 2024 г.
- 8) Определение достаточного размера выборки по апостериорному распределению параметров модели // 66-я Всероссийская научная конференция МФТИ, Москва, 1–6 апреля 2024 г.