

Масштабирование параметрических моделей машинного обучения на основе локальной геометрии оптимизационной поверхности

Киселев Никита Сергеевич

Диссертация на соискание ученой степени
кандидата физико-математических наук

1.2.1 — Искусственный интеллект и машинное обучение

Научный руководитель: к.ф.-м.н. Грабовой А. В.

Москва — 2026

Масштабирование параметрических моделей машинного обучения на основе локальной геометрии оптимизационной поверхности

Проблема

Эмпирические законы масштабирования воспроизводятся на практике, но не имеют общего теоретического объяснения. Множество оптимальных параметров зависит от конечной обучающей выборки.

Требуется

Описать масштабирование параметрических моделей на основе локальной геометрии оптимизационной поверхности и определить по нему достаточный размер обучающей выборки.

Метод решения

Анализ **стабилизации ландшафта функции потерь** при росте выборки: для нейронных сетей — через спектр матрицы Гессе, для линейных моделей — через правдоподобие и апостериорные распределения.

Разложение Гаусса—Ньютона матрицы Гессе

Функция потерь и матрица Гессе

$$\mathfrak{D}_m = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^m$$

$$\mathbf{x} \in \mathbb{R}^n, \quad \mathbf{y} \in \mathbb{R}^K, \quad \mathbf{w} \in \mathbb{R}^N$$

$$\mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \ell_i(\mathbf{w}), \quad \ell_i(\mathbf{w}) = \ell(f_{\mathbf{w}}(\mathbf{x}_i), \mathbf{y}_i)$$

$$\mathbf{H}^{(m)}(\mathbf{w}) = \nabla_{\mathbf{w}}^2 \mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \mathbf{H}_i(\mathbf{w})$$

Обозначения на одном объекте

$$\mathbf{z} = f_{\mathbf{w}}(\mathbf{x}), \quad \mathbf{J} = \frac{\partial \mathbf{z}}{\partial \mathbf{w}}, \quad \mathbf{A} = \nabla_{\mathbf{z}}^2 \ell$$

Разложение Гаусса—Ньютона

$$\mathbf{H}(\mathbf{w}) = \mathbf{G}(\mathbf{w}) + \mathbf{R}(\mathbf{w})$$


$$\mathbf{G} = \mathbf{J}^\top \mathbf{A} \mathbf{J}$$

$$\mathbf{R}(\mathbf{w}) = \sum_{c=1}^K \frac{\partial \ell}{\partial z_c} \nabla_{\mathbf{w}}^2 z_c$$

Ключевая идея

При малых невязках $\mathbf{R}(\mathbf{w})$ мало и $\|\mathbf{G}\|_2 \approx \|\mathbf{H}\|_2$: кривизна анализируется через **компоненту $\mathbf{G}(\mathbf{w})$** .

Блочная факторизация гаусс—ньютоновской компоненты



Лемма (Киселев, 2026)

Сеть матрично-представима, если слой линеен по входу: $\mathbf{z}^{(p)} = T^{(p)}(\mathbf{x}^{(p)})$, $\mathbf{x}^{(p+1)} = \sigma^{(p)}(\mathbf{z}^{(p)})$. Тогда

$$\mathbf{G}^{(p,q)}(\mathbf{w}) = \mathbf{P}^{(p)\top} \mathbf{S}^{(p)\top} \mathbf{A} \mathbf{S}^{(q)} \mathbf{P}^{(q)},$$

где $\mathbf{P}^{(p)} = \partial \mathbf{z}^{(p)} / \partial \mathbf{w}^{(p)}$ — якобиан слоя по своим параметрам, $\mathbf{S}^{(p)} = \partial \mathbf{z} / \partial \mathbf{z}^{(p)}$ — распространение возмущения до выхода.

Оценки спектральной нормы $\|\mathbf{G}\|_2$

Пусть $\|\mathbf{x}\|_2 \leq M_{\mathbf{x}}$, $\|\mathbf{A}\|_2 \leq M_{\mathbf{A}}$, $\|\mathbf{D}^{(p)}\|_2 \leq M_{\sigma}$, где $\mathbf{D}^{(p)}$ — производные активации. Сети без смещений.

Теорема (Киселев, 2024)

L -слойная **полносвязная** сеть, $\|\mathbf{W}^{(p)}\|_2 \leq M_{\mathbf{W}}$:

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq LM_{\mathbf{x}}^2 M_{\mathbf{A}} (M_{\mathbf{W}} M_{\sigma})^{2L-2}.$$


Теорема (Мешков, Киселев, 2024)

L -слойная **сверточная** сеть, $\|\mathcal{W}^{(p)}\|_1 \leq M_{\mathcal{W}}$, $K_{\max} = \max_p (C_{\text{out}}^{(p)} k_h k_w)$:


$$\|\mathbf{G}(\mathbf{w})\|_2 \leq LM_{\mathbf{x}}^2 M_{\mathbf{A}} K_{\max} (M_{\mathcal{W}} M_{\sigma})^{2L-2}.$$

Эксперимент: гаусс—ньютоновская компонента и матрица Гессе

MNIST, 10 эпох Adam, шаг 10^{-3} . MLP и CNN, глубина $L \in \{2, 4, 8\}$, ширина $h \in \{64, 128, 256\}$. Нормы — степенные итерации на мини-пакете 128, контрольные точки: инициализация, эпохи 1, 5 и 10.



Полносвязная сеть



Сверточная сеть

Вывод

На поздних эпохах $\|G\|_2$ и $\|H\|_2$ близки. Превышение верхней оценки над измерением растет с глубиной экспоненциально: у MLP от 10^4 – 10^5 при $L = 2$ до 10^{14} – 10^{21} при $L = 8$. Оценка передает зависимость от архитектуры и не дает точного числа.

Критерий сходимости поверхности функции потерь

К выборке $\mathfrak{D}_k$ с эмпирическим риском $\mathcal{L}_k$ и минимумом $\mathbf{w}_k^*$ добавляется один объект. Пробное распределение q сосредоточено вблизи $\mathbf{w}_k^*$.

Определение

$$\Delta_p(k+1) = \int |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|^p q(\mathbf{w}) d\mathbf{w}.$$

Утверждение (точное представление)

$$\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) = \frac{\ell_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})}{k+1},$$

поэтому $\Delta_p(k+1) = \mathbb{E}_q |\ell_{k+1} - \mathcal{L}_k|^p / (k+1)^p$. Если $|\ell_i| \leq M_\ell$, то

$\Delta_p(k+1) \leq_p (2M_\ell)^p / (k+1)^p$.


Порядок k возникает до разложения Тейлора. Квадратичная аппроксимация и матрица Гессе оценивают числитель, а не порядок.

Абсолютный одноточечный критерий сходимости

Одноточечный критерий — изменение ландшафта в одной точке окрестности минимума радиуса R :

$$\Delta_1(k+1) = |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|,$$

то есть $p = 1$ и q — дельта-мера в точке $\mathbf{w} \in \mathcal{U}_R(\mathbf{w}_k^*)$.



Теорема (Киселев, 2024)

В $\mathcal{U}_R(\mathbf{w}_k^*)$ верна квадратичная аппроксимация, $\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{g}}$, $|\ell_i(\mathbf{w}_k^*)| \leq M_{\ell}$ и $\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{H}}$. Тогда

$$\Delta_1(k+1) \leq \frac{2M_{\ell} + M_{\mathbf{g}}R + M_{\mathbf{H}}R^2}{k+1} = \mathcal{O}(k^{-1}).$$

Среднеквадратичный критерий сходимости

Средний квадрат того же приращения по гауссовскому пробному распределению

$q = \mathcal{N}(\mathbf{w}_k^*, \sigma^2 \mathbf{I}_N)$:

$$\Delta_2(k+1) = \mathbb{E}_q(\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2.$$


На практике среднее заменяется выборкой Монте-Карло $\mathbf{w}_s \sim q$.

Теорема (Киселев, 2025)

В предположениях предыдущей теоремы

$$\Delta_2(k+1) \leq \frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(\mathbf{N}^2 + 2N)M_{\mathbf{H}}^2}{(k+1)^2} = \mathcal{O}(k^{-2}).$$


Множитель $N^2 + 2N$ растет с числом параметров, и константа теряет практический смысл.



Критерий в подпространстве наибольшей кривизны

Пусть $\lambda_1^{(k)} \geq \dots \geq \lambda_N^{(k)}$ — собственные значения $\mathbf{H}^{(k)}(\mathbf{w}_k^*)$, $\mathbf{U}_D = [\mathbf{u}_1, \dots, \mathbf{u}_D]$, $\mathcal{S}_D = \text{Im } \mathbf{U}_D$.
Пробное распределение сосредоточено в $\mathbf{w}_k^* + \mathcal{S}_D$:

$$\mathbf{w} = \mathbf{w}_k^* + \mathbf{U}_D \mathbf{z}, \quad \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D).$$



Теорема (Киселев, 2026)


В предположениях предыдущих теорем

$$\Delta_2^{(D)}(k+1) \leq \frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4 (\mathbf{D}^2 + 2\mathbf{D}) M_{\mathbf{H}}^2}{(k+1)^2} = \mathcal{O}(k^{-2}).$$


Порядок тот же. В константе N заменено размерностью подпространства D .

Эксперимент: стабилизация ландшафта

MNIST, MLP с одним скрытым слоем ширины 64. Для каждого k от 100 до 10 000 сеть обучается 100 эпох. Δ_2 — 200 точек Монте-Карло при $\sigma = 0,5$; подпространство — $D \in \{5, 10, 20\}$. Три инициализации, семена 42, 43, 44.



Δ_2 и сужения; штрих — k^{-2}



Сечения при $k = 1000$

Вывод

Показатель Δ_2 равен 1,94 ($R^2 = 1,00$) при теоретическом значении около 2; штрих через одну точку не подбирался. Сужения на $D = 5, 10, 20$ дают 1,80–1,83 и лежат ниже полного критерия. Вдоль ведущих направлений поверхность поднимается, вдоль случайных остается плоской.

Достаточный размер выборки

Размер m^* называется ε -достаточным по критерию Δ , если $\Delta(m) \leq \varepsilon$ для всех $m \geq m^*$.
Подстановка $\|\mathbf{H}_i\|_2 \leq M_{\mathbf{G}}(\mathcal{A}) + \delta_R$ в оценки предыдущих теорем дает явные пороги.

Теорема (Киселев, 2026). Одноточечный критерий

$$m_1^*(\varepsilon, \mathcal{A}) = \frac{2M_\ell + M_{\mathbf{g}}R + (M_{\mathbf{G}}(\mathcal{A}) + \delta_R)R^2}{\varepsilon}.$$

Теорема (Киселев, 2026). Среднеквадратичный критерий

$$m_2^*(\varepsilon, \mathcal{A}) = \sqrt{\frac{12M_\ell^2 + 3\sigma^2M_{\mathbf{g}}^2 + 3\sigma^4(N^2 + 2N)(M_{\mathbf{G}}(\mathcal{A}) + \delta_R)^2}{\varepsilon}}.$$

Теорема (Киселев, 2026). Подпространство размерности D

$$m_3^*(\varepsilon, \mathcal{A}, D) = \sqrt{\frac{12M_\ell^2 + 3\sigma^2M_{\mathbf{g}}^2 + 3\sigma^4(D^2 + 2D)(M_{\mathbf{G}}(\mathcal{A}) + \delta_R)^2}{\varepsilon}}.$$

Схема закона масштабирования

Средний риск в точке решения раскладывается тождественно:

$$\mathbb{E} \mathcal{L}(\mathbf{w}_m^*) = E + \Phi(N) + \mathcal{E}(m),$$

где E — неустранимая ошибка, $\Phi(N)$ — ошибка выразимости класса с N параметрами, $\mathcal{E}(m) \geq 0$ — ошибка оценивания.

Предположение (Киселев, 2026). Локальный статистический режим

Существуют $\rho \in (0, 1]$ и $C > 0$ такие, что $\mathcal{E}(m) \leq C(M_{\mathbf{G}}(\mathcal{A}) + \delta_R) m^{-\rho}$. Это структурное предположение: оно не следует из предыдущих глав.

Предложение (Киселев, 2026)

$$\mathbb{E} \mathcal{L}(\mathbf{w}_m^*) \leq E + \Phi(N) + \frac{C(M_{\mathbf{G}}(\mathcal{A}) + \delta_R)}{m^\rho}.$$

Для линейной регрессии предположение выполнено точно с $\rho = 1$, а константа ошибки оценивания есть $\text{tr}(\mathbf{H}^{-1}\mathbf{C})/2$, не $\|\mathbf{G}\|_2$.

Линейная модель с неполным набором признаков

Признаки $\mathbf{x} \sim \mathcal{N}(\mathbf{0}, \mathbf{\Lambda})$, $\mathbf{\Lambda} = \text{diag}(\lambda_j)$, ответ $y = \sum_j \theta_j^* x_j + \varepsilon$. Модель с N параметрами видит первые N признаков. $e_j = \lambda_j (\theta_j^*)^2$, $\Phi(N) = \frac{1}{2} \sum_{j>N} e_j$, $\sigma_N^2 = \sigma^2 + 2\Phi(N)$, $E = \sigma^2/2$.

Теорема (Киселев, 2026)

При $m > N + 1$

$$\mathbb{E} \mathcal{L}(\hat{\mathbf{w}}_{N,m}) = \frac{\sigma^2}{2} + \Phi(N) + \frac{\sigma_N^2 N}{2(m - N - 1)},$$


$$\mathcal{E}(N, m) = \frac{\text{tr}(\mathbf{H}_N^{-1} \mathbf{C}_N)}{2m} \left(1 + \frac{N + 1}{m - N - 1} \right), \quad \mathbf{H}_N = \mathbf{\Lambda}_N, \quad \mathbf{C}_N = \sigma_N^2 \mathbf{\Lambda}_N.$$

Следствие (Киселев, 2026). При $e_j = c j^{-b}$, $b > 1$


$\alpha = b - 1$, при фиксированном N верно $\rho = 1$, а при бюджете $\mathcal{C} = Nm$ вычислительно-оптимальный размер $N^* \asymp \mathcal{C}^{1/(\alpha+2)}$.

Эксперимент: проверка точных формул

Слева: МНК при $n = 10$ и модель с N признаками, $\lambda_j = j^{-1,5}$, $e_j = j^{-2}$, $\sigma = 0,5$. Справа: $D = 10^6$, три пары (a, b) . Точки — Монте-Карло, линии — формулы, не подгонка.



Сравнение с Монте-Карло




Показатели при $D = 10^6$

Вывод

Расхождение с Монте-Карло не превышает двух стандартных ошибок, в том числе у порога интерполяции. Наклоны $-0,51$, $-0,67$ и $-0,60$ при предсказанных $-0,5$, $-0,667$ и $-0,6$.

Эксперимент: локальный режим

Линейная и логистическая регрессия, $n = 20$, 2 000 повторений. Штриховая линия — $\text{tr}(\mathbf{H}^{-1}\mathbf{C})/2$ по популяционному спектру, по точкам не подбирается. Справа 15% меток






заменены.

Вывод

В линейной регрессии Монте-Карло совпадает с точной формулой и с константой из спектра. В логистической регрессии та же константа описывает и верные метки, и выборку с заменой 15% меток.

Эксперимент: сходимость критерия на сетях

MNIST, Adam, 100 эпох, три запуска. MLP- L - h и CNN- L - c , ядро 3×3 . Объем выборки до 30 000. Справа достаточный размер при $\varepsilon = 0,05$; пустой треугольник — порог не достигнут.



m^* и глубина при $\varepsilon = 0,05$

$\Delta_2(m)$; штрих наклона -2

Вывод

Наклон близок к -2 и взят из тождества усреднения, а не подобран. При фиксированном m более глубокие сети дают больший Δ_2 . У части глубоких сетей порог $\varepsilon = 0,05$ до 30 000 объектов не достигается.

Критерии достаточного размера для линейных моделей

Подвыборки $\mathfrak{D}_k \subset \mathfrak{D}_m$, $\hat{\mathbf{w}}_k$ — оценка максимума правдоподобия, p_k — апостериор. Схожие подвыборки отличаются одним объектом.

Теорема (Киселев, 2024). *M*-достаточность

$M(k+1) = |\mathbb{E}L(\mathfrak{D}_m, \hat{\mathbf{w}}_{k+1}) - \mathbb{E}L(\mathfrak{D}_m, \hat{\mathbf{w}}_k)|$. Если средние и ковариации $\hat{\mathbf{w}}_k$ сходятся, то для любого $\varepsilon > 0$ найдется m^* с $M(k) \leq \varepsilon$ при $k \geq m^*$.

Теорема (Киселев, 2024). *KL*- и *S*-достаточность


$KL(k+1) = D_{KL}(p_k \| p_{k+1})$, *S* — s-score тех же апостериоров. Для нормальных апостериоров сходимость средних и ковариаций дает $KL(k) \leq \varepsilon$; для $S(k) \geq 1 - \varepsilon$ достаточно сходимости средних.

Теорема (Киселев, 2025). Моменты


При $\|\mathbf{x}\|_2 \leq M$, $|y| \leq M$ и $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k) = \omega(\sqrt{k})$ средние и ковариации апостериора линейной регрессии сходятся, так что условия двух предыдущих теорем выполнены.

Эксперимент: достаточный размер линейных моделей

Синтетические регрессия и классификация и набор Liver Disorders. D и M оцениваются бутстрапом правдоподобия в точке оценки, KL и S — по нормальному апостериору на схожих подвыборках.



Сходимость $D(k)$ и $M(k)$



Вывод

$D(k)$ и $M(k)$ стремятся к нулю, $m^*(\epsilon)$ убывает с ростом порога. Пороги разных критериев не имеют общего масштаба, поэтому размеры при одном ϵ не сравниваются. Там, где найдены оба, S -достаточный размер не меньше KL -достаточного.

Положения, выносимые на защиту

- 1) Теоремы о верхних оценках спектральной нормы гаусс—ньютоновской компоненты матрицы Гессе для полносвязных и сверточных архитектур нейронных сетей.
- 2) Критерии стабилизации ландшафта функции потерь: порядок $\mathcal{O}(k^{-1})$ и $\mathcal{O}(k^{-2})$ следует из усреднения по объектам, а оценки констант получены по локальной квадратичной аппроксимации в одной точке, в полном пространстве параметров и в подпространстве главных собственных направлений матрицы Гессе.
- 3) Схема законов масштабирования, в которой ошибка оценивания задается отношением шума градиентов к кривизне, и ее точный вид для линейной модели с неполным набором признаков.
- 4) Критерии достаточного размера выборки для параметрических моделей, основанные на стабилизации ландшафта функции потерь.
- 5) Критерии достаточного размера выборки для вероятностных линейных моделей, основанные на стабилизации распределения оптимальных параметров при увеличении объема данных.

Публикации и апробация

Основные результаты изложены в 10 научных работах, из которых 4 — в рецензируемых периодических научных журналах, а остальные 6 — в сборниках трудов конференций и тезисах докладов. Результаты докладывались на конференциях:

- 1) 16-я конференция «Интеллектуализация обработки информации» (ИОИ-2026), Витебск, 28 сентября—2 октября 2026 г.
- 2) Международная конференция «Иванниковские чтения», Этномир, 28–30 мая 2026 г.
- 3) 68-я Всероссийская научная конференция МФТИ, Москва, 30 марта—4 апреля 2026 г.
- 4) Открытая конференция ИСП РАН, Москва, 9–10 декабря 2025 г.
- 5) 22-я конференция «Математические методы распознавания образов» (ММРО-2025), Муром, 22–26 сентября 2025 г.
- 6) 67-я Всероссийская научная конференция МФТИ, Москва, 31 марта—5 апреля 2025 г.
- 7) Открытая конференция ИСП РАН, Москва, 11–12 декабря 2024 г.
- 8) 66-я конференция МФТИ, Москва, 1–6 апреля 2024 г.

Спасибо за внимание

Масштабирование параметрических моделей машинного обучения
на основе локальной геометрии оптимизационной поверхности