

Методы определения достаточного размера выборки в параметрических моделях

Киселев Никита Сергеевич

Научный руководитель: к.ф.-м.н., доцент Грабовой А. В.

Кафедра интеллектуальных систем ФПМИ МФТИ

Специализация: Интеллектуальный анализ данных

Направление: 09.04.01 Информатика и вычислительная техника

20 декабря 2025 г.

Методы определения достаточного размера выборки

Исследуется взаимосвязь между сложностью параметрической модели и количеством данных, необходимым для ее обучения до заранее заданной точности.

Проблема

Множество оптимальных параметров модели неявным образом зависит от набора обучающих данных. Статистические подходы не применимы в практических задачах.

Требуется

Предложить определение достаточного размера выборки, учитывающее структуру заданной параметрической модели. Разработать методы, реализующие предложенные критерии достаточности обучающего набора данных на практике.

Метод решения

Предлагается рассмотреть изменение распределения оптимальных параметров модели при увеличении размера выборки. Для нейросетевых моделей предлагается использовать в качестве критерия сходимости поверхность функции потерь.

Задача определения достаточного размера выборки

Выборка

$$\mathfrak{D}_m = \{(\mathbf{x}_i, \mathbf{y}_i)\}, \quad i = 1, \dots, m$$

- 1) $\mathbf{x} \in \mathbb{X}$ — признаковое описание объекта;
- 2) $\mathbf{y} \in \mathbb{Y}$ — значение целевой переменной.

Вероятностная модель

$$p(\mathbf{y}, \mathbf{w}|\mathbf{x}) = p(\mathbf{y}|\mathbf{x}, \mathbf{w})p(\mathbf{w}) : \mathbb{Y} \times \mathbb{W} \times \mathbb{X} \rightarrow \mathbb{R}^+$$

- 1) $p(\mathbf{y}|\mathbf{x}, \mathbf{w})$ — правдоподобие;
- 2) $p(\mathbf{w})$ — априорное распределение.

Определение

Размер выборки m^* называется **достаточным** согласно критерию T , если T выполняется для всех $k \geq m^*$.

Требуется

- 1) Предложить критерий T определения достаточного размера выборки m^* ;
- 2) Построить метод, реализующий критерий T на практике.

Правдоподобие обучающей выборки в модели линейной регрессии и его сходимость в точках максимума на подвыборках

Функция правдоподобия

$$L(\mathcal{D}_m, \mathbf{w}) = \prod_{i=1}^m p(y_i | \mathbf{x}_i, \mathbf{w})$$

Определение (D-достаточность)

$$\forall k \geq m^* : D(k) = \mathbb{D}_{\hat{\mathbf{w}}_k} L(\mathcal{D}_m, \hat{\mathbf{w}}_k) \leq \varepsilon$$

Оценка максимума правдоподобия

Определение (M-достаточность)

$$\hat{\mathbf{w}}_k = \arg \max_{\mathbf{w} \in \mathbb{W}} L(\mathcal{D}_k, \mathbf{w})$$


$$\forall k \geq m^* :$$

$$M(k) = |\mathbb{E}_{\hat{\mathbf{w}}_{k+1}} L(\mathcal{D}_m, \hat{\mathbf{w}}_{k+1}) - \mathbb{E}_{\hat{\mathbf{w}}_k} L(\mathcal{D}_m, \hat{\mathbf{w}}_k)| \leq \varepsilon$$

Теорема 1 (Киселев, 2023)

Обозначим $\mathbb{E}_{\hat{\mathbf{w}}_k} = \mathbf{m}_k$, $\mathbb{D}_{\hat{\mathbf{w}}_k} = \Sigma_k$. Пусть $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$ и $\|\Sigma_{k+1} - \Sigma_k\|_F \rightarrow 0$ при $k \rightarrow \infty$. Тогда **в модели линейной регрессии** определение M-достаточного размера выборки является корректным. А именно, для любого $\varepsilon > 0$ найдется такой m^* , что для всех $k \geq m^*$ выполнено $M(k) \leq \varepsilon$.

Близость апостериорных распределений параметров на схожих подвыборках в вероятностной модели линейной регрессии



Определение (KL-достаточность)

$$\begin{aligned} \forall k \geq m^* : KL(k) = D_{\text{KL}}(p_k || p_{k+1}) = \\ = \int p_k(\mathbf{w}) \log \frac{p_k(\mathbf{w})}{p_{k+1}(\mathbf{w})} d\mathbf{w} \leq \varepsilon \end{aligned}$$

Определение (S-достаточность)

$$\forall k \geq m^* :$$

$$S(k) = \text{s-score}(p_k, p_{k+1}) \geq 1 - \varepsilon$$

Вероятностная модель линейной регрессии

$$p(\mathbf{y}, \mathbf{w} | \mathbf{X}) = \mathcal{N}(\mathbf{y} | \mathbf{X}\mathbf{w}, \sigma^2 \mathbf{I}) \mathcal{N}(\mathbf{w} | \mathbf{0}, \alpha^{-1} \mathbf{I})$$

Теорема 2 (Киселев, 2024)

Пусть множества значений признаков и целевой переменной ограничены, т.е. $\exists M \in \mathbb{R} :$

$\|\mathbf{X}\|_2 \leq M$ и $|y| \leq M$. Если

$\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k) = \omega(\sqrt{k})$ при $k \rightarrow \infty$, то **в**

модели линейной регрессии с нормальным априорным распределением параметров

определения KL- и S-достаточного размера выборки являются корректными.

Стабилизация ландшафта функции потерь в нейронных сетях

Модель

Условное распределение $p(\mathbf{y}|\mathbf{x})$ аппроксимируется нейросетью $f_{\mathbf{w}} : \mathcal{X} \rightarrow \mathcal{Y}$ с параметрами $\mathbf{w} \in \mathbb{R}^N$.

Функция потерь


$$\mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \ell(f_{\mathbf{w}}(\mathbf{x}_i), \mathbf{y}_i) = \frac{1}{m} \sum_{i=1}^m \ell_i(\mathbf{w})$$

Изменение значения в точке при добавлении одного объекта

$$\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) = \frac{1}{k+1} (\ell_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))$$

Предположение

Пусть $\mathbf{w}^*$ является точкой минимума обеих функций $\mathcal{L}_k(\mathbf{w})$ и $\mathcal{L}_{k+1}(\mathbf{w})$, т.е. $\nabla \mathcal{L}_k(\mathbf{w}^*) = \nabla \mathcal{L}_{k+1}(\mathbf{w}^*) = \mathbf{0}$.



Аппроксимация второго порядка и разложение Гаусса–Ньютона


Аппроксимация второго порядка

$$\mathbf{H}^{(k)}(\mathbf{w}) = \nabla_{\mathbf{w}}^2 \mathcal{L}_k(\mathbf{w}) = \frac{1}{k} \sum_{i=1}^k \nabla_{\mathbf{w}}^2 \ell(f_{\mathbf{w}}(\mathbf{x}_i), \mathbf{y}_i) = \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\mathbf{w})$$
$$\mathcal{L}_k(\mathbf{w}) \approx \mathcal{L}_k(\mathbf{w}^*) + \frac{1}{2}(\mathbf{w} - \mathbf{w}^*)^\top \mathbf{H}^{(k)}(\mathbf{w}^*)(\mathbf{w} - \mathbf{w}^*)$$

Разложение Гаусса–Ньютона матрицы Гессе

$$\mathbf{H}_i(\mathbf{w}) = \underbrace{\nabla_{\mathbf{w}\mathbf{z}_i} \frac{\partial^2 \ell(\mathbf{z}_i, \mathbf{y}_i)}{\partial \mathbf{z}_i^2} \nabla_{\mathbf{w}\mathbf{z}_i}^\top}_{\text{Гаусс–Ньютоновская часть}} + \underbrace{\sum_{k=1}^K \frac{\partial \ell(\mathbf{z}_i, \mathbf{y}_i)}{\partial z_{ik}} \nabla_{\mathbf{w}}^2 z_{ik}}_{\text{остаточный член}} \quad \|\cdot\|_2 \approx 0$$

Оценка сходимости в одной точке из окрестности минимума



$$\Delta_{k+1} = |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|, \quad \mathbf{w} \in \mathcal{U}_R(\mathbf{w}^*)$$

Теорема 3 (Киселев, 2024)

В **полносвязной нейронной сети**, используемой для решения задачи K -классовой классификации с использованием кросс-энтропийной функции потерь, содержащей L слоев и имеющей размер скрытого слоя h , для всякого объекта i верно

$$\|\mathbf{H}_i(\mathbf{w})\|_2 \propto L(hM)^{2L}, \quad \Delta_k \propto \frac{L(hM)^{2L}}{k},$$

Оценка сходимости по набору точек из окрестности минимума

$$\begin{aligned}\Delta_{k+1} &= \int (\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 p(\mathbf{w}) d\mathbf{w} = \\ &= \mathbb{E}_{p(\mathbf{w})} \left[(\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 \right],\end{aligned}$$


где $p(\mathbf{w})$ задает предпочтение по выбору точек в пространстве параметров (в общем случае может быть и не вероятностным распределением).

Теорема 4 (Киселев, 2025)

При выборе нормального распределения $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{w}^*, \sigma^2 \mathbf{I})$ справедливо

$$\Delta_k \propto \frac{\sigma^4 N^2 M_{\mathbf{H}}^2}{k^2}$$

где $M_{\mathbf{H}}$ есть верхняя оценка на спектральную норму матрицы Гессе.



Выбор линейного подпространства для сэмплирования набора точек


Проекция на линейное подпространство

Рассматриваем подпространство, натянутое на D векторов, соответствующих D наибольшим собственным значениям матрицы Гессе: $\lambda_k^{(1)}, \dots, \lambda_k^{(D)}$. В таком случае происходит замена: $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{m}, \sigma^2 \mathbf{I}_N) \rightarrow p(\boldsymbol{\theta}) = \mathcal{N}(\boldsymbol{\theta}|\mathbf{0}, \sigma^2 \mathbf{I}_D)$.

Теорема 5 (Киселев, 2025)

Пусть $\mathbf{P} = [\mathbf{e}_1, \dots, \mathbf{e}_D] \in \mathbb{R}^{N \times D}$ — матрица из D главных собственных векторов $\mathbf{H}^{(k)}(\mathbf{w}^*)$, и $\mathbf{w} = \mathbf{w}^* + \mathbf{P}\boldsymbol{\theta}$, где $\boldsymbol{\theta} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D)$, тогда



$$\Delta_{k+1} \leq \frac{\sigma^4}{4} \left(2 \sum_{d=1}^D (\lambda_{k+1}^{(d)} - \lambda_k^{(d)})^2 + \left(\sum_{d=1}^D (\lambda_{k+1}^{(d)} - \lambda_k^{(d)}) \right)^2 \right)$$



Вычислительный эксперимент


- ▶ **Задача:** классификация изображений;
- ▶ **Выборка:** MNIST, CIFAR10;
- ▶ **Архитектура:** полносвязная L -слойная сеть со скрытым размером h на каждом слое и ReLU после каждого из них;
- ▶ **Варьирование архитектуры:** фиксируем число слоев L и варьируем размер скрытого слоя h ;
- ▶ **Постановка эксперимента:**
 - 1) Проводим $N = 10$ независимых обучений модели на полном наборе данных $\rightarrow$ получаем набор точек $\hat{\mathbf{w}}_1, \dots, \hat{\mathbf{w}}_N$;
 - 2) По мере обучения подсчитываем Accuracy на отложенной выборке;
 - 3) Подсчитываем $|\mathcal{L}_{k+1}(\hat{\mathbf{w}}_n) - \mathcal{L}_k(\hat{\mathbf{w}}_n)|$ для всех $k = 1, \dots, m$ и $n = 1, \dots, N$;
 - 4) Повторяем 3 пункт $B = 100$ раз, используя разный порядок добавления, усредняем результаты;
 - 5) Усредняем результаты по $N = 10$ обучением.

Связь между качеством модели и сходимостью функции потерь




Зависимость **Accuracy** на отложенной выборке от значения абсолютной разности функции потерь на обучающей выборке. Полученные на наборах данных MNIST и CIFAR10 графики показывают, что чем меньше становится изменение поверхности функции потерь, тем выше качество модели.


Сходимость поверхности при увеличении k



(a) $(\mathcal{L}_1 - \mathcal{L}_2)^2 p(\mathbf{w})$



(b) $(\mathcal{L}_{50} - \mathcal{L}_{49})^2 p(\mathbf{w})$



(c) $(\mathcal{L}_{100} - \mathcal{L}_{101})^2 p(\mathbf{w})$

Рассматривается нормальное распределение с центром в точке минимума. Изменяется количество используемых данных для подсчета: слева 2 объекта, по центру 50 объектов, справа 100 объектов. Видно, что при увеличении k начинает уменьшаться эффективная локальность окрестность.

Выносятся на защиту

- 1) Исследована проблема определения достаточного размера выборки в параметрических моделях машинного обучения.
- 2) Предложены критерии достаточности количества обучающих данных в линейных моделях. Методы используют распределение оптимальных параметров модели и его изменение с увеличением размера выборки.
- 3) Для нейросетевых моделей предложены критерии, основанные на сходимости поверхности функции потерь при увеличении числа обучающих данных. Исследованы различные подходы к обоснованию такой сходимости для моделей с архитектурами MLP, CNN, Transformer.
- 4) Доказаны теоремы о корректности предложенных определений. Вычислительные эксперименты демонстрируют применимость полученных теоретических результатов в ряде практических задач.

Список работ автора по теме диссертации

Публикации в рецензируемых научных журналах (BAK, Scopus)

- 1) **Kiselev N. S.**, Meshkov V. S., Grabovoy A. V. Robust Convergence of Loss Landscapes through Distributional Averaging // *Proceedings of the ISP RAS*, 2025.
- 2) Meshkov V., **Kiselev N.**, Grabovoy A. ConvNets Landscape Convergence: Hessian-Based Analysis of Matricized Networks // *Ivannikov ISPRAS Open Conference*, 2024.
- 3) **Kiselev N. S.**, Grabovoy A. V. Unraveling the Hessian: A Key to Smooth Convergence in Loss Function Landscapes // *Doklady Mathematics*, 2024.
- 4) **Kiselev N.**, Grabovoy A. Sample Size Determination: Posterior Distributions Proximity // *Computational Management Science*, 2025.
- 5) **Kiselev N. S.**, Grabovoy A. V. Sample Size Determination: Likelihood Bootstrapping // *Computational Mathematics and Mathematical Physics*, 2025.

Выступления с докладом

- 1) Устойчивая сходимость поверхности функции потерь через усреднение по распределению // Открытая конференция ИСП РАН, 2025.
- 2) Достаточный размер выборки и его связь со сходимостью поверхности функции потерь // 22-я Всероссийская конференция с международным участием «Математические методы распознавания образов», 2025.
- 3) Сходимость поверхности функции потерь как признак достаточного размера выборки // 67-я Всероссийская научная конференция МФТИ, 2025.
- 4) Определение достаточного размера выборки по апостериорному распределению параметров модели // 66-я Всероссийская научная конференция МФТИ, 2024.