

Методы определения достаточного размера выборки в параметрических моделях

Киселев Никита Сергеевич

Научный руководитель: к.ф.-м.н. Грабовой А. В.

Кафедра интеллектуальных систем ФПМИ МФТИ

Специализация: Интеллектуальный анализ данных

Направление: 09.04.01 Информатика и вычислительная техника

Москва — 2026

Стабилизация ландшафта потерь и достаточный размер выборки

Исследуется связь между **локальной геометрией** поверхности эмпирической функции потерь параметрических моделей и **достаточным размером** обучающей выборки.

Проблема

Эмпирические законы масштабирования современных моделей не имеют общего теоретического обоснования. Существующие критерии стабилизации ландшафта не учитывают структуру матрицы Гессе.

Требуется

Построить критерий стабилизации поверхности функции потерь, согласованный с эмпирически наблюдаемой **анизотропией** спектра матрицы Гессе, и получить количественные оценки достаточного размера обучающей выборки.

Метод решения


Унифицированный критерий p -сходимости с функцией предпочтения точек в пространстве параметров; в качестве пробной области используется подпространство **наибольшей кривизны**, натянутое на ведущие собственные векторы матрицы Гессе.

Унифицированный критерий p -сходимости

Критерий p -сходимости ландшафта функции потерь при добавлении одного объекта в выборку $\mathfrak{D}_k$:

$$\Delta_p(k+1) = \int |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|^p q(\mathbf{w}) d\mathbf{w},$$

где функция $q : \mathbb{R}^N \rightarrow \mathbb{R}_+$ задает предпочтение по выбору точек в пространстве параметров.




- 1) Без ограничения общности $\int q(\mathbf{w}) d\mathbf{w} = 1$, то есть $q(\mathbf{w})$ — плотность распределения;
- 2) Существующие подходы соответствуют частным выборам пары (p, q) :
одноточечный (Дирак) и изотропный среднеквадратичный (гаусс в полном $\mathbb{R}^N$);
- 3) Локальный интерес $\Rightarrow q(\mathbf{w})$ с массой возле минимума.

Абсолютный одноточечный критерий сходимости

Абсолютный одноточечный критерий сходимости:

$$\Delta_1(k+1) = |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|,$$

где $\mathbf{w} \in \mathcal{U}_R(\mathbf{w}_k^*)$ — точка из окрестности радиуса $R > 0$ минимума $\mathbf{w}_k^*$, т. е. $p = 1$ и $q(\tilde{\mathbf{w}}) = \delta(\tilde{\mathbf{w}} - \mathbf{w})$.



Теорема (Киселев, 2024)

Пусть в $\mathcal{U}_R(\mathbf{w}_k^*)$ справедлива квадратичная аппроксимация, $\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{g}}$ и для всех $i = 1, \dots, k+1$ верно $|\ell_i(\mathbf{w}_k^*)| \leq M_{\ell}$, $\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{H}}$, тогда

$$\Delta_1(k+1) \leq \frac{2M_{\ell} + M_{\mathbf{g}}R + M_{\mathbf{H}}R^2}{k+1} = \mathcal{O}(k^{-1}).$$

Среднеквадратичный критерий сходимости

Среднеквадратичный критерий сходимости:

$$\Delta_2(k+1) = \mathbb{E}_{q(\mathbf{w})} \left[(\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 \right],$$


т. е. $p = 2$, для теоретического анализа удобно выбрать $q(\mathbf{w}) = \mathcal{N}(\mathbf{w}_k^*, \sigma^2 \mathbf{I}_N)$, а на практике вычисляется методом Монте—Карло через $\mathbf{w}_s \sim q(\mathbf{w})$:

$$\hat{\Delta}_2(k+1) = \frac{1}{S} \sum_{s=1}^S (\mathcal{L}_{k+1}(\mathbf{w}_s) - \mathcal{L}_k(\mathbf{w}_s))^2.$$

Теорема (Киселев, 2025)

Пусть в $\mathcal{U}_R(\mathbf{w}_k^*)$ справедлива квадратичная аппроксимация, $\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{g}}$ и для всех $i = 1, \dots, k+1$ верно $|\ell_i(\mathbf{w}_k^*)| \leq M_{\ell}$, $\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{H}}$, тогда

$$\Delta_2(k+1) \leq \frac{12M_{\ell}^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4 (N^2 + 2N) M_{\mathbf{H}}}{(k+1)^2} = \mathcal{O}(k^{-2}).$$



Среднеквадратичный критерий в подпространстве наибольшей кривизны

Обозначим $\mathbf{H}^{(k)}(\mathbf{w}_k^*)\mathbf{u}_i = \lambda_i^{(k)}\mathbf{u}_i$, $\lambda_1^{(k)} \geq \dots \geq \lambda_N^{(k)}$, $\mathbf{U}_D = [\mathbf{u}_1, \dots, \mathbf{u}_D] \in \mathbb{R}^{N \times D}$, $\mathcal{S}_D = \text{Im}(\mathbf{U}_D)$, тогда среднеквадратичный критерий с $\text{supp } q \subset \mathbf{w}_k^* + \mathcal{S}_D$:


$$\Delta_2^{(D)}(k+1) = \mathbb{E}_{q(\mathbf{w})} \left[(\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 \right],$$

На практике вычисляется методом Монте—Карло через $\mathbf{w}_s = \mathbf{w}_k^* + \mathbf{U}_D \mathbf{z}_s$, где $\mathbf{z}_s \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D)$.

Теорема (Киселев, 2026)

Пусть в $\mathcal{U}_R(\mathbf{w}_k^*)$ справедлива квадратичная аппроксимация, $\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_g$ и для всех $i = 1, \dots, k+1$ верно $|\ell_i(\mathbf{w}_k^*)| \leq M_\ell$, $\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_H$, тогда

$$\Delta_2^{(D)}(k+1) \leq \frac{12M_\ell^2 + 3\sigma^2 M_g^2 + 3\sigma^4 (D^2 + 2D) M_H}{(k+1)^2} = \mathcal{O}(k^{-2}).$$



Архитектурно-зависимая оценка $\|\mathbf{G}\|_2$ для полносвязной сети

Разложение Гаусса—Ньютона

$$\mathbf{H}_i(\mathbf{w}) = \mathbf{G}_i(\mathbf{w}) + \mathbf{R}_i(\mathbf{w})$$

В окрестности минимума

$\|\mathbf{H}_i(\mathbf{w})\|_2 \approx \|\mathbf{G}_i(\mathbf{w})\|_2$, поэтому константа $M_{\mathbf{H}}$ контролируется через спектральную норму гаусс—ньютоновской компоненты.

Следствие для $\Delta_2^{(D)}$

Подстановка архитектурно-зависимой оценки в теорему дает явную верхнюю оценку $\Delta_2^{(D)}(k+1)$ через число слоев L , нормы матриц весов и липшицевы константы активаций.

Утверждение (Киселев, 2024)

Пусть $f_{\mathbf{w}}$ — L -слойная полносвязная нейронная сеть без смещений, и для всех слоев $p = 1, \dots, L$ верно

$$\|\mathbf{x}\|_2 \leq M_{\mathbf{x}}, \|\mathbf{A}(\mathbf{w})\|_2 \leq M_{\mathbf{A}}, \\ \|\mathbf{W}^{(p)}\|_2 \leq M_{\mathbf{W}}, \|\mathbf{D}^{(p)}\|_2 \leq M_{\sigma}. \text{ Тогда}$$

$$\|\mathbf{G}_i(\mathbf{w})\|_2 \leq LM_{\mathbf{x}}^2 M_{\mathbf{A}} (M_{\mathbf{W}} M_{\sigma})^{2L-2}.$$

Масштабируемые алгоритмы оценивания $\Delta_2^{(D)}$

Общий шаг для всех алгоритмов — построение подпространства наибольшей кривизны $\mathbf{U}_D$ итерационным спектральным методом на произведениях матрицы Гессе на вектор. В координатах $\mathbf{z} = \mathbf{U}_D^\top (\mathbf{w} - \mathbf{w}_k^*)$ критерий определяется тремя сжатыми объектами:

$$a_k = \mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*), \quad \mathbf{c}_k = \mathbf{U}_D^\top \mathbf{g}^{(k+1)}(\mathbf{w}_k^*), \quad \mathbf{B}_k = \mathbf{U}_D^\top (\mathbf{H}^{(k+1)} - \mathbf{H}^{(k)}) \mathbf{U}_D.$$

Алгоритм	Объект оценки	Настройка	Вычисл. сложность оценки
Прямая Монте-Карло	истинный $\Delta_2^{(D)}$	—	$\mathcal{O}(S(ND + C_{\text{fwd}}))$
Квадратичная МК $\hat{\Delta}_{2,\text{quad}}^{(D)}$	квадратичный суррогат	$a_k, \mathbf{c}_k, \mathbf{B}_k$	$\mathcal{O}(SD^2)$
Замкнутая форма $\hat{\Delta}_{2,\text{GM}}^{(D)}$	квадратичный суррогат	$a_k, \mathbf{c}_k, \mathbf{B}_k$	$\mathcal{O}(D^2)$

Выражение через моменты гауссовской квадратичной формы




$$\hat{\Delta}_{2,\text{GM}}^{(D)}(k+1) = a_k^2 + a_k \sigma^2 \text{Tr}(\mathbf{B}_k) + \sigma^2 \|\mathbf{c}_k\|_2^2 + \frac{\sigma^4}{4} (2 \text{Tr}(\mathbf{B}_k^2) + \text{Tr}(\mathbf{B}_k)^2)$$

Вычислительный эксперимент 1: полносвязная сеть на MNIST

- 1) 10-классовая классификация на MNIST;
- 2) MLP, варьируется размер выборки k ;
- 3) Критерии вычисляются методом Монте–Карло;
- 4) Собств. векторы Гессе — степенной итерацией.



Показатели $\Delta(k) \sim k^{-\alpha}$ согласуются с теоретическим значением $\alpha = 2$ для Δ_2 и $\Delta_2^{(D)}$.

Критерий	Оценка α	R^2	Теория
Δ_1	2,33	0,63	1
Δ_2	1,94	1,00	2
$\Delta_2^{(D=5)}$	1,80	0,96	2
$\Delta_2^{(D=10)}$	1,83	0,99	2
$\Delta_2^{(D=20)}$	1,84	0,99	2



Вычислительный эксперимент 2: трансформер nanochat d6

- 1) Декодерный трансформер $\sim 10^8$ параметров, контрольная точка обучения 3500;
- 2) Все вычисления в float32 на произведениях матрицы Гессе на вектор без явного построения матрицы Гессе;
- 3) При $D/N < 10^{-6}$ подпространственный $\Delta_2^{(D)}$ воспроизводит полнопространственный сигнал Δ_2 в пределах численной погрешности при $\sigma \leq 10^{-3}$;
- 4) Замкнутая форма $\hat{\Delta}_{2,\text{GM}}^{(D)}$ примерно в $1,8 \cdot 10^4$ раз быстрее прямой Монте—Карло без потери точности в локальном режиме.



Выносятся на защиту

- 1) Унифицированный критерий p -сходимости Δ_p с функцией предпочтения точек в пространстве параметров, охватывающий одноточечную и интегральные постановки задачи о стабилизации поверхности функции потерь.
- 2) Среднеквадратичный критерий $\Delta_2^{(D)}$ в подпространстве ведущих собственных векторов матрицы Гессе сохраняет скорость убывания $\mathcal{O}(k^{-2})$, заменяя зависимость от размерности пространства параметров на зависимость от размерности подпространства, и допускает явное спектральное выражение; подпространство главных направлений Гессе является экстремальным.
- 3) Масштабируемые алгоритмы оценивания критериев на основе произведений матрицы Гессе на вектор и замкнутого выражения через моменты гауссовских квадратичных форм, согласующиеся с прямой оценкой методом Монте—Карло в пределах численной точности.
- 4) Получаемые оценки скорости убывания критериев дают количественное выражение для достаточного размера обучающей выборки, обеспечивающего заданный уровень стабилизации поверхности функции потерь.

Список работ автора по теме ВКР

Публикации в рецензируемых научных журналах (BAK, Web of Science, Scopus)

- 1) *Kiselev N., Meshkov V., Grabovoy A. Robust Convergence of Loss Landscapes through Distributional Averaging // Proceedings of the ISP RAS, 2025.*
- 2) *Meshkov V., Kiselev N., Grabovoy A. ConvNets Landscape Convergence: Hessian-Based Analysis of Matricized Networks // Ivannikov ISPRAS Open Conference, 2024.*
- 3) *Kiselev N., Grabovoy A. Unraveling the Hessian: A Key to Smooth Convergence in Loss Function Landscapes // Doklady Mathematics, 2024.*
- 4) *Kiselev N., Grabovoy A. Sample Size Determination: Posterior Distributions Proximity // Computational Management Science, 2025.*
- 5) *Kiselev N., Grabovoy A. Sample Size Determination: Likelihood Bootstrapping // Computational Mathematics and Mathematical Physics, 2025.*

Выступления с докладом

- 1) Среднеквадратичный критерий сходимости ландшафта функции потерь на основе перехода к подпространству главных собственных векторов матрицы Гессе // 68-я Всероссийская научная конференция МФТИ, 2026.
- 2) Устойчивая сходимость поверхности функции потерь через усреднение по распределению // Открытая конференция ИСП РАН, 2025.
- 3) Достаточный размер выборки и его связь со сходимостью поверхности функции потерь // 22-я Всероссийская конференция с международным участием «Математические методы распознавания образов», 2025.
- 4) Сходимость поверхности функции потерь как признак достаточного размера выборки // 67-я Всероссийская научная конференция МФТИ, 2025.
- 5) Определение достаточного размера выборки по апостериорному распределению параметров модели // 66-я Всероссийская научная конференция МФТИ, 2024.