

На правах рукописи



**Киселев Никита Сергеевич**

**Ландшафтный метод оценки масштабируемости  
параметрических моделей машинного обучения**

Специальность 1.2.1 —  
«Искусственный интеллект и машинное обучение»

Автореферат  
диссертации на соискание учёной степени  
кандидата физико-математических наук

Москва — 2026

Работа выполнена в Федеральном государственном автономном образовательном учреждении высшего образования «Московский физико-технический институт (национальный исследовательский университет)», Физтех-школе прикладной математики и информатики, на Кафедре интеллектуальных систем.

Научный руководитель: кандидат физико-математических наук  
**Грабовой Андрей Валериевич**

Официальные оппоненты: **Фамилия Имя Отчество**,  
доктор физико-математических наук, профессор,  
Не очень длинное название для места работы,  
старший научный сотрудник

**Фамилия Имя Отчество**,  
кандидат физико-математических наук,  
Основное место работы с длинным длинным  
длинным длинным названием,  
старший научный сотрудник

Ведущая организация: Федеральное государственное бюджетное образовательное учреждение высшего профессионального образования с длинным длинным длинным длинным названием

Защита состоится **DD mmmmmmmmm YYY Y** г. в **XX часов** на заседании диссертационного совета 24.1.224.03 на базе Федерального государственного учреждения «Федеральный исследовательский центр «Информатика и управление» Российской Академии Наук» (ФИЦ ИУ РАН) по адресу: 119333, г. Москва, ул. Вавилова, д. 44/2.

С диссертацией можно ознакомиться в библиотеке Федерального государственного учреждения «Федеральный исследовательский центр «Информатика и управление» Российской Академии Наук» (ФИЦ ИУ РАН) и на официальном сайте <https://www.frccsc.ru>.

Автореферат разослан **DD mmmmmmmmm** 2026 года.

Ученый секретарь  
диссертационного совета  
24.1.224.03,  
кандидат технических наук



Рейер Иван Александрович

## Общая характеристика работы

**Актуальность темы.** В статистической теории обучения обоснована принципиальная связь между сложностью семейства моделей, объемом обучающей выборки и способностью к обобщению [1]. Для надежного выбора модели требуется достаточное количество данных. Подавляющее большинство современных моделей машинного обучения являются параметрическими: они задаются конечным набором параметров, определяемых минимизацией эмпирической функции потерь на выборке. Поскольку функция потерь вычисляется по ограниченным данным и зависит от параметров модели, возникает фундаментальный вопрос о взаимосвязи объема выборки, структуры модели и свойств множества оптимальных параметров, а также о **минимальном объеме данных**, необходимом для успешного обучения [2; 3].

Эмпирические **законы масштабирования** показывают, что качество моделей закономерно зависит от размера данных и модели: в языковых моделях установлены степенные зависимости потерь от объема данных и числа параметров [2], а для вычислительно-оптимального обучения предложено согласованное масштабирование размера модели и объема данных [3]. Эти результаты опираются на масштабные эксперименты и не имеют пока единого теоретического обоснования.

Естественным объектом для такого анализа является **ландшафт функции потерь** в пространстве параметров. Его визуализация и анализ структуры минимумов [4], изучение локальной геометрии и связей с обобщающей способностью [5], а также доказательство связности множества решений [6] показывают, что геометрия поверхности функции потерь определяет как выбор решения методами градиентной оптимизации [7; 8], так и устойчивость к возмущениям данных. Спектральные свойства **матрицы Гессе** в окрестности минимума характеризуют кривизну оптимизационной поверхности и используются при анализе сходимости и обобщения [9]. Вместе с тем остается открытой задача систематического описания того, как ландшафт функции потерь стабилизируется при увеличении объема выборки и как связать эту стабилизацию с законами масштабирования и достаточным размером данных.

*Таким образом, актуальной задачей является разработка теоретических методов, связывающих архитектуру параметрической модели, объем обучающей выборки и локальную геометрию множества оптимальных параметров, задаваемую ландшафтом функции потерь.*

**Целью** данной работы является разработка ландшафтного метода оценки масштабируемости параметрических моделей машинного обучения, основанного на локальной геометрии ландшафта функции потерь в окрестности точки минимума и на стабилизации распределения оптимальных

параметров. Для достижения цели были поставлены и решены следующие **задачи**:

1. Исследовать спектральные свойства матриц Гессе нейронных сетей и получить архитектурно-зависимые верхние оценки спектральных норм для полносвязных и сверточных архитектур.
2. Разработать критерии стабилизации оптимизационной поверхности при увеличении объема обучающей выборки.
3. Оценить масштабируемость параметрических моделей машинного обучения на основе локальной геометрии ландшафта функции потерь, связав ее с архитектурой модели и объемом обучающей выборки.
4. Построить критерии достаточного размера выборки для параметрических моделей на основе стабилизации ландшафта функции потерь.
5. Исследовать вероятностные линейные модели как частный случай параметрических моделей и построить для них критерии достаточного размера выборки на основе сходимости распределения оптимальных параметров.

**Объектом исследования** настоящей работы являются параметрические модели машинного обучения и возникающие при их обучении оптимизационные задачи на конечных обучающих выборках.

**Предметом исследования** данной работы являются локальные свойства оптимизационной поверхности функции потерь параметрических моделей машинного обучения, спектральные свойства матрицы Гессе, стабилизация множества оптимальных параметров при увеличении объема обучающей выборки и критерии достаточного размера выборки, основанные на этой стабилизации.

#### **Научная новизна:**

1. Получены верхние оценки спектральных норм гаусс-ньютоновской компоненты матрицы Гессе для полносвязных и сверточных архитектур нейронных сетей на основе ее блочной факторизации в классе матрично-представимых моделей.
2. Предложены критерии стабилизации оптимизационной поверхности. Порядок их убывания следует из усреднения эмпирического риска по объектам выборки; локальная квадратичная аппроксимация и спектр матрицы Гессе оценивают константу в этой оценке.
3. Предложена схема законов масштабирования, в которой ошибка оценивания задается отношением шума градиентов к кривизне. Для линейной модели с неполным набором признаков схема выполнена точно.
4. Получены критерии достаточного размера выборки для параметрических моделей на основе стабилизации ландшафта функции потерь.

5. Для вероятностных линейных моделей построены критерии достаточного размера выборки, основанные на сходимости апостериорного распределения параметров и стабилизации вероятностных характеристик решения.

**Теоретическая значимость** полученных результатов состоит в том, что предложено обоснование связи между объемом обучающей выборки и стабилизацией оптимизационной поверхности (для линейных моделей — через правдоподобие и апостериорные распределения, для нейронных сетей — через спектр матрицы Гессе и сходимость ландшафта функции потерь), дополняющее известные эмпирические законы масштабирования строгими оценками и единой постановкой задачи.

**Практическая значимость** настоящей работы заключается в возможности применения разработанных методов для обоснованного определения достаточного объема данных при планировании экспериментов и сборе выборок для линейных и нейросетевых моделей, а также для формулировки критериев остановки сбора данных и интерпретации достаточности выборки в терминах геометрии поверхности функции потерь.

**Методология и методы исследования.** Для достижения поставленных в диссертационной работе целей используются:

1. Методы линейной алгебры, математического и функционального анализа: матричное дифференцирование, анализ функций многих переменных, спектральный анализ матриц (в том числе матрицы Гессе).
2. Методы теории вероятностей и математической статистики: байесовский вывод, анализ сходимости последовательностей случайных величин и распределений, элементы теории оптимизации.
3. Методы вычислительного эксперимента и анализа результатов: бутстрап (англ. bootstrap), метод Монте—Карло, воспроизводимая постановка экспериментов.

### **Основные положения, выносимые на защиту:**

1. Теоремы о верхних оценках спектральной нормы гаусс-ньютоновской компоненты матрицы Гессе для полносвязных и сверточных архитектур нейронных сетей.
2. Критерии стабилизации ландшафта функции потерь: порядок  $\mathcal{O}(k^{-1})$  и  $\mathcal{O}(k^{-2})$  следует из усреднения по объектам, а оценки констант получены по локальной квадратичной аппроксимации в одной точке, в полном пространстве параметров и в подпространстве главных собственных направлений матрицы Гессе.
3. Схема законов масштабирования, в которой ошибка оценивания задается отношением шума градиентов к кривизне, и ее точный вид для линейной модели с неполным набором признаков.

4. Критерии достаточного размера выборки для параметрических моделей, основанные на стабилизации ландшафта функции потерь.
5. Критерии достаточного размера выборки для вероятностных линейных моделей, основанные на стабилизации распределения оптимальных параметров при увеличении объема данных.

**Соответствие паспорту специальности.** Диссертационная работа соответствует паспорту научной специальности 1.2.1 — «Искусственный интеллект и машинное обучение», а именно в наибольшей степени следующим направлениям исследований: п. 1 «Естественно-научные основы и методы искусственного интеллекта»; п. 2 «Исследования в области оценки качества и эффективности алгоритмических решений для систем искусственного интеллекта и машинного обучения»; п. 12 «Исследования в области надежности, устойчивости и переобучения систем класса ИИ»; п. 15 «Математические исследования в области статистики, логики, алгебры, топологии, анализа функций и других областях, ориентированные на решение задач искусственного интеллекта и машинного обучения»; п. 16 «Исследования в области специальных методов оптимизации, проблем сложности и снижения размерности»; п. 17 «Исследования в области многослойных алгоритмических конструкций, в том числе многослойных нейросетей».

**Достоверность** полученных результатов обеспечивается корректностью применения апробированного в научной практике математического аппарата теории вероятностей, математической статистики и других смежных теоретических областей, а также экспериментальной проверкой разработанных методов на большом количестве модельных и практических задач машинного обучения. Полученные теоретические результаты обосновываются математически строгими доказательствами, а для проведенных вычислительных экспериментов даются детальные описания, обеспечивающие их воспроизводимость. Результаты опубликованы в рецензируемых научных изданиях и в трудах рецензируемых российских и международных конференций по машинному обучению и искусственному интеллекту.

**Апробация работы.** Основные результаты работы докладывались и обсуждались на следующих научных конференциях:

1. 16-я Международная конференция «Интеллектуализация обработки информации» (ИОИ-2026), Витебск, 28 сентября – 2 октября 2026 г.
2. Международная конференция «Иванниковские чтения», Этномир, 28–30 мая 2026 г.
3. 68-я Всероссийская научная конференция МФТИ, Москва, 30 марта – 4 апреля 2026 г.
4. Открытая конференция ИСП РАН, Москва, 9–10 декабря 2025 г.

5. 22-я Всероссийская конференция с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября 2025 г.
6. 67-я Всероссийская научная конференция МФТИ, Москва, 31 марта – 5 апреля 2025 г.
7. Открытая конференция ИСП РАН, Москва, 11–12 декабря 2024 г.
8. 66-я Всероссийская научная конференция МФТИ, Москва, 1–6 апреля 2024 г.

**Личный вклад.** Все приведенные результаты, кроме отдельно оговоренных случаев, получены диссертантом лично при научном руководстве к.ф.-м.н. А. В. Грабового.

**Публикации.** *Список публикаций приведен в конце автореферата.* Основные результаты по теме диссертации изложены в 9 научных работах, из которых 4 — в рецензируемых периодических научных журналах, а остальные 5 — в сборниках трудов конференций и тезисах докладов.

**Объем и структура работы.** Диссертация состоит из введения, 5 глав и заключения. Полный объем диссертации составляет 152 страницы, включая 25 рисунков и 5 таблиц. Список литературы содержит 82 наименования.

## Содержание работы

Во **введении** обосновывается актуальность исследований, проводимых в рамках данной диссертационной работы, приводится обзор научной литературы по изучаемой проблеме, формулируется цель, ставятся задачи работы, излагается научная новизна и практическая значимость представляемой работы.

**Первая глава** носит постановочный характер и посвящена анализу проблемы определения достаточного размера обучающей выборки для параметрических моделей машинного обучения. Объектом называется пара  $(\mathbf{x}, y)$ , где  $\mathbf{x} \in \mathbb{X} \subseteq \mathbb{R}^n$  — вектор признаков описания,  $y \in \mathbb{Y}$  — целевая переменная. В задаче регрессии  $\mathbb{Y} = \mathbb{R}$ , в задаче классификации  $\mathbb{Y} = \{1, \dots, K\}$ . Выборка размера  $m$  задается множеством  $\mathfrak{D}_m = \{(\mathbf{x}_i, y_i)\}_{i=1}^m$  из  $m$  независимых реализаций пар  $(\mathbf{x}, y)$ , распределенных согласно неизвестному распределению  $p(\mathbf{x}, y)$ .

Параметрической моделью называется семейство функций  $f_{\mathbf{w}} : \mathbb{X} \rightarrow \mathbb{Y}$ , задаваемое вектором параметров  $\mathbf{w} \in \mathbb{W} \subset \mathbb{R}^N$ . Выбор модели из этого семейства проводится с помощью эмпирической функции потерь, вычисляемой на заданной выборке:

$$\mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \ell(f_{\mathbf{w}}(\mathbf{x}_i), y_i), \quad (1)$$

где  $\ell : \mathbb{Y} \times \mathbb{Y} \rightarrow \mathbb{R}^+$  — функция потерь на одном объекте (например, квадратичная или кросс-энтропийная). Обучение модели таким образом есть решение оптимизационной задачи

$$\mathbf{w}_m^* \in \arg \min_{\mathbf{w} \in \mathbb{W}} \mathcal{L}_m(\mathbf{w}). \quad (2)$$

Далее рассмотрены основные существующие подходы к оценке достаточного размера выборки — статистические, байесовские, информационно-теоретические и основанные на оценках сложности модели — и показаны их ограничения применительно к современным многопараметрическим нейросетевым архитектурам. На этой основе обоснована необходимость построения новых критериев, опирающихся не на внешние характеристики качества или асимптотические статистические гипотезы, а на локальные свойства самой оптимизационной задачи.

В качестве ключевого объекта исследования предложено использовать оптимизационную поверхность функции потерь и ее локальную геометрию в окрестности точки минимума. Эта локальная геометрия, а не глобальная картина поверхности, составляет основу ландшафтного метода оценки масштабируемости: стабилизация ландшафта при увеличении объема обучающей выборки дает критерии достаточного размера выборки и схему законов масштабирования.

В заключение главы сформулированы задачи диссертационного исследования и описана логика последующих глав: анализ спектральных свойств матрицы Гессе, построение критериев стабилизации ландшафта, вывод критериев достаточного размера выборки и исследование вероятностных линейных моделей как частного случая параметрических моделей.

**Во второй главе** исследуются спектральные свойства матрицы Гессе функции потерь нейронной сети и выводятся архитектурно-зависимые оценки локальной кривизны оптимизационной поверхности.

В качестве основного объекта рассматривается матрица Гессе эмпирической функции потерь

$$\mathbf{H}^{(m)}(\mathbf{w}) = \nabla_{\mathbf{w}}^2 \mathcal{L}_m(\mathbf{w}). \quad (3)$$

Для анализа спектрально значимой части второй производной используется разложение Гаусса–Ньютона

$$\mathbf{H}(\mathbf{w}) = \mathbf{G}(\mathbf{w}) + \mathbf{R}(\mathbf{w}), \quad \mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w}), \quad (4)$$

где  $\mathbf{J}(\mathbf{w}) = \partial \mathbf{z} / \partial \mathbf{w}$  — якобиан выхода модели по параметрам, а  $\mathbf{A}(\mathbf{w}) = \nabla_{\mathbf{z}}^2 \ell(\mathbf{z}, \mathbf{y})$  — матрица кривизны функции потерь по выходу модели.

Для широкого класса матрично-представимых нейронных сетей в работе получена блочная факторизация гаусс–ньютоновской компоненты.

Если  $\mathbf{w} = \text{col}(\mathbf{w}^{(1)}, \dots, \mathbf{w}^{(L)})$  — разбиение параметров по слоям, а

$$\mathbf{S}^{(p)}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{z}^{(p)}}, \quad \mathbf{P}^{(p)}(\mathbf{w}) = \frac{\partial \mathbf{z}^{(p)}}{\partial \mathbf{w}^{(p)}},$$

то для  $(p, q)$ -го блока матрицы  $\mathbf{G}(\mathbf{w})$  доказано представление

$$\mathbf{G}^{(p,q)}(\mathbf{w}) = \mathbf{P}^{(p)}(\mathbf{w})^\top \mathbf{S}^{(p)}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{S}^{(q)}(\mathbf{w}) \mathbf{P}^{(q)}(\mathbf{w}). \quad (5)$$

Полученная факторизация, проиллюстрированная на рисунке 1, позволяет разделить вклад архитектуры сети, функции потерь и параметризации слоев в локальную кривизну.




Рисунок 1 — Блочная факторизация гаусс–ньютоновской компоненты матрицы Гессе для матрично-представимой нейронной сети

На основе этого результата для  $L$ -слойной полносвязной сети получена верхняя оценка спектральной нормы гаусс–ньютоновской компоненты

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq LM_{\mathbf{x}}^2 M_{\mathbf{A}} (M_{\mathbf{W}} M_{\sigma})^{2L-2}, \quad (6)$$

где  $M_{\mathbf{x}}$  ограничивает норму входа,  $M_{\mathbf{A}}$  — спектральную норму матрицы  $\mathbf{A}(\mathbf{w})$ ,  $M_{\mathbf{W}}$  — нормы весовых матриц, а  $M_{\sigma}$  — нормы матриц производных активаций.

Для сверточной нейронной сети доказана аналогичная оценка

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq LM_{\mathbf{x}}^2 M_{\mathbf{A}} K_{\max} (M_{\mathcal{W}} M_{\sigma})^{2L-2}, \quad (7)$$

где  $M_{\mathcal{W}}$  ограничивает  $\ell_1$ -нормы сверточных ядер, а множитель  $K_{\max}$  определяется максимальным размером рецептивного поля слоя. Тем самым показано, что для сверточных сетей верхняя оценка локальной кривизны зависит от локальности связей и разделения весов.

Кроме того, для полносвязной сети с активацией ReLU (англ. rectified linear unit) и кросс-энтропийной функцией потерь получено частное следствие

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq \sqrt{2} L M_{\mathbf{x}}^2 M_{\mathbf{w}}^{2L-2}. \quad (8)$$

Проведенные вычислительные эксперименты для полносвязных и сверточных архитектур на задаче классификации показывают, что на поздних этапах обучения выполняется соотношение

$$\|\mathbf{G}(\mathbf{w})\|_2 \approx \|\mathbf{H}(\mathbf{w})\|_2,$$

что подтверждает возможность использования гаусс–ньютоновской компоненты как практически значимой характеристики локальной кривизны оптимизационной поверхности.

В третьей главе исследуется стабилизация ландшафта функции потерь нейронной сети при увеличении объема обучающей выборки. В отличие от классического анализа, основанного на сходимости эмпирического риска как скалярной величины, в главе рассматривается изменение локальной геометрии оптимизационной поверхности в окрестности точки минимума.

В качестве исходного объекта изучается разность  $\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})$  эмпирических функций потерь на выборках размеров  $k$  и  $k+1$ . В окрестности точки локального минимума  $\mathbf{w}_k^*$  функции  $\mathcal{L}_k(\mathbf{w})$  эта разность аппроксимируется формулой второго порядка

$$\begin{aligned} \mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) &= \mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*) \\ &+ \mathbf{g}^{(k+1)}(\mathbf{w}_k^*)^\top (\mathbf{w} - \mathbf{w}_k^*) \\ &+ \frac{1}{2} (\mathbf{w} - \mathbf{w}_k^*)^\top (\mathbf{H}^{(k+1)}(\mathbf{w}_k^*) - \mathbf{H}^{(k)}(\mathbf{w}_k^*)) (\mathbf{w} - \mathbf{w}_k^*). \end{aligned} \quad (9)$$

где  $\mathbf{g}^{(k+1)}(\mathbf{w}_k^*)$  — градиент функции потерь на выборке из  $k+1$  объектов, а  $\mathbf{H}^{(k)}(\mathbf{w}_k^*)$  и  $\mathbf{H}^{(k+1)}(\mathbf{w}_k^*)$  — соответствующие матрицы Гессе. Тем самым изменение ландшафта описывается тремя составляющими: сдвигом значения функции потерь в точке минимума, градиентным рассогласованием (см. иллюстрацию на рисунке 2) и изменением локальной кривизны.

На этой основе вводится общий критерий  $p$ -сходимости ландшафта функции потерь:

$$\Delta_p(k+1) = \int |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|^p q(\mathbf{w}) d\mathbf{w}, \quad (10)$$

где функция  $q(\mathbf{w})$  задает предпочтение по выбору точек в пространстве параметров. Такой критерий позволяет единообразно рассматривать как




Рисунок 2 — Иллюстрация условия слабого градиентного рассогласования в окрестности локального минимума

изменение функции потерь в одной фиксированной точке, так и усредненные характеристики стабилизации поверхности в полном пространстве параметров или в выделенном подпространстве, как это проиллюстрировано на рисунке 3.




Рисунок 3 — Иллюстрация введенных критериев стабилизации ландшафта функции потерь: а) абсолютный одноточечный критерий; б) среднеквадратичный критерий в полном пространстве параметров; в) среднеквадратичный критерий в подпространстве наибольшей кривизны

Для абсолютного одноточечного критерия

$$\Delta_1(k+1) = |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|, \quad \mathbf{w} \in \mathcal{U}_R(\mathbf{w}_k^*), \quad (11)$$

получена оценка

$$\Delta_1(k+1) \leq \frac{2M_\ell + M_{\mathbf{g}}R + M_{\mathbf{H}}R^2}{k+1} = \mathcal{O}(k^{-1}), \quad (12)$$

где  $M_\ell$ ,  $M_{\mathbf{g}}$  и  $M_{\mathbf{H}}$  ограничивают соответственно значения функции потерь на одном объекте, градиента и матрицы Гессе в окрестности минимума.

Для среднеквадратичного критерия

$$\Delta_2(k+1) = \int (\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 q(\mathbf{w}) d\mathbf{w} \quad (13)$$

при выборе гауссовского распределения

$$q(\mathbf{w}) = \mathcal{N}(\mathbf{w}_k^*, \sigma^2 \mathbf{I}_N) \quad (14)$$

доказана оценка

$$\Delta_2(k+1) \leq \frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(N^2 + 2N)M_{\mathbf{H}}^2}{(k+1)^2} = \mathcal{O}(k^{-2}). \quad (15)$$

Таким образом, после усреднения квадрата изменения ландшафта по распределению точек получается более быстрая скорость убывания по сравнению с одноточечным критерием. Множитель  $(k+1)^{-2}$  возникает из тождества усреднения до квадратичной аппроксимации; матрица Гессе ограничивает числитель.

Далее вводится подпространство наибольшей кривизны

$$\mathcal{S}_D = \text{Im}(\mathbf{U}_D), \quad \mathbf{U}_D = [\mathbf{u}_1, \dots, \mathbf{u}_D], \quad (16)$$

натянутое на собственные векторы  $\mathbf{u}_1, \dots, \mathbf{u}_D$ , соответствующие  $D$  наибольшим собственным значениям матрицы Гессе  $\mathbf{H}^{(k)}(\mathbf{w}_k^*)$ . В этом подпространстве рассматривается критерий

$$\Delta_2^{(D)}(k+1) = \int (\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 q(\mathbf{w}) d\mathbf{w}, \quad \mathbf{w} \in \mathbf{w}_k^* + \mathcal{S}_D. \quad (17)$$

При гауссовском распределении в координатах подпространства доказано, что

$$\Delta_2^{(D)}(k+1) \leq \frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(D^2 + 2D)M_{\mathbf{H}}^2}{(k+1)^2} = \mathcal{O}(k^{-2}). \quad (18)$$

Тем самым показано, что ограничение анализа подпространством главных собственных направлений матрицы Гессе сохраняет тот же порядок сходимости, что и в полном пространстве параметров, но позволяет заменить размерность  $N$  на существенно меньшую размерность  $D$ .

В частном случае отсутствия нулевого и линейного вкладов критерий в подпространстве наибольшей кривизны выражается непосредственно через приращения ведущих собственных значений матрицы Гессе:

$$\Delta_2^{(D)}(k+1) = \frac{\sigma^4}{4} \left( 2 \sum_{i=1}^D \left( \lambda_i^{(k+1)} - \lambda_i^{(k)} \right)^2 + \left( \sum_{i=1}^D \left( \lambda_i^{(k+1)} - \lambda_i^{(k)} \right) \right)^2 \right). \quad (19)$$

Это дает спектральную интерпретацию стабилизации ландшафта функции потерь.

Вычислительный эксперимент для полносвязной нейронной сети на задаче классификации MNIST проверяет порядок. Среднеквадратичный критерий в полном пространстве и подпространственные критерии убывают близко к  $\mathcal{O}(k^{-2})$ . Этот порядок следует из тождества усреднения; эксперимент не измеряет константу, зависящую от матрицы Гессе. Абсолютный одноточечный критерий также убывает, но его степенная оценка неустойчива. Спектр матрицы Гессе отделяет несколько старших собственных значений от более пологого хвоста.

**В четвертой главе** результаты, полученные ранее для спектральных свойств матрицы Гессе и для критериев стабилизации ландшафта функции потерь, объединяются в единую схему, позволяющую построить архитектурно-зависимые критерии достаточного размера выборки для параметрических моделей машинного обучения.

Исходным пунктом является разложение пообъектной матрицы Гессе в форме Гаусса–Ньютона

$$\mathbf{H}_i(\mathbf{w}) = \mathbf{G}_i(\mathbf{w}) + \mathbf{R}_i(\mathbf{w}), \quad (20)$$

где  $\mathbf{G}_i(\mathbf{w})$  есть гаусс–ньютоновская компонента, а  $\mathbf{R}_i(\mathbf{w})$  — остаточный член. Для фиксированной архитектуры  $\mathcal{A}$  вводится локальная архитектурно-зависимая константа кривизны

$$M_{\mathbf{G}}(\mathcal{A}) = \sup_{\mathbf{w} \in \mathcal{U}_R(\mathbf{w}^*)} \sup_i \|\mathbf{G}_i(\mathbf{w})\|_2, \quad (21)$$

а также величина

$$\delta_R = \sup_{\mathbf{w} \in \mathcal{U}_R(\mathbf{w}^*)} \sup_i \|\mathbf{R}_i(\mathbf{w})\|_2, \quad (22)$$

характеризующая вклад остаточного члена. Тогда для любой точки локальной окрестности минимума справедливо неравенство

$$\|\mathbf{H}_i(\mathbf{w})\|_2 \leq M_{\mathbf{G}}(\mathcal{A}) + \delta_R. \quad (23)$$

Это позволяет во всех критериях стабилизации ландшафта заменить общую константу  $M_{\mathbf{H}}$  на величину  $M_{\mathbf{G}}(\mathcal{A}) + \delta_R$ , зависящую от архитектуры модели.

На этой основе достаточный размер выборки определяется через выбранный критерий стабилизации ландшафта функции потерь:

$$m^* = \inf\{m \in \mathbb{N} : \Delta(m) \leq \varepsilon\}, \quad (24)$$

где  $\varepsilon > 0$  — заранее заданный уровень точности. Тем самым выборка считается достаточной, если при дальнейшем увеличении числа обучающих объектов изменение локальной геометрии функции потерь становится несущественным по выбранному критерию.

Для абсолютного однотоочечного критерия получена оценка достаточного размера выборки вида

$$m_1^*(\varepsilon, \mathcal{A}) = \frac{2M_\ell + M_{\mathbf{g}}R + (M_{\mathbf{G}}(\mathcal{A}) + \delta_R)R^2}{\varepsilon}, \quad (25)$$

где  $M_\ell$  ограничивает значения функции потерь на отдельных объектах,  $M_{\mathbf{g}}$  — величину градиентного рассогласования, а  $R$  — радиус локальной окрестности минимума.

Для среднеквадратичного критерия в полном пространстве параметров при гауссовской функции предпочтения

$$q(\mathbf{w}) = \mathcal{N}(\mathbf{w}^*, \sigma^2 \mathbf{I}_N) \quad (26)$$

получена оценка

$$m_2^*(\varepsilon, \mathcal{A}) = \left[ \frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4 (N^2 + 2N) (M_{\mathbf{G}}(\mathcal{A}) + \delta_R)^2}{\varepsilon} \right]^{1/2}. \quad (27)$$

Аналогично, для среднеквадратичного критерия в подпространстве наибольшей кривизны размерности  $D$  доказана оценка

$$m_3^*(\varepsilon, \mathcal{A}, D) = \left[ \frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4 (D^2 + 2D) (M_{\mathbf{G}}(\mathcal{A}) + \delta_R)^2}{\varepsilon} \right]^{1/2}. \quad (28)$$

По сравнению с полным пространством параметров здесь размерностный множитель зависит не от полной размерности модели  $N$ , а только от размерности выбранного информативного подпространства  $D$ .

Подстановка полученных во второй главе архитектурно-зависимых оценок для  $M_{\mathbf{G}}(\mathcal{A})$  дает явные критерии достаточного размера выборки для полносвязных и сверточных нейронных сетей. Для  $L$ -слойной полносвязной сети без смещений локальная константа кривизны имеет вид

$$M_{\mathbf{G}}^{\text{FC}} = LM_{\mathbf{x}}^2 M_{\mathbf{A}} (M_{\mathbf{W}} M_{\sigma})^{2L-2}, \quad (29)$$

а для  $L$ -слойной сверточной сети без смещений

$$M_{\mathbf{G}}^{\text{CNN}} = LM_{\mathbf{x}}^2 M_{\mathbf{A}} K_{\max} (M_{\mathbf{W}} M_{\sigma})^{2L-2}. \quad (30)$$

Тем самым достаточный размер выборки выражается через глубину архитектуры, нормы весовых операторов, свойства функций активации и, в сверточном случае, размер рецептивного поля.

Полученные формулы показывают, что при прочих равных увеличение глубины приводит к росту необходимого объема данных для стабилизации ландшафта функции потерь. В полносвязных сетях этот рост связан с накоплением кривизны в длинных произведениях плотных операторов, тогда как в сверточных сетях существенную роль играет локальность связей, отражаемая множителем  $K_{\max}$ . В результате архитектура модели интерпретируется не только как класс реализуемых функций, но и как фактор, определяющий скорость стабилизации локальной геометрии задачи оптимизации.

Помимо строгих критериев достаточного размера выборки, в главе предложена более общая интерпретация полученных результатов в терминах законов масштабирования параметрических моделей. Для этого рассматривается декомпозиция среднего значения популяционной функции потерь в обученной точке  $\mathbf{w}_m^*$ :

$$\mathbb{E}_{\mathcal{D}_m} \mathcal{L}(\mathbf{w}_m^*) = \underbrace{\mathcal{L}(\mathbf{w}_\infty^*)}_E + \underbrace{\Phi(N)}_{\text{ошибка выразимости}} + \underbrace{\left( \mathbb{E}_{\mathcal{D}_m} \mathcal{L}(\mathbf{w}_m^*) - \inf_{\mathbf{w} \in \mathcal{W}_N} \mathcal{L}(\mathbf{w}) \right)}_{\mathcal{E}(m)}, \quad (31)$$

$$\Phi(N) = \inf_{\mathbf{w} \in \mathcal{W}_N} \mathcal{L}(\mathbf{w}) - \mathcal{L}(\mathbf{w}_\infty^*). \quad (32)$$

Здесь  $E$  есть неустраняемая ошибка задачи,  $\Phi(N)$  — ошибка выразимости класса моделей с  $N$  параметрами, а  $\mathcal{E}(m) \geq 0$  — ошибка оценивания, то есть та часть ошибки, которую может устранить увеличение объема данных. Структурное предположение о локальном статистическом режиме имеет вид

$$\mathcal{E}(m) \leq \frac{C(M_{\mathbf{G}}(\mathcal{A}) + \delta_R)}{m^\rho}, \quad \rho \in (0, 1], \quad (33)$$

и приводит к схеме локального закона масштабирования

$$\mathbb{E}_{\mathcal{D}_m} \mathcal{L}(\mathbf{w}_m^*) \leq E + \Phi(N) + \frac{C(M_{\mathbf{G}}(\mathcal{A}) + \delta_R)}{m^\rho}. \quad (34)$$

Для линейной регрессии с гауссовским распределением признаков предположение выполняется точно: средний избыточный риск оценки наименьших квадратов равен

$$\mathcal{E}(m) = \frac{\sigma^2 n}{2(m - n - 1)} = \frac{\text{tr}(\mathbf{H}^{-1} \mathbf{C})}{2m} \left( 1 + \frac{n + 1}{m - n - 1} \right), \quad (35)$$

то есть  $\rho = 1$ , а константа определяется отношением шума градиентов к кривизне  $\text{tr}(\mathbf{H}^{-1}\mathbf{C})$ . Архитектурно-зависимая константа входит в верхнюю оценку этой величины:  $\text{tr}(\mathbf{H}^{-1}\mathbf{C}) \leq \|\mathbf{C}\|_2 \text{tr}(\mathbf{H}^{-1}) \leq a_{\min}^{-1} \mathbb{E}_{(\mathbf{x}, \mathbf{y})} \|\mathbf{s}\|^2 M_{\mathbf{G}}(\mathcal{A}) \text{tr}(\mathbf{H}^{-1})$ .

Для линейной модели с неполным набором признаков, использующей первые  $N$  собственных направлений матрицы Гессе  $\mathbf{\Lambda} = \text{diag}(\lambda_j)$ , схема реализуется точно со всеми тремя слагаемыми:

$$\mathbb{E}_{\mathfrak{D}_m} \mathcal{L}(\hat{\mathbf{w}}_{N,m}) = \frac{\sigma^2}{2} + \Phi(N) + \frac{(\sigma^2 + 2\Phi(N))N}{2(m - N - 1)}, \quad \Phi(N) = \frac{1}{2} \sum_{j>N} \lambda_j (\theta_j^*)^2. \quad (36)$$

Если энергия истинной зависимости убывает по собственным направлениям кривизны как  $\lambda_j (\theta_j^*)^2 \asymp j^{-b}$ ,  $b > 1$ , то показатель ошибки выразимости равен  $\alpha = b - 1$ , при оптимальном размере модели риск убывает по объему данных как  $m^{-(b-1)/b}$ , а при вычислительном бюджете  $\mathcal{C} \propto Nm$  оптимальный размер модели растет как  $\mathcal{C}^{1/(\alpha+2)}$ .

В общем случае при вычислительном бюджете  $\mathcal{C} \propto Nm$  и росте коэффициента ошибки оценивания с размером модели как  $K(N) \sim BN^\gamma$  оптимальное соотношение между размером модели и размером выборки удовлетворяет асимптотикам

$$N^* \propto \mathcal{C}^{\frac{\rho}{\alpha+\gamma+\rho}}, \quad m^* \propto \mathcal{C}^{\frac{\alpha+\gamma}{\alpha+\gamma+\rho}}. \quad (37)$$

В точно решаемой модели  $\gamma = 1$ : показатель описывает рост с размером модели отношения шума к кривизне, то есть эффективного числа параметров, а не спектральной нормы кривизны, которая от  $N$  не зависит.

Проведенные вычислительные эксперименты на полносвязных и сверточных архитектурах для задачи классификации MNIST согласуются с теми выводами главы, которые задают порядок или монотонность. Во-первых, критерий стабилизации ландшафта  $\Delta_2(m)$  убывает с ростом объема выборки с порядком, близким к  $\mathcal{O}(m^{-2})$ . Этот порядок следует из усреднения по объектам. Во-вторых, внутри каждого семейства архитектур достаточный размер выборки возрастает с увеличением глубины. В-третьих, в локальном режиме линейной и логистической регрессии константа избыточного риска, вычисленная по спектру, согласуется с методом Монте-Карло, и показатель  $k^{-1}$  по кривой не подбирается.

**В пятой главе** рассматриваются критерии достаточного размера выборки для вероятностных линейных моделей. В отличие от предыдущих глав, где достаточность выборки исследовалась через стабилизацию ландшафта функции потерь и его локальной геометрии, здесь изучается вероятностная постановка, в которой основным объектом анализа становится стабилизация оценок параметров и соответствующих апостериорных распределений.

Рассматривается вероятностная модель линейной регрессии

$$p(y|\mathbf{x}, \mathbf{w}) = \mathcal{N}(y|\mathbf{w}^\top \mathbf{x}, \sigma^2), \quad (38)$$

где  $\mathbf{x} \in \mathbb{R}^n$  — вектор признаков,  $y \in \mathbb{R}$  — отклик,  $\mathbf{w} \in \mathbb{R}^n$  — вектор параметров, а  $\sigma^2 > 0$  — дисперсия шума. Для выборки  $\mathfrak{D}_k = (\mathbf{X}_k, \mathbf{y}_k)$  оценка максимального правдоподобия определяется как решение задачи наименьших квадратов

$$\hat{\mathbf{w}}_k = \arg \min_{\mathbf{w} \in \mathbb{R}^n} \|\mathbf{y}_k - \mathbf{X}_k \mathbf{w}\|_2^2. \quad (39)$$

При гауссовском априорном распределении параметров апостериорное распределение имеет сопряженный вид

$$p(\mathbf{w}|\mathfrak{D}_k) = \mathcal{N}(\mathbf{w}|\mathbf{m}_k, \Sigma_k), \quad (40)$$

где параметры  $\mathbf{m}_k$  и  $\Sigma_k$  явно выражаются через  $\mathbf{X}_k$  и  $\mathbf{y}_k$ .

На этой основе в главе вводятся четыре критерия достаточного размера выборки, основанные на различных характеристиках стабилизации решения. Первые два критерия, проиллюстрированные на рисунке 4, используют поведение функции правдоподобия в точке оценки максимального правдоподобия. D-критерий основан на уменьшении дисперсии правдоподобия при варьировании подвыборок, а M-критерий — на уменьшении изменения его математического ожидания при переходе от выборки размера  $k$  к выборке размера  $k + 1$ .




Рисунок 4 — Визуализация критериев D-достаточности и M-достаточности размера выборки в вероятностной модели линейной регрессии

Оставшиеся два критерия, проиллюстрированные на рисунке 5, используют близость апостериорных распределений параметров на схожих подвыборках. KL-критерий определяется через дивергенцию Кульбака–Лейблера

$$D_{\text{KL}}(p_k \| p_{k+1}) = \int p_k(\mathbf{w}) \log \frac{p_k(\mathbf{w})}{p_{k+1}(\mathbf{w})} d\mathbf{w}, \quad (41)$$

а S-критерий — через функцию близости (англ. s-score), нормированную так, что для совпадающих распределений она равна единице. Тем самым

достаточный размер выборки определяется через стабилизацию либо правдоподобия, либо полного апостериорного распределения параметров.



Рисунок 5 — Визуализация критериев KL-достаточности и S-достаточности размера выборки в вероятностной модели линейной регрессии

В главе формализуется понятие корректности критерия достаточности: критерий называется корректным, если соответствующая функция сходится к своему предельному значению при увеличении объема выборки. Для М-, KL- и S-критериев доказываются теоремы корректности, связывающие ее со сходимостью моментов апостериорного распределения. В частности, показывается, что если

$$\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0, \quad \|\Sigma_{k+1} - \Sigma_k\|_F \rightarrow 0 \quad \text{при } k \rightarrow \infty, \quad (42)$$

то М- и KL-критерии являются корректными, а для S-критерия достаточно сходимости апостериорных средних.

Далее для вероятностной линейной регрессии с гауссовским априором доказывается теорема, дающая достаточные условия для выполнения этих сходимостей. Предполагается ограниченность признаков и отклика, а также условие роста минимального собственного значения матрицы Грама:

$$\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k) = \omega(\sqrt{k}). \quad (43)$$

При этих предположениях устанавливается, что

$$\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0, \quad \|\Sigma_{k+1} - \Sigma_k\|_F \rightarrow 0 \quad \text{при } k \rightarrow \infty. \quad (44)$$

Тем самым получаются проверяемые условия, обеспечивающие корректность введенных критериев достаточности в модели линейной регрессии.

Помимо стабилизации самих распределений параметров, в главе исследуется стабилизация полного байесовского прогноза на отложенной тестовой выборке. Пусть

$$p(\mathbf{y}_{\text{test}} | \mathbf{X}_{\text{test}}, \mathbf{X}_k, \mathbf{y}_k) \quad (45)$$

обозначает предиктивное распределение, полученное по обучающей подвыборке размера  $k$ . Доказывается, что при тех же условиях на данные и матрицу признаков

$$D_{\text{KL}}(p(\mathbf{y}_{\text{test}} | \mathbf{X}_{\text{test}}, \mathbf{X}_k, \mathbf{y}_k) \| p(\mathbf{y}_{\text{test}} | \mathbf{X}_{\text{test}}, \mathbf{X}_{k+1}, \mathbf{y}_{k+1})) \rightarrow 0 \quad \text{при } k \rightarrow \infty. \quad (46)$$

Это означает, что увеличение объема обучающей выборки приводит не только к стабилизации апостериорного распределения параметров, но и к стабилизации байесовского прогноза на новых данных.

Вычислительный эксперимент проведен на синтетической выборке линейной регрессии, на метках  $\pm 1$ , порожденных логистической моделью и оцененных по гауссовскому правдоподобию в точке оценки наименьших квадратов, и на одном наборе данных Liver Disorders. При увеличении размера подвыборки функции  $D(k)$ ,  $M(k)$  и  $KL(k)$  стремятся к нулю, а функция  $S(k)$  стремится к единице. Это согласуется с корректностью критериев и не задает скорость убывания: теоремы гарантируют существование достаточного размера выборки, а не порядок.

Таким образом, в содержательной части автореферата последовательно раскрывается общая логика диссертационного исследования. Сначала формулируется задача определения достаточного размера обучающей выборки для параметрических моделей, затем исследуются архитектурно-зависимые свойства локальной кривизны оптимизационной поверхности, после чего строятся критерии стабилизации ландшафта функции потерь и выводятся критерии достаточного размера выборки. Отдельно рассматривается вероятностная линейная регрессия как частный случай параметрических моделей, для которого достаточность выборки описывается через стабилизацию распределения оптимальных параметров и байесовского прогноза.

В заключении приведены основные результаты работы, которые заключаются в следующем:

1. Для нейронных сетей получена блочная факторизация гаусс—ньютоновской компоненты матрицы Гессе в классе матрично-представимых моделей и выведены архитектурно-зависимые верхние оценки ее спектральной нормы для полносвязных и сверточных архитектур.
2. Введен общий критерий  $p$ -сходимости ландшафта функции потерь и его частные случаи: абсолютный одноточечный критерий, среднеквадратичный критерий в полном пространстве параметров и среднеквадратичный критерий в подпространстве наибольшей кривизны.
3. Порядок убывания этих критериев следует из тождества усреднения: одноточечный критерий имеет порядок  $\mathcal{O}(k^{-1})$ , среднеквадратичный критерий и его подпространственный аналог имеют порядок  $\mathcal{O}(k^{-2})$ . Квадратичная аппроксимация и матрица Гессе входят в константу, а не в порядок.
4. Построены критерии достаточного размера выборки на основе стабилизации ландшафта функции потерь. Верхние оценки локальной кривизны через спектральную норму гаусс—ньютоновской

компоненты дают архитектурно-зависимые оценки достаточного объема данных для полносвязных и сверточных моделей.

5. Предложена схема законов масштабирования, в которой ошибка оценивания определяется отношением шума градиентов к кривизне оптимизационной поверхности. Для линейной регрессии схема выполняется точно; для линейной модели с неполным набором признаков показатели по размеру модели и объему данных выражены через спектр матрицы Гессе.
6. Для вероятностных линейных моделей построены критерии достаточного размера выборки по дисперсии и математическому ожиданию функции правдоподобия, дивергенции Кульбака—Лейблера между апостериорными распределениями и функции близости (англ. s-score). Получены условия их корректности.
7. Вычислительные эксперименты согласуются с теорией там, где она дает проверяемый порядок или точную формулу. Наклон среднеквадратичного критерия близок к  $-2$  и проверяет порядок из тождества усреднения. Для линейной модели избыточный риск совпадает с точной формулой, а вероятностные критерии сходятся к своим пределам. Теоремы о существовании достаточного размера выборки не задают скорость его убывания.

## **Публикации автора по теме диссертации**

### **В рецензируемых научных журналах**

- A1. *Kiselev, N.* Robust Convergence of Loss Landscapes through Distributional Averaging / N. Kiselev, V. Meshkov, A. Grabovoy // Proceedings of the Institute for System Programming of the RAS. — 2026. — Vol. 38, no. 3. — P. 71–82.
- A2. *Kiselev, N.* Sample Size Determination: Posterior Distributions Proximity / N. Kiselev, A. Grabovoy // Computational Management Science. — 2025. — Vol. 22, no. 1.
- A3. *Kiselev, N.* Sample Size Determination: Likelihood Bootstrapping / N. Kiselev, A. Grabovoy // Computational Mathematics and Mathematical Physics. — 2025. — Vol. 65, no. 2. — P. 416–423.
- A4. *Kiselev, N.* Unraveling the Hessian: A Key to Smooth Convergence in Loss Function Landscapes / N. Kiselev, A. Grabovoy // Doklady Mathematics. — 2024. — Vol. 110, S1. — S49–S61.

### **В сборниках трудов конференций**

- A5. *Киселев, Н. С.* Среднеквадратичный критерий сходимости ландшафта функции потерь на основе перехода к подпространству главных собственных векторов матрицы Гессе / Н. С. Киселев, А. В. Грабовой // Труды 68-й Всероссийской научной конференции МФТИ. — Москва : МФТИ, 2026.
- A6. *Киселев, Н. С.* Достаточный размер обучающей выборки и его связь со сходимостью поверхности функции потерь / Н. С. Киселев, В. С. Мешков, А. В. Грабовой // Тезисы докладов 22-й всероссийской конференции с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября, 2025 г. — 2025. — С. 73–76.
- A7. *Киселев, Н. С.* Сходимость поверхности функции потерь как признак достаточного размера выборки / Н. С. Киселев, А. В. Грабовой // Труды 67-й Всероссийской научной конференции МФТИ. — Москва : МФТИ, 2025.
- A8. *Meshkov, V.* ConvNets Landscape Convergence: Hessian-Based Analysis of Matricized Networks / V. Meshkov, N. Kiselev, A. Grabovoy // 2024 Ivannikov Ispras Open Conference (ISPRAS). — 2024. — P. 1–10.
- A9. *Киселев, Н. С.* Определение достаточного размера выборки по апостериорному распределению параметров модели / Н. С. Киселев, А. В. Грабовой // Труды 66-й Всероссийской научной конференции МФТИ, 1–6 апреля 2024 г. — Москва : МФТИ, 2024. — С. 141.

## Список литературы

1. *Vapnik, V. N.* The Nature of Statistical Learning Theory / V. N. Vapnik. — New York : Springer, 1995.
2. Scaling Laws for Neural Language Models / J. Kaplan [et al.]. — 2020. — arXiv: [2001.08361](https://arxiv.org/abs/2001.08361). — URL: <https://arxiv.org/abs/2001.08361> (visited on 10/07/2026).
3. An Empirical Analysis of Compute-Optimal Large Language Model Training / J. Hoffmann [et al.] // Advances in Neural Information Processing Systems. Vol. 35. — 2022. — P. 30016–30030.
4. Visualizing the Loss Landscape of Neural Nets / H. Li [et al.] // Advances in Neural Information Processing Systems. Vol. 31. — 2018. — P. 6389–6399.
5. *Fort, S.* Emergent Properties of the Local Geometry of Neural Loss Landscapes / S. Fort, S. Ganguli. — 2019. — arXiv: [1910.05929](https://arxiv.org/abs/1910.05929). — URL: <https://arxiv.org/abs/1910.05929> (visited on 10/07/2026).

6. Essentially No Barriers in Neural Network Energy Landscape / F. Draxler [et al.] // Proceedings of the 35th International Conference on Machine Learning. Vol. 80. — 2018. — P. 1309–1318. — (Proceedings of Machine Learning Research).
7. Loss Surfaces, Mode Connectivity, and Fast Ensembling of DNNs / T. Garipov [et al.] // Advances in Neural Information Processing Systems. Vol. 31. — 2018. — P. 8803–8812.
8. Entropy-SGD: Biasing Gradient Descent into Wide Valleys / P. Chaudhari [et al.] // Journal of Statistical Mechanics: Theory and Experiment. — 2019. — Vol. 2019, no. 12. — P. 124018.
9. *Papayan, V.* Measurements of Three-Level Hierarchical Structure in the Outliers in the Spectrum of Deepnet Hessians / V. Papayan // Proceedings of the 36th International Conference on Machine Learning. Vol. 97. — 2019. — P. 5012–5021. — (Proceedings of Machine Learning Research).

*Киселев Никита Сергеевич*

Ландшафтный метод оценки масштабируемости параметрических моделей  
машинного обучения

Автореф. дис. на соискание ученой степени канд. физ.-мат. наук

Подписано в печать \_\_\_\_\_.\_\_\_\_\_.\_\_\_\_\_. Заказ № \_\_\_\_\_

Формат 60×90/16. Усл. печ. л. 1. Тираж 100 экз.

Типография \_\_\_\_\_

